Inférence d'IA en périphérie - NetApp avec Lenovo ThinkSystem - conception de la solution

NetApp Solutions

NetApp
March 19, 2024

This PDF was generated from https://docs.netapp.com/fr-fr/netapp-solutions/ai/ai-edge-introduction.html on March 19, 2024. Always check docs.netapp.com for the latest.

Sommaire

Inférence d'IA en périphérie - NetApp avec Lenovo ThinkSystem - conception de la solution 1
Tr-4886 : Inférence d'IA en périphérie - NetApp avec Lenovo ThinkSystem - conception de la solution 1
Présentation de la technologie 6
Plan de test 13
Configuration du test 14
Procédure de test 16
Résultats du test 17
Options de dimensionnement de l'architecture 22
Conclusion 23

Inférence d’IA en périphérie - NetApp avec Lenovo ThinkSystem - conception de la solution

Tr-4886 : Inférence d’IA en périphérie - NetApp avec Lenovo ThinkSystem - conception de la solution

Satish Thyagarajan, NetApp Miroslav Hodak, Lenovo

Récapitulatif

Plusieurs scénarios d’applications émergents, tels que les systèmes d’assistance à la conduite automobile (ADAS), le concept d’industrie 4.0, les Smart cities et l’Internet des objets (IoT), requièrent le traitement des flux de données en continu avec une latence quasi nulle. Ce document présente une architecture de calcul et de stockage permettant de déployer l’inférence d’intelligence artificielle (IA) basée sur les processeurs graphiques sur des contrôleurs de stockage NetApp et des serveurs Lenovo ThinkSystem dans un environnement en périphérie qui répond à ces exigences. Ce document fournit également des données de performance pour le banc d’essai MLPerf Inférence standard, en évaluant diverses tâches d’inférence sur des serveurs de périphérie équipés de processeurs graphiques NVIDIA T4. Nous examinons les performances des scénarios d’inférence hors ligne, à flux unique et à flux multiples. Nous montrons également que l’architecture associée à un système de stockage en réseau partagé économique est hautement performante et qu’elle constitue un point central pour la gestion des données et des modèles pour les serveurs de périphérie multiples.

Introduction

De plus en plus d’entreprises génèrent des volumes massifs de données à la périphérie du réseau. Pour tirer le meilleur parti des capteurs intelligents et des données de l’IoT, les entreprises recherchent une solution de streaming en temps réel qui met à profit l’informatique en périphérie. De ce fait, les tâches de calcul exigeantes sont de plus en plus effectuées à la périphérie, en dehors des data centers. L’inférence d’IA est un moteur de cette tendance. Les serveurs de périphérie offrent une puissance de calcul suffisante pour ces charges de travail, en particulier lorsqu’ils sont utilisés des accélérateurs, mais le stockage est souvent limité, en particulier dans les environnements multiserveurs. Dans ce document, nous vous montrons comment déployer un système de stockage partagé dans l’environnement de périphérie et comment il tire parti des charges de travail d’inférence d’IA sans imposer de baisse des performances.

Ce document décrit une architecture de référence pour l’inférence d’IA à la périphérie. Elle regroupe plusieurs serveurs Lenovo ThinkSystem Edge avec un système de stockage NetApp pour créer une solution facile à déployer et à gérer. Il est destiné à servir de guide de référence pour les déploiements pratiques dans diverses situations, comme le sol en usine avec plusieurs caméras et capteurs industriels, les systèmes de point de vente dans les transactions au détail ou les systèmes de conduite autonome (FSD) qui identifient les anomalies visuelles des véhicules autonomes.

Ce document comprend le test et la validation d’une configuration de calcul et de stockage composée du serveur Lenovo ThinkSystem SE350 Edge Server et d’un système de stockage NetApp AFF et EF-Series d’entrée de gamme. Ces architectures de référence constituent une solution efficace et économique pour les déploiements d’IA. Elles fournissent également des services de données complets, une protection des données intégrée, une évolutivité transparente et un stockage de données connecté au cloud avec NetApp ONTAP et le logiciel de gestion des données NetApp SANtricity.

Public visé

Ce document est destiné aux publics suivants :

- Les dirigeants et les architectes d'entreprise qui souhaitent proposer l'IA de manière adéquate à la périphérie.
- Les data Scientists, les ingénieurs de données, les chercheurs d'IA et de machine learning (ML) et les développeurs de systèmes d'IA.
- Les architectes d'entreprise qui conçoivent des solutions pour le développement de modèles et d'applications d'IA/ML.
- Les data Scientists et les ingénieurs d'IA qui recherchent des méthodes efficaces pour déployer les modèles de deep learning (DL) et DE MACHINE LEARNING (ML).
- Des gestionnaires de terminaux et des administrateurs de serveurs en périphérie sont chargés du déploiement et de la gestion des modèles d'inférence à la périphérie.

Architecture de la solution

Ce serveur Lenovo ThinkSystem, avec NetApp ONTAP ou NetApp SANtricity, est conçu pour gérer l'inférence d'IA sur de grands datasets grâce à la puissance de traitement des GPU avec les processeurs classiques. Cette validation démontre les performances élevées et une gestion optimale des données grâce à une architecture qui utilise des serveurs Lenovo de périphérie SR350 uniques ou multiples interconnectés à un seul système de stockage AFF NetApp, comme l'illustre les deux figures suivantes.

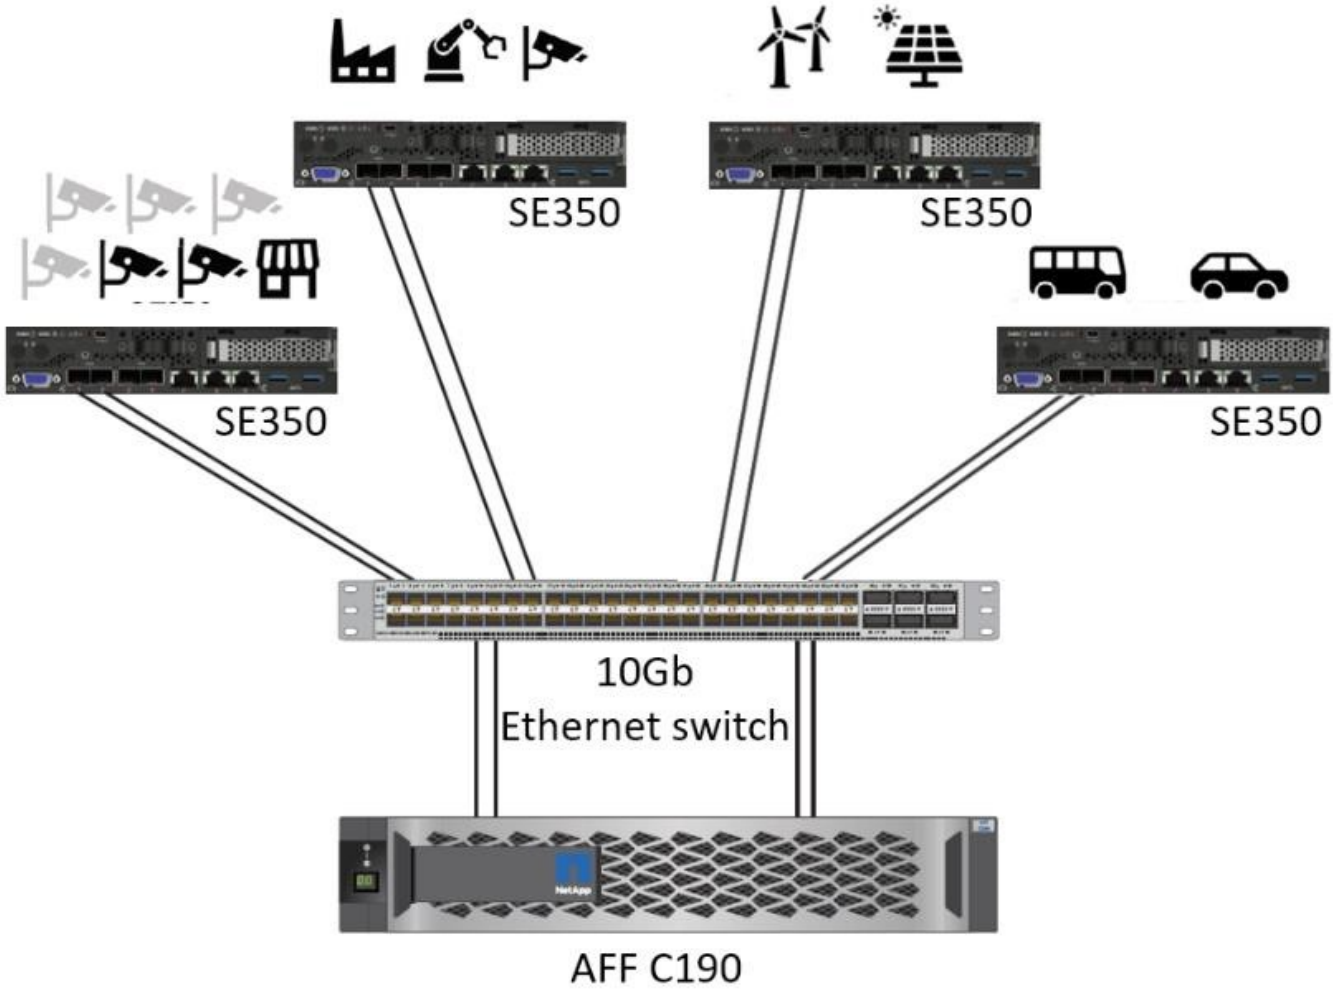

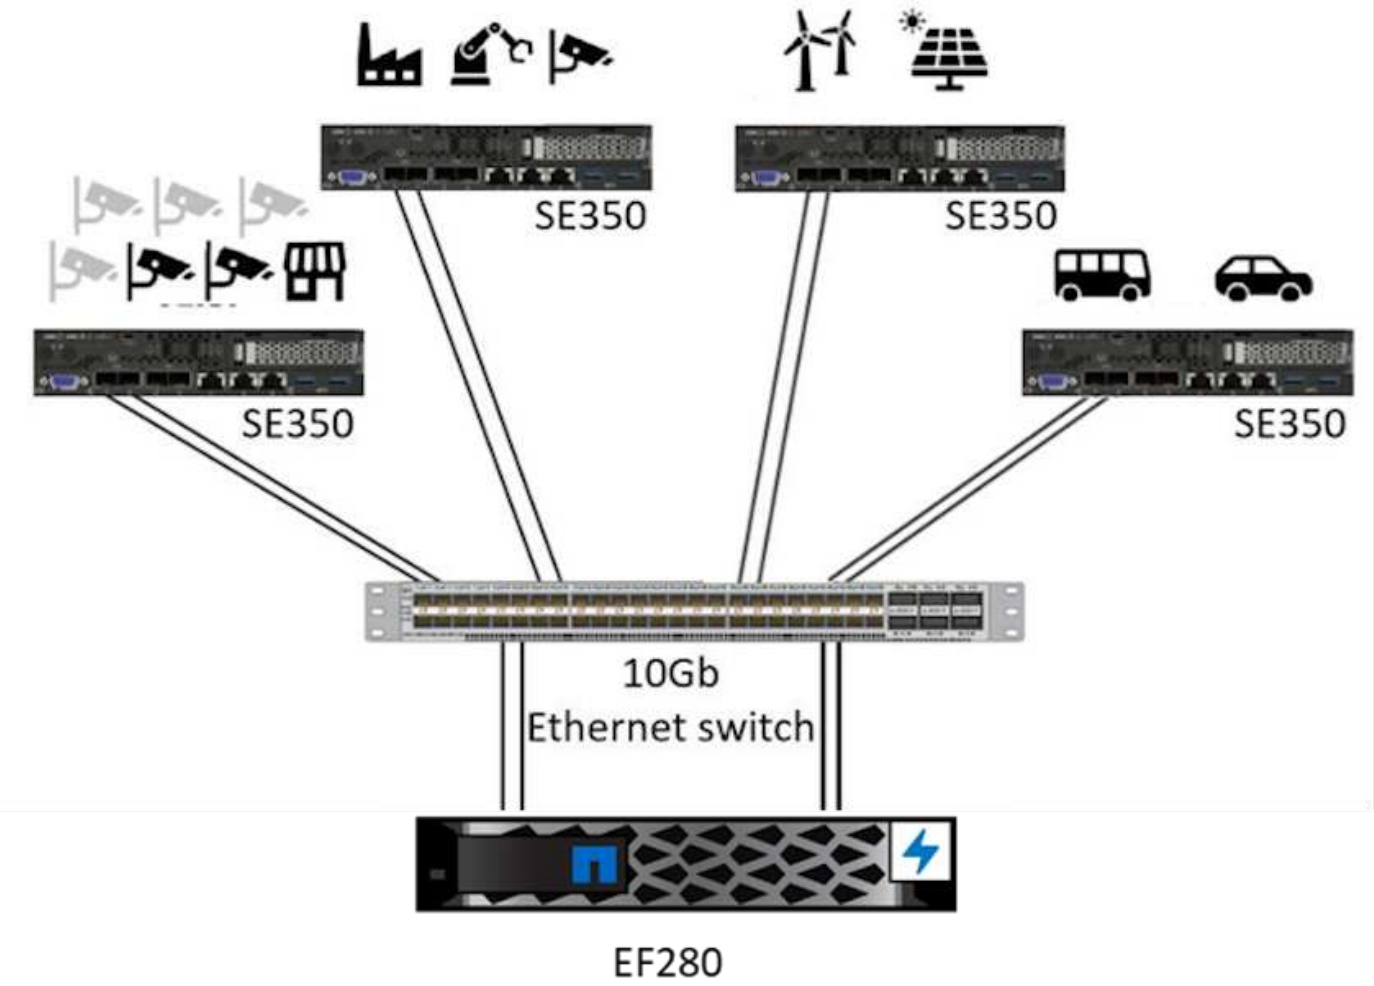

La présentation de l'architecture logique de la figure suivante montre le rôle des éléments de calcul et de stockage dans cette architecture. Elle indique en particulier les éléments suivants :

- Les dispositifs de calcul de périphérie exécutant l'inférence sur les données qu'ils reçoivent des caméras, des capteurs, etc.
- Élément de stockage partagé qui répond à plusieurs besoins :
  - Fournit un emplacement central pour les modèles d'inférence et les autres données requises pour effectuer l'inférence. Les serveurs de calcul accèdent directement au stockage et utilisent les modèles d'inférence à l'échelle du réseau sans avoir à les copier localement.
  - Les modèles mis à jour sont fournis ici.
  - Archive les données d'entrée que les serveurs de périphérie reçoivent pour une analyse ultérieure. Par exemple, si les périphériques sont connectés à des caméras, l'élément de stockage conserve les vidéos capturées par les caméras.

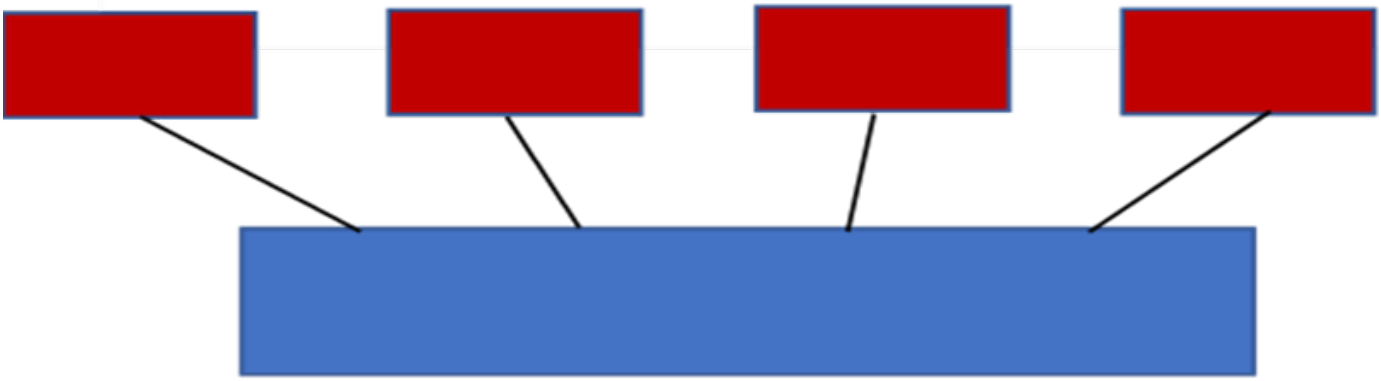

rouge	bleu
Système de calcul Lenovo	Système de stockage NetApp AFF
Périphériques exécutant l'inférence sur les entrées des caméras, des capteurs, etc.	Stockage partagé qui contient les modèles d'inférence et les données de terminaux en périphérie à des fins d'analyse ultérieure.

Cette solution NetApp et Lenovo offre les avantages suivants :

- Les GPU ont accéléré le calcul en périphérie.
- Déploiement de plusieurs serveurs de périphérie sauvegardés et gérés à partir d'un stockage partagé.
- Protection fiable des données pour respecter les objectifs de point de récupération (RPO) et de délai de restauration (RTO) faibles, sans perte de données.
- Gestion des données optimisée grâce aux copies et clones NetApp Snapshot pour rationaliser les workflows de développement.

Utilisation de cette architecture

Ce document valide la conception et les performances de l'architecture proposée. Toutefois, nous n'avons pas testé certains éléments logiciels, tels que les conteneurs, la charge de travail ou la synchronisation des données avec le cloud ou le data Center sur site, car ils sont spécifiques à un scénario de déploiement. Il existe ici plusieurs choix.

Au niveau de la gestion des conteneurs, la gestion des conteneurs Kubernetes est un bon choix et est bien prise en charge dans une version entièrement en amont (Canonical) ou dans une version modifiée adaptée aux déploiements d'entreprise (Red Hat). Le "Plan de contrôle d'IA NetApp" Qui utilise NetApp Trident et le nouveau système ajouté "Kit NetApp DataOps" Traçabilité intégrée, fonctions de gestion des données, interfaces et outils pour les data Scientists et les ingénieurs de données à intégrer au stockage NetApp. Kubeflow, le kit DE ML pour Kubernetes, fournit des fonctionnalités d'IA supplémentaires, ainsi qu'une prise en charge des versions de modèles et KFServing sur plusieurs plateformes telles que TensorFlow ou NVIDIA Triton Inférence Server. Autre option : la plateforme NVIDIA EGX, qui fournit la gestion des charges de travail et l'accès à un catalogue de conteneurs d'inférence d'IA compatibles avec les GPU. Toutefois, il peut être nécessaire de mettre en production des efforts et une expertise considérables. Pour ce faire, il faut parfois l'assistance d'un éditeur indépendant de logiciels ou d'un consultant.

Domaines de solutions

Le principal avantage de l'inférence d'IA et du calcul en périphérie est la capacité des terminaux à calculer, à traiter et à analyser les données avec un niveau élevé de qualité et sans latence. Ce document présente trop d'exemples d'utilisation de Edge Computing, mais voici quelques exemples bien connus :

Automobiles : véhicules autonomes

Le classique illustration se trouve dans les systèmes d'assistance à la conduite automobile (ADAS) pour les véhicules autonomes (AV). Pour être un conducteur sûr, l'IA dans les voitures sans chauffeur doit rapidement traiter un grand nombre de données provenant des caméras et des capteurs. Prendre trop de temps pour interpréter un objet et un être humain peut signifier la vie ou la mort, c'est pourquoi il est essentiel de pouvoir traiter ces données aussi près que possible du véhicule. Dans ce cas, un ou plusieurs serveurs de calcul de périphérie gèrent les entrées des caméras, DES RADARS, lidar et autres capteurs, tandis que le stockage partagé contient les modèles d'inférence et stocke les données d'entrée des capteurs.

Soins de santé : surveillance des patients

L'un des plus grands impacts de l'IA et de l'Edge Computing est sa capacité à améliorer la surveillance continue des patients atteints de maladies chroniques dans les établissements de soins à domicile et les unités de soins intensifs. Les données provenant de dispositifs périphériques qui surveillent les niveaux d'insuline, la respiration, l'activité neurologique, le rythme cardiaque et les fonctions gastro-intestinales nécessitent une analyse instantanée des données qui doivent être traitées immédiatement parce qu'il y a peu de temps pour agir afin de sauver la vie d'une personne.

Vente au détail : paiement sans caissier

L'informatique en périphérie peut alimenter l'IA et LE ML afin d'aider les détaillants à réduire les délais d'exécution et à accroître le trafic au pied. Les systèmes sans caissier prennent en charge différents composants, tels que :

- Authentification et accès. Connecter le client-revendeur physique à un compte validé et autoriser l'accès à l'espace de vente.
- Surveillance des stocks. Utilisation de capteurs, de tags RFID et de systèmes de vision informatique pour confirmer la sélection ou la désélection d'articles par les acheteurs.

  Dans ce cas, chacun des serveurs périphériques gère chaque compteur de réservation et le système de stockage partagé sert de point de synchronisation central.

Services financiers : sécurité humaine dans les kiosques et prévention de la fraude

Les services bancaires exploitent l'IA et l'informatique en périphérie pour innover et créer des expériences bancaires personnalisées. Les kiosques interactifs qui utilisent l'analytique en temps réel et l'inférence d'IA permettent désormais aux clients d'utiliser les guichets automatiques pour se retirer de l'argent, mais ils surveillent de façon proactive les kiosques visant à identifier les risques de sécurité humaine ou de comportements frauduleux. Dans ce scénario, les serveurs de calcul en périphérie et les systèmes de stockage partagé sont connectés à des kiosques et caméras interactifs pour aider les banques à collecter et à traiter des données à l'aide de modèles d'inférence IA.

Fabrication : industrie 4.0

La quatrième révolution industrielle (Industrie 4.0) a commencé, ainsi que les nouvelles tendances comme Smart Factory et l'impression 3D. Pour se préparer à un avenir piloté par les données, une communication M2M (machine-to-machine) à grande échelle et l'Internet des objets sont intégrés pour permettre une automatisation accrue sans intervention humaine. Le secteur de la fabrication est déjà hautement automatisé et l'ajout de fonctionnalités d'IA représente une continuation naturelle de la tendance à long terme. L'IA permet d'automatiser les opérations qui peuvent être automatisées avec la vision par ordinateur et d'autres fonctionnalités d'IA. Vous pouvez automatiser le contrôle de qualité ou les tâches qui reposent sur la vision humaine ou la prise de décision pour réaliser des analyses plus rapides des matériaux sur les lignes d'assemblage dans les usines de fabrication afin d'aider les usines à respecter les normes ISO requises en

matière de sécurité et de gestion de la qualité. Ici, chaque serveur Edge de calcul est connecté à une matrice de capteurs qui surveille le processus de fabrication et les modèles d'inférence mis à jour sont déplacés vers le stockage partagé, si nécessaire.

Télécommunications : détection de la rouille, inspection des tours et optimisation du réseau

Le secteur des télécommunications utilise la vision par ordinateur et des techniques d'IA pour traiter les images qui détectent automatiquement la rouille et identifient les tours cellulaires qui contiennent de la corrosion et requièrent donc une inspection plus poussée. L'utilisation d'images de drone et de modèles d'IA pour identifier des régions distinctes d'une tour pour analyser la rouille, les fissures de surface et la corrosion a augmenté au cours des dernières années. La demande continue d'augmenter pour les technologies d'IA, qui permettent aux infrastructures de télécommunications et aux tours cellulaires d'être inspectées efficacement, évaluées régulièrement pour vérifier leur dégradation et réparées rapidement si nécessaire.

En outre, dans le secteur des télécommunications, l'utilisation d'algorithmes d'IA et DE ML permet de prévoir les modèles de trafic de données, de détecter des périphériques compatibles 5G et d'automatiser et d'augmenter la gestion de l'énergie à entrées multiples et à sorties multiples (MIMO). Le matériel MIMO est utilisé dans les tours radio pour augmenter la capacité du réseau, mais cela est fourni avec des coûts d'énergie supplémentaires. Les modèles ML pour le « mode veille MIMO » déployés sur les sites cellulaires permettent de prévoir l'utilisation efficace des radios et de réduire les coûts de consommation d'énergie pour les opérateurs de réseaux mobiles (MNO). Les solutions d'inférence et de calcul en périphérie d'IA permettent aux entreprises non seulement de réduire la quantité de données transmises aux data centers, mais aussi de réduire leur coût total de possession, d'optimiser les opérations réseau et d'améliorer les performances globales des utilisateurs.

Présentation de la technologie

Cette section décrit la base technologique de cette solution d'IA.

Systèmes NetApp AFF

Les systèmes de stockage NetApp AFF de pointe permettent les déploiements d'inférence d'IA à la périphérie de répondre aux besoins de stockage des entreprises avec les meilleures performances du secteur, la flexibilité supérieure, l'intégration au cloud et une gestion de données optimale. Conçues spécifiquement pour les systèmes Flash, les AFF NetApp contribuent à accélérer, gérer et protéger les données stratégiques.

- Les systèmes de stockage NetApp AFF d'entrée de gamme sont basés sur du matériel FAS2750 et sur les disques SSD Flash
- Deux contrôleurs en configuration haute disponibilité

Les fonctionnalités des systèmes de stockage AFF C190 d'entrée de gamme de NetApp sont les suivantes :

- Le nombre maximal de disques SSD 24 x 960 Go
- Deux configurations possibles :
  - Ethernet (10GbE) : 4 ports 10GBASE-T (RJ-45)
  - Unifié (FC 16 Gb ou 10 GbE) : 4 ports UTA2 (adaptateur « Unified Target » 2)
- Un maximum de 50,5 To de capacité effective

> Pour les workloads NAS, un seul système AFF C190 d'entrée de gamme prend en charge un débit de 4,4 Gbit/s pour les lectures séquentielles, et 230 000 IOPS pour les lectures aléatoires de petite taille à des latences inférieures ou inférieures à 1 ms.

Avec AFF A220

NetApp propose également d'autres systèmes de stockage d'entrée de gamme qui offrent des performances et une évolutivité supérieures pour les déploiements à plus grande échelle. Pour les charges de travail NAS, un système AFF A220 unique d'entrée de gamme prend en charge :

- Débit de 6,2 Gbit/s pour les lectures séquentielles
- 375 000 IOPS pour les lectures aléatoires de petite taille à des latences inférieures ou inférieures à 1 ms.
- Le nombre maximum de disques de 144 SSD de 960 Go, de 3,8 To ou 7,6 To
- AFF A220 évolue jusqu'à plus de 1 po de capacité effective

NetApp AFF A250

- La capacité effective maximale est de 35 po avec une évolutivité scale-out maximale de 2-24 nœuds (12 paires HA)
- Offre une augmentation ≥ 45 % des performances par rapport à AFF A220
- 440 000 IOPS en lectures aléatoires à 1 ms.
- Basé sur la dernière version de NetApp ONTAP : ONTAP 9.8

- Exploite deux Ethernet 25 Gb pour la haute disponibilité et l'interconnexion de clusters

Baies NetApp E-Series EF

La gamme EF-Series est une gamme de baies de stockage SAN d'entrée de gamme et de milieu de gamme. Elles accélèrent l'accès à vos données et vous permettent de les valoriser plus rapidement grâce au logiciel NetApp SANtricity. Proposant un stockage Flash NVMe et SAS, ces systèmes incluent des IOPS exceptionnelles, des temps de réponse inférieurs à 100 microsecondes et 44 Gbit/s de bande passante. Ils sont ainsi parfaitement adaptés aux workloads mixtes et aux applications exigeantes telles que l'inférence d'IA et le calcul haute performance (HPC).

La figure suivante montre la baie de stockage NetApp EF280.

NetApp EF280

- Prise en charge des protocoles FC 32 Gb/16 Gb, iSCSI 25 Gb/10 Gb et SAS 12 Gb
- La capacité effective maximale est de 96 disques totalisant 1,5 po
- Débit de 10 Gbit/s (lectures séquentielles)
- 300 000 IOPS (lectures aléatoires)
- La baie NetApp EF280 est la baie 100 % Flash la moins chère du portefeuille NetApp

NetApp EF300

- 24 disques SSD NVMe pour une capacité totale de 367 To
- Vous pouvez étendre des options d'extension au total 240 disques durs NL-SAS, 96 disques SSD SAS, ou une combinaison
- NVMe/IB 100 Gb, NVMe/RoCE, iser/IB et SRP/IB
- NVME/FC 32 GB, FCP
- ISCSI 25 Gb
- 20 Gbit/s (lectures séquentielles)
- 670 000 IOPS (lectures aléatoires)

Pour plus d'informations, reportez-vous à la section "Fiche technique des baies 100 % Flash NetApp EF-Series EF600, F300, EF570 et EF280".

NetApp ONTAP 9

ONTAP 9.8.1, la dernière génération de logiciel de gestion du stockage de NetApp, permet aux entreprises de moderniser l'infrastructure et de passer à un data Center prêt pour le cloud. Avec des capacités de gestion des données à la pointe du secteur, ONTAP permet de gérer et de protéger les données avec un seul ensemble d'outils, quel que soit leur emplacement. Vous pouvez aussi déplacer vos données librement partout où elles sont nécessaires : la périphérie, le cœur ou le cloud. ONTAP 9.8.1 comprend de nombreuses fonctionnalités qui simplifient la gestion des données, accélèrent et protègent les données stratégiques, et permettent d'utiliser des fonctionnalités d'infrastructure nouvelle génération dans toutes les architectures de cloud hybride.

Gestion simplifiée

La gestion des données est essentielle pour les opérations IT, car elle permet d'utiliser les ressources appropriées pour les applications et les jeux de données. ONTAP inclut les fonctionnalités suivantes pour rationaliser et simplifier les opérations et réduire le coût total d'exploitation :

- **La compaction des données à la volée et la déduplication étendue** la compaction des données réduit le gaspillage d'espace dans les blocs de stockage, et la déduplication augmente considérablement la capacité effective. Cela s'applique aux données stockées localement et à leur placement dans le cloud.
- **Les contrôles de qualité de service (AQoS) granulaires (minimum, maximum et adaptative).** les contrôles de qualité de service (QoS) aident à maintenir les niveaux de performance des applications critiques dans des environnements hautement partagés.
- **NetApp FabricPool** cette fonctionnalité permet une hiérarchisation automatique des données inactives vers des options de stockage en cloud public et privé, notamment Amazon Web Services (AWS), Azure et NetApp StorageGRID. Pour plus d'informations sur FabricPool, voir "TR-4598".

Accélération et protection des données

ONTAP 9 offre des niveaux supérieurs de performances et de protection des données et étend ces fonctionnalités aux méthodes suivantes :

- * Performances et latence plus faible.* ONTAP offre le débit le plus élevé possible à la latence la plus faible possible.
- **Protection des données.** ONTAP fournit des fonctionnalités de protection des données intégrées avec une gestion commune sur toutes les plates-formes.
- **NetApp Volume Encryption (NVE).** ONTAP offre le chiffrement natif au niveau du volume, avec prise en charge de la gestion des clés à la fois intégrée et externe.
- **Colocation et authentification multifactorielle.** ONTAP permet de partager les ressources de l'infrastructure avec les niveaux de sécurité les plus élevés.

Une infrastructure pérenne

ONTAP 9 propose les fonctionnalités suivantes pour répondre aux besoins métier en constante évolution :

- **Évolutivité transparente et continuité de l'activité.** ONTAP prend en charge l'ajout non disruptif de capacité aux contrôleurs et l'évolution scale-out des clusters. Les clients peuvent effectuer la mise à niveau vers les technologies les plus récentes, telles que NVMe et FC 32 Gb, sans migration des données ni panne coûteuse.
- **Connexion au cloud.** ONTAP est le logiciel de gestion de stockage le plus connecté au cloud, avec des options de stockage SDS (ONTAP Select) et des instances natives du cloud (NetApp Cloud Volumes Service) dans tous les clouds publics.

- **Intégration avec les applications émergentes** ONTAP offre des services de données d'entreprise pour les plates-formes et applications de nouvelle génération, telles que les véhicules autonomes, les villes intelligentes et l'industrie 4.0, en utilisant la même infrastructure qui prend en charge les applications d'entreprise existantes.

NetApp SANtricity

Les systèmes SANtricity de NetApp offrent les meilleures performances, la fiabilité et la simplicité des baies 100 % Flash hybrides E-Series et EF-Series. Optimisez les performances et l'utilisation de vos baies 100 % Flash hybrides E-Series et EF-Series pour les applications nécessitant des charges de travail importantes, notamment l'analytique des données, la vidéosurveillance, et la sauvegarde et la restauration. Avec SANtricity, les tâches de configuration, de maintenance et d'extension de la capacité peuvent être effectuées en garantissant la disponibilité du système de stockage. SANtricity offre d'excellentes fonctionnalités de protection des données et de surveillance proactive, ainsi qu'une sécurité certifiée. System Manager, son interface intégrée, est facile d'emploi. Pour en savoir plus, consultez le "Logiciel SANtricity NetApp E-Series : Fiche technique".

Optimisation des performances

Le logiciel SANtricity combine d'excellentes performances, des IOPS élevées, un haut débit et une faible latence, pour l'analytique, la vidéosurveillance et les applications de sauvegarde. Accélérez les performances des applications à débit d'IOPS élevé et à faible latence, et celles des applications à large bande passante et à haut débit.

Disponibilité optimisée

Réalisez toutes vos tâches de gestion pendant que le stockage reste en ligne. Modifiez la configuration, effectuez la maintenance ou étendez la capacité de stockage sans interrompre les E/S. Bénéficiez d'une fiabilité exceptionnelle avec les fonctionnalités automatisées, la configuration en ligne, la technologie DPP (Dynamic Disk pools), et bien plus encore.

Travaillez en toute sérénité

Le logiciel SANtricity, qui respecte les normes de sécurité les plus strictes, offre d'excellentes fonctionnalités de protection des données et assure une surveillance proactive. System Manager, son interface intégrée, est facile d'emploi. Simplifiez les tâches courantes de gestion du stockage. Obtenez la flexibilité dont vous avez besoin pour un réglage ultra-précis de tous les systèmes de stockage E-Series. Gérez votre système NetApp E-Series grâce à Une interface web intégrée conçue pour simplifier vos workflows de gestion.

NetApp Trident

"Trident" À partir de NetApp, est un orchestrateur de stockage dynamique open source pour Docker et Kubernetes qui simplifie la création, la gestion et la consommation du stockage persistant. Trident, une application Kubernetes native, s'exécute directement dans un cluster Kubernetes. Trident permet de déployer de manière transparente des images de conteneur d'apprentissage profond sur un système de stockage NetApp et offre une expérience haute performance pour les déploiements de conteneurs d'IA. Les utilisateurs de Kubernetes (développeurs DE ML et data Scientists, par exemple) peuvent créer, gérer et automatiser l'orchestration et le clonage pour exploiter les fonctionnalités avancées de gestion de données de NetApp optimisées par la technologie NetApp.

Copie et synchronisation NetApp BlueXP

"Copie et synchronisation BlueXP" Est un service NetApp qui permet une synchronisation sûre et rapide des données. Que vous ayez besoin de transférer des fichiers entre des partages de fichiers NFS ou SMB sur site,

NetApp StorageGRID, NetApp ONTAP S3, NetApp Cloud Volumes Service, Azure NetApp Files, Amazon simple Storage Service (Amazon S3), Amazon Elastic File System (Amazon EFS), Azure Blob, Google Cloud Storage, ou IBM Cloud Object Storage, BlueXP Copy and Sync déplace les fichiers là où vous en avez besoin rapidement et en toute sécurité. Une fois vos données transférées, elles peuvent être utilisées à la source et à la cible. BlueXP Copy and Sync synchronise en continu les données en fonction de votre calendrier prédéfini, en déplaçant uniquement les données modifiées. Le temps et l'argent consacrés à la réplication des données sont ainsi réduits. BlueXP Copy and Sync est un outil SaaS extrêmement simple à configurer et à utiliser. Les transferts de données déclenchés par la copie et la synchronisation BlueXP sont effectués par les courtiers de données. Vous pouvez déployer des courtiers de données BlueXP Copy and Sync dans AWS, Azure, Google Cloud Platform ou sur site.

Serveurs Lenovo ThinkSystem

Les serveurs Lenovo ThinkSystem sont dotés de matériel, de logiciels et de services innovants qui répondent aux défis actuels des clients et offrent une approche évolutive, adaptée et modulaire pour répondre aux défis de demain. Ces serveurs exploitent les meilleures technologies standard du secteur, associées à des innovations Lenovo différenciées, pour offrir la plus grande flexibilité possible aux serveurs x86.

Les principaux avantages du déploiement des serveurs Lenovo ThinkSystem sont les suivants :

- Des conceptions modulaires extrêmement évolutives qui s'étendent à votre business
- La résilience optimale du secteur pour économiser des heures de temps d'arrêt imprévus coûteux
- Des technologies Flash rapides pour des latences plus faibles, des temps de réponse plus rapides et une gestion intelligente des données en temps réel

Dans le domaine de l'IA, Lenovo propose une approche pratique pour aider les entreprises à comprendre et à exploiter les avantages DU ML et de l'IA pour leurs workloads. Les clients Lenovo peuvent explorer et évaluer les offres d'IA de Lenovo dans les centres d'innovation d'IA de Lenovo afin de connaître pleinement la valeur de leur utilisation. Pour améliorer le retour sur investissement, cette approche axée sur le client permet aux clients de réaliser des démonstrations de faisabilité pour les plateformes de développement de solutions prêtes à l'emploi et optimisées pour l'IA.

Serveur Lenovo ThinkSystem SE350 Edge

Le Edge Computing permet aux données des terminaux IoT d'être analysées à la périphérie du réseau avant d'être envoyées vers le data Center ou le cloud. Le Lenovo ThinkSystem SE350, tel qu'illustré dans la figure ci-dessous, est conçu pour répondre aux exigences uniques de déploiement en périphérie, avec un accent sur la flexibilité, la connectivité, la sécurité et la téléadministration dans un format compact renforcé et résistant à l'environnement.

Doté d'un processeur Intel Xeon D avec la flexibilité nécessaire pour prendre en charge l'accélération des charges de travail Edge ai, le SE350 est conçu pour relever les défis de déploiement de serveurs dans divers environnements en dehors du centre de données.

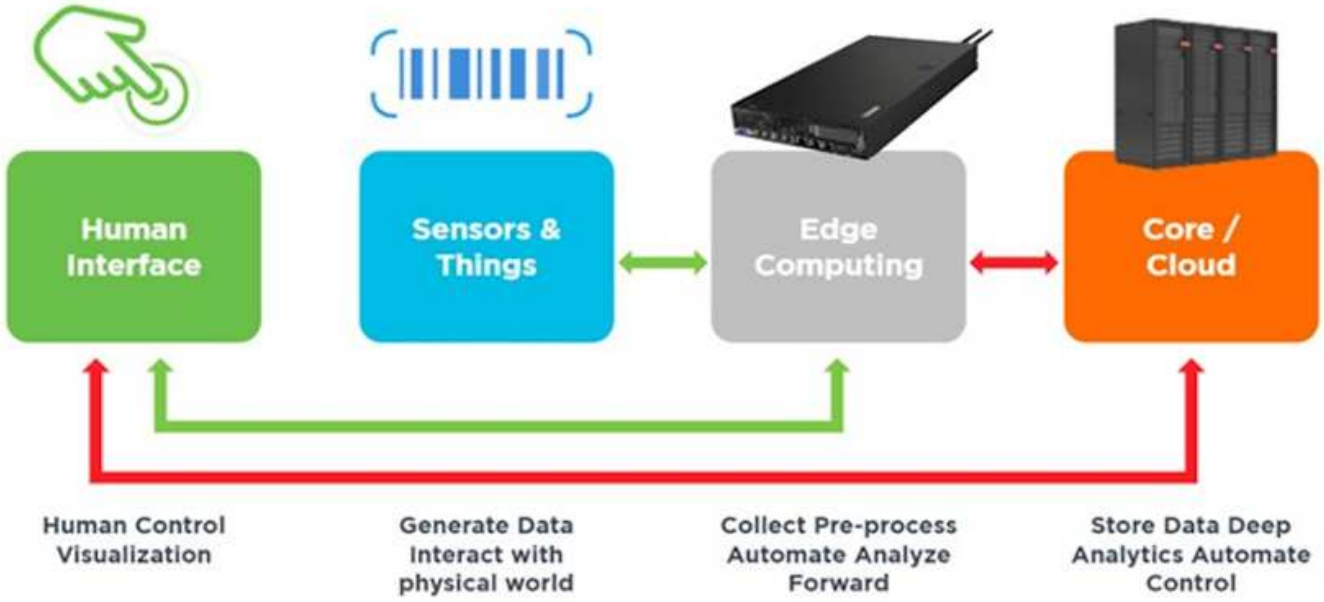

Diminution des

MLPerf est une suite de banc d'essai leader du secteur pour évaluer les performances de l'IA. Il couvre de nombreux domaines de l'IA appliquée, notamment le classement des images, la détection des objets, l'imagerie médicale et le traitement du langage naturel (NLP). Dans cette validation, nous avons utilisé des charges de travail Inférence v0.7, qui est la dernière itération de l'Inférence MLPerf à la fin de cette validation. Le "Inférence MLPerf v0.7" la suite comprend quatre nouveaux bancs d'essai pour les systèmes de data center et de périphérie :

- **BERT.** Encoder bidirectionnel représentation des transformateurs (BERT) affinée pour répondre aux questions en utilisant le jeu de données de l'équipe.
- **DLRM.** le modèle de recommandation en apprentissage profond (DLRM) est un modèle de personnalisation et de recommandation qui est formé pour optimiser les taux de clics (CTR).
- **3D U-Net.** l'architecture 3D U-Net est formée sur le dataset de segmentation de la tumeur cérébrale (brats).

- **RNN-T.** transducteur de réseau neuronal récurrent (RNN-T) est un modèle de reconnaissance vocale automatique (ASR) qui est entraîné sur un sous-ensemble de LibriSpeech. Les résultats et le code MLPerf Inférence sont accessibles au public et publiés sous licence Apache. MLPerf Inférence possède une division Edge qui prend en charge les scénarios suivants :
- **Single stream.** ce scénario imite les systèmes où la réactivité est un facteur critique, comme les requêtes ai hors ligne effectuées sur les smartphones. Les requêtes individuelles sont envoyées au système et les temps de réponse sont enregistrés. le résultat est une latence du 90e centile de toutes les réponses.
- **Multistream.** ce banc d'essai est destiné aux systèmes qui traitent l'entrée à partir de plusieurs capteurs. Pendant le test, les requêtes sont envoyées à un intervalle de temps fixe. Une contrainte de QoS (latence maximale autorisée) est imposée. Le test indique le nombre de flux que le système peut traiter tout en respectant la contrainte QoS.
- **Hors ligne.** c'est le scénario le plus simple pour les applications de traitement par lots et la mesure est le débit en échantillons par seconde. Toutes les données sont disponibles pour le système et le banc d'essai mesure le temps nécessaire pour traiter tous les échantillons.

Lenovo a publié les scores d'inférence MLPerf pour SE350 avec T4, le serveur utilisé dans ce document. Voir les résultats à "https://mlperf.org/inference-results-0-7/" Dans la section "Edge, Closed Division" de l'entrée 0.7-145.

Plan de test

Ce document suit l'Inférence MLPerf v0.7 "code", MLPerf Inférence v1.1 "code", et "règles". Nous avons exécuté des bancs d'essai MLPerf conçus pour l'inférence à la périphérie, comme défini dans le tableau suivant.

De service	Tâche	Modèle	Jeu de données	Taille QSL	Qualité	La contrainte de latence multiflux
Vision	Classification des images	Reset50v1.5	ImageNET (224 x 224)	1024	99 % de FP32	50 ms.
Vision	Détection d'objet (grande taille)	SSD-ResNet34	COCO (1200 x 1200)	64	99 % de FP32	66 ms.
Vision	Détection d'objet (petite taille)	SSD : MobileNetsv1	COCO (300 x 300)	256	99 % de FP32	50 ms.
Vision	Segmentation des images médicales	NON-ET 3D	Brages 2019 (224 x 224 x 160)	16	99 % et 99.9 % du FP32	s/o
Voix	Parole au texte	RNNT	Lirispeech dev-Clean	2513	99 % de FP32	s/o
Langue	Traitement de la langue	BERT	Squad v1.1	10833	99 % de FP32	s/o

Le tableau suivant présente des scénarios de banc d'essai pour Edge.

De service	Tâche	Scénarios
Vision	Classification des images	Flux unique, hors ligne, flux multiples
Vision	Détection d'objet (grande taille)	Flux unique, hors ligne, flux multiples
Vision	Détection d'objet (petite taille)	Flux unique, hors ligne, flux multiples
Vision	Segmentation des images médicales	Flux unique, hors ligne
Voix	Parole-à-texte	Flux unique, hors ligne
Langue	Traitement de la langue	Flux unique, hors ligne

Nous avons réalisé ces bancs d'essai à l'aide de l'architecture de stockage en réseau développée lors de cette validation et avons comparé les résultats à ceux des exécutions locales sur les serveurs de périphérie préalablement soumis à MLPerf. La comparaison consiste à déterminer l'impact du stockage partagé sur les performances d'inférence.

Configuration du test

La figure suivante présente la configuration de test. Nous avons utilisé le système de stockage NetApp AFF C190 et deux serveurs Lenovo ThinkSystem SE350 (chacun avec un accélérateur NVIDIA T4). Ces composants sont connectés via un commutateur réseau 10GbE. Le stockage réseau contient des datasets de validation/test et des modèles pré-entraînés. Les serveurs fournissent des fonctionnalités de calcul, et le stockage est accessible via le protocole NFS.

Cette section décrit les configurations testées, l'infrastructure réseau, le serveur SE350 et les détails du provisionnement de stockage. Le tableau suivant répertorie les composants de base de l'architecture de la solution.

Composants de la solution	Détails
Serveurs Lenovo ThinkSystem	• 2 serveurs SE350 chacun avec une carte graphique NVIDIA T4
	• Chaque serveur contient un processeur Intel Xeon D-2123IT avec quatre cœurs physiques fonctionnant à 2,20 GHz et 128 Go de RAM
Système de stockage NetApp AFF d'entrée de gamme (paire HA)	• Le logiciel NetApp ONTAP 9 • SSD 24x 960 Go • Protocole NFS • Un groupe d'interface par contrôleur, avec quatre adresses IP logiques pour les points de montage

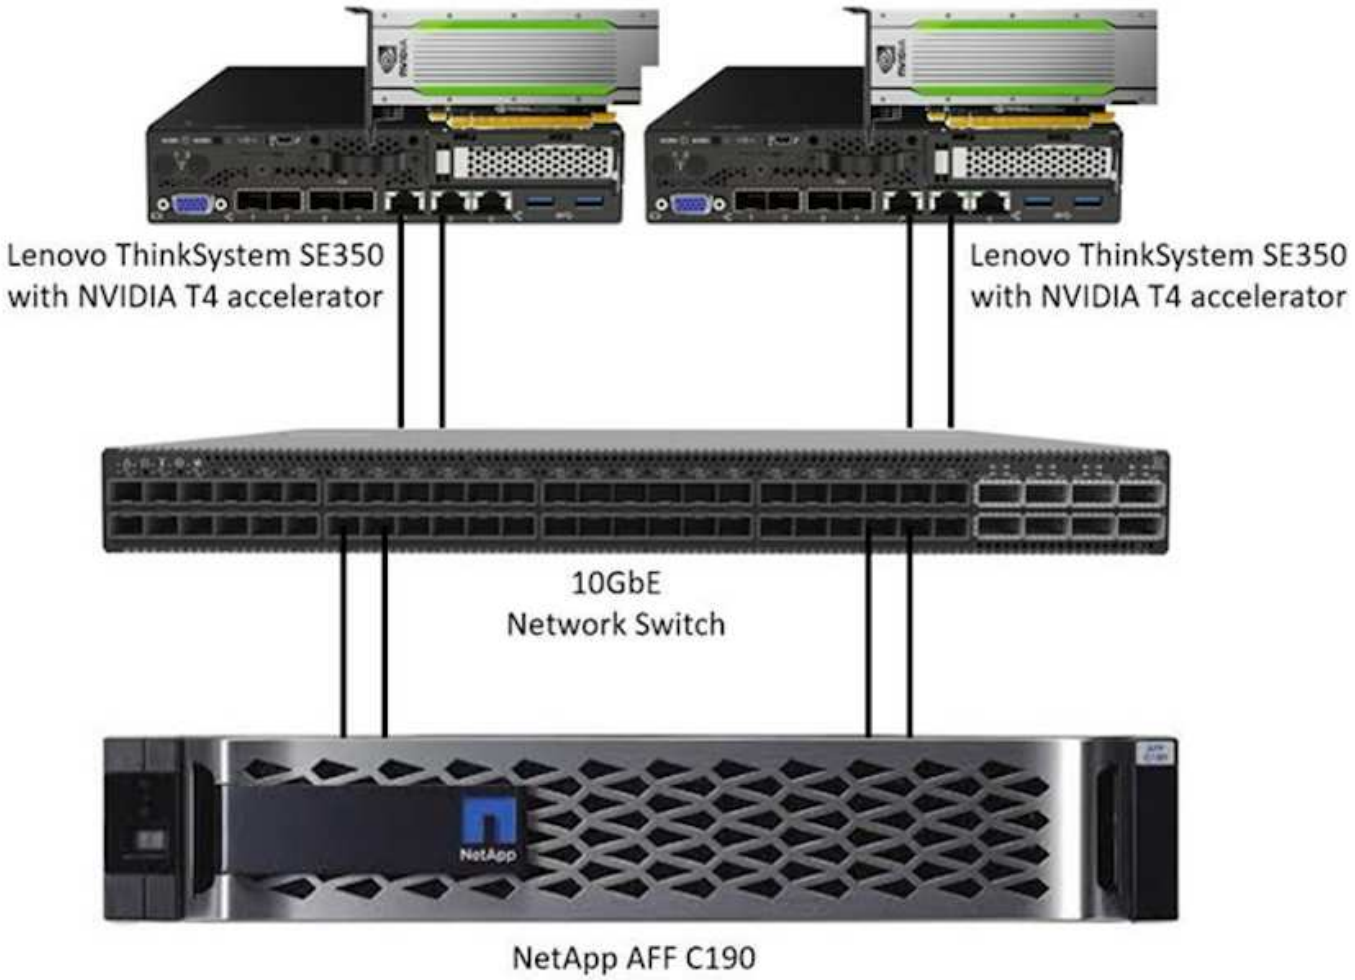

Le tableau suivant répertorie la configuration du stockage : AFF C190 avec 24 emplacements de disque 2RU.

Contrôleur	Agrégat	Volume FlexGroup	Agrégez-les	Volumétrique	Point de montage du système d'exploitation
Contrôleur 1	Agr1	/Netapplenovo_ai_fg	8,42 Tio	15 TO	/netapp_lenovo_fg
Contrôleur 2	Agr2		8,42 Tio		

Le dossier /netappLenovo_ai_fg contient les ensembles de données utilisés pour la validation du modèle.

La figure ci-dessous présente la configuration de test. Nous avons utilisé le système de stockage NetApp EF280 et deux serveurs Lenovo ThinkSystem SE350 (chacun avec un accélérateur NVIDIA T4). Ces composants sont connectés via un commutateur réseau 10GbE. Le stockage réseau contient des datasets de validation/test et des modèles pré-entraînés. Les serveurs fournissent des fonctionnalités de calcul, et le stockage est accessible via le protocole NFS.

Le tableau ci-dessous répertorie la configuration de stockage de la baie EF280.

Contrôleur	Groupe de volumes	Volumétrie	Volumétrique	DDPsize	Méthode de connexion
Contrôleur 1	DDP1	Volume 1	8,42 Tio	16 TO	SE350-1 vers LUN iSCSI 0
Contrôleur 2		Volume 2	8,42 Tio		SE350-2 vers la LUN iSCSI 1

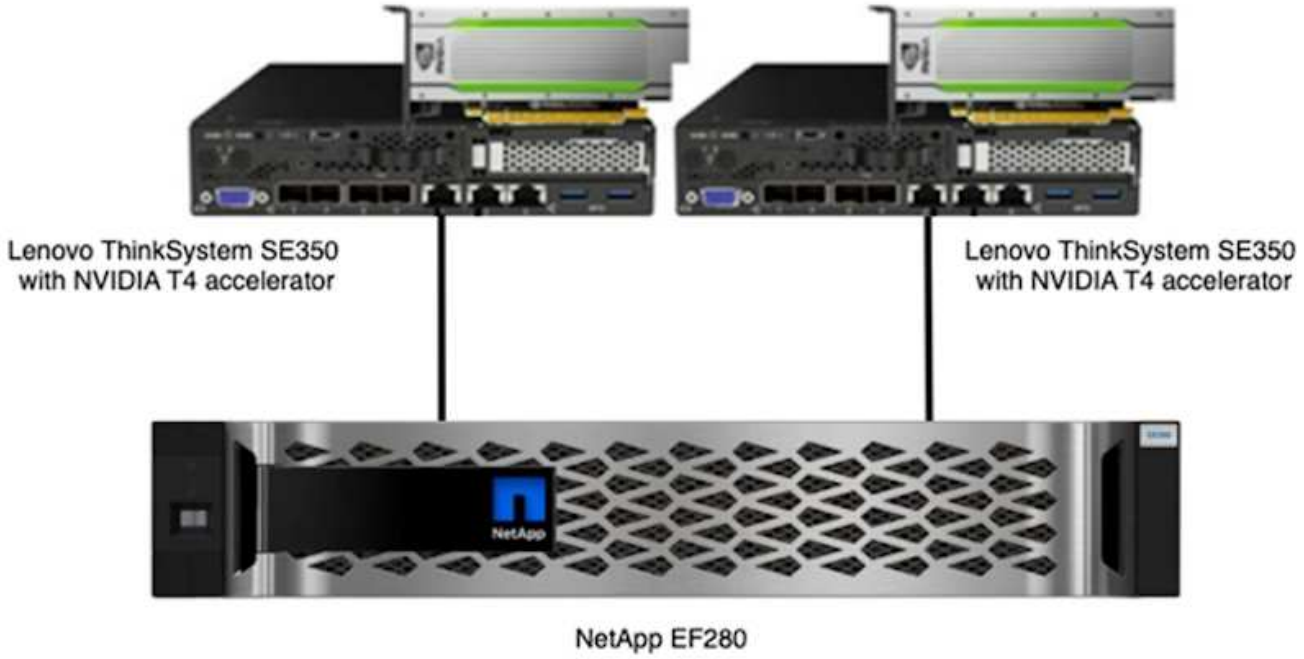

Procédure de test

Cette section décrit les procédures de test utilisées pour valider cette solution.

Installation du système d'exploitation et de l'inférence d'IA

Pour la baie AFF C190, nous avons utilisé Ubuntu 18.04 avec les pilotes NVIDIA et docker avec la prise en charge des GPU NVIDIA et MLPerf "code" Disponible dans le cadre de la soumission Lenovo à MLPerf Inférence v0.7.

Pour l'EF280, nous avons utilisé Ubuntu 20.04 avec les pilotes NVIDIA et docker avec prise en charge des GPU NVIDIA et MLPerf "code" Disponible dans le cadre de la soumission Lenovo à MLPerf Inférence v1.1.

Pour configurer l'inférence d'IA, procédez comme suit :

1. Téléchargez les datasets qui nécessitent un enregistrement, le jeu de validation ImageNet 2012, le jeu de données Criteo Terabyte et brats 2019 Training Set, puis décompressez les fichiers.
2. Créez un répertoire de travail d'au moins 1 To et définissez une variable d'environnement `MLPERF_SCRATCH_PATH` se référant au répertoire.

   Vous devez partager ce répertoire sur le stockage partagé pour le cas d'utilisation du stockage réseau ou

sur le disque local lors des tests avec des données locales.

3. Exécuter la marque `prebuild` commande, qui crée et lance le conteneur docker pour les tâches d'inférence requises.

> Les commandes suivantes sont toutes exécutées depuis le conteneur Docker en cours d'exécution :

- Télécharger les modèles d'IA pré-entraînés pour les tâches d'inférence MLPerf : `make download_model`
- Téléchargez des datasets supplémentaires qui peuvent être téléchargés librement : `make download_data`
- Prétraiter les données : marque `preprocess_data`
- Exécuter : `make build`.
- Création de moteurs d'inférence optimisés pour les GPU dans les serveurs de calcul : `make generate_engines`
- Pour exécuter des workloads Inférence, exécutez les éléments suivants (une commande) :

```
make run_harness RUN_ARGS="--benchmarks=<BENCHMARKS>
--scenarios=<SCENARIOS>"
```

L'inférence d'IA s'exécute

Trois types de passages ont été exécutés :

- Inférence d'IA à un seul serveur avec le stockage local
- Inférence d'IA à un serveur unique avec le stockage réseau
- Inférence d'IA à plusieurs serveurs à l'aide d'un stockage réseau

Résultats du test

Une multitude de tests ont été effectués afin d'évaluer les performances de l'architecture proposée.

Il existe six charges de travail différentes (classification des images, détection des objets [petite taille], détection des objets [grande], imagerie médicale, synthèse vocale, Et le traitement du langage naturel [NLP]), que vous pouvez exécuter dans trois scénarios différents : hors ligne, flux unique et flux multiples.

> Le dernier scénario est implémenté uniquement pour la classification des images et la détection des objets.

Ainsi, 15 charges de travail ont été testées sous trois configurations différentes :

- Stockage local/serveur unique
- Stockage à serveur unique/réseau

- Stockage multiserveur/réseau

Les résultats sont décrits dans les sections suivantes.

Inférence d'IA dans un scénario hors ligne pour AFF

Dans ce scénario, toutes les données étaient disponibles pour le serveur et le temps nécessaire pour traiter tous les échantillons a été mesuré. Nous avons signalé des largeurs de bande dans les échantillons par seconde comme résultats des tests. Lorsque plus d'un serveur de calcul était utilisé, nous faisons état de la bande passante totale additionnée sur tous les serveurs. Les résultats des trois cas d'utilisation sont présentés dans la figure ci-dessous. Pour le cas des deux serveurs, nous avons signalé la bande passante combinée des deux serveurs.

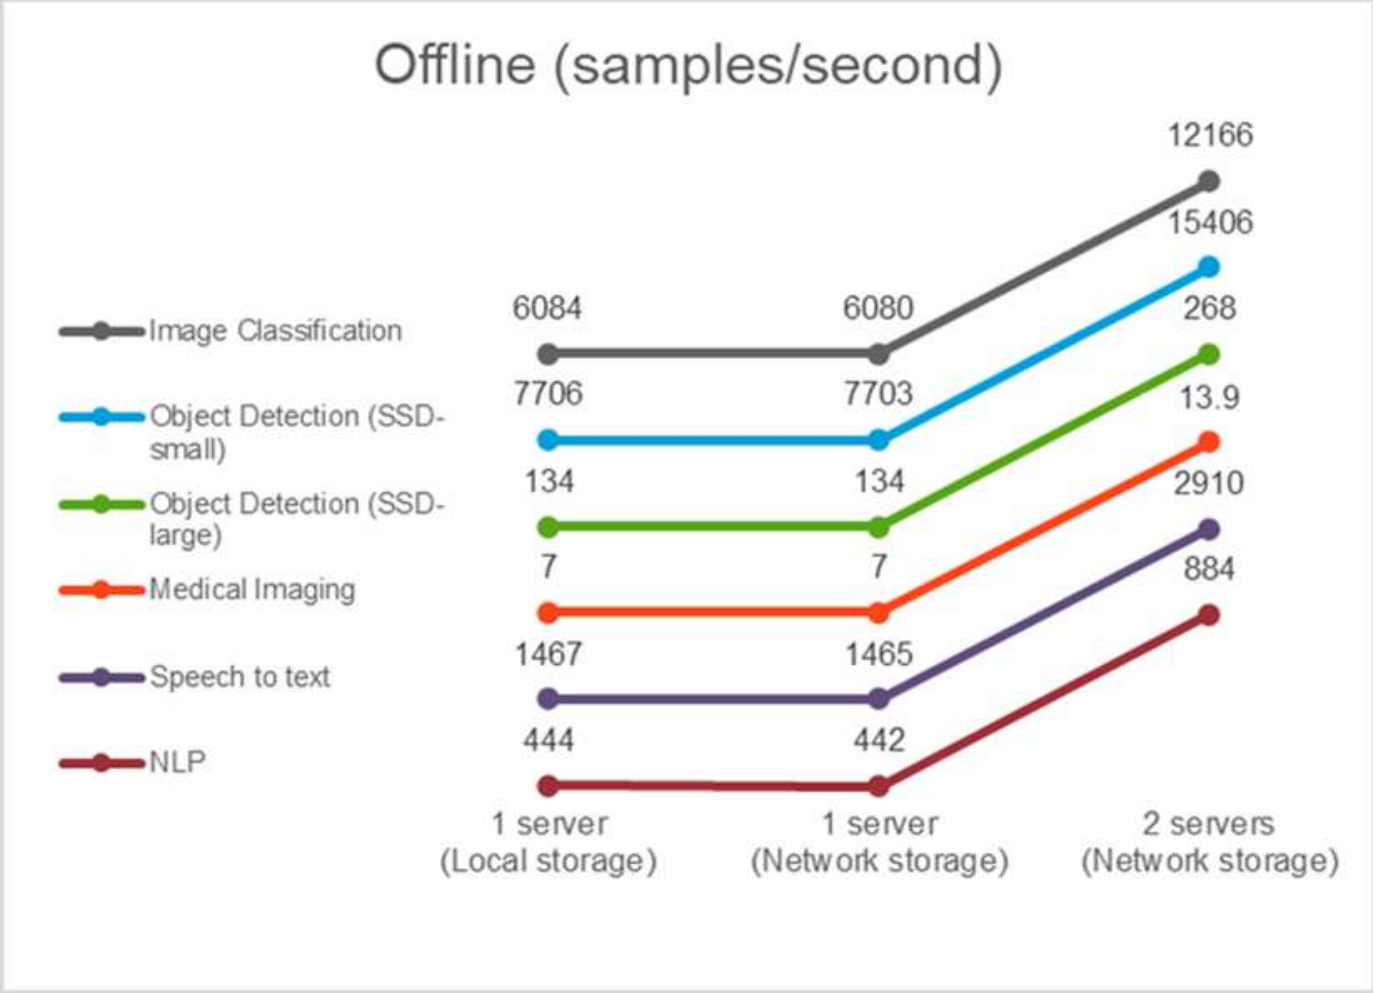

Les résultats montrent que le stockage en réseau n'affecte pas les performances : le changement est minime et aucune n'a été trouvée pour certaines tâches. Lorsque vous ajoutez le second serveur, la bande passante totale double exactement ou, dans le pire des cas, cette modification est inférieure à 1 %.

L'inférence d'IA dans un scénario de flux unique pour le AFF

Ce banc d'essai mesure la latence. Dans le cas d'un serveur de calcul multiple, nous faisons état de la latence moyenne. Les résultats de la suite de tâches sont indiqués dans la figure ci-dessous. Pour le cas des deux serveurs, nous avons signalé la latence moyenne des deux serveurs.

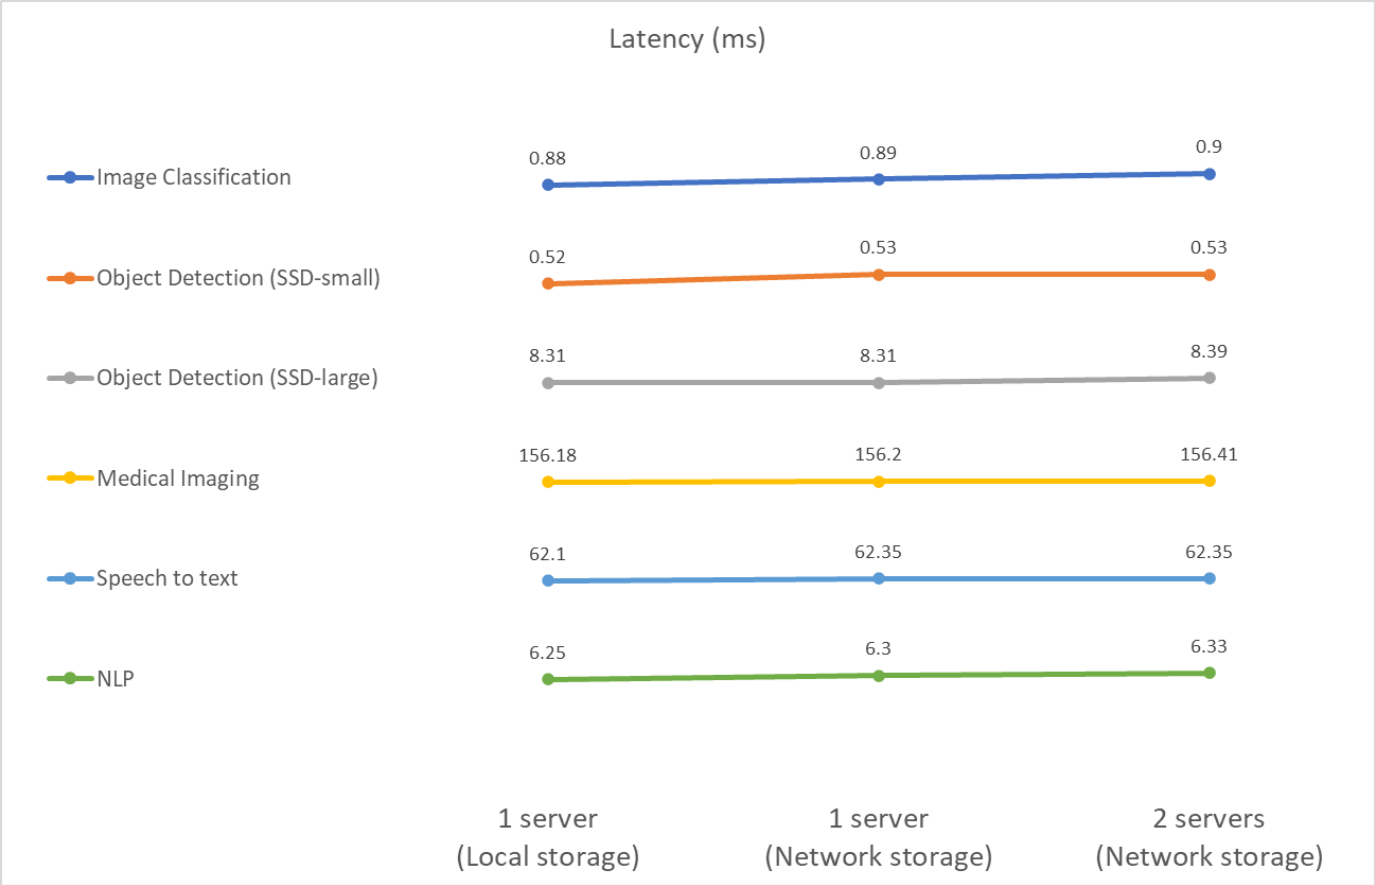

Les résultats, encore une fois, montrent que le stockage réseau suffit à gérer les tâches. La différence entre le stockage local et le stockage réseau dans un même cas de serveur est minime, voire aucune. De même, lorsque deux serveurs utilisent le même stockage, la latence sur les deux serveurs reste inchangée ou les modifications par une très petite quantité.

Inférence IA dans le scénario à flux multiples pour le AFF

Dans ce cas, le résultat est le nombre de flux que le système peut traiter tout en satisfaisant la contrainte QoS. Ainsi, le résultat est toujours un entier. Pour plus d'un serveur, nous faisons état du nombre total de flux sur tous les serveurs. Toutes les charges de travail ne prennent pas en charge ce scénario, mais nous en avons fait toutes. Les résultats de nos tests sont résumés dans la figure ci-dessous. Dans le cas des deux serveurs, nous faisons état du nombre combiné de flux provenant des deux serveurs.

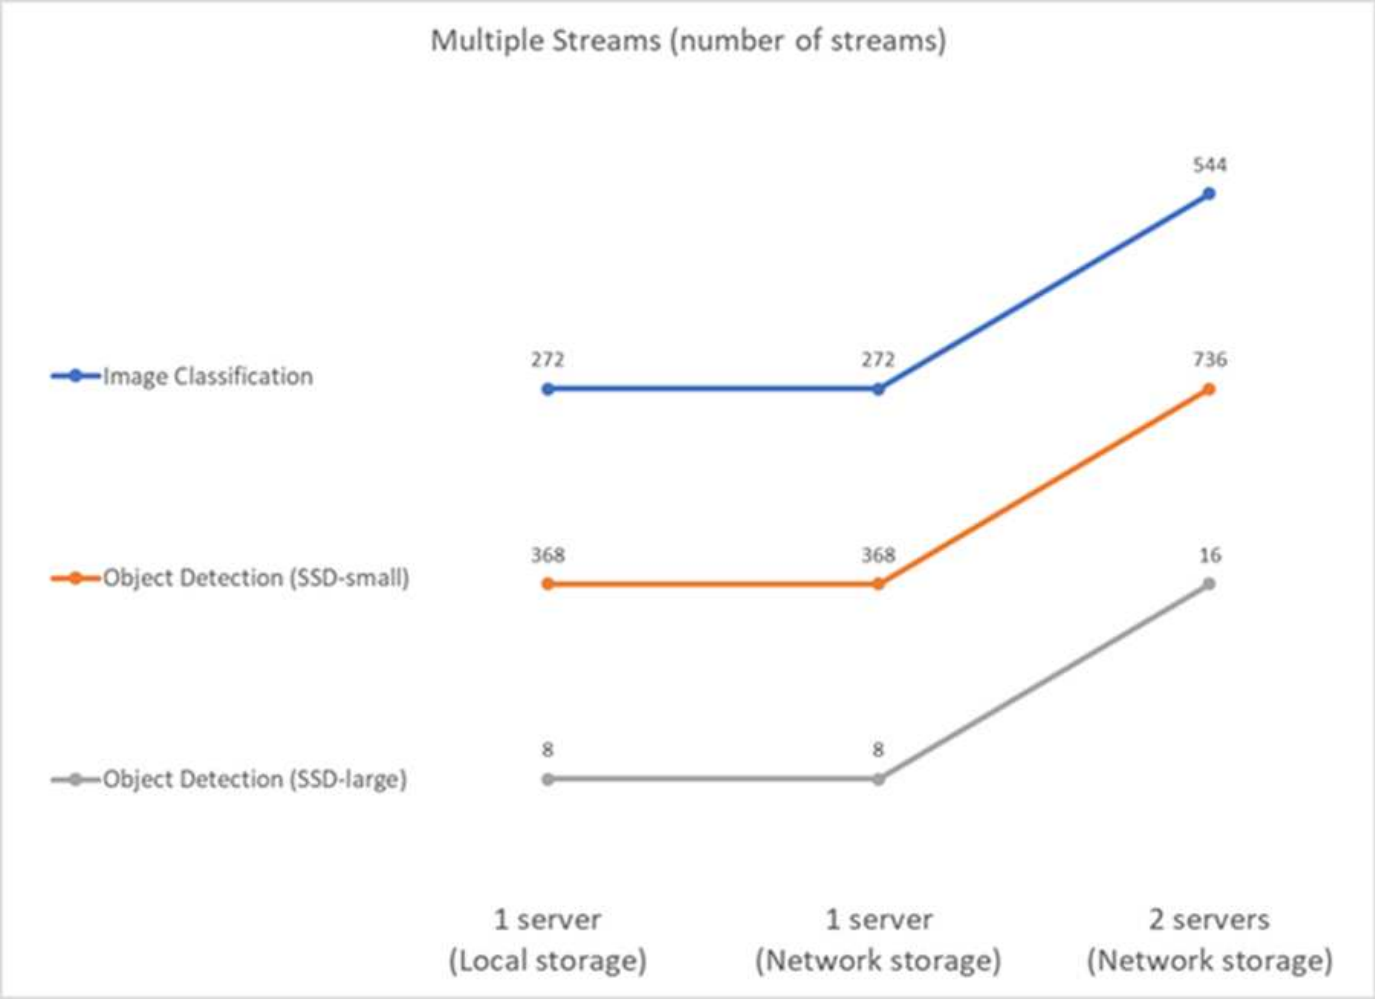

Les résultats montrent des performances parfaites de la configuration : le stockage local et réseau donne les mêmes résultats et l'ajout du second serveur double le nombre de flux que la configuration proposée peut gérer.

Résultats des tests pour EF

Une multitude de tests ont été effectués afin d'évaluer les performances de l'architecture proposée. Il existe six charges de travail différentes (classification des images, détection des objets [petite taille], détection des objets [grande], imagerie médicale, synthèse vocale, Et traitement du langage naturel [NLP]), qui ont été exécutés dans deux scénarios différents : hors ligne et flux unique. Les résultats sont décrits dans les sections suivantes.

Inférence d'IA dans un scénario hors ligne pour la baie EF

Dans ce scénario, toutes les données étaient disponibles pour le serveur et le temps nécessaire pour traiter tous les échantillons a été mesuré. Nous avons signalé des largeurs de bande dans les échantillons par seconde comme résultats des tests. Pour les exécutions d'un nœud, nous faisons état d'une moyenne des deux serveurs, tandis que pour deux exécutions de serveur, nous avons signalé que la bande passante totale a été additionnée sur l'ensemble des serveurs. Les résultats pour des cas d'utilisation sont présentés dans la figure ci-dessous.

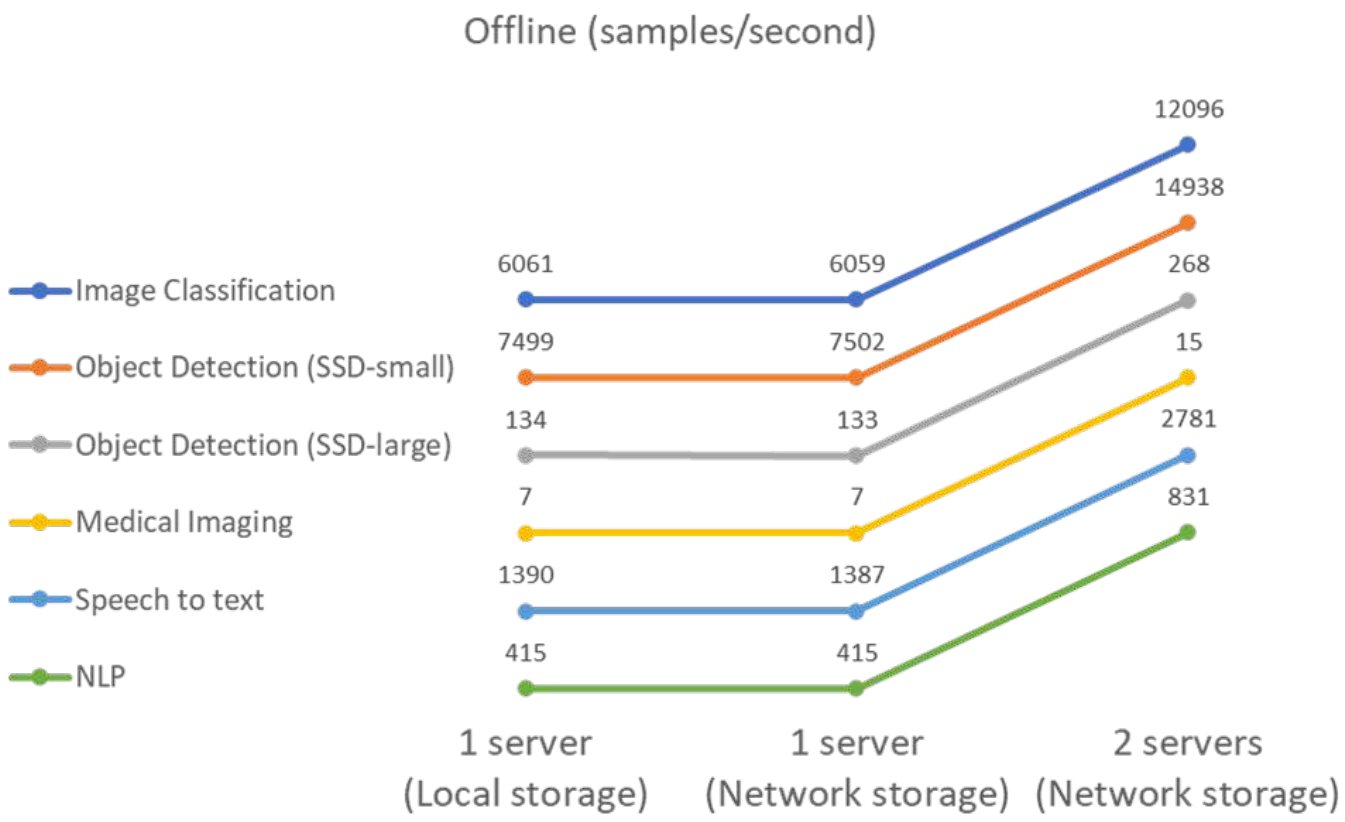

Les résultats montrent que le stockage en réseau n'affecte pas les performances : le changement est minime et aucune n'a été trouvée pour certaines tâches. Lorsque vous ajoutez le second serveur, la bande passante totale double exactement ou, dans le pire des cas, cette modification est inférieure à 1 %.

Scénario d'inférence d'IA dans un flux unique pour la gamme EF

Ce banc d'essai mesure la latence. Dans tous les cas, nous faisons état d'une latence moyenne sur tous les serveurs en cours d'exécution. Les résultats de la suite de tâches sont donnés.

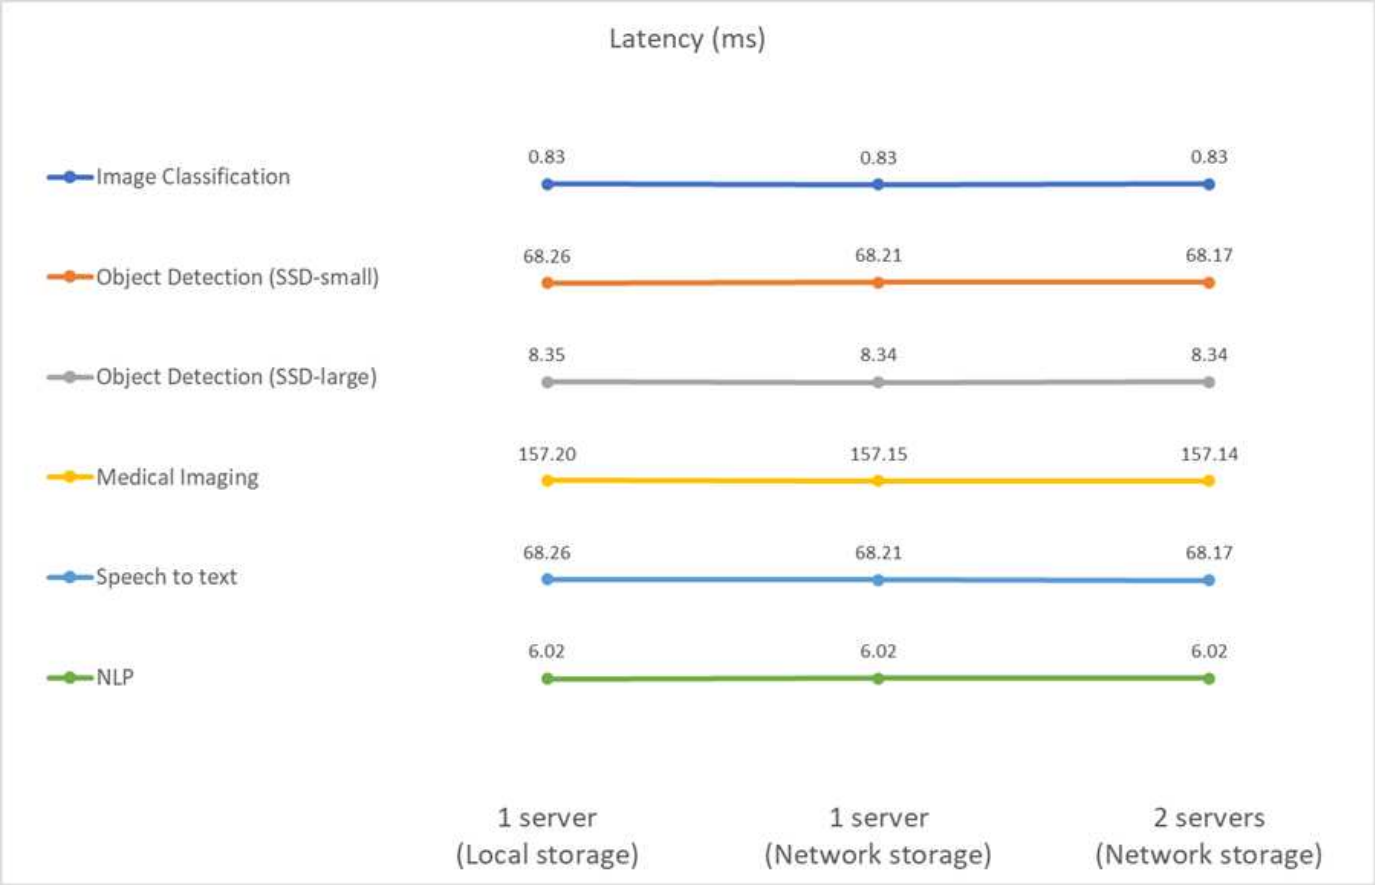

Les résultats indiquent à nouveau que le stockage réseau suffit à gérer les tâches. La différence entre le stockage local et réseau dans un cas de serveur est minime ou aucun. De même, lorsque deux serveurs utilisent le même stockage, la latence sur les deux serveurs reste inchangée ou les modifications par une très petite quantité.

Options de dimensionnement de l'architecture

Vous pouvez ajuster la configuration utilisée pour la validation afin qu'elle s'adapte à d'autres cas d'utilisation.

Serveur de calcul

Nous avons utilisé un processeur Intel Xeon D-2123IT, qui est le niveau de CPU le plus bas pris en charge dans SE350, avec quatre cœurs physiques et 60 W TDP. Bien que le serveur ne prend pas en charge le remplacement des processeurs, il peut être commandé avec un processeur plus puissant. Le processeur le plus pris en charge est le processeur Intel Xeon D-2183IT avec 16 cœurs, 100 W fonctionnant à 2,20 GHz. Cela augmente considérablement la capacité de calcul du processeur. Bien que le processeur ne constitue pas un goulot d'étranglement pour l'exécution des workloads d'inférence eux-mêmes, il facilite le traitement des données et d'autres tâches liées à l'inférence. Actuellement, NVIDIA T4 est le seul GPU disponible pour les cas d'utilisation en périphérie. Il n'est donc pas possible de mettre à niveau ou de rétrograder le GPU.

Stockage partagé

À des fins de test et de validation, le système NetApp AFF C190, qui possède une capacité de stockage maximale de 50,5 To, un débit de 4,4 Gbit/s pour les lectures séquentielles et 230 000 IOPS pour les lectures aléatoires de petite taille, a été utilisé pour ce document. Il est prouvé qu'il est parfaitement adapté aux

workloads d'inférence à la périphérie.

Toutefois, si vous avez besoin de plus de capacité de stockage ou de vitesses réseau plus rapides, vous devriez utiliser NetApp AFF A220 ou bien "NetApp AFF A250" systèmes de stockage netapp fas. Elle a également permis d'utiliser le système NetApp EF280, dont la capacité maximale est de 1,5 po et 10 Gbit/s de bande passante, pour cette validation. Si vous préférez augmenter votre capacité de stockage avec une bande passante plus élevée, "NetApp EF300" peut être utilisé.

Conclusion

L'automatisation basée sur l'IA et l'Edge Computing constituent une approche majeure pour aider les entreprises à réussir la transformation digitale et à optimiser l'efficacité opérationnelle et la sécurité. Avec l'Edge Computing, le traitement des données est beaucoup plus rapide car il n'est pas nécessaire de se rendre au data Center ni de les déplacer. C'est pourquoi les coûts associés à l'envoi de données vers des data centers ou le cloud sont réduits. Une latence plus faible et une vitesse plus élevée peuvent être utiles pour les entreprises qui doivent prendre des décisions en temps quasi réel à l'aide de modèles d'inférence d'IA déployés à la périphérie.

Les systèmes de stockage NetApp offrent les performances identiques ou supérieures au stockage SSD local et offrent les avantages suivants aux data Scientists, aux ingénieurs du data Center, aux développeurs d'IA/ML et aux décideurs IT ou business :

- Partage sans effort des données entre des systèmes d'IA, l'analytique et d'autres systèmes métier stratégiques. Ce partage des données permet de réduire la surcharge de l'infrastructure, d'améliorer les performances et de rationaliser la gestion des données à l'échelle de l'entreprise.
- Faites évoluer indépendamment les ressources de calcul et de stockage pour réduire les coûts et améliorer l'utilisation des ressources.
- Rationalisation des workflows de développement et de déploiement à l'aide de copies et de clones Snapshot intégrés pour des espaces de travail utilisateur instantanés et compacts, un contrôle intégré des versions et un déploiement automatisé.
- Une protection des données d'entreprise pour la reprise après incident et la continuité de l'activité. La solution NetApp et Lenovo présentée dans ce document est une architecture scale-out flexible, idéale pour les déploiements d'inférence d'IA en périphérie.

Remerciements

- J.J. Falkanger Directeur des solutions HPC et d'IA, Lenovo
- Dave Arnette, Ingénieur marketing et technique, NetApp
- Joey Parnell, Tech Lead E-Series ai Solutions, NetApp
- Cody Harryman, ingénieur QA, NetApp

Où trouver des informations complémentaires

Pour en savoir plus sur les informations fournies dans ce document, consultez ces documents et/ou sites web :

- Page produit sur les baies NetApp AFF A-Series

  "https://www.netapp.com/data-storage/aff-a-series/"

- Le logiciel de gestion des données NetApp ONTAP – bibliothèque d'informations ONTAP 9

  http://mysupport.netapp.com/documentation/productlibrary/index.html?productID=62286

- Tr-4727 : introduction à la gamme EF-Series de NetApp

  https://www.netapp.com/pdf.html?item=/media/17179-tr4727pdf.pdf

- Logiciel SANtricity NetApp E-Series : Fiche technique

  https://www.netapp.com/pdf.html?item=/media/19775-ds-3171-66862.pdf

- NetApp Trident pour le stockage persistant pour les conteneurs

  "https://netapp.io/persistent-storage-provisioner-for-kubernetes/"

- Diminution des
  - "https://mlcommons.org/en/"
  - "http://www.image-net.org/"
  - "https://mlcommons.org/en/news/mlperf-inference-v11/"
- Copie et synchronisation NetApp BlueXP

  "https://docs.netapp.com/us-en/occm/concept_cloud_sync.html#how-cloud-sync-works"

- Banc d'essai TensorFlow

  "https://github.com/tensorflow/benchmarks"

- Serveur Lenovo ThinkSystem SE350 Edge

  "https://lenovopress.com/lp1168"

- Baie de stockage Flash unifiée Lenovo ThinkSystem DM5100F

  "https://lenovopress.com/lp1365-thinksystem-dm5100f-unified-flash-storage-array"

Informations sur le copyright

Copyright © 2024 NetApp, Inc. Tous droits réservés. Imprimé aux États-Unis. Aucune partie de ce document protégé par copyright ne peut être reproduite sous quelque forme que ce soit ou selon quelque méthode que ce soit (graphique, électronique ou mécanique, notamment par photocopie, enregistrement ou stockage dans un système de récupération électronique) sans l'autorisation écrite préalable du détenteur du droit de copyright.

Les logiciels dérivés des éléments NetApp protégés par copyright sont soumis à la licence et à l'avis de non-responsabilité suivants :

CE LOGICIEL EST FOURNI PAR NETAPP « EN L'ÉTAT » ET SANS GARANTIES EXPRESSES OU TACITES, Y COMPRIS LES GARANTIES TACITES DE QUALITÉ MARCHANDE ET D'ADÉQUATION À UN USAGE PARTICULIER, QUI SONT EXCLUES PAR LES PRÉSENTES. EN AUCUN CAS NETAPP NE SERA TENU POUR RESPONSABLE DE DOMMAGES DIRECTS, INDIRECTS, ACCESSOIRES, PARTICULIERS OU EXEMPLAIRES (Y COMPRIS L'ACHAT DE BIENS ET DE SERVICES DE SUBSTITUTION, LA PERTE DE JOUISSANCE, DE DONNÉES OU DE PROFITS, OU L'INTERRUPTION D'ACTIVITÉ), QUELLES QU'EN SOIENT LA CAUSE ET LA DOCTRINE DE RESPONSABILITÉ, QU'IL S'AGISSE DE RESPONSABILITÉ CONTRACTUELLE, STRICTE OU DÉLICTUELLE (Y COMPRIS LA NÉGLIGENCE OU AUTRE) DÉCOULANT DE L'UTILISATION DE CE LOGICIEL, MÊME SI LA SOCIÉTÉ A ÉTÉ INFORMÉE DE LA POSSIBILITÉ DE TELS DOMMAGES.

NetApp se réserve le droit de modifier les produits décrits dans le présent document à tout moment et sans préavis. NetApp décline toute responsabilité découlant de l'utilisation des produits décrits dans le présent document, sauf accord explicite écrit de NetApp. L'utilisation ou l'achat de ce produit ne concède pas de licence dans le cadre de droits de brevet, de droits de marque commerciale ou de tout autre droit de propriété intellectuelle de NetApp.

Le produit décrit dans ce manuel peut être protégé par un ou plusieurs brevets américains, étrangers ou par une demande en attente.

LÉGENDE DE RESTRICTION DES DROITS : L'utilisation, la duplication ou la divulgation par le gouvernement sont sujettes aux restrictions énoncées dans le sous-paragraphe (b)(3) de la clause Rights in Technical Data-Noncommercial Items du DFARS 252.227-7013 (février 2014) et du FAR 52.227-19 (décembre 2007).

Les données contenues dans les présentes se rapportent à un produit et/ou service commercial (tel que défini par la clause FAR 2.101). Il s'agit de données propriétaires de NetApp, Inc. Toutes les données techniques et tous les logiciels fournis par NetApp en vertu du présent Accord sont à caractère commercial et ont été exclusivement développés à l'aide de fonds privés. Le gouvernement des États-Unis dispose d'une licence limitée irrévocable, non exclusive, non cessible, non transférable et mondiale. Cette licence lui permet d'utiliser uniquement les données relatives au contrat du gouvernement des États-Unis d'après lequel les données lui ont été fournies ou celles qui sont nécessaires à son exécution. Sauf dispositions contraires énoncées dans les présentes, l'utilisation, la divulgation, la reproduction, la modification, l'exécution, l'affichage des données sont interdits sans avoir obtenu le consentement écrit préalable de NetApp, Inc. Les droits de licences du Département de la Défense du gouvernement des États-Unis se limitent aux droits identifiés par la clause 252.227-7015(b) du DFARS (février 2014).

Informations sur les marques commerciales

NETAPP, le logo NETAPP et les marques citées sur le site http://www.netapp.com/TM sont des marques déposées ou des marques commerciales de NetApp, Inc. Les autres noms de marques et de produits sont des marques commerciales de leurs propriétaires respectifs.