NetApp AFF A400 avec Lenovo ThinkSystem SR670 V2 pour l'IA et l'entraînement des modèles DE ML

NetApp Solutions

NetApp
March 19, 2024

This PDF was generated from https://docs.netapp.com/fr-fr/netapp-solutions/ai/a400-thinksystem-introduction.html on March 19, 2024. Always check docs.netapp.com for the latest.

Sommaire

NetApp AFF A400 avec Lenovo ThinkSystem SR670 V2 pour l'IA et l'entraînement des modèles DE ML 1
Tr-4810 : NetApp AFF A400 avec Lenovo ThinkSystem SR670 V2 pour l'IA et l'entraînement des modèles DE ML 1
Présentation de la technologie 2
Plan de test 7
Résultats du test 7
Configuration du test 8
Procédure de test et résultats détaillés 9
Ajustements d'architecture 12
Conclusion 12

NetApp AFF A400 avec Lenovo ThinkSystem SR670 V2 pour l'IA et l'entraînement des modèles DE ML

Tr-4810 : NetApp AFF A400 avec Lenovo ThinkSystem SR670 V2 pour l'IA et l'entraînement des modèles DE ML

Satish Thyagarajan, David Arnette, NetApp Mircea Troaca, Lenovo

Cette solution présente une architecture en cluster de milieu de gamme reposant sur un système de stockage NetApp et des serveurs Lenovo optimisés pour les workloads d'intelligence artificielle (IA). Elle s'adresse aux entreprises de toutes tailles, pour lesquelles la plupart des tâches de calcul sont des nœuds uniques (un ou plusieurs processeurs graphiques) ou distribuées sur quelques nœuds de calcul. Cette solution répond à la plupart des tâches quotidiennes d'entraînement IA de nombreuses entreprises.

Ce document porte sur le test et la validation d'une configuration de calcul et de stockage composée de huit processeurs graphiques Lenovo SR670V2, d'un système de stockage NetApp AFF A400 de milieu de gamme et d'un commutateur d'interconnexion 100 GbE. Pour mesurer les performances, nous avons utilisé ResNet50 avec le dataset ImageNet, une taille de batchs de 408, une demi-précision, CUDA et cuDNN. Cette architecture offre une solution efficace et économique pour les petites et moyennes entreprises. Il s'agit du premier démarrage des initiatives d'IA qui requièrent les fonctionnalités haute performance du stockage de données NetApp ONTAP connecté au cloud.

Public visé

Ce document est destiné aux publics suivants :

- Data Scientists, ingénieurs de données, administrateurs de données et développeurs de systèmes d'IA
- Les architectes d'entreprise qui conçoivent des solutions pour le développement des modèles d'IA
- Data Scientists et ingénieurs de données qui recherchent des méthodes efficaces pour atteindre leurs objectifs de développement du deep learning (DL) et du machine learning (ML)
- Dirigeants d'entreprise et décideurs IT/d'entreprise qui veulent accélérer le délai de mise sur le marché des initiatives d'IA

Architecture de la solution

Dotée de serveurs Lenovo ThinkSystem et de NetApp ONTAP avec stockage AFF, cette solution est conçue pour gérer l'entraînement d'IA sur de grands datasets, grâce à la puissance de traitement des processeurs graphiques avec des processeurs classiques. Cette validation démontre les performances élevées et une gestion optimale des données grâce à une architecture scale-out qui utilise un, deux ou quatre serveurs Lenovo SR670 V2 avec un seul système de stockage NetApp AFF A400. La figure suivante fournit une vue d'ensemble de l'architecture.

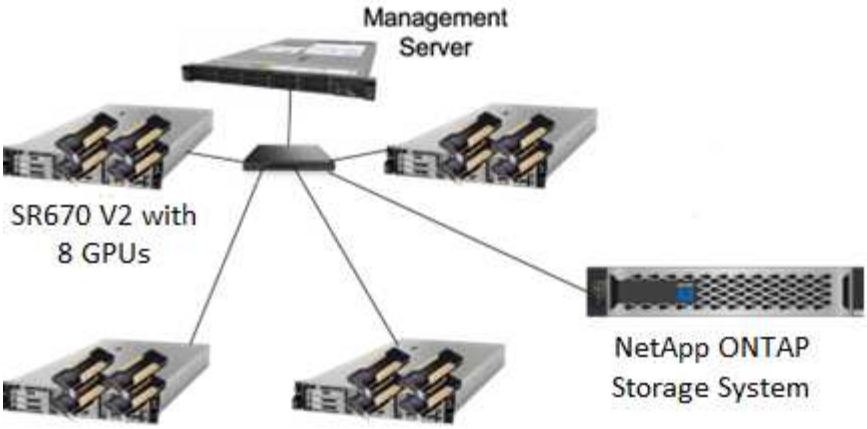

Cette solution NetApp et Lenovo offre les avantages suivants :

- Performances très efficaces et économiques lors de l'exécution de plusieurs tâches de formation en parallèle
- Performances évolutives en fonction du nombre de serveurs Lenovo et de différents modèles de contrôleurs de stockage NetApp
- Protection fiable des données pour respecter les objectifs de point de récupération (RPO) et de délai de restauration (RTO) faibles, sans perte de données
- Gestion des données optimisée avec les copies Snapshot et les clones pour rationaliser les workflows de développement

Présentation de la technologie

Cette section présente plus en détail les principaux composants de cette solution.

Systèmes NetApp AFF

Les systèmes de stockage NetApp AFF permettent aux entreprises de répondre aux besoins des entreprises grâce aux meilleures performances du secteur, à la flexibilité supérieure, à l'intégration au cloud et à une excellente gestion des données. Conçues spécifiquement pour les systèmes Flash, les baies AFF contribuent à accélérer, gérer et protéger les données stratégiques.

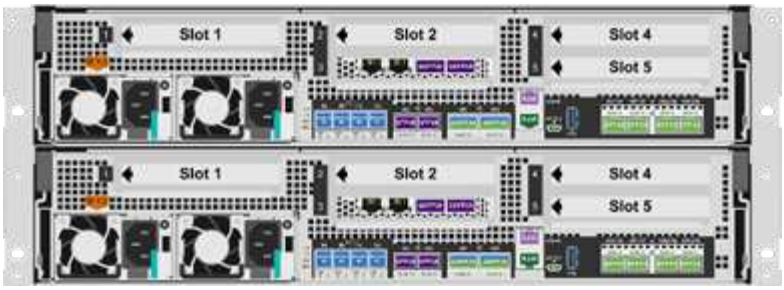

NetApp AFF A400 est un système de stockage Flash NVMe de milieu de gamme qui comprend les fonctionnalités suivantes :

- Capacité effective maximale : environ 20 po
- Évolutivité scale-out maximale : 2-24 nœuds (12 paires HA)
- Prise en charge des hôtes FC 25 GbE et 16 Gb
- Connectivité 100 GbE RDMA over Converged Ethernet (RoCE) avec les tiroirs de stockage d'extension NVMe
- Les ports RoCE 100 GbE peuvent être utilisés pour la connexion au réseau hôte si les tiroirs NVMe ne sont pas connectés
- Tiroirs de stockage d'extension de connectivité SAS de 12 Gbit/s complets
- Deux configurations disponibles :
  - Ethernet : 4 ports Ethernet 25 Gb (SFP28)
  - Fibre Channel : 4 ports FC 16 Gbit/s (SFP+
- 100 % 8 Ko en lecture aléatoire @.4 ms 400 000 IOPS

Voici les fonctionnalités de NetApp AFF A250 pour les déploiements d'entrée de gamme spécialisés dans l'IA et LE ML :

- Capacité effective maximale : 35 po
- Évolutivité scale-out maximale : 2-24 nœuds (12 paires HA)
- 440 000 IOPS en lectures aléatoires à 1 ms.
- Basé sur la dernière version de NetApp ONTAP, ONTAP 9.8 ou version ultérieure
- Deux ports Ethernet 25 Gb pour la haute disponibilité et l'interconnexion de clusters

NetApp propose également d'autres systèmes de stockage, tels que les systèmes AFF A800 et AFF A700 qui offrent des performances et une évolutivité supérieures pour les déploiements d'IA/ML à plus grande échelle.

NetApp ONTAP

ONTAP 9, la dernière génération de logiciel de gestion du stockage de NetApp, permet aux entreprises de moderniser l'infrastructure et de passer à un data Center prêt pour le cloud. Avec des capacités de gestion des données à la pointe du secteur, ONTAP permet de gérer et de protéger les données avec un seul ensemble d'outils, quel que soit leur emplacement. Les données peuvent aussi être déplacées librement partout où elles sont nécessaires : la périphérie, le cœur ou le cloud. ONTAP 9 comprend de nombreuses fonctionnalités qui simplifient la gestion des données, accélèrent et protègent les données stratégiques et pérennisent l'infrastructure sur toutes les architectures de cloud hybride.

Gestion simplifiée

La gestion des données est essentielle pour les opérations IT, car elle permet d'utiliser les ressources appropriées pour les applications et les jeux de données. ONTAP inclut les fonctionnalités suivantes pour rationaliser et simplifier les opérations et réduire le coût total d'exploitation :

- **La compaction des données à la volée et la déduplication étendue** la compaction des données réduit le gaspillage d'espace dans les blocs de stockage, et la déduplication augmente considérablement la capacité effective. Cela s'applique aux données stockées localement et à leur placement dans le cloud.
- **Qualité de service (QoS) minimale, maximale et adaptative.** les contrôles de qualité de service granulaires permettent de maintenir les niveaux de performance des applications critiques dans des environnements hautement partagés.
- **ONTAP FabricPool** cette fonctionnalité transfère automatiquement les données inactives vers des options de stockage de cloud public et privé, notamment le stockage objet Amazon Web Services (AWS), Azure et NetApp StorageGRID.

Accélération et protection des données

ONTAP offre des niveaux supérieurs de performances et de protection des données et étend ces fonctionnalités aux méthodes suivantes :

- * Performances et latence plus faible.* ONTAP offre le débit le plus élevé possible à la latence la plus faible possible.
- **Protection des données.** ONTAP fournit des fonctionnalités de protection des données intégrées avec une gestion commune sur toutes les plates-formes.
- **NetApp Volume Encryption**. ONTAP offre un chiffrement natif au niveau du volume avec prise en charge de la gestion des clés à la fois intégrée et externe.

Une infrastructure pérenne

ONTAP 9 aide à répondre aux besoins métier en constante évolution :

- **Évolutivité transparente et continuité de l'activité.** ONTAP prend en charge l'ajout non disruptif de capacité aux contrôleurs existants et l'évolution scale-out des clusters. Les clients peuvent effectuer la mise à niveau vers les technologies les plus récentes, telles que NVMe et FC 32 Gb, sans migration des données ni panne coûteuse.
- **Connexion au cloud.** ONTAP est le logiciel de gestion de stockage le plus connecté au cloud, avec des options de stockage SDS (ONTAP Select) et des instances natives du cloud (NetApp Cloud Volumes Service) dans tous les clouds publics.
- **Intégration avec les applications émergentes** ONTAP propose des services de données haute performance pour les plateformes et applications nouvelle génération, telles qu'OpenStack, Hadoop et MongoDB, en utilisant la même infrastructure prenant en charge les applications d'entreprise existantes.

Volumes NetApp FlexGroup

Les datasets d'entraînement sont généralement un ensemble de milliards de fichiers. Les fichiers peuvent inclure du texte, de l'audio, de la vidéo et d'autres formes de données non structurées qui doivent être stockées et traitées pour être lues en parallèle. Le système de stockage doit stocker de petits fichiers et doit lire ces fichiers en parallèle pour les E/S séquentielles et aléatoires

Un volume FlexGroup (la figure suivante) est un namespace unique composé de plusieurs volumes de membres constitutifs qui est géré et agit comme un volume NetApp FlexVol pour les administrateurs de

stockage. Les fichiers du volume FlexGroup sont alloués aux volumes de membres individuels,et non répartis entre les volumes ou les nœuds. Ils présentent de nombreux atouts :

- Jusqu'à 20 pétaoctets de capacité et faible latence prévisible pour les charges de travail comportant un grand nombre de métadonnées
- Jusqu'à 400 milliards de fichiers dans le même espace de nom
- Opérations parallélisées dans les charges de travail NAS sur les processeurs, les nœuds, les agrégats et les volumes FlexVol constitutifs

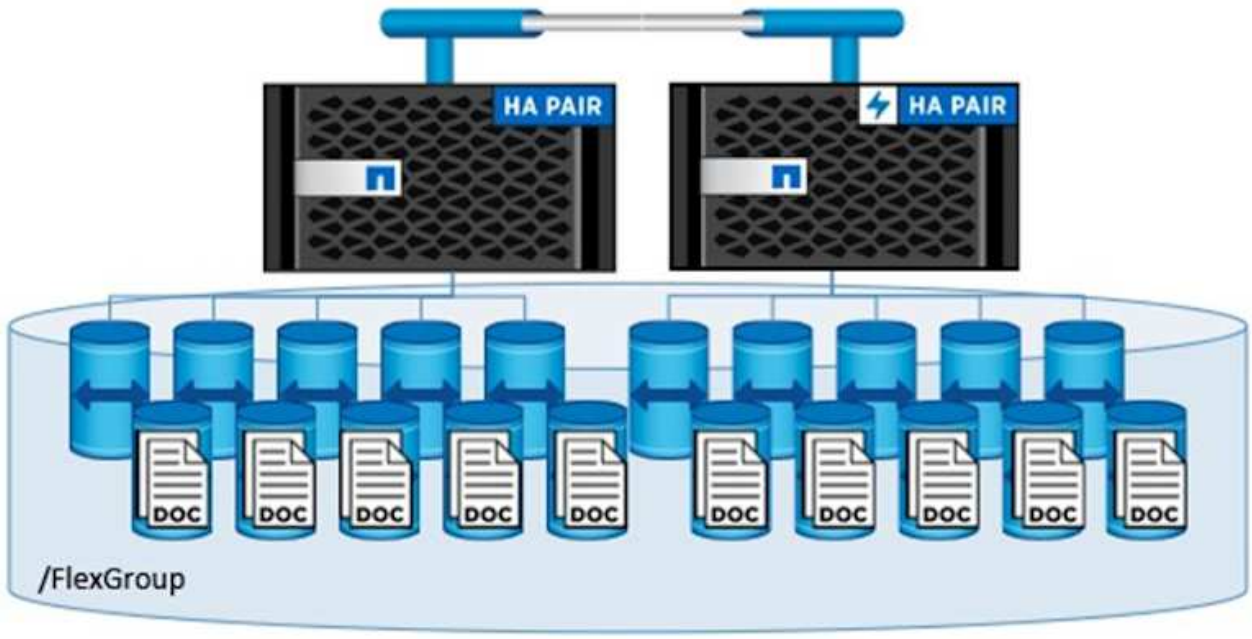

«

Gamme Lenovo ThinkSystem

Les serveurs Lenovo ThinkSystem sont dotés de matériel, de logiciels et de services innovants qui répondent aux défis actuels des clients et offrent une approche évolutive, adaptée et modulaire pour répondre aux défis de demain. Ces serveurs exploitent les meilleures technologies standard du secteur, associées à des innovations Lenovo différenciées, pour offrir la plus grande flexibilité possible aux serveurs x86.

Les principaux avantages du déploiement des serveurs Lenovo ThinkSystem sont les suivants :

- Des conceptions modulaires extrêmement évolutives qui s'étendent à votre activité
- La résilience optimale du secteur pour économiser des heures de temps d'arrêt imprévus coûteux
- Des technologies Flash rapides pour des latences plus faibles, des temps de réponse plus rapides et une gestion intelligente des données en temps réel

Dans le domaine de l'IA, Lenovo propose une approche pratique pour aider les entreprises à comprendre et à exploiter les avantages DU ML et de l'IA pour leurs workloads. Les clients Lenovo peuvent explorer et évaluer les offres d'IA de Lenovo dans les centres d'innovation d'IA de Lenovo afin de connaître pleinement la valeur de leur utilisation. Pour améliorer le retour sur investissement, cette approche axée sur le client propose des démonstrations de faisabilité pour les plateformes de développement de solutions prêtes à l'emploi et optimisées pour l'IA.

Lenovo SR670 V2

Le serveur rack Lenovo ThinkSystem SR670 V2 offre des performances optimales pour l'IA accélérée et le calcul haute performance (HPC). Prenant en charge jusqu'à huit GPU, la SR670 V2 est parfaitement adaptée aux exigences de charges de travail de calcul intensives du ML, du DL et de l'inférence.

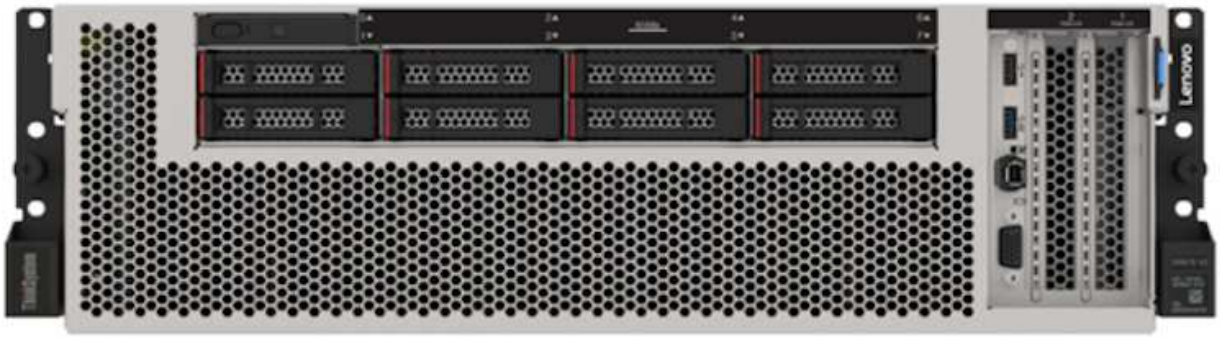

4x SXM GPUs with 8x 2.5-inch HS drives and 2x PCIe I/O slots

4x double-wide or 8x single-wide GPU slots and 2x PCIe I/O slots with 8x 2.5-inch or 4x 3.5-inch HS drives

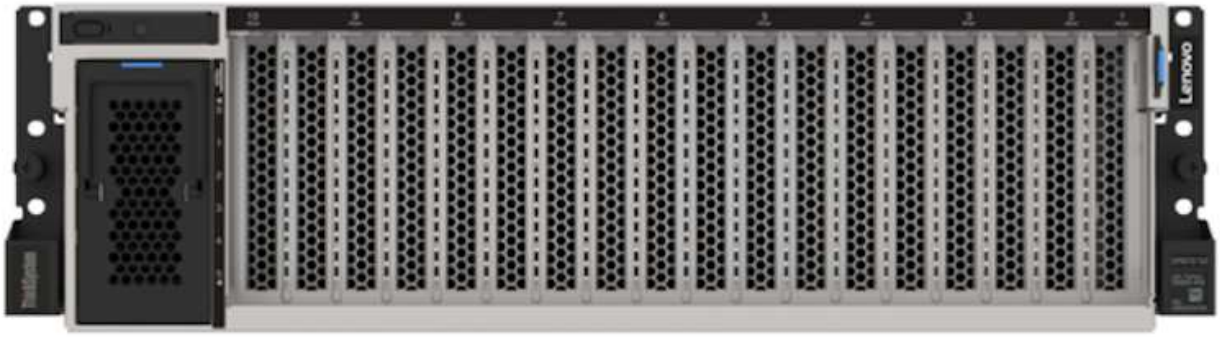

8x double-wide GPU slots with 6x EDSFF HS drives and 2x PCIe I/O slots

Avec les derniers processeurs Intel Xeon évolutifs prenant en charge les processeurs graphiques haut de gamme (notamment le processeur graphique NVIDIA A100 80 Go PCIe 8x), le ThinkSystem SR670 V2 offre des performances optimisées et accélérées pour les workloads d'IA et d'HPC.

En effet, la densité des GPU est plus élevée parce qu'un plus grand nombre de charges de travail utilisent des accélérateurs de performances. Les secteurs tels que le Retail, les services financiers, l'énergie et le domaine de la santé utilisent des GPU pour extraire des informations exploitables et stimuler l'innovation avec des techniques DE ML, d'apprentissage profond et d'inférence.

Le ThinkSystem SR670 V2 est une solution optimisée pour le déploiement de charges de travail HPC et ai accélérées en production. Il optimise ainsi les performances du système tout en maintenant la densité du data Center pour les clusters de supercalculateurs dotés de plateformes nouvelle génération.

Voici quelques-unes des autres fonctionnalités :

- Prise en charge des E/S RDMA directes au niveau des GPU, dans lesquelles les adaptateurs réseau ultra-rapides sont directement connectés aux GPU afin d'optimiser les performances d'E/S.
- La prise en charge du stockage direct par processeur graphique dans lequel les disques NVMe sont directement connectés aux processeurs graphiques pour optimiser les performances du stockage.

Diminution des

MLPerf est une suite de banc d'essai leader du secteur pour évaluer les performances de l'IA. Lors de cette validation, nous avons utilisé son banc d'essai de classification des images avec MXNet, l'un des frameworks d'IA les plus répandus. Le script d'entraînement MXNet_bancs d'essai a été utilisé pour entraîner l'entraînement à l'IA. Le script contient des implémentations de plusieurs modèles classiques courants et est conçu pour être aussi rapide que possible. Il peut être exécuté sur une seule machine ou en mode distribué sur plusieurs hôtes.

Plan de test

Dans cette validation, nous avons suivi une formation sur la reconnaissance d'images comme spécifié par MLPerf v2.0. Nous avons plus particulièrement entraîné le modèle ResNet v2.0 avec le dataset ImageNet jusqu'à ce que nous soyons parvenus à un niveau de précision de 76.1 %. La mesure principale est le temps d'atteindre la précision souhaitée. Nous avons également établi des rapports sur la bande passante d'entraînement en images par seconde afin de mieux évaluer l'efficacité évolutive.

Le principal cas d'essai a évalué plusieurs processus de formation indépendants (un par nœud) exécutés simultanément. Cela simule l'utilisation principale, un système partagé utilisé par plusieurs data Scientists. Dans le deuxième cas, l'efficacité du stockage scale-out a été évaluée.

Résultats du test

Le tableau suivant récapitule les résultats de tous les tests effectués pour cette solution.

Description du test	Résumé des résultats
Formation à la reconnaissance d'images : plusieurs tâches simultanées	Efficacité et performance exceptionnelles. Toutes les tâches s'exécutaient à pleine vitesse, même lorsque le cluster était entièrement utilisé. Les systèmes de stockage NetApp ont fourni des performances d'entraînement comparables au stockage SSD local tout en facilitant le partage des données entre les serveurs.

Description du test	Résumé des résultats
Formation à la reconnaissance d'images : évolutivité horizontale	Efficacité élevée pour un maximum de quatre nœuds. À ce stade, l'évolutivité horizontale était moins efficace, mais tout de même faisable. L'utilisation d'un réseau informatique à vitesse élevée améliore l'évolutivité. Les systèmes de stockage NetApp ont offert des performances d'entraînement comparables au stockage SSD local tout en facilitant le partage des données entre les serveurs.

Configuration du test

Cette section décrit les configurations testées, l'infrastructure réseau, le serveur SR670 V2 et les détails du provisionnement de stockage NetApp.

Architecture de la solution

Nous avons utilisé les composants de la solution répertoriés dans le tableau suivant pour cette validation.

Composants de la solution	Détails
Serveurs Lenovo ThinkSystem	• Deux serveurs SR670 V2 équipés chacun de huit cartes graphiques NVIDIA A100 de 80 Go • Chaque serveur contient 2 processeurs Intel Xeon Platinum 8360Y (28 cœurs physiques) et 1 To de RAM
Linux (Ubuntu – 20.04 avec CUDA 11.8)	
Système de stockage NetApp AFF (paire HA)	• Le logiciel NetApp ONTAP 9.10.1 • SSD 24x 960 Go • Protocole NFS • 1 groupe d'interface (ifgrp) par contrôleur, avec quatre adresses IP logiques pour les points de montage

Pour cette validation, nous avons utilisé ResNet v2.0 avec le niveau de base ImageNet défini par MLPerf v2.0. Le dataset est stocké dans un système de stockage NetApp AFF avec le protocole NFS. Les SR670 ont été connectés au système de stockage NetApp AFF A400 via un switch de 100 GbE.

ImageNET est un jeu de données d'images fréquemment utilisé. Il contient près de 1.3 millions d'images pour une taille totale de 144 Go. La taille moyenne de l'image est de 108Ko.

La figure suivante représente la topologie réseau de la configuration testée.

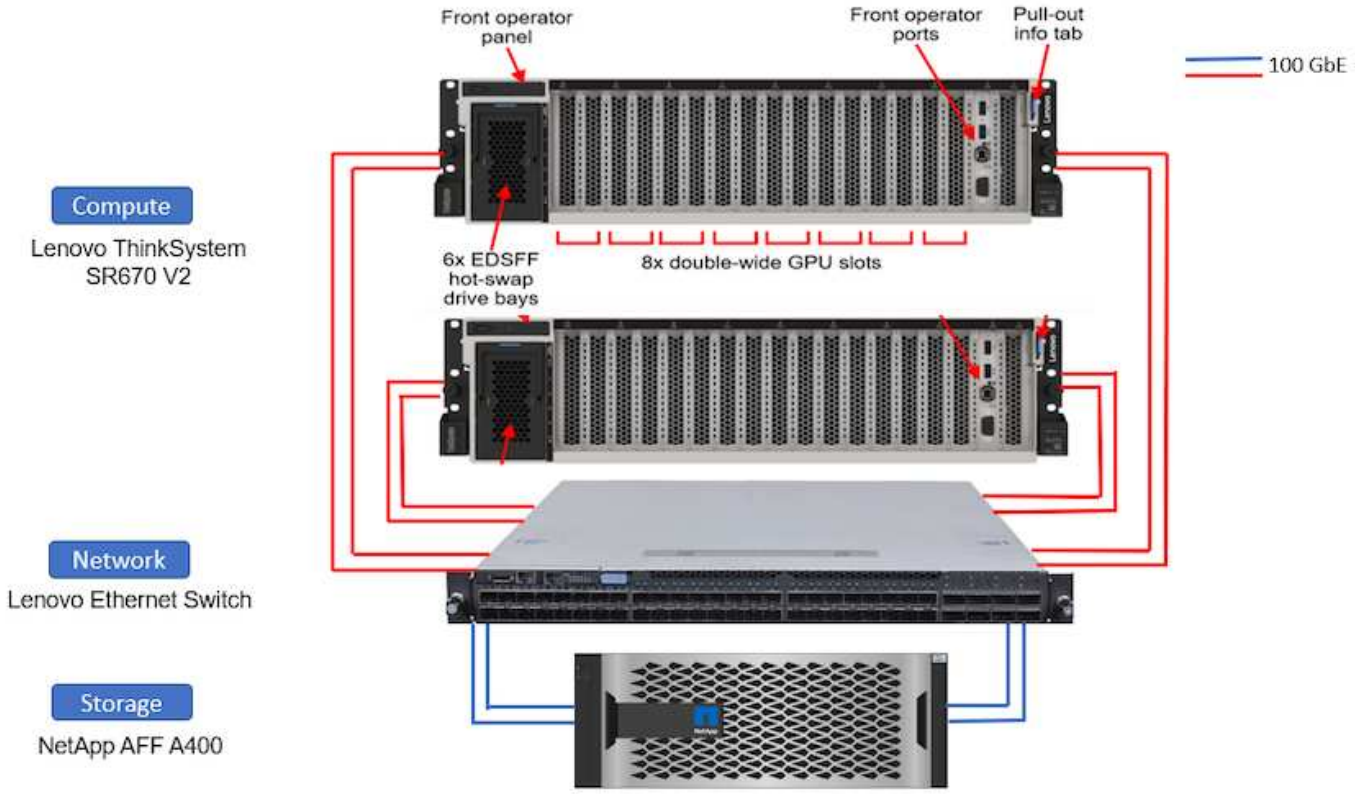

Contrôleur de stockage

Le tableau suivant répertorie la configuration du stockage.

Contrôleur	Agrégat	Volume FlexGroup	Taille de l'agrégat	Taille du volume	Point de montage du système d'exploitation
Contrôleur 1	Agr1	/a400-100g	9 TO	19 TO	/a400-100g
Contrôleur 2	Agr2	/a400-100g	9 TO		/a400-100g

Le dossier /a400-100g contient le dataset utilisé pour la validation ResNet.

Procédure de test et résultats détaillés

Cette section décrit les résultats détaillés de la procédure de test.

Entraînement de reconnaissance d'images à l'aide de ResNet dans ONTAP

Nous avons exécuté le banc d'essai ResNet50 avec un ou deux serveurs SR670 V2. Ce test a utilisé le conteneur MXNet 22.04-py3 NGC pour effectuer l'entraînement.

Cette validation a été effectuée à l'aide de la procédure de test suivante :

1. Nous avons effacé le cache de l'hôte avant d'exécuter le script pour nous assurer que les données n'étaient pas déjà mises en cache :

```
sync ; sudo /sbin/sysctl vm.drop_caches=3
```

2. Nous avons exécuté le script de test avec le dataset ImageNet sur le stockage serveur (stockage SSD local) ainsi que sur le système de stockage NetApp AFF.
3. Nous avons validé les performances du réseau et du stockage local à l'aide du `dd` commande.
4. Pour l'exécution à un seul nœud, nous avons utilisé la commande suivante :

```
python train_imagenet.py --gpus 0,1,2,3,4,5,6,7 --batch-size 408 --kv
-store horovod --lr 10.5 --mom 0.9 --lr-step-epochs pow2 --lars-eta
0.001 --label-smoothing 0.1 --wd 5.0e-05 --warmup-epochs 2 --eval-period
4 --eval-offset 2 --optimizer sgdwfastlars --network resnet-v1b-stats-fl
--num-layers 50 --num-epochs 37 --accuracy-threshold 0.759 --seed 27081
--dtype float16 --disp-batches 20 --image-shape 4,224,224 --fuse-bn-relu
1 --fuse-bn-add-relu 1 --bn-group 1 --min-random-area 0.05 --max-random
-area 1.0 --conv-algo 1 --force-tensor-core 1 --input-layout NHWC --conv
-layout NHWC --batchnorm-layout NHWC --pooling-layout NHWC --batchnorm
-mom 0.9 --batchnorm-eps 1e-5 --data-train /data/train.rec --data-train
-idx /data/train.idx --data-val /data/val.rec --data-val-idx
/data/val.idx --dali-dont-use-mmap 0 --dali-hw-decoder-load 0 --dali
-prefetch-queue 5 --dali-nvjpeg-memory-padding 256 --input-batch
-multiplier 1 --dali- threads 6 --dali-cache-size 0 --dali-roi-decode 1
--dali-preallocate-width 5980 --dali-preallocate-height 6430 --dali-tmp
-buffer-hint 355568328 --dali-decoder-buffer-hint 1315942 --dali-crop
-buffer-hint 165581 --dali-normalize-buffer-hint 441549 --profile 0
--e2e-cuda-graphs 0 --use-dali
```

5. Pour les exécutions distribuées, nous avons utilisé le modèle de parallélisation du serveur de paramètres. Nous avons utilisé deux serveurs de paramètres par nœud et nous avons fixé le nombre de séries de tests à la même chose que pour l'exécution d'un nœud unique. Nous l'avons fait parce que la formation distribuée prend souvent plus de séries de tests en raison de la synchronisation imparfaite entre les processus. Les différentes séries de tests peuvent fausser les comparaisons entre des cas à un seul nœud et distribués.

Vitesse de lecture des données : locale ou stockage réseau

La vitesse de lecture a été testée à l'aide du `dd` Commande sur l'un des fichiers pour le dataset ImageNet. Nous avons exécuté les commandes suivantes pour les données locales et réseau :

```
sync ; sudo /sbin/sysctl vm.drop_caches=3dd if=/a400-100g/netapp-
ra/resnet/data/preprocessed_data/train.rec of=/dev/null bs=512k
count=2048Results (average of 5 runs):
Local storage: 1.7 GB/s Network storage: 1.5 GB/s.
```

Ces deux valeurs sont similaires. Elles démontrent que le stockage réseau peut fournir des données à un débit

similaire au stockage local.

Cas d'utilisation partagé : plusieurs tâches indépendantes et simultanées

Ce test a permis d'évaluer l'utilisation prévue de cette solution : la formation sur l'IA multi-tâche et multi-utilisateurs. Chaque nœud a exécuté sa propre formation en utilisant le stockage réseau partagé. Les résultats s'affichent dans la figure suivante, qui montre que la solution offrait d'excellentes performances pour toutes les tâches exécutées à la même vitesse que les tâches individuelles. Le débit total augmente de façon linéaire en fonction du nombre de nœuds.

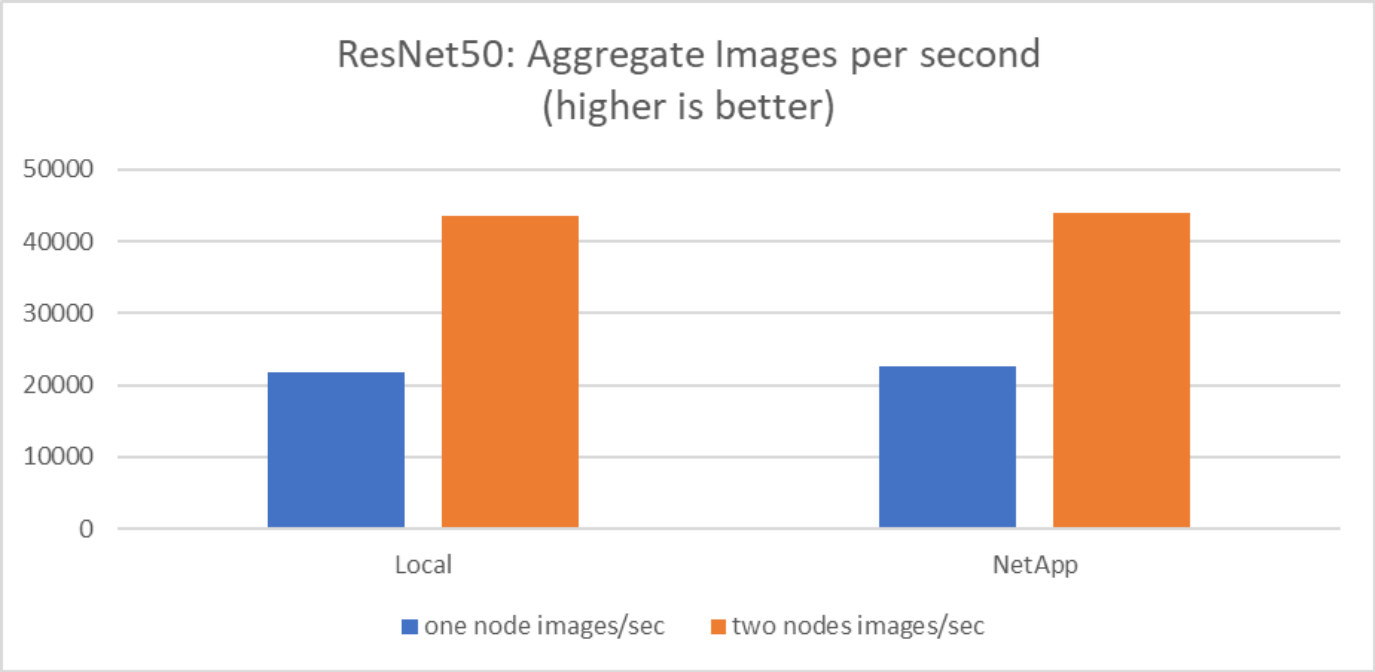

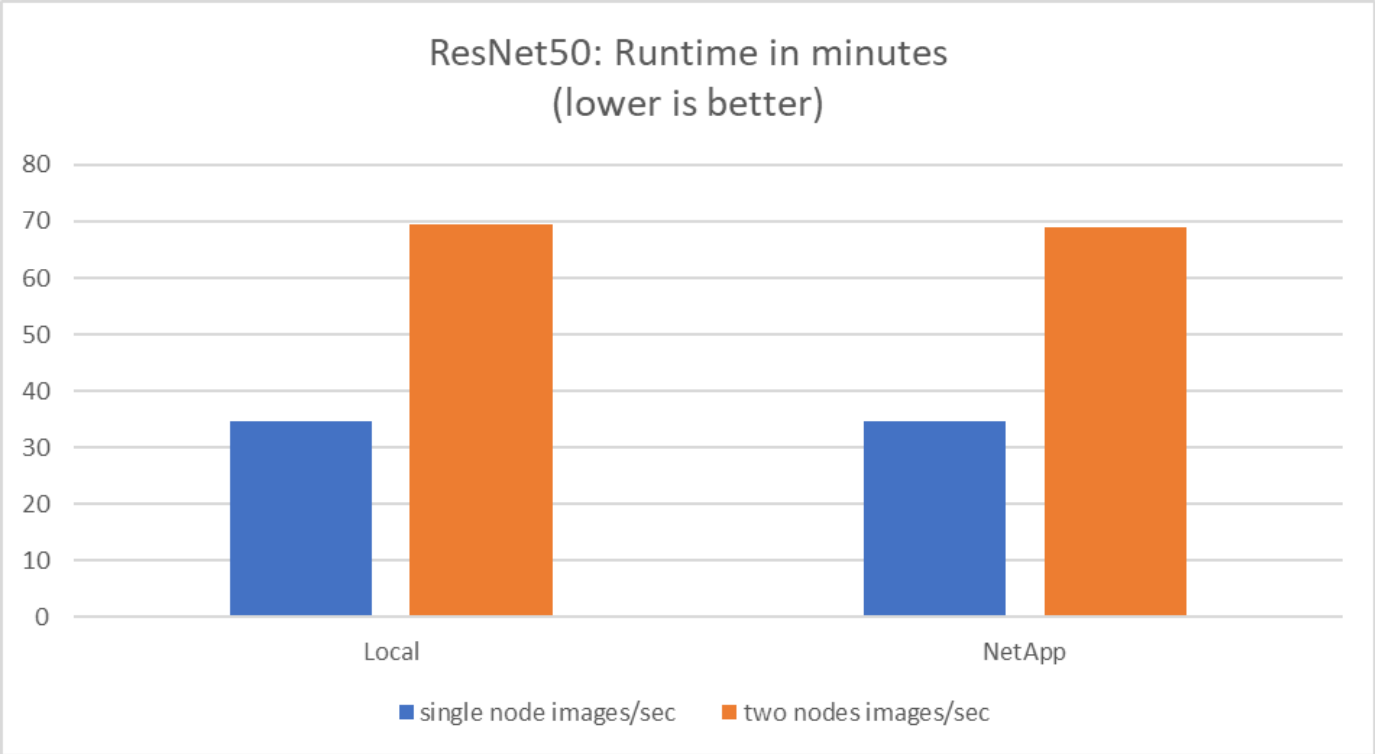

Ces graphiques présentent un temps d'exécution de quelques minutes. Les images agrégées par seconde

pour les nœuds de calcul qui ont utilisé huit GPU de chaque serveur de 100 GbE client, associant le modèle d'entraînement simultané et le modèle d'entraînement unique. La durée d'exécution moyenne du modèle d'entraînement était de 35 minutes et 9 secondes. Les cycles individuels étaient de 34 minutes et 32 secondes, 36 minutes et 21 secondes, 34 minutes et 37 secondes, 35 minutes et 25 secondes, et 34 minutes et 31 secondes. Le modèle d'entraînement comptait en moyenne 22,573 images par seconde et 21,764 images par seconde, 23,438, 22,556, 22,564 et 22,547.

Sur la base de notre validation, un modèle d'entraînement indépendant avec un temps d'exécution des données NetApp s'est établi à 34 minutes et 54 secondes, avec 22,231 images/s. Un modèle d'entraînement indépendant avec un temps d'exécution des données locales (DAS) était de 34 minutes et 21 secondes avec 22,102 images/s. Lors de ces exécutions, l'utilisation moyenne des GPU était de 96 %, comme observé sur nvidia-smi. Notez que cette moyenne inclut la phase de test, au cours de laquelle les GPU n'ont pas été utilisés, tandis que l'utilisation du CPU a été de 40 % mesurée par mpstat. Cela démontre que le taux de livraison des données est suffisant dans chaque cas.

Ajustements d'architecture

La configuration utilisée pour cette validation peut être ajustée en fonction d'autres cas d'utilisation.

Réglages du processeur

Nous avons utilisé un processeur Skylake Intel Xeon Platinum 8360Y pour cette validation, comme recommandé par Lenovo. Nous nous attendons à ce que le processeur Cascade Lake équivalent, un processeur Intel Xeon Gold 6330, offre des performances similaires car cette charge de travail n'est pas liée au processeur.

Augmentation de la capacité de stockage

En fonction de vos besoins en capacité de stockage, vous pouvez augmenter le stockage partagé (volume NFS) à la demande, à condition que vous disposiez des tiroirs disques et des modèles de contrôleurs supplémentaires. Vous pouvez le faire depuis l'interface de ligne de commandes ou l'interface Web de NetApp du contrôleur de stockage en tant qu'utilisateur administrateur.

Conclusion

La solution NetApp et Lenovo validée ici est une architecture scale-out flexible, idéale pour commencer dans les environnements d'IA d'entreprise de taille moyenne.

Le stockage NetApp offre des performances identiques ou supérieures à celles du stockage SSD local et offre les avantages suivants aux data Scientists, aux ingénieurs de données et aux décideurs IT :

- Partage sans effort des données entre des systèmes d'IA, l'analytique et d'autres systèmes métier stratégiques. Ce partage des données permet de réduire la surcharge de l'infrastructure, d'améliorer les performances et de rationaliser la gestion des données à l'échelle de l'entreprise.
- Faire évoluer indépendamment les ressources de calcul et de stockage pour réduire les coûts et améliorer l'utilisation des ressources.
- Rationalisation des workflows de développement et de déploiement à l'aide de snapshots et de clones intégrés, pour des espaces de travail utilisateur instantanés et compacts, un contrôle intégré des versions et un déploiement automatisé.

- Protection des données haute performance pour la reprise après incident et la continuité de l'activité.

Remerciements

- Karthikeyan Nagalingam, Ingénieur marketing et technique, NetApp
- Jarrett Upton, administrateur, ai Lab Systems, Lenovo

Où trouver des informations complémentaires

Pour en savoir plus sur les informations fournies dans ce document, consultez ces documents et/ou sites web :

- Page produit sur les baies 100 % Flash de NetApp

  "https://www.netapp.com/us/products/storage-systems/all-flash-array/aff-a-series.aspx"

- Page NetApp AFF A400

  "https://docs.netapp.com/us-en/ontap-systems/a400/index.html"

- Page produit du logiciel de gestion des données NetApp ONTAP

  "http://www.netapp.com/us/products/data-management-software/ontap.aspx"

- Diminution des

  "https://mlperf.org"

- Banc d'essai TensorFlow

  "https://github.com/tensorflow/benchmarks"

- NVIDIA SMI (nvidia-smi)

  "https://developer.nvidia.com/nvidia-system-management-interface"

Informations sur le copyright

Copyright © 2024 NetApp, Inc. Tous droits réservés. Imprimé aux États-Unis. Aucune partie de ce document protégé par copyright ne peut être reproduite sous quelque forme que ce soit ou selon quelque méthode que ce soit (graphique, électronique ou mécanique, notamment par photocopie, enregistrement ou stockage dans un système de récupération électronique) sans l'autorisation écrite préalable du détenteur du droit de copyright.

Les logiciels dérivés des éléments NetApp protégés par copyright sont soumis à la licence et à l'avis de non-responsabilité suivants :

CE LOGICIEL EST FOURNI PAR NETAPP « EN L'ÉTAT » ET SANS GARANTIES EXPRESSES OU TACITES, Y COMPRIS LES GARANTIES TACITES DE QUALITÉ MARCHANDE ET D'ADÉQUATION À UN USAGE PARTICULIER, QUI SONT EXCLUES PAR LES PRÉSENTES. EN AUCUN CAS NETAPP NE SERA TENU POUR RESPONSABLE DE DOMMAGES DIRECTS, INDIRECTS, ACCESSOIRES, PARTICULIERS OU EXEMPLAIRES (Y COMPRIS L'ACHAT DE BIENS ET DE SERVICES DE SUBSTITUTION, LA PERTE DE JOUISSANCE, DE DONNÉES OU DE PROFITS, OU L'INTERRUPTION D'ACTIVITÉ), QUELLES QU'EN SOIENT LA CAUSE ET LA DOCTRINE DE RESPONSABILITÉ, QU'IL S'AGISSE DE RESPONSABILITÉ CONTRACTUELLE, STRICTE OU DÉLICTUELLE (Y COMPRIS LA NÉGLIGENCE OU AUTRE) DÉCOULANT DE L'UTILISATION DE CE LOGICIEL, MÊME SI LA SOCIÉTÉ A ÉTÉ INFORMÉE DE LA POSSIBILITÉ DE TELS DOMMAGES.

NetApp se réserve le droit de modifier les produits décrits dans le présent document à tout moment et sans préavis. NetApp décline toute responsabilité découlant de l'utilisation des produits décrits dans le présent document, sauf accord explicite écrit de NetApp. L'utilisation ou l'achat de ce produit ne concède pas de licence dans le cadre de droits de brevet, de droits de marque commerciale ou de tout autre droit de propriété intellectuelle de NetApp.

Le produit décrit dans ce manuel peut être protégé par un ou plusieurs brevets américains, étrangers ou par une demande en attente.

LÉGENDE DE RESTRICTION DES DROITS : L'utilisation, la duplication ou la divulgation par le gouvernement sont sujettes aux restrictions énoncées dans le sous-paragraphe (b)(3) de la clause Rights in Technical Data-Noncommercial Items du DFARS 252.227-7013 (février 2014) et du FAR 52.227-19 (décembre 2007).

Les données contenues dans les présentes se rapportent à un produit et/ou service commercial (tel que défini par la clause FAR 2.101). Il s'agit de données propriétaires de NetApp, Inc. Toutes les données techniques et tous les logiciels fournis par NetApp en vertu du présent Accord sont à caractère commercial et ont été exclusivement développés à l'aide de fonds privés. Le gouvernement des États-Unis dispose d'une licence limitée irrévocable, non exclusive, non cessible, non transférable et mondiale. Cette licence lui permet d'utiliser uniquement les données relatives au contrat du gouvernement des États-Unis d'après lequel les données lui ont été fournies ou celles qui sont nécessaires à son exécution. Sauf dispositions contraires énoncées dans les présentes, l'utilisation, la divulgation, la reproduction, la modification, l'exécution, l'affichage des données sont interdits sans avoir obtenu le consentement écrit préalable de NetApp, Inc. Les droits de licences du Département de la Défense du gouvernement des États-Unis se limitent aux droits identifiés par la clause 252.227-7015(b) du DFARS (février 2014).

Informations sur les marques commerciales

NETAPP, le logo NETAPP et les marques citées sur le site http://www.netapp.com/TM sont des marques déposées ou des marques commerciales de NetApp, Inc. Les autres noms de marques et de produits sont des marques commerciales de leurs propriétaires respectifs.