NVIDIA ai Enterprise avec NetApp et VMware

NetApp Solutions

NetApp
March 19, 2024

This PDF was generated from https://docs.netapp.com/fr-fr/netapp-solutions/ai/nvaie_introduction.html on March 19, 2024. Always check docs.netapp.com for the latest.

Sommaire

NVIDIA ai Enterprise avec NetApp et VMware . . . 1
- NVIDIA ai Enterprise avec NetApp et VMware . . . 1
- Présentation de la technologie . . . 1
- Architecture . . . 3
- Configuration initiale . . . 4
- Utilisez le logiciel NVIDIA NGC . . . 5
- Sources d’informations complémentaires . . . 10

NVIDIA ai Enterprise avec NetApp et VMware

NVIDIA ai Enterprise avec NetApp et VMware

Mike Oglesby, NetApp

Pour les architectes ET les administrateurs IT, les outils d'IA peuvent être complexes et peu familiers. En outre, beaucoup de plateformes d'IA ne sont pas prêtes pour l'entreprise. La solution NVIDIA ai Enterprise, optimisée par NetApp et VMware, a été créée pour fournir une architecture d'IA rationalisée et haute performance.

NVIDIA ai Enterprise est une suite logicielle cloud complète d'IA et d'analytique de données optimisée, certifiée et prise en charge par NVIDIA pour s'exécuter sur VMware vSphere avec les systèmes NVIDIA certifiés. Ce logiciel facilite le déploiement, la gestion et l'évolutivité simples et rapides des workloads d'IA dans un environnement de cloud hybride moderne. La solution NVIDIA ai Enterprise, optimisée par NetApp et VMware, fournit un workload d'IA haute performance et une gestion des données dans un pack simplifié et familier.

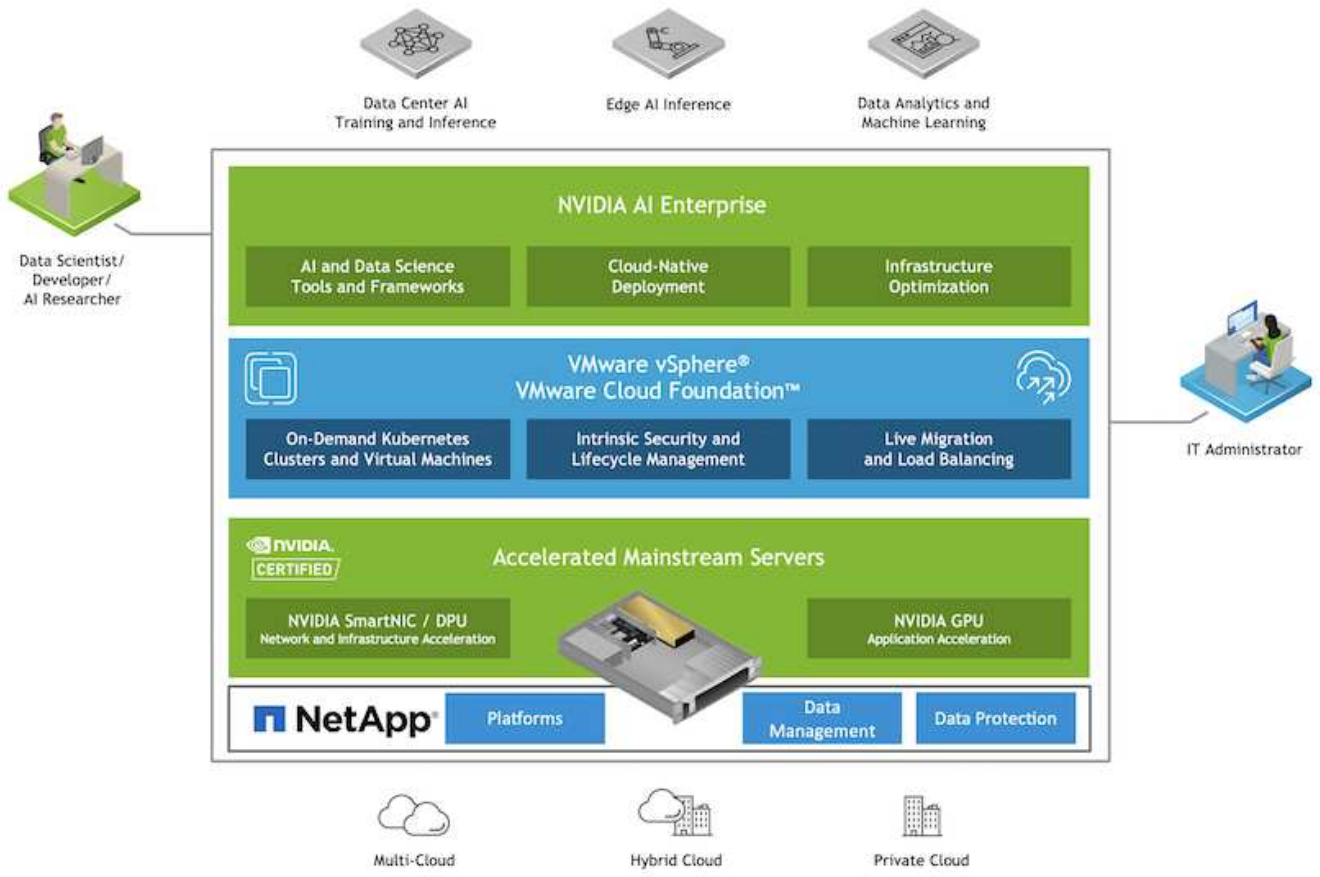

Présentation de la technologie

NVIDIA ai Enterprise

NVIDIA ai Enterprise est une suite logicielle cloud complète d'IA et d'analytique de données optimisée,

certifiée et prise en charge par NVIDIA pour s'exécuter sur VMware vSphere avec les systèmes NVIDIA certifiés. Ce logiciel facilite le déploiement, la gestion et l'évolutivité simples et rapides des workloads d'IA dans un environnement de cloud hybride moderne.

NVIDIA GPU CLOUD (NGC)

NVIDIA NGC héberge un catalogue de logiciels optimisés pour les GPU destinés aux professionnels de l'IA afin qu'ils développent leurs solutions d'IA. Elle permet également d'accéder à plusieurs services d'IA, notamment NVIDIA base Command pour l'entraînement des modèles, NVIDIA Fleet Command pour déployer et surveiller les modèles, et NGC Private Registry pour accéder et gérer en toute sécurité des logiciels d'IA propriétaires. En outre, les clients NVIDIA ai Enterprise peuvent demander une assistance via le portail NGC.

VMware vSphere

VMware vSphere est la plateforme de virtualisation de VMware, qui transforme les data centers en infrastructures informatiques agrégées, incluant les ressources de CPU, de stockage et de réseau. VSphere gère ces infrastructures en tant qu'environnement d'exploitation unifié et fournit aux administrateurs les outils nécessaires pour gérer les data centers participant à cet environnement.

Les deux principaux composants de vSphere sont ESXi et vCenter Server. ESXi est la plateforme de virtualisation sur laquelle les administrateurs créent et exécutent des machines virtuelles et des appliances virtuelles. VCenter Server est le service par l'intermédiaire duquel les administrateurs gèrent plusieurs hôtes connectés dans un réseau et regroupent des ressources hôtes.

NetApp ONTAP

ONTAP 9, la dernière génération de logiciel de gestion du stockage de NetApp, permet aux entreprises de moderniser l'infrastructure et de passer à un data Center prêt pour le cloud. Avec des capacités de gestion des données à la pointe du secteur, ONTAP permet de gérer et de protéger les données avec un seul ensemble d'outils, quel que soit leur emplacement. Vous pouvez aussi déplacer vos données librement partout où elles sont nécessaires : la périphérie, le cœur ou le cloud. ONTAP 9 comprend de nombreuses fonctionnalités qui simplifient la gestion des données, accélèrent et protègent les données stratégiques, et permettent d'utiliser des fonctionnalités d'infrastructure nouvelle génération dans toutes les architectures de cloud hybride.

Gestion simplifiée

La gestion des données est cruciale pour les opérations IT et les data Scientists, de sorte que les ressources appropriées sont utilisées pour les applications d'IA et pour l'entraînement des datasets d'IA/DE ML. Les informations supplémentaires suivantes sur les technologies NetApp ne sont pas incluses dans cette validation, mais elles peuvent être pertinentes en fonction de votre déploiement.

Le logiciel de gestion des données ONTAP comprend les fonctionnalités suivantes pour rationaliser et simplifier les opérations et réduire le coût total d'exploitation :

- Compaction des données à la volée et déduplication étendue La compaction des données réduit le gaspillage d'espace à l'intérieur des blocs de stockage, et la déduplication augmente considérablement la capacité effective. Cela s'applique aux données stockées localement et à leur placement dans le cloud.
- Qualité de service (AQoS) minimale, maximale et adaptative. Les contrôles granulaires de la qualité de service (QoS) permettent de maintenir les niveaux de performance des applications stratégiques dans des environnements hautement partagés.
- NetApp FabricPool Tiering automatique des données inactives vers des options de stockage de cloud public et privé, notamment Amazon Web Services (AWS), Azure et la solution de stockage NetApp StorageGRID. Pour plus d'informations sur FabricPool, voir "Tr-4598 : meilleures pratiques de FabricPool".

Accélération et protection des données

ONTAP offre des niveaux supérieurs de performances et de protection des données et étend ces fonctionnalités aux méthodes suivantes :

- Des performances élevées et une faible latence. ONTAP offre le débit le plus élevé possible à la latence la plus faible possible.
- Protection des données. ONTAP fournit des fonctionnalités de protection des données intégrées avec une gestion commune sur toutes les plateformes.
- NetApp Volume Encryption (NVE). ONTAP offre un chiffrement natif au niveau du volume avec un support de gestion des clés interne et externe.
- Colocation et authentification multifacteur. ONTAP permet le partage des ressources d'infrastructure avec les plus hauts niveaux de sécurité.

Une infrastructure pérenne

ONTAP permet de répondre aux besoins métier en constante évolution grâce aux fonctionnalités suivantes :

- Évolutivité transparente et opérations non disruptives. ONTAP prend en charge l'ajout non disruptif de capacité aux contrôleurs et l'évolution scale-out des clusters. Les clients peuvent effectuer la mise à niveau vers les technologies les plus récentes, telles que NVMe et FC 32 Gb, sans migration des données ni panne coûteuse.
- Connexion cloud. ONTAP est le logiciel de gestion de stockage le plus connecté au cloud, avec des options de stockage SDS (ONTAP Select) et des instances natives de cloud (NetApp Cloud Volumes Service) dans tous les clouds publics.
- Intégration avec les applications émergentes ONTAP propose des services de données d'entreprise pour les plateformes et applications nouvelle génération, telles que les véhicules autonomes, les Smart cities et Industry 4.0, en utilisant la même infrastructure prenant en charge les applications d'entreprise existantes.

Kit NetApp DataOps

Le kit NetApp DataOps est un outil Python qui simplifie la gestion des espaces de travail de développement/formation et des serveurs d'inférence, lesquels sont basés sur un stockage NetApp haute performance et scale-out. Les fonctionnalités principales comprennent :

- Provisionnez rapidement de nouveaux espaces de travail JupyterLab haute capacité, soutenus par un stockage NetApp haute performance et scale-out.
- Provisionnez rapidement les nouvelles instances NVIDIA Triton Inférence Server, qui sont sauvegardées par un système de stockage NetApp de grande qualité.
- Cloner simultanément des espaces de travail JupyterLab haute capacité afin de permettre des expériences ou une itération rapide.
- Vous pouvez sauvegarder simultanément des snapshots des espaces de travail JupyterLab haute capacité pour la sauvegarde et/ou la traçabilité/l'établissement de base.
- Provisionnement, clonage et snapshot quasi instantanés des volumes de données haute capacité haute performance.

Architecture

Cette solution s'appuie sur une architecture familière et familière avec des systèmes

NetApp, VMware et NVIDIA-Certified. Voir le tableau suivant pour plus de détails.

Composant	Détails
Logiciels d'IA et d'analytique	"NVIDIA ai Enterprise pour VMware"
Plateforme de virtualisation	"VMware vSphere"
Plateforme de calcul	"Systèmes certifiés NVIDIA"
Plateforme de gestion de données	"NetApp ONTAP"

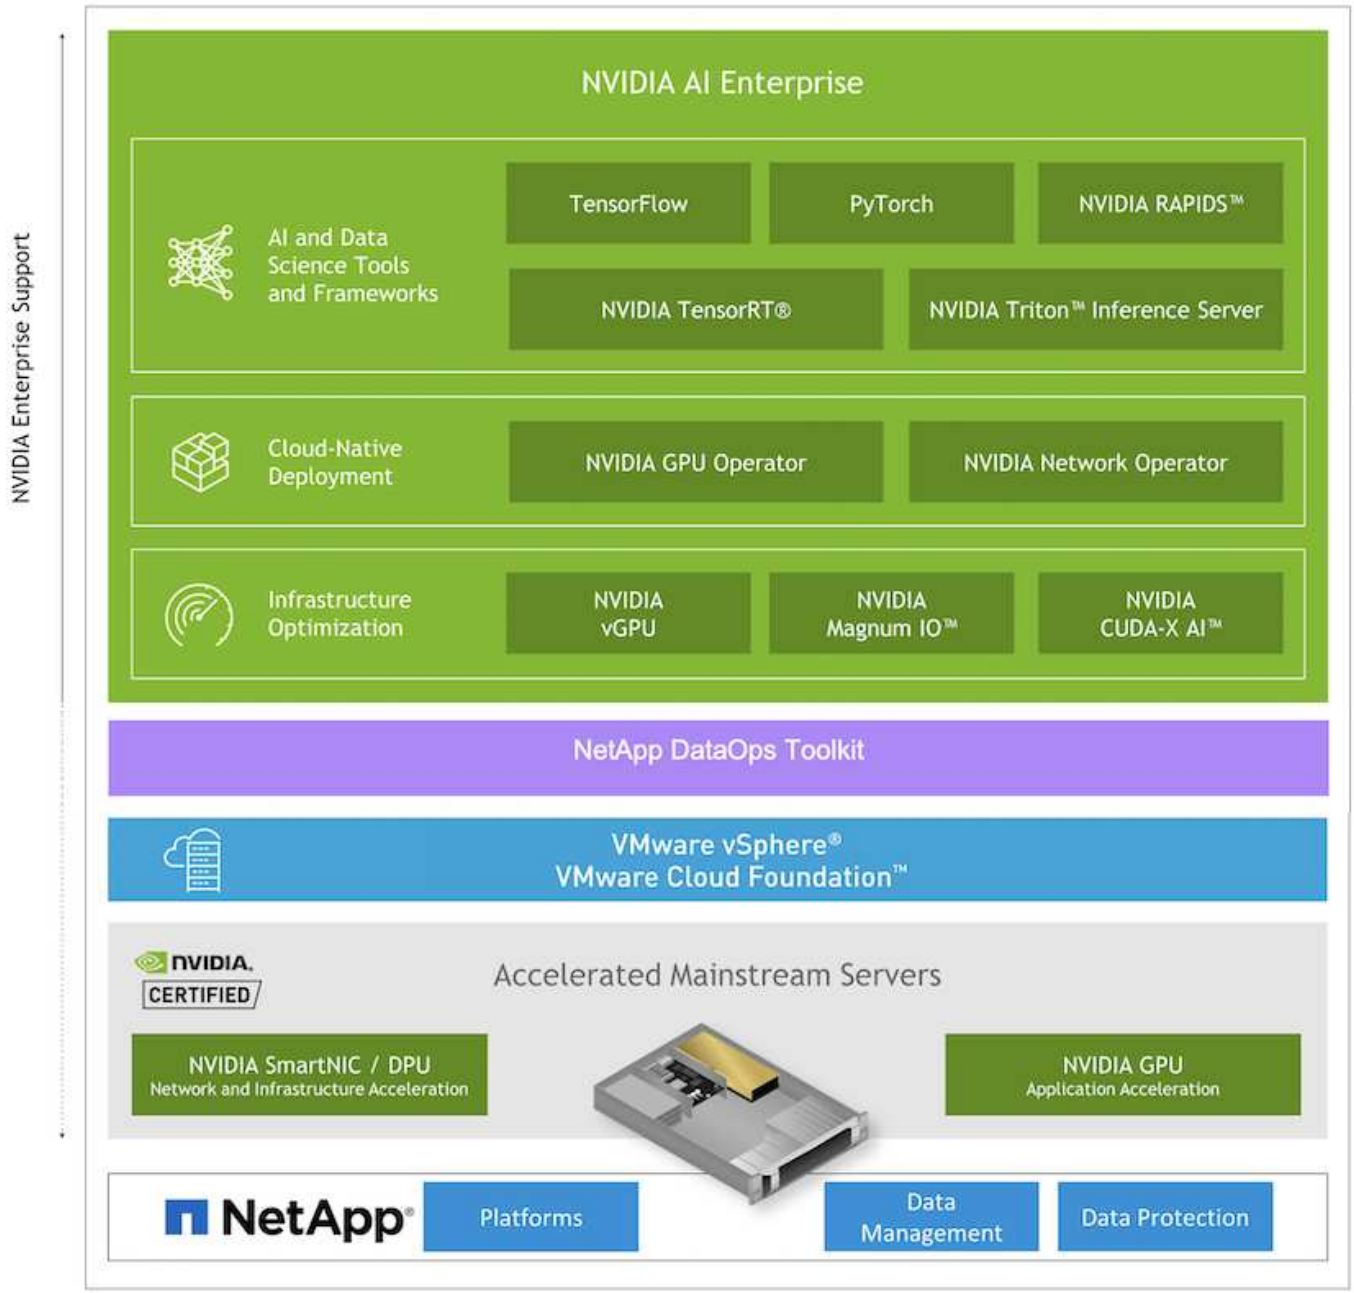

Configuration initiale

Cette section décrit les tâches de configuration initiales à effectuer afin d'utiliser NVIDIA

ai Enterprise avec NetApp et VMware.

Prérequis

Avant d'exécuter les étapes décrites dans cette section, nous supposons que vous avez déjà déployé VMware vSphere et NetApp ONTAP. Reportez-vous à la "Matrice de support des produits NVIDIA ai Enterprise" Pour plus d'informations sur les versions vSphere prises en charge. Reportez-vous à la "Documentation des solutions NetApp et VMware" Pour des informations détaillées sur le déploiement de VMware vSphere avec NetApp ONTAP.

Installez le logiciel hôte NVIDIA ai

Pour installer le logiciel hôte NVIDIA ai Entrprise, suivez les instructions décrites dans les sections 1-4 du "Guide de démarrage rapide de la solution NVIDIA ai Enterprise".

Utilisez le logiciel NVIDIA NGC

Cette section décrit les tâches à effectuer afin d'utiliser le logiciel NVIDIA NGC d'entreprise dans un environnement NVIDIA ai Enterprise.

Configuration

Cette section décrit les tâches de configuration initiales à effectuer pour utiliser le logiciel NVIDIA NGC d'entreprise dans un environnement NVIDIA ai Enterprise.

Prérequis

Avant d'effectuer les étapes décrites dans cette section, nous supposons que vous avez déjà déployé le logiciel hôte d'entrée d'entreprise NVIDIA ai en suivant les instructions du "Configuration initiale" page.

Créez une machine virtuelle Ubuntu Guest avec vGPU

Tout d'abord, vous devez créer une machine virtuelle Ubuntu 20.04 invitée avec vGPU. Pour créer une machine virtuelle invitée Ubuntu 20.04 avec vGPU, suivez les instructions du "Guide de déploiement de NVIDIA ai Enterprise".

Téléchargez et installez le logiciel invité NVIDIA

Vous devez ensuite installer le logiciel invité NVIDIA requis sur la machine virtuelle invitée que vous avez créée à l'étape précédente. Pour télécharger et installer le logiciel NVIDIA invité nécessaire sur la machine virtuelle invitée, suivez les instructions des sections 5.1-5.4 du "Guide de démarrage rapide de la solution NVIDIA ai Enterprise".

> Lors de l'exécution des tâches de vérification décrites dans la section 5.4, il se peut que vous deviez utiliser une balise de version d'image du conteneur CUDA différente car l'image du conteneur CUDA a été mise à jour depuis l'écriture du guide. Dans notre validation, nous avons utilisé NVIDIA/cuda:11.0.3-base-ubuntu20.04 ».

Télécharger le ou les conteneurs Framework d'IA/d'analytique

Vous devez ensuite télécharger les images de conteneur d'IA ou d'analytique requises depuis NVIDIA NGC

afin qu'elles soient disponibles dans votre VM invité. Pour télécharger les conteneurs de structure dans la machine virtuelle invitée, suivez les instructions du "Guide de déploiement de NVIDIA ai Enterprise".

Installez et configurez le kit NetApp DataOps

Vous devez ensuite installer le kit NetApp DataOps Toolkit pour les environnements traditionnels sur la machine virtuelle invitée. Le kit NetApp DataOps permet de gérer les volumes de données scale-out sur votre système ONTAP directement depuis le terminal au sein du serveur virtuel invité. Pour installer le kit NetApp DataOps Toolkit sur la machine virtuelle invitée, effectuez les tâches suivantes.

1. Installer pip.

```
$ sudo apt update
$ sudo apt install python3-pip
$ python3 -m pip install netapp-dataops-traditional
```

2. Déconnectez-vous du terminal de machine virtuelle invité, puis reconnectez-vous.
3. Configuration du kit NetApp DataOps. Pour effectuer cette étape, vous aurez besoin des informations d'accès à l'API pour votre système ONTAP. Vous devrez peut-être les obtenir de votre administrateur du stockage.

```
$ netapp_dataops_cli.py config

Enter ONTAP management LIF hostname or IP address (Recommendation: Use
SVM management interface): 172.22.10.10
Enter SVM (Storage VM) name: NVAIE-client
Enter SVM NFS data LIF hostname or IP address: 172.22.13.151
Enter default volume type to use when creating new volumes
(flexgroup/flexvol) [flexgroup]:
Enter export policy to use by default when creating new volumes
[default]:
Enter snapshot policy to use by default when creating new volumes
[none]:
Enter unix filesystem user id (uid) to apply by default when creating
new volumes (ex. '0' for root user) [0]:
Enter unix filesystem group id (gid) to apply by default when creating
new volumes (ex. '0' for root group) [0]:
Enter unix filesystem permissions to apply by default when creating new
volumes (ex. '0777' for full read/write permissions for all users and
groups) [0777]:
Enter aggregate to use by default when creating new FlexVol volumes:
aff_a400_01_NVME_SSD_1
Enter ONTAP API username (Recommendation: Use SVM account): admin
Enter ONTAP API password (Recommendation: Use SVM account):
Verify SSL certificate when calling ONTAP API (true/false): false
Do you intend to use this toolkit to trigger BlueXP Copy and Sync
operations? (yes/no): no
Do you intend to use this toolkit to push/pull from S3? (yes/no): no
Created config file: '/home/user/.netapp_dataops/config.json'.
```

Créer un modèle de machine virtuelle invité

Enfin, vous devez créer un modèle de machine virtuelle basé sur la machine virtuelle invitée. Vous pouvez utiliser ce modèle pour créer rapidement des machines virtuelles invitées à utiliser le logiciel NVIDIA NGC.

Pour créer un modèle de machine virtuelle basé sur votre machine virtuelle invitée, connectez-vous à VMware vSphere, cliquez sur le nom de la machine virtuelle invitée, sélectionnez « Cloner », choisissez « Cloner vers modèle… », puis suivez l'assistant.

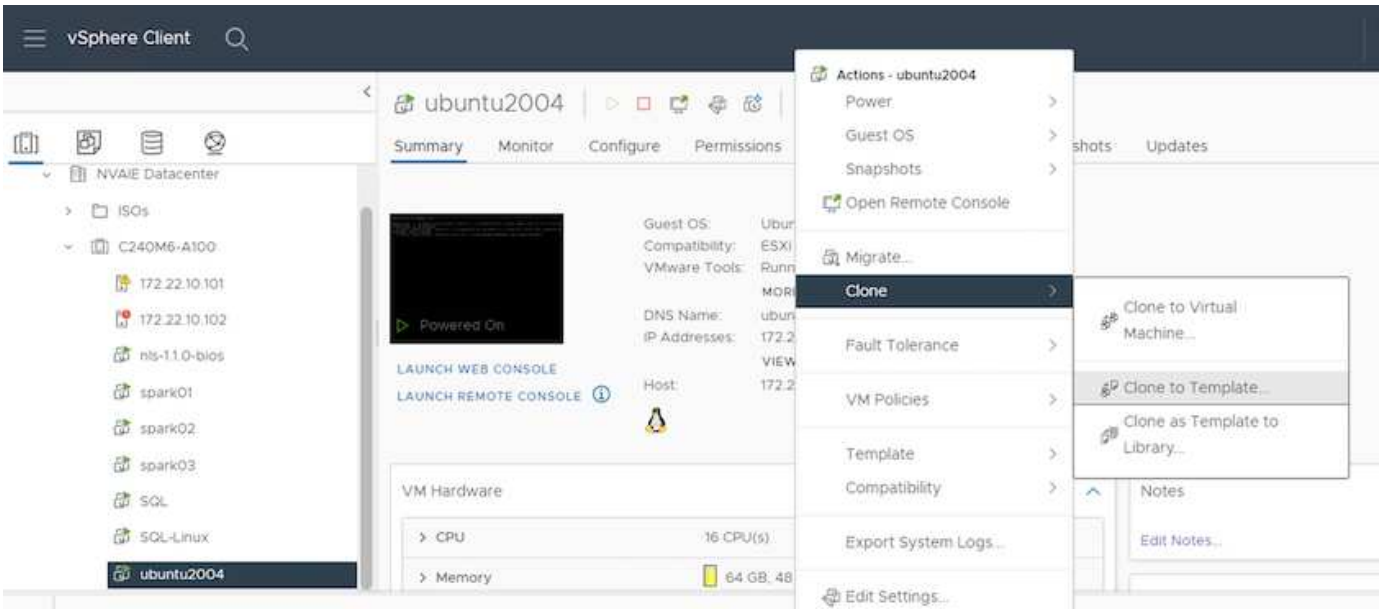

Exemple d’utilisation - travail de formation TensorFlow

Cette section décrit les tâches à effectuer pour exécuter un travail d’entraînement TensorFlow dans un environnement NVIDIA d’IA Enterprise.

Prérequis

Avant d’effectuer les étapes décrites dans cette section, nous supposons que vous avez déjà créé un modèle de machine virtuelle invité en suivant les instructions décrites dans le "Configuration" page.

Créer une VM invité à partir d’un modèle

Tout d’abord, vous devez créer une machine virtuelle invitée à partir du modèle que vous avez créé dans la section précédente. Pour créer une nouvelle machine virtuelle invitée à partir de votre modèle, connectez-vous à VMware vSphere, cliquez sur le nom du modèle, choisissez « New VM from this Template… », puis suivez l’assistant.

vSphere Client

vgpu-client-ubu

Summary Monitor Co

172.22.10.100

NVAIE Datacenter

Discovered virtual machine

vCLS

nls-1.1.0-bios

spark01

spark02

spark03

SQL

SQL-Linux

ubuntu2004

vgpu-client-ubuntu2

Guest OS:

Compatibility

VMware Tool

Actions - vgpu-client-ubuntu2004

New VM from This Template...

Convert to Virtual Machine...

Clone to Template...

Clone to Library...

Move to folder...

Rename...

Edit Notes...

Tags & Custom Attributes

Add Permission...

Alarms

Remove from Inventory

Delete from Disk

vSAN

Recent Tasks Alarms

Task Name Targe

Delete virtual machine

Clone virtual machine

All More Tasks

Créer et monter un volume de données

Vous devez ensuite créer un nouveau volume de données sur lequel stocker le dataset d'entraînement. Vous pouvez créer rapidement un nouveau volume de données à l'aide du kit NetApp DataOps. L'exemple de commande ci-dessous montre la création d'un volume nommé 'imagenet' d'une capacité de 2 To.

```
$ netapp_dataops_cli.py create vol -n imagenet -s 2TB
```

Avant de pouvoir alimenter le volume de données avec des données, vous devez le monter sur la machine virtuelle invitée. Vous pouvez monter rapidement un volume de données à l'aide du kit NetApp DataOps. L'exemple de commande ci-dessous montre la commande de création du volume à l'étape précédente.

```
$ sudo -E netapp_dataops_cli.py mount vol -n imagenet -m ~/imagenet
```

Remplir le volume de données

Une fois le nouveau volume provisionné et monté, le dataset d'entraînement peut être récupéré à partir de l'emplacement source et placé sur le nouveau volume. Cela implique généralement de extraire les données d'un data Lake S3 ou Hadoop, et parfois d'obtenir de l'aide d'un ingénieur de données.

Exécuter le travail de formation TensorFlow

Vous êtes maintenant prêt à exécuter votre travail de formation TensorFlow. Pour exécuter votre travail de formation TensorFlow, effectuez les tâches suivantes.

1. Tirez l'image du conteneur NVIDIA NGC Enterprise TensorFlow.

   ```
   $ sudo docker pull nvcr.io/nvaie/tensorflow-2-1:22.05-tf1-nvaie-2.1-py3
   ```

2. Lancez une instance du conteneur d'entreprise NVIDIA NGC. Utilisez l'option '-v' pour attacher votre volume de données au conteneur.

   ```
   $ sudo docker run --gpus all -v ~/imagenet:/imagenet -it --rm
   nvcr.io/nvaie/tensorflow-2-1:22.05-tf1-nvaie-2.1-py3
   ```

3. Exécutez votre programme de formation TensorFlow sur le conteneur. L'exemple de commande ci-dessous montre l'exécution d'un exemple de programme d'entraînement ResNet-50 inclus dans l'image conteneur.

   ```
   $ python ./nvidia-examples/cnn/resnet.py --layers 50 -b 64 -i 200 -u
   batch --precision fp16 --data_dir /imagenet/data
   ```

Sources d'informations complémentaires

Pour en savoir plus sur les informations fournies dans ce document, consultez ces

documents et/ou sites web :

- Le logiciel de gestion des données NetApp ONTAP : bibliothèque d'informations ONTAP

  http://mysupport.netapp.com/documentation/productlibrary/index.html?productID=62286

- Kit NetApp DataOps

  "https://github.com/NetApp/netapp-dataops-toolkit"

- NVIDIA ai Enterprise avec VMware

  https://www.nvidia.com/en-us/data-center/products/ai-enterprise/vmware/^]

Remerciements

- Bobby Oommen, Sr Responsable, NetApp
- Ramesh Isaac, Administrateur système, NetApp
- Roney Daniel, Ingénieur marketing et technique, NetApp

Informations sur le copyright

Copyright © 2024 NetApp, Inc. Tous droits réservés. Imprimé aux États-Unis. Aucune partie de ce document protégé par copyright ne peut être reproduite sous quelque forme que ce soit ou selon quelque méthode que ce soit (graphique, électronique ou mécanique, notamment par photocopie, enregistrement ou stockage dans un système de récupération électronique) sans l'autorisation écrite préalable du détenteur du droit de copyright.

Les logiciels dérivés des éléments NetApp protégés par copyright sont soumis à la licence et à l'avis de non-responsabilité suivants :

CE LOGICIEL EST FOURNI PAR NETAPP « EN L'ÉTAT » ET SANS GARANTIES EXPRESSES OU TACITES, Y COMPRIS LES GARANTIES TACITES DE QUALITÉ MARCHANDE ET D'ADÉQUATION À UN USAGE PARTICULIER, QUI SONT EXCLUES PAR LES PRÉSENTES. EN AUCUN CAS NETAPP NE SERA TENU POUR RESPONSABLE DE DOMMAGES DIRECTS, INDIRECTS, ACCESSOIRES, PARTICULIERS OU EXEMPLAIRES (Y COMPRIS L'ACHAT DE BIENS ET DE SERVICES DE SUBSTITUTION, LA PERTE DE JOUISSANCE, DE DONNÉES OU DE PROFITS, OU L'INTERRUPTION D'ACTIVITÉ), QUELLES QU'EN SOIENT LA CAUSE ET LA DOCTRINE DE RESPONSABILITÉ, QU'IL S'AGISSE DE RESPONSABILITÉ CONTRACTUELLE, STRICTE OU DÉLICTUELLE (Y COMPRIS LA NÉGLIGENCE OU AUTRE) DÉCOULANT DE L'UTILISATION DE CE LOGICIEL, MÊME SI LA SOCIÉTÉ A ÉTÉ INFORMÉE DE LA POSSIBILITÉ DE TELS DOMMAGES.

NetApp se réserve le droit de modifier les produits décrits dans le présent document à tout moment et sans préavis. NetApp décline toute responsabilité découlant de l'utilisation des produits décrits dans le présent document, sauf accord explicite écrit de NetApp. L'utilisation ou l'achat de ce produit ne concède pas de licence dans le cadre de droits de brevet, de droits de marque commerciale ou de tout autre droit de propriété intellectuelle de NetApp.

Le produit décrit dans ce manuel peut être protégé par un ou plusieurs brevets américains, étrangers ou par une demande en attente.

LÉGENDE DE RESTRICTION DES DROITS : L'utilisation, la duplication ou la divulgation par le gouvernement sont sujettes aux restrictions énoncées dans le sous-paragraphe (b)(3) de la clause Rights in Technical Data-Noncommercial Items du DFARS 252.227-7013 (février 2014) et du FAR 52.227-19 (décembre 2007).

Les données contenues dans les présentes se rapportent à un produit et/ou service commercial (tel que défini par la clause FAR 2.101). Il s'agit de données propriétaires de NetApp, Inc. Toutes les données techniques et tous les logiciels fournis par NetApp en vertu du présent Accord sont à caractère commercial et ont été exclusivement développés à l'aide de fonds privés. Le gouvernement des États-Unis dispose d'une licence limitée irrévocable, non exclusive, non cessible, non transférable et mondiale. Cette licence lui permet d'utiliser uniquement les données relatives au contrat du gouvernement des États-Unis d'après lequel les données lui ont été fournies ou celles qui sont nécessaires à son exécution. Sauf dispositions contraires énoncées dans les présentes, l'utilisation, la divulgation, la reproduction, la modification, l'exécution, l'affichage des données sont interdits sans avoir obtenu le consentement écrit préalable de NetApp, Inc. Les droits de licences du Département de la Défense du gouvernement des États-Unis se limitent aux droits identifiés par la clause 252.227-7015(b) du DFARS (février 2014).

Informations sur les marques commerciales

NETAPP, le logo NETAPP et les marques citées sur le site http://www.netapp.com/TM sont des marques déposées ou des marques commerciales de NetApp, Inc. Les autres noms de marques et de produits sont des marques commerciales de leurs propriétaires respectifs.