Pipelines de données, data Lakes et gestion

NetApp Solutions

NetApp
December 23, 2022

This PDF was generated from https://docs.netapp.com/fr-fr/netapp-solutions/ai/nvaie_introduction.html on December 23, 2022. Always check docs.netapp.com for the latest.

Table des matières

Pipelines de données, data Lakes et gestion . . . 1
NVIDIA ai Enterprise avec NetApp et VMware . . . 1
Tr-4851 : Data Lake NetApp StorageGRID pour les charges de travail de conduite autonome - conception de solution . . . 11
Plan de contrôle d'IA NetApp . . . 11
Pipeline MLRun avec Iguazio . . . 70
Tr-4915 : déplacement des données avec les workflows E-Series et BeeGFS pour l'IA et l'analytique . . . 98

Pipelines de données, data Lakes et gestion

NVIDIA ai Enterprise avec NetApp et VMware

NVIDIA ai Enterprise avec NetApp et VMware

Mike Oglesby, NetApp

Pour les architectes ET les administrateurs IT, les outils d'IA peuvent être complexes et peu familiers. En outre, beaucoup de plateformes d'IA ne sont pas prêtes pour l'entreprise. La solution NVIDIA ai Enterprise, optimisée par NetApp et VMware, a été créée pour fournir une architecture d'IA rationalisée et haute performance.

NVIDIA ai Enterprise est une suite logicielle cloud complète d'IA et d'analytique de données optimisée, certifiée et prise en charge par NVIDIA pour s'exécuter sur VMware vSphere avec les systèmes NVIDIA certifiés. Ce logiciel facilite le déploiement, la gestion et l'évolutivité simples et rapides des workloads d'IA dans un environnement de cloud hybride moderne. La solution NVIDIA ai Enterprise, optimisée par NetApp et VMware, fournit un workload d'IA haute performance et une gestion des données dans un pack simplifié et familier.

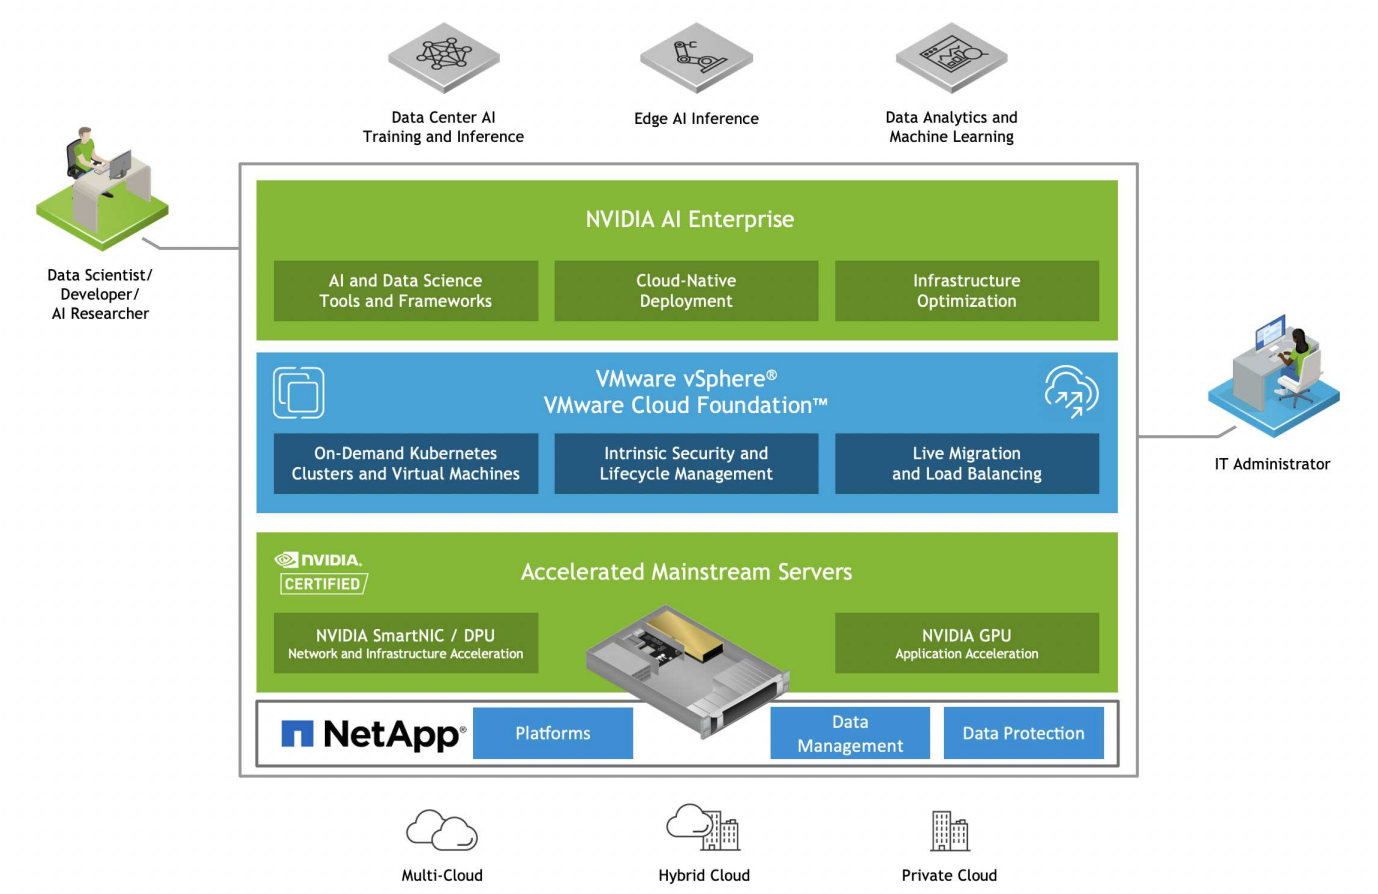

"Suivant : présentation de la technologie."

Présentation de la technologie

"Précédent : introduction."

NVIDIA ai Enterprise

NVIDIA ai Enterprise est une suite logicielle cloud complète d'IA et d'analytique de données optimisée, certifiée et prise en charge par NVIDIA pour s'exécuter sur VMware vSphere avec les systèmes NVIDIA certifiés. Ce logiciel facilite le déploiement, la gestion et l'évolutivité simples et rapides des workloads d'IA dans un environnement de cloud hybride moderne.

NVIDIA GPU CLOUD (NGC)

NVIDIA NGC héberge un catalogue de logiciels optimisés pour les GPU destinés aux professionnels de l'IA afin qu'ils développent leurs solutions d'IA. Elle permet également d'accéder à plusieurs services d'IA, notamment NVIDIA base Command pour l'entraînement des modèles, NVIDIA Fleet Command pour déployer et surveiller les modèles, et NGC Private Registry pour accéder et gérer en toute sécurité des logiciels d'IA propriétaires. En outre, les clients NVIDIA ai Enterprise peuvent demander une assistance via le portail NGC.

VMware vSphere

VMware vSphere est la plateforme de virtualisation de VMware, qui transforme les data centers en infrastructures informatiques agrégées, incluant les ressources de CPU, de stockage et de réseau. VSphere gère ces infrastructures en tant qu'environnement d'exploitation unifié et fournit aux administrateurs les outils nécessaires pour gérer les data centers participant à cet environnement.

Les deux principaux composants de vSphere sont ESXi et vCenter Server. ESXi est la plateforme de virtualisation sur laquelle les administrateurs créent et exécutent des machines virtuelles et des appliances virtuelles. VCenter Server est le service par l'intermédiaire duquel les administrateurs gèrent plusieurs hôtes connectés dans un réseau et regroupent des ressources hôtes.

NetApp ONTAP

ONTAP 9, la dernière génération de logiciel de gestion du stockage de NetApp, permet aux entreprises de moderniser l'infrastructure et de passer à un data Center prêt pour le cloud. Avec des capacités de gestion des données à la pointe du secteur, ONTAP permet de gérer et de protéger les données avec un seul ensemble d'outils, quel que soit leur emplacement. Vous pouvez aussi déplacer vos données librement partout où elles sont nécessaires : la périphérie, le cœur ou le cloud. ONTAP 9 comprend de nombreuses fonctionnalités qui simplifient la gestion des données, accélèrent et protègent les données stratégiques, et permettent d'utiliser des fonctionnalités d'infrastructure nouvelle génération dans toutes les architectures de cloud hybride.

Gestion simplifiée

La gestion des données est cruciale pour les opérations IT et les data Scientists, de sorte que les ressources appropriées sont utilisées pour les applications d'IA et pour l'entraînement des datasets d'IA/DE ML. Les informations supplémentaires suivantes sur les technologies NetApp ne sont pas incluses dans cette validation, mais elles peuvent être pertinentes en fonction de votre déploiement.

Le logiciel de gestion des données ONTAP comprend les fonctionnalités suivantes pour rationaliser et simplifier les opérations et réduire le coût total d'exploitation :

- Compaction des données à la volée et déduplication étendue La compaction des données réduit le gaspillage d'espace à l'intérieur des blocs de stockage, et la déduplication augmente considérablement la capacité effective. Cela s'applique aux données stockées localement et à leur placement dans le cloud.
- Qualité de service (AQoS) minimale, maximale et adaptative. Les contrôles granulaires de la qualité de service (QoS) permettent de maintenir les niveaux de performance des applications stratégiques dans des environnements hautement partagés.
- NetApp FabricPool Tiering automatique des données inactives vers des options de stockage de cloud

public et privé, notamment Amazon Web Services (AWS), Azure et la solution de stockage NetApp StorageGRID. Pour plus d'informations sur FabricPool, voir "Tr-4598 : meilleures pratiques de FabricPool".

Accélération et protection des données

ONTAP offre des niveaux supérieurs de performances et de protection des données et étend ces fonctionnalités aux méthodes suivantes :

- Des performances élevées et une faible latence. ONTAP offre le débit le plus élevé possible à la latence la plus faible possible.
- Protection des données. ONTAP fournit des fonctionnalités de protection des données intégrées avec une gestion commune sur toutes les plateformes.
- NetApp Volume Encryption (NVE). ONTAP offre un chiffrement natif au niveau du volume avec un support de gestion des clés interne et externe.
- Colocation et authentification multifacteur. ONTAP permet le partage des ressources d'infrastructure avec les plus hauts niveaux de sécurité.

Une infrastructure pérenne

ONTAP permet de répondre aux besoins métier en constante évolution grâce aux fonctionnalités suivantes :

- Évolutivité transparente et opérations non disruptives. ONTAP prend en charge l'ajout non disruptif de capacité aux contrôleurs et l'évolution scale-out des clusters. Les clients peuvent effectuer la mise à niveau vers les technologies les plus récentes, telles que NVMe et FC 32 Gb, sans migration des données ni panne coûteuse.
- Connexion cloud. ONTAP est le logiciel de gestion de stockage le plus connecté au cloud, avec des options de stockage SDS (ONTAP Select) et des instances natives de cloud (NetApp Cloud Volumes Service) dans tous les clouds publics.
- Intégration avec les applications émergentes ONTAP propose des services de données d'entreprise pour les plateformes et applications nouvelle génération, telles que les véhicules autonomes, les Smart cities et Industry 4.0, en utilisant la même infrastructure prenant en charge les applications d'entreprise existantes.

Kit NetApp DataOps

Le kit NetApp DataOps est un outil Python qui simplifie la gestion des espaces de travail de développement/formation et des serveurs d'inférence, lesquels sont basés sur un stockage NetApp haute performance et scale-out. Les fonctionnalités principales comprennent :

- Provisionnez rapidement de nouveaux espaces de travail JupyterLab haute capacité, soutenus par un stockage NetApp haute performance et scale-out.
- Provisionnez rapidement les nouvelles instances NVIDIA Triton Inférence Server, qui sont sauvegardées par un système de stockage NetApp de grande qualité.
- Cloner simultanément des espaces de travail JupyterLab haute capacité afin de permettre des expériences ou une itération rapide.
- Vous pouvez sauvegarder simultanément des snapshots des espaces de travail JupyterLab haute capacité pour la sauvegarde et/ou la traçabilité/l'établissement de base.
- Provisionnement, clonage et snapshot quasi instantanés des volumes de données haute capacité haute performance.

"Ensuite : l'architecture."

Architecture

"Précédent : présentation de la technologie."

Cette solution s'appuie sur une architecture familière et familière avec des systèmes NetApp, VMware et NVIDIA-Certified. Voir le tableau suivant pour plus de détails.

Composant	Détails
Logiciels d'IA et d'analytique	"NVIDIA ai Enterprise pour VMware"
Plateforme de virtualisation	"VMware vSphere"
Plateforme de calcul	"Systèmes certifiés NVIDIA"
Plateforme de gestion de données	"NetApp ONTAP"

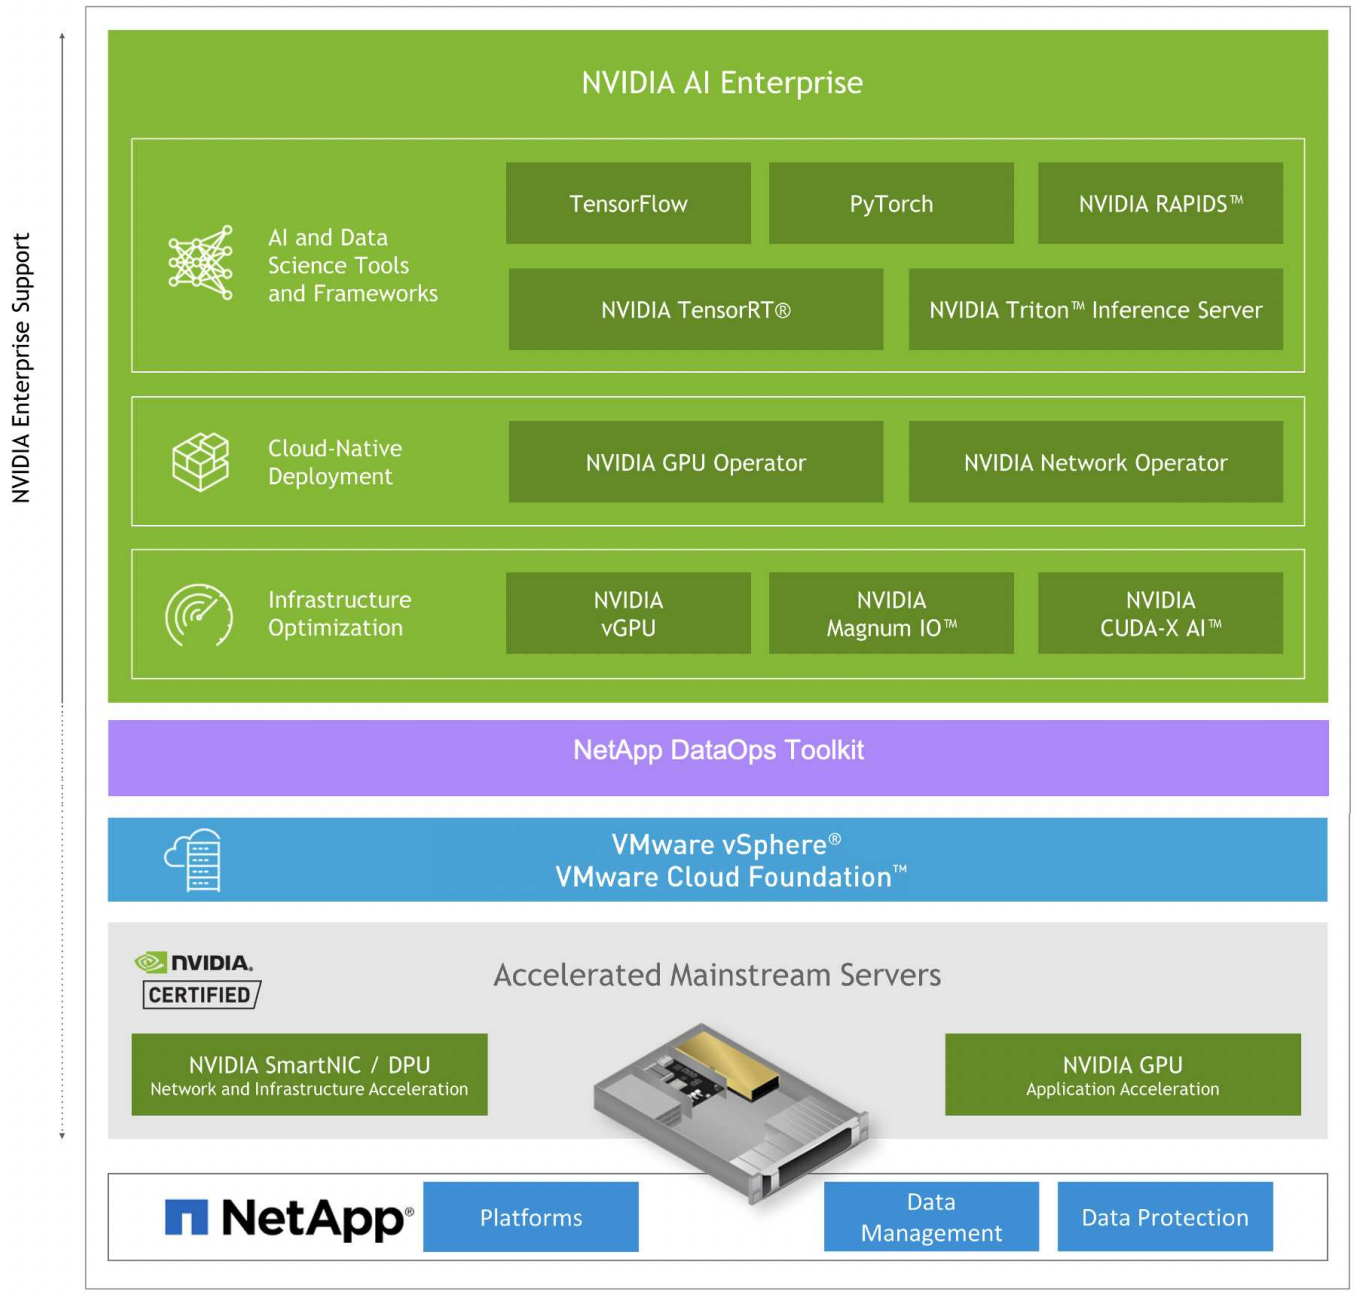

"Suivant : configuration initiale."

Configuration initiale

"Précédent : architecture."

Cette section décrit les tâches de configuration initiales à effectuer afin d'utiliser NVIDIA ai Enterprise avec NetApp et VMware.

Prérequis

Avant d'exécuter les étapes décrites dans cette section, nous supposons que vous avez déjà déployé VMware vSphere et NetApp ONTAP. Reportez-vous à la "Matrice de support des produits NVIDIA ai Enterprise" Pour plus d'informations sur les versions vSphere prises en charge. Reportez-vous à la "Documentation des solutions NetApp et VMware" Pour des informations détaillées sur le déploiement de VMware vSphere avec NetApp ONTAP.

Installez le logiciel hôte NVIDIA ai

Pour installer le logiciel hôte NVIDIA ai Entrprise, suivez les instructions décrites dans les sections 1-4 du "Guide de démarrage rapide de la solution NVIDIA ai Enterprise".

"Suivant : utilisez le logiciel NVIDIA NGC."

Utilisez le logiciel NVIDIA NGC

"Précédent : configuration initiale."

Cette section décrit les tâches à effectuer afin d'utiliser le logiciel NVIDIA NGC d'entreprise dans un environnement NVIDIA ai Enterprise.

"Suivant : Configuration."

Configuration

"Précédent : utilisation du logiciel NVIDIA NGC."

Cette section décrit les tâches de configuration initiales à effectuer pour utiliser le logiciel NVIDIA NGC d'entreprise dans un environnement NVIDIA ai Enterprise.

Prérequis

Avant d'effectuer les étapes décrites dans cette section, nous supposons que vous avez déjà déployé le logiciel hôte d'entrée d'entreprise NVIDIA ai en suivant les instructions du "Configuration initiale" page.

Créez une machine virtuelle Ubuntu Guest avec vGPU

Tout d'abord, vous devez créer une machine virtuelle Ubuntu 20.04 invitée avec vGPU. Pour créer une machine virtuelle invitée Ubuntu 20.04 avec vGPU, suivez les instructions du "Guide de déploiement de NVIDIA ai Enterprise".

Téléchargez et installez le logiciel invité NVIDIA

Vous devez ensuite installer le logiciel invité NVIDIA requis sur la machine virtuelle invitée que vous avez créée à l'étape précédente. Pour télécharger et installer le logiciel NVIDIA invité nécessaire sur la machine

virtuelle invitée, suivez les instructions des sections 5.1-5.4 du "Guide de démarrage rapide de la solution NVIDIA ai Enterprise".

> Lors de l'exécution des tâches de vérification décrites dans la section 5.4, il se peut que vous deviez utiliser une balise de version d'image du conteneur CUDA différente car l'image du conteneur CUDA a été mise à jour depuis l'écriture du guide. Dans notre validation, nous avons utilisé NVIDIA/cuda:11.0.3-base-ubuntu20.04 ».

Télécharger le ou les conteneurs Framework d'IA/d'analytique

Vous devez ensuite télécharger les images de conteneur d'IA ou d'analytique requises depuis NVIDIA NGC afin qu'elles soient disponibles dans votre VM invité. Pour télécharger les conteneurs de structure dans la machine virtuelle invitée, suivez les instructions du "Guide de déploiement de NVIDIA ai Enterprise".

Installez et configurez le kit NetApp DataOps

Vous devez ensuite installer le kit NetApp DataOps Toolkit pour les environnements traditionnels sur la machine virtuelle invitée. Le kit NetApp DataOps permet de gérer les volumes de données scale-out sur votre système ONTAP directement depuis le terminal au sein du serveur virtuel invité. Pour installer le kit NetApp DataOps Toolkit sur la machine virtuelle invitée, effectuez les tâches suivantes.

1. Installer pip.

```
$ sudo apt update
$ sudo apt install python3-pip
$ python3 -m pip install netapp-dataops-traditional
```

2. Déconnectez-vous du terminal de machine virtuelle invité, puis reconnectez-vous.
3. Configuration du kit NetApp DataOps. Pour effectuer cette étape, vous aurez besoin des informations d'accès à l'API pour votre système ONTAP. Vous devrez peut-être les obtenir de votre administrateur du stockage.

```
$ netapp_dataops_cli.py config

Enter ONTAP management LIF hostname or IP address (Recommendation: Use
SVM management interface): 172.22.10.10
Enter SVM (Storage VM) name: NVAIE-client
Enter SVM NFS data LIF hostname or IP address: 172.22.13.151
Enter default volume type to use when creating new volumes
(flexgroup/flexvol) [flexgroup]:
Enter export policy to use by default when creating new volumes
[default]:
Enter snapshot policy to use by default when creating new volumes
[none]:
Enter unix filesystem user id (uid) to apply by default when creating
new volumes (ex. '0' for root user) [0]:
Enter unix filesystem group id (gid) to apply by default when creating
new volumes (ex. '0' for root group) [0]:
Enter unix filesystem permissions to apply by default when creating new
volumes (ex. '0777' for full read/write permissions for all users and
groups) [0777]:
Enter aggregate to use by default when creating new FlexVol volumes:
aff_a400_01_NVME_SSD_1
Enter ONTAP API username (Recommendation: Use SVM account): admin
Enter ONTAP API password (Recommendation: Use SVM account):
Verify SSL certificate when calling ONTAP API (true/false): false
Do you intend to use this toolkit to trigger Cloud Sync operations?
(yes/no): no
Do you intend to use this toolkit to push/pull from S3? (yes/no): no
Created config file: '/home/user/.netapp_dataops/config.json'.
```

Créer un modèle de machine virtuelle invité

Enfin, vous devez créer un modèle de machine virtuelle basé sur la machine virtuelle invitée. Vous pouvez utiliser ce modèle pour créer rapidement des machines virtuelles invitées à utiliser le logiciel NVIDIA NGC.

Pour créer un modèle de machine virtuelle basé sur votre machine virtuelle invitée, connectez-vous à VMware vSphere, cliquez sur le nom de la machine virtuelle invitée, sélectionnez « Cloner », choisissez « Cloner vers modèle… », puis suivez l’assistant.

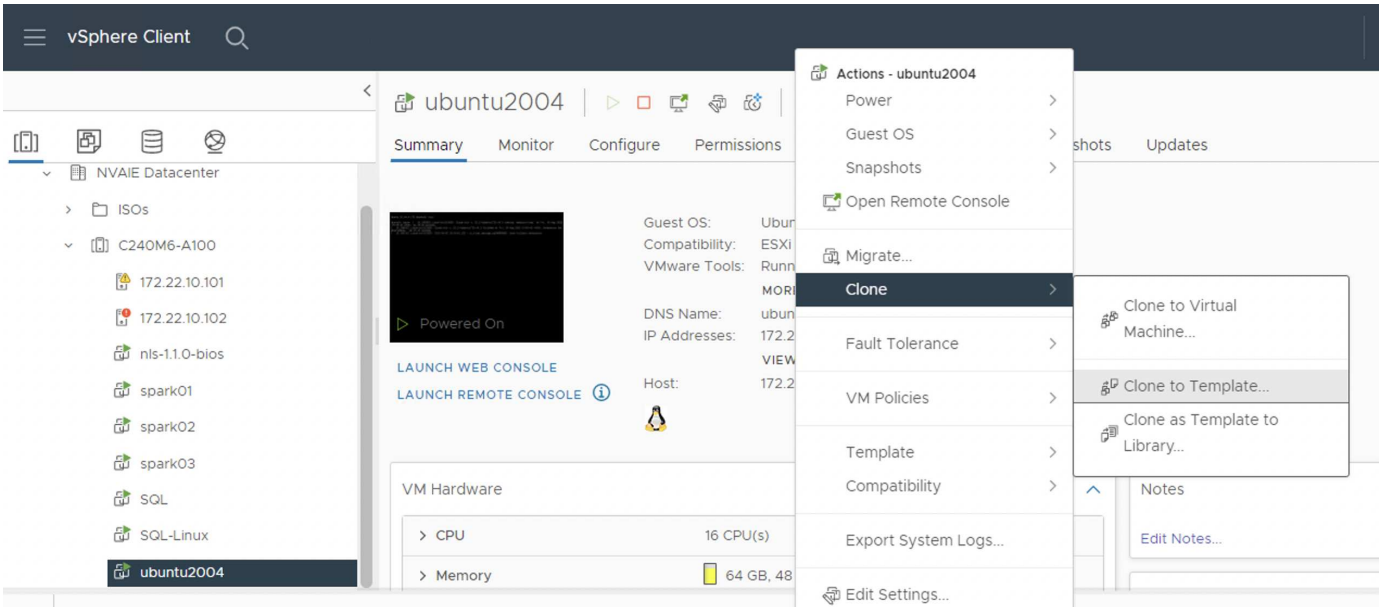

"Suivant : exemple d’utilisation - travail de formation TensorFlow."

Exemple d’utilisation - travail de formation TensorFlow

"Précédent : Configuration."

Cette section décrit les tâches à effectuer pour exécuter un travail d’entraînement TensorFlow dans un environnement NVIDIA d’IA Enterprise.

Prérequis

Avant d’effectuer les étapes décrites dans cette section, nous supposons que vous avez déjà créé un modèle de machine virtuelle invité en suivant les instructions décrites dans le "Configuration" page.

Créer une VM invité à partir d’un modèle

Tout d’abord, vous devez créer une machine virtuelle invitée à partir du modèle que vous avez créé dans la section précédente. Pour créer une nouvelle machine virtuelle invitée à partir de votre modèle, connectez-vous à VMware vSphere, cliquez sur le nom du modèle, choisissez « New VM from this Template… », puis suivez l’assistant.

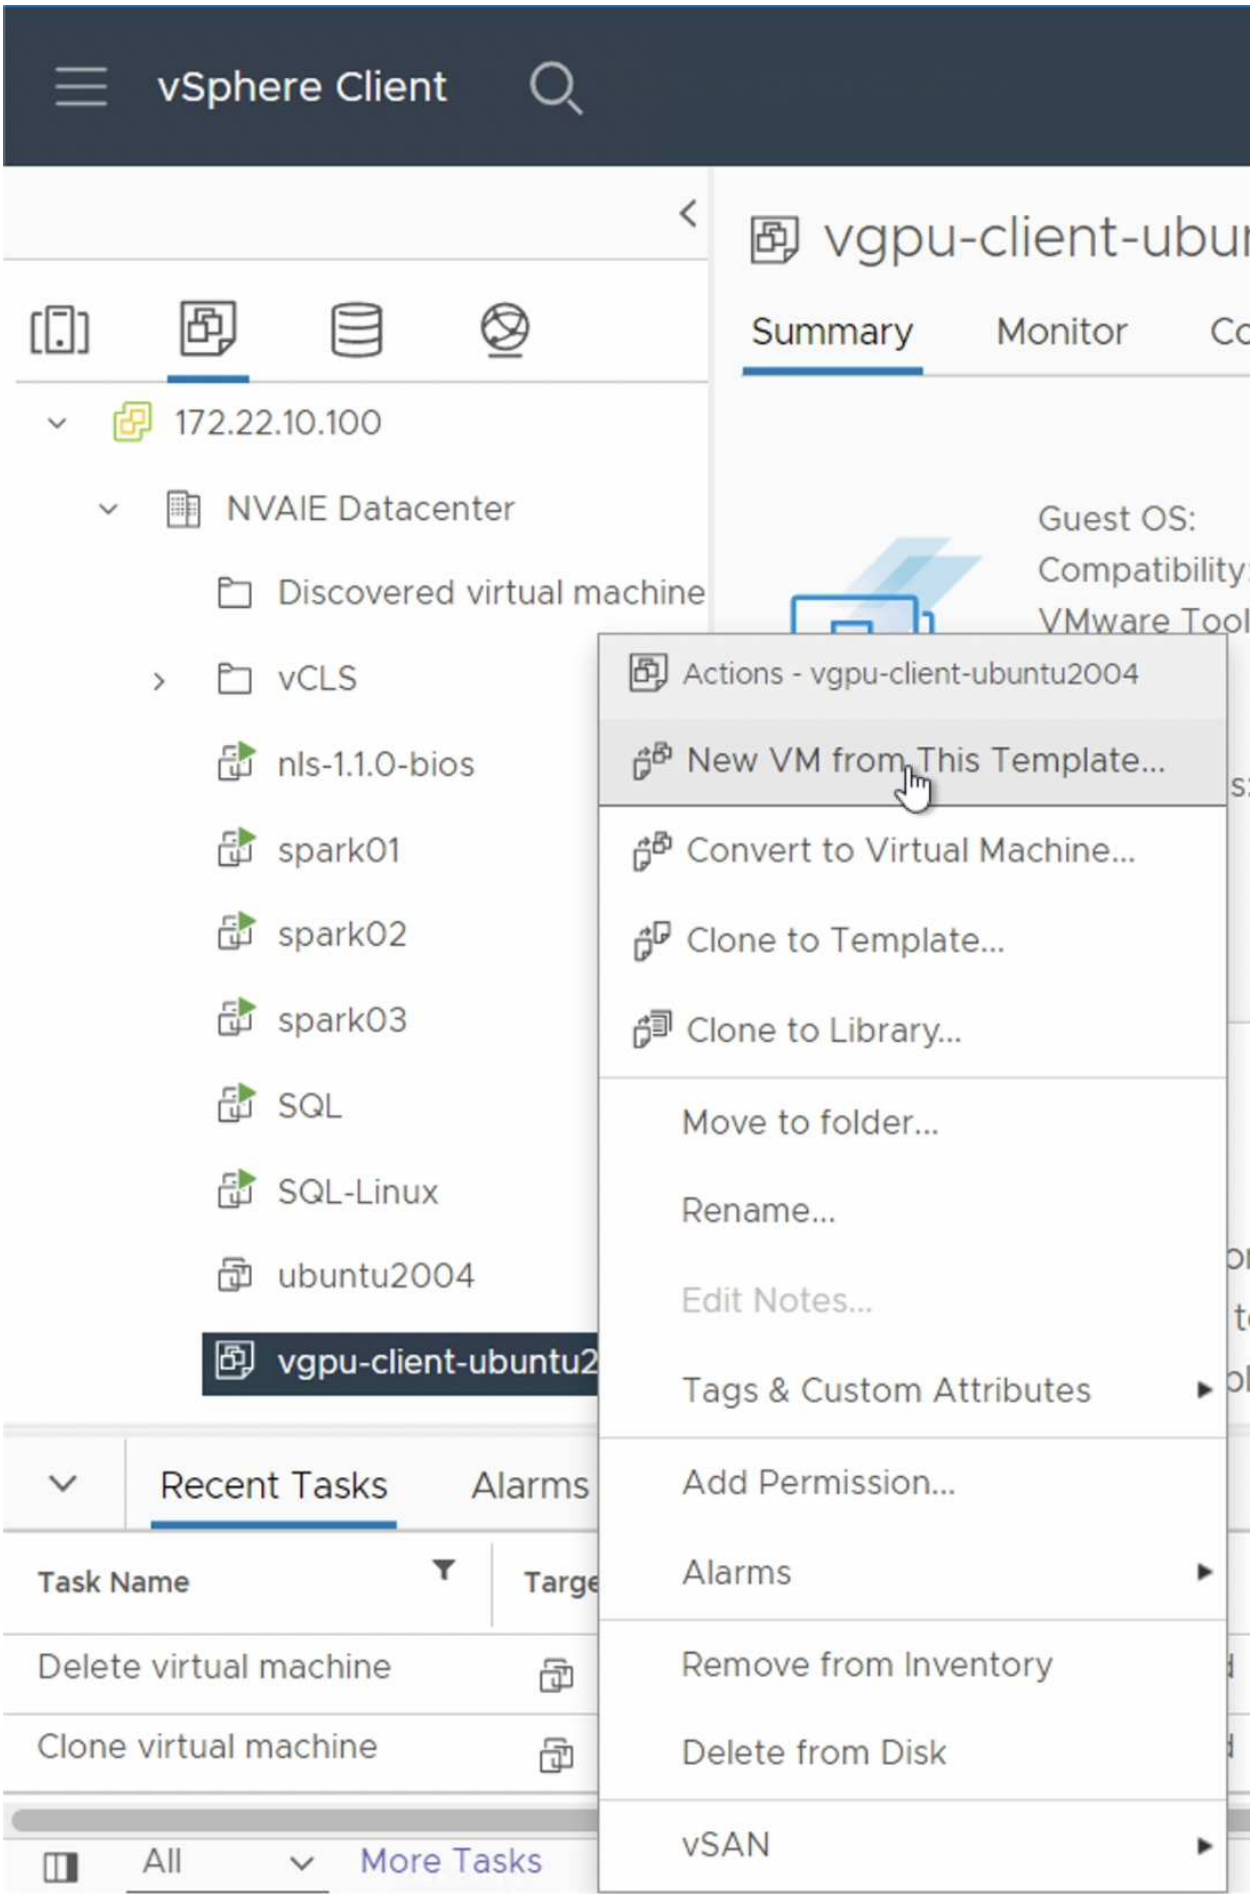
vSphere Client
vgpu-client-ubu
Summary
Monitor
Co
172.22.10.100
NVAIE Datacenter
Discovered virtual machine
vCLS
nls-1.1.0-bios
spark01
spark02
spark03
SQL
SQL-Linux
ubuntu2004
vgpu-client-ubuntu2
Guest OS:
Compatibility:
VMware Tool
Actions - vgpu-client-ubuntu2004
New VM from This Template...
Convert to Virtual Machine...
Clone to Template...
Clone to Library...
Move to folder...
Rename...
Edit Notes...
Tags & Custom Attributes
Add Permission...
Alarms
Remove from Inventory
Delete from Disk
vSAN
Recent Tasks
Alarms
Task Name
Targe
Delete virtual machine
Clone virtual machine
All
More Tasks

Créer et monter un volume de données

Vous devez ensuite créer un nouveau volume de données sur lequel stocker le dataset d'entraînement. Vous pouvez créer rapidement un nouveau volume de données à l'aide du kit NetApp DataOps. L'exemple de commande ci-dessous montre la création d'un volume nommé 'imagenet' d'une capacité de 2 To.

```
$ netapp_dataops_cli.py create vol -n imagenet -s 2TB
```

Avant de pouvoir alimenter le volume de données avec des données, vous devez le monter sur la machine virtuelle invitée. Vous pouvez monter rapidement un volume de données à l'aide du kit NetApp DataOps. L'exemple de commande ci-dessous montre la commande de création du volume à l'étape précédente.

```
$ sudo -E netapp_dataops_cli.py mount vol -n imagenet -m ~/imagenet
```

Remplir le volume de données

Une fois le nouveau volume provisionné et monté, le dataset d'entraînement peut être récupéré à partir de l'emplacement source et placé sur le nouveau volume. Cela implique généralement de extraire les données d'un data Lake S3 ou Hadoop, et parfois d'obtenir de l'aide d'un ingénieur de données.

Exécuter le travail de formation TensorFlow

Vous êtes maintenant prêt à exécuter votre travail de formation TensorFlow. Pour exécuter votre travail de formation TensorFlow, effectuez les tâches suivantes.

1. Tirez l'image du conteneur NVIDIA NGC Enterprise TensorFlow.

   ```
   $ sudo docker pull nvcr.io/nvaie/tensorflow-2-1:22.05-tf1-nvaie-2.1-py3
   ```

2. Lancez une instance du conteneur d'entreprise NVIDIA NGC. Utilisez l'option '-v' pour attacher votre volume de données au conteneur.

   ```
   $ sudo docker run --gpus all -v ~/imagenet:/imagenet -it --rm
   nvcr.io/nvaie/tensorflow-2-1:22.05-tf1-nvaie-2.1-py3
   ```

3. Exécutez votre programme de formation TensorFlow sur le conteneur. L'exemple de commande ci-dessous montre l'exécution d'un exemple de programme d'entraînement ResNet-50 inclus dans l'image conteneur.

   ```
   $ python ./nvidia-examples/cnn/resnet.py --layers 50 -b 64 -i 200 -u
   batch --precision fp16 --data_dir /imagenet/data
   ```

"Suivante : où trouver des informations complémentaires ?"

Sources d'informations complémentaires

"Précédent : exemple d'utilisation - travail de formation TensorFlow."

Pour en savoir plus sur les informations fournies dans ce document, consultez ces documents et/ou sites web :

- Le logiciel de gestion des données NetApp ONTAP : bibliothèque d'informations ONTAP

  http://mysupport.netapp.com/documentation/productlibrary/index.html?productID=62286

- Kit NetApp DataOps

  "https://github.com/NetApp/netapp-dataops-toolkit"

- NVIDIA ai Enterprise avec VMware

  https://www.nvidia.com/en-us/data-center/products/ai-enterprise/vmware/^]

Remerciements

- Bobby Oommen, Sr Responsable, NetApp
- Ramesh Isaac, Administrateur système, NetApp
- Roney Daniel, Ingénieur marketing et technique, NetApp

Tr-4851 : Data Lake NetApp StorageGRID pour les charges de travail de conduite autonome - conception de solution

David Arnette, NetApp

Le rapport TR-4851 démontre l'utilisation du stockage objet NetApp StorageGRID en tant que système de gestion et de référentiel de données pour le développement des logiciels de machine learning (ML) et de deep learning (DL). Ce livre blanc décrit le flux et les exigences de développement logiciel de véhicules autonomes, ainsi que les fonctionnalités StorageGRID qui rationalisent le cycle de vie des données. Cette solution s'applique à tout workflow de pipeline de traitement de données à plusieurs étapes standard dans les processus de développement DU ML et du DL.

https://www.netapp.com/pdf.html?item=/media/19399-tr-4851.pdf

Plan de contrôle d'IA NetApp

Tr-4798 : plan de contrôle pour l'IA de NetApp

Mike Oglesby, NetApp

Toutes les entreprises, quelle que soit leur taille et leurs secteurs, se tournent vers l'intelligence artificielle (IA), le machine learning (ML) et le deep learning (DL) pour résoudre des problèmes concrets, proposer des produits et des services innovants et se démarquer sur un marché de plus en plus concurrentiel. Alors que les entreprises ont de plus en plus recours à l'IA, AU ML et au DL, elles sont confrontées à de nombreux défis, notamment l'évolutivité des workloads et la disponibilité des données. Ce document explique comment relever ces défis en utilisant NetApp ai Control plane, une solution qui associe les fonctionnalités de gestion des données NetApp aux outils et frameworks open source les plus répandus.

Ce rapport vous explique comment cloner rapidement un espace de noms de données. Il vous montre également comment répliquer de manière fluide les données entre plusieurs sites et régions pour créer un pipeline de données d'IA/AM/AP cohérent et unifié. Vous y trouverez également des informations sur la définition et l'implémentation des workflows d'entraînement d'IA, DE ML et de DL pour créer quasi instantanément des données et des modèles de base à des fins de traçabilité et de gestion des versions. Avec cette solution, vous pouvez suivre l'entraînement des modèles jusqu'au dataset exact où on a utilisé pour entraîner et/ou valider le modèle. Enfin, ce document vous montre comment provisionner rapidement des espaces de travail Jupyter Notebook avec accès à des jeux de données volumineux.

Remarque : pour un entraînement distribué de style HPC à grande échelle impliquant un grand nombre de serveurs GPU qui nécessitent un accès partagé au même dataset, ou si vous avez besoin/préférez un système de fichiers parallèle, consultez le document "TR-4890". Ce rapport technique décrit comment inclure "La solution de système de fichiers parallèle entièrement prise en charge par NetApp, BeeGFS" Dans le cadre du plan de contrôle d'IA NetApp. Cette solution est conçue pour s'adapter de quelques systèmes NVIDIA DGX A100 à un superPOD de 140 nœuds.

Le plan de contrôle de l'IA de NetApp est destiné aux data Scientists et aux ingénieurs de données. L'expertise minimale de NetApp ou de NetApp ONTAP® est donc requise. Avec cette solution, les fonctions de gestion des données peuvent être exécutées à l'aide d'outils et d'interfaces simples et familiers. Si votre environnement dispose déjà d'un système de stockage NetApp, vous pouvez tester le plan NetApp ai Control dès aujourd'hui. Si vous souhaitez tester la solution, mais que vous ne disposez pas encore de système de stockage NetApp, rendez-vous sur "cloud.netapp.com", Vous pouvez être opérationnel avec une solution de stockage NetApp dans le cloud en quelques minutes. La figure suivante fournit une visualisation de la solution.

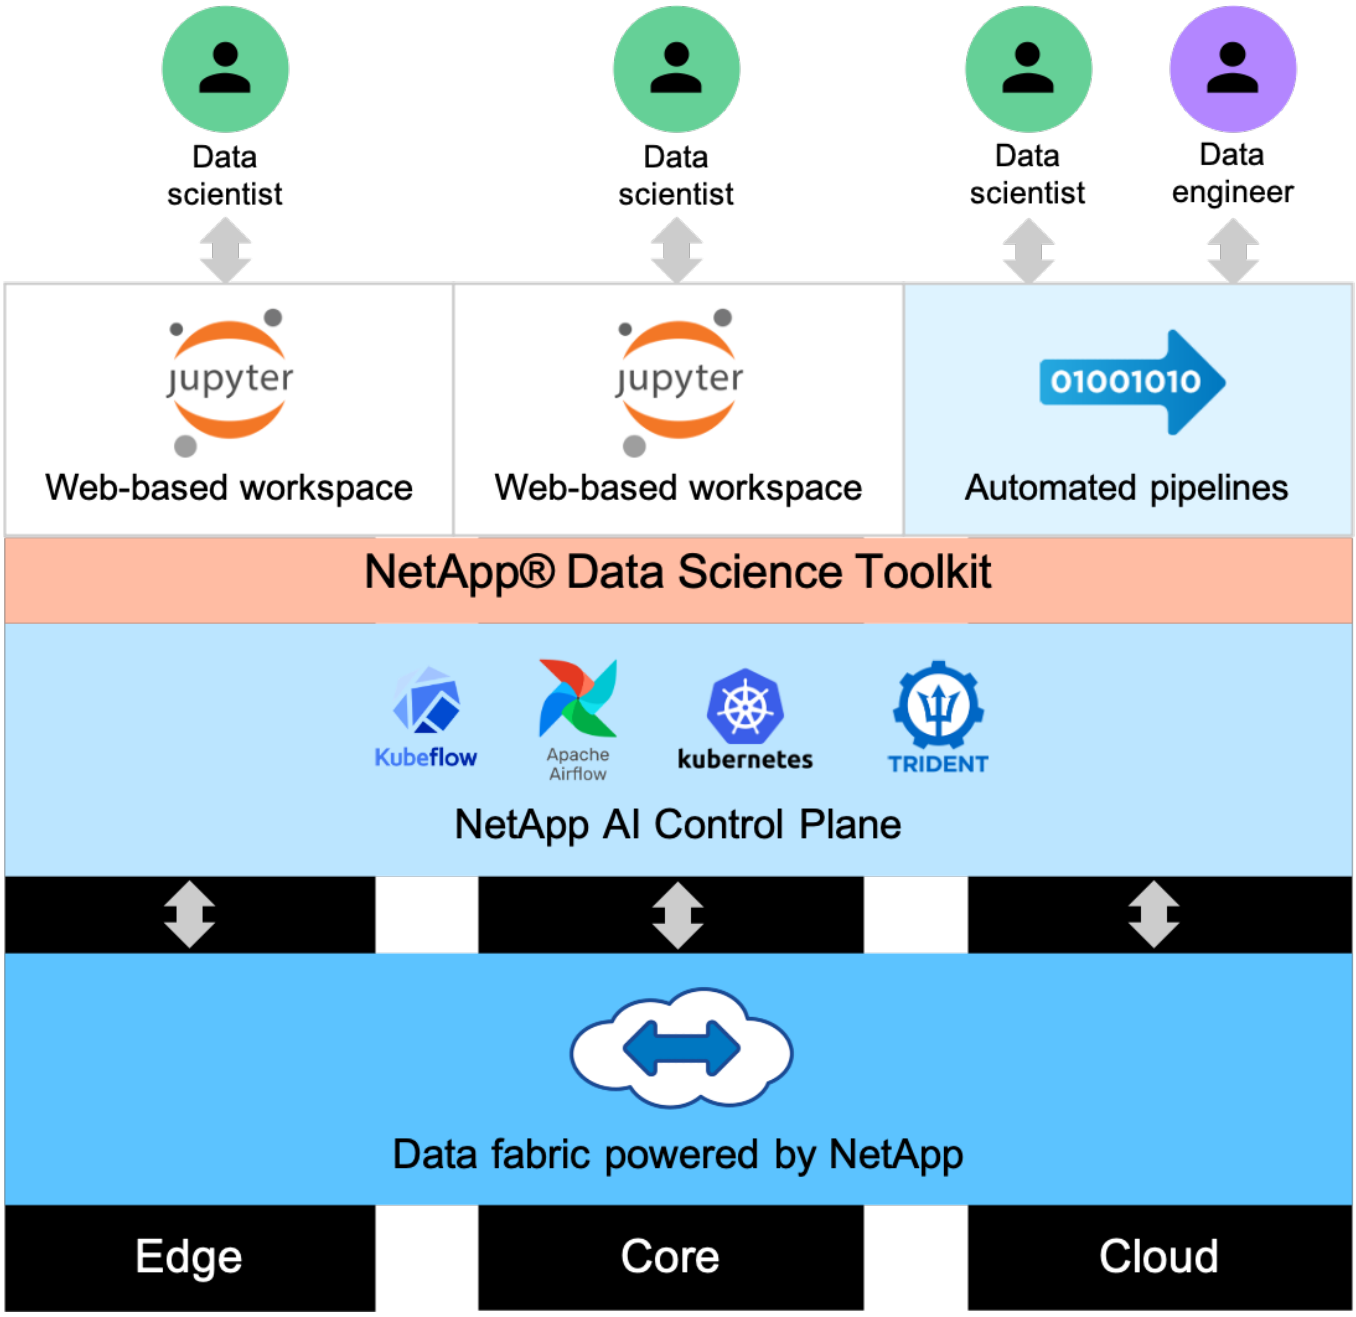

"Suivant : concepts et composants."

Concepts et composants

L'intelligence artificielle

L'IA est une discipline scientifique informatique dans laquelle les ordinateurs sont entraînés pour imiter les fonctions cognitives de l'esprit humain. Les développeurs d'IA entraînent des ordinateurs pour apprendre et résoudre les problèmes de manière similaire, voire supérieure, à celle des humains. L'apprentissage profond et l'apprentissage machine sont des sous-domaines de l'IA. Les entreprises adoptent de plus en plus l'IA, LE ML et le DL pour répondre à leurs besoins stratégiques. Voici quelques exemples :

- Analyser d'importants volumes de données pour obtenir des informations stratégiques inexistantes
- Interagir directement avec les clients à l'aide du traitement du langage naturel

- Automatisation de divers processus et fonctions métier

Les workloads d'entraînement et d'inférence d'IA modernes requièrent des fonctionnalités de calcul parallèle. Par conséquent, les GPU sont de plus en plus utilisés pour exécuter les opérations d'IA, car les capacités de traitement parallèle des GPU sont largement supérieures à celles des processeurs génériques.

Conteneurs

Les conteneurs sont des instances isolées de l'espace utilisateur qui s'exécutent sur un noyau de système d'exploitation hôte partagé. Les conteneurs se généraaffichent de plus en plus rapidement. Les conteneurs offrent bon nombre des avantages de la boxe applicative offerts par les machines virtuelles. Cependant, les couches de l'hyperviseur et du système d'exploitation invité sur lesquelles reposent les machines virtuelles ont été éliminées, les conteneurs sont beaucoup plus légers. La figure suivante montre une visualisation des machines virtuelles par rapport aux conteneurs.

Les conteneurs permettent également de packaging efficace des dépendances entre applications, des durées d'exécution, etc., directement avec une application. Le format de conditionnement de conteneurs le plus utilisé est le container Docker. Une application conteneurisée dans le format de conteneur Docker peut être exécutée sur n'importe quel ordinateur capable d'exécuter des conteneurs Docker. Cela est vrai même si les dépendances de l'application ne sont pas présentes sur la machine car toutes les dépendances sont conditionnées dans le conteneur lui-même. Pour plus d'informations, consultez la "Site Web de Docker".

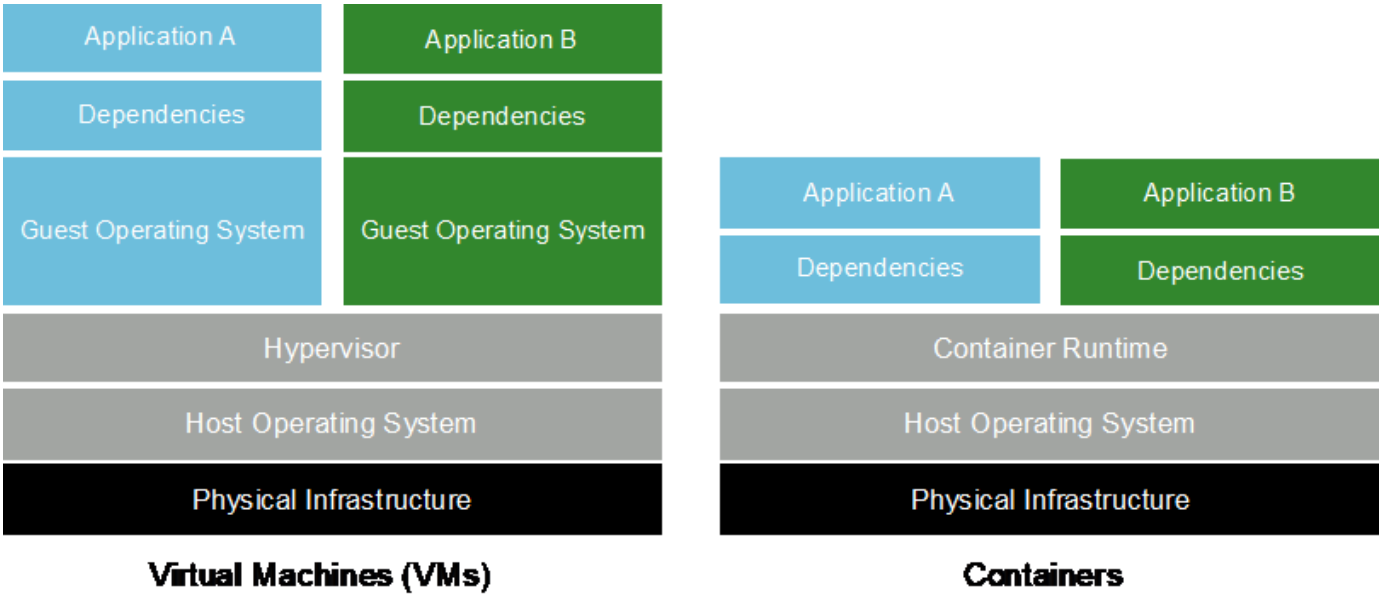

Kubernetes

Kubernetes est une plateforme open source d'orchestration de conteneurs distribuée, conçue à l'origine par Google, et désormais gérée par Cloud Native Computing Foundation (CNCF). Kubernetes permet d'automatiser le déploiement, la gestion et l'évolutivité des fonctions pour les applications conteneurisées. Depuis quelques années, Kubernetes devient la plateforme dominante d'orchestration de conteneurs. Bien que les autres formats de conditionnement et les temps d'exécution des conteneurs soient pris en charge, Kubernetes est le plus souvent utilisé comme système d'orchestration pour les conteneurs Docker. Pour plus d'informations, consultez la "Site Web de Kubernetes".

NetApp Trident

Trident est un orchestrateur de stockage open source développé et géré par NetApp qui simplifie considérablement la création, la gestion et la consommation du stockage persistant pour les workloads

Kubernetes. Trident, une application Kubernetes native, s'exécute directement dans un cluster Kubernetes. Avec Trident, les utilisateurs de Kubernetes (développeurs, data Scientists, administrateurs Kubernetes, etc.) peuvent créer, gérer et interagir avec les volumes de stockage persistant dans le format Kubernetes standard qu'ils connaissent déjà. Ils peuvent également bénéficier des fonctionnalités avancées de gestion des données de NetApp et d'un environnement Data Fabric optimisé par la technologie NetApp. Trident élimine les complexités du stockage persistant et facilite la consommation. Pour plus d'informations, consultez la "Site Web Trident".

NVIDIA DeepOps

DeepOps est un projet open source de NVIDIA qui, grâce à Ansible, automatise le déploiement de clusters de serveurs GPU conformément aux bonnes pratiques. DeepOps est modulaire et peut être utilisé pour diverses tâches de déploiement. Pour ce document et l'exercice de validation décrit, DeepOps est utilisé pour déployer un cluster Kubernetes composé de nœuds workers de serveurs GPU. Pour plus d'informations, consultez la "Site Web de DeepOps".

Kubeflow

Kubeflow est un kit d'IA et DE ML open source pour Kubernetes qui a été développé à l'origine par Google. Le projet Kubeflow permet de déployer des workflows d'IA et DE ML sur Kubernetes de façon simple, portable et évolutive. Kubeflow s'affranchit des complexités de Kubernetes, ce qui permet aux data Scientists de se concentrer sur les meilleures connaissances—data science. Voir la figure suivante pour une visualisation. Kubeflow s'est beaucoup plus à l'mesure que les services IT d'entreprise sont de plus en plus standardisés sur Kubernetes. Pour plus d'informations, consultez la "Site web Kubeflow".

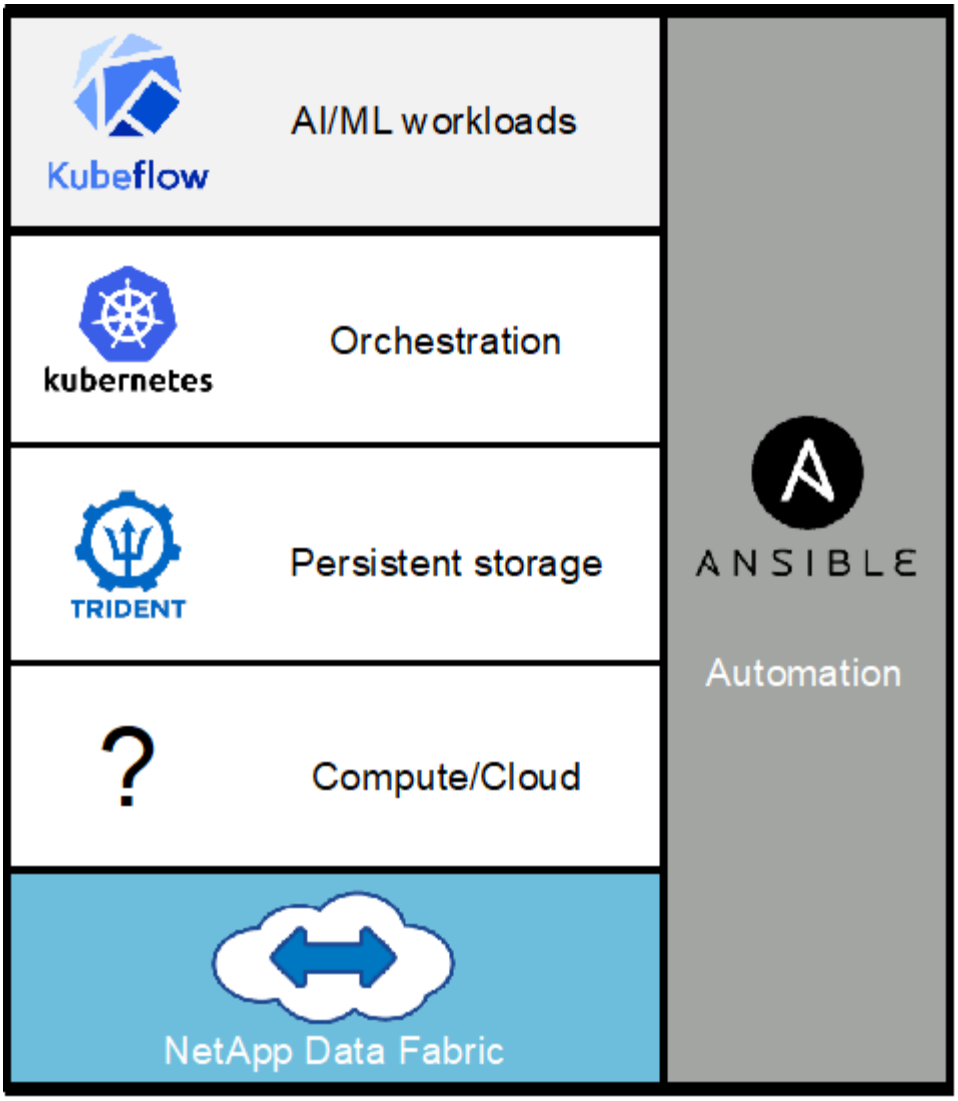

Kubeflow pipelines

Kubeflow pipelines est un composant clé de Kubeflow. Kubeflow pipelines est une plateforme et une norme pour définir et déployer des workflows d'IA et DE ML portables et évolutifs. Pour plus d'informations, reportez-vous à la section "Documentation officielle Kubeflow".

Jupyter Notebook Server

Un Jupyter Notebook Server est une application web open source qui permet aux data Scientists de créer des documents de type wiki appelés ordinateurs portables Jupyter contenant du code en direct ainsi que des tests descriptifs. Les ordinateurs portables Jupyter sont largement utilisés dans la communauté de l'IA et DU ML afin de documenter, de stocker et de partager des projets d'IA et DE ML. Kubeflow simplifie le provisionnement et le déploiement de Jupyter Notebooks Servers sur Kubernetes. Pour plus d'informations sur les ordinateurs portables Jupyter, visitez le "Site Web de Jupyter". Pour plus d'informations sur les ordinateurs portables Jupyter dans le contexte de Kubeflow, consultez le "Documentation officielle Kubeflow".

Débit d'air Apache

Apache Airflow est une plateforme de gestion des flux de production open source qui permet de créer des programmes, de planifier et de surveiller des flux de travail d'entreprise complexes. Il est souvent utilisé pour automatiser les workflows ETL et de pipeline de traitement de données, mais ne se limite pas à ces types de flux de travail. Le projet de flux d'air a été lancé par Airbnb mais est depuis devenu très populaire dans

l'industrie et est maintenant sous les auspices de la Apache Software Foundation. Le flux d'air est écrit en Python, les flux de production du flux d'air sont créés via des scripts Python, et le flux d'air est conçu selon le principe de « configuration as code ». De nombreux utilisateurs de flux d'air utilisent désormais Kubernetes.

Graphes acycliques dirigés (DAG)

Dans le flux d'air, les flux de travail sont appelés graphiques acycliques dirigés (DAG). Les GDAs sont constitués de tâches exécutées dans l'ordre, en parallèle ou une combinaison des deux, en fonction de la définition DAG. Le planificateur de flux d'air exécute des tâches individuelles sur un ensemble de travailleurs, en respectant les dépendances au niveau des tâches spécifiées dans la définition DAG. Les DAG sont définis et créés par le biais de scripts Python.

NetApp ONTAP 9

NetApp ONTAP 9 est la dernière génération de logiciel de gestion du stockage de NetApp qui permet à des entreprises comme la vôtre de moderniser l'infrastructure et de passer à un data Center prêt pour le cloud. Avec des capacités de gestion des données à la pointe du secteur, ONTAP vous permet de gérer et de protéger vos données avec un seul ensemble d'outils, quel que soit leur emplacement. Vous pouvez aussi déplacer vos données librement partout où vous en avez besoin : la périphérie, le cœur ou le cloud. ONTAP 9 comprend de nombreuses fonctionnalités qui simplifient la gestion des données, accélèrent et protègent les données stratégiques et pérennisent l'infrastructure sur toutes les architectures de cloud hybride.

Simplifiez la gestion des données

La gestion des données est cruciale pour les opérations IT, car elle vous permet d'utiliser les ressources appropriées pour vos applications et vos datasets. ONTAP inclut les fonctionnalités suivantes pour rationaliser et simplifier vos opérations et réduire le coût total d'exploitation :

- **La compaction des données à la volée et la déduplication étendue** la compaction des données réduit le gaspillage d'espace dans les blocs de stockage, et la déduplication augmente considérablement la capacité effective.
- **Qualité de service (QoS) minimale, maximale et adaptative.** les contrôles de qualité de service granulaires permettent de maintenir les niveaux de performance des applications critiques dans des environnements hautement partagés.
- **ONTAP FabricPool** cette fonctionnalité permet la hiérarchisation automatique des données inactives vers des options de stockage en cloud public et privé, notamment Amazon Web Services (AWS), Azure et le stockage objet NetApp StorageGRID.

Accélération et protection des données

ONTAP offre des niveaux supérieurs de performances et de protection des données et étend ces fonctionnalités grâce à plusieurs fonctionnalités :

- * Hautes performances et faible latence.* ONTAP offre le débit le plus élevé possible à la latence la plus faible possible.
- **Technologie NetApp ONTAP FlexGroup** Un volume FlexGroup est un conteneur de données haute performance pouvant évoluer de manière linéaire jusqu'à 20 po et 400 milliards de fichiers, fournissant un espace de noms unique qui simplifie la gestion des données.
- **Protection des données.** ONTAP fournit des fonctionnalités de protection des données intégrées avec une gestion commune sur toutes les plates-formes.
- **NetApp Volume Encryption**. ONTAP offre un chiffrement natif au niveau du volume avec prise en charge de la gestion des clés à la fois intégrée et externe.

Une infrastructure pérenne

ONTAP 9 aide à répondre aux besoins métier en constante évolution :

- **Évolutivité transparente et continuité de l'activité.** ONTAP prend en charge l'ajout non disruptif de capacité aux contrôleurs et l'évolution scale-out des clusters. Vous pouvez effectuer la mise à niveau vers les technologies les plus récentes, telles que NVMe et FC 32 Gb, sans migration des données ni panne coûteuse.
- **Connexion au cloud.** ONTAP est l'un des logiciels de gestion de stockage les plus connectés au cloud, avec des options de stockage SDS (ONTAP Select) et des instances natives du cloud (NetApp Cloud Volumes Service) dans tous les clouds publics.
- **Intégration avec les applications émergentes** en utilisant la même infrastructure qui prend en charge les applications d'entreprise existantes, ONTAP propose des services de données haute performance pour les plateformes et applications nouvelle génération, comme OpenStack, Hadoop et MongoDB.

Copies NetApp Snapshot

Une copie NetApp Snapshot est une image ponctuelle en lecture seule d'un volume. La consommation d'espace de stockage de l'image est minime et l'impact sur les performances est négligeable, car elle enregistre uniquement les modifications apportées aux fichiers depuis la dernière copie Snapshot, comme illustré dans la figure ci-dessous.

Les copies Snapshot doivent optimiser leur efficacité par rapport à la technologie de virtualisation de base du stockage ONTAP, WAFL (Write Anywhere File Layout). Tout comme une base de données, WAFL utilise des métadonnées pour désigner des blocs de données réels sur le disque. Contrairement à une base de données, WAFL ne remplace pas les blocs existants. Il écrit les données mises à jour sur un nouveau bloc et modifie les métadonnées. C'est parce que ONTAP référence les métadonnées lorsqu'il crée une copie Snapshot, plutôt que de copier des blocs de données, ces copies sont si efficaces. Vous éliminez ainsi les temps de recherche engendrés par d'autres systèmes pour localiser les blocs à copier, et par ailleurs le coût d'une copie.

Vous pouvez utiliser une copie Snapshot pour restaurer des fichiers ou des LUN individuels, ou pour restaurer l'ensemble du contenu d'un volume. ONTAP compare les informations du pointeur de la copie Snapshot aux données d'un disque pour reconstruire l'objet manquant ou endommagé, sans temps d'indisponibilité ni coûts de performance significatifs.

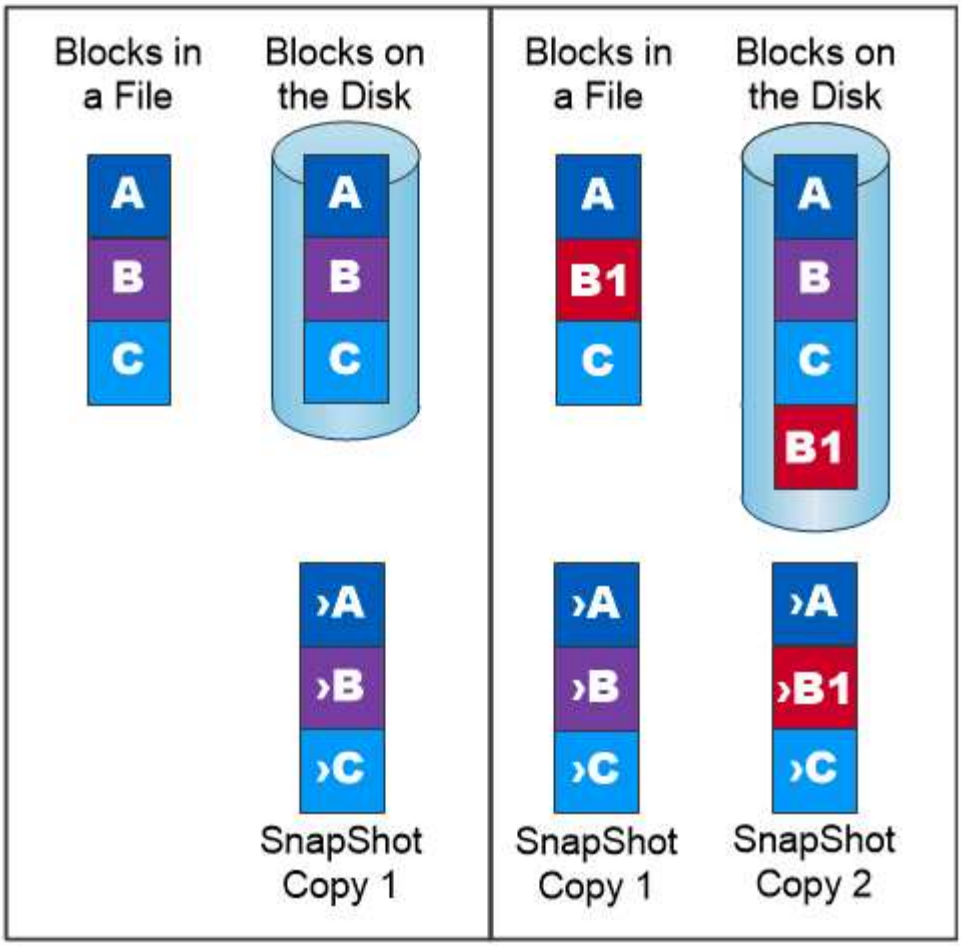

A Snapshot copy records only changes to the active file system since the last Snapshot copy.

Technologie NetApp FlexClone

La technologie NetApp FlexClone référence les métadonnées Snapshot pour créer des copies inscriptibles instantanées d'un volume. Les copies partagent les blocs de données avec leurs parents. Aucun stockage n'est utilisé, sauf pour les métadonnées, jusqu'à ce que les modifications soient écrites sur la copie, comme illustré dans la figure ci-dessous. Là où les copies classiques peuvent prendre des minutes, voire des heures, pour créer des copies, FlexClone vous permet de copier même les jeux de données les plus volumineux quasi instantanément. C'est pourquoi il est idéal si vous avez besoin de plusieurs copies de jeux de données identiques (un espace de travail de développement, par exemple) ou de copies temporaires d'un jeu de données (afin de tester une application par rapport à un jeu de données de production).

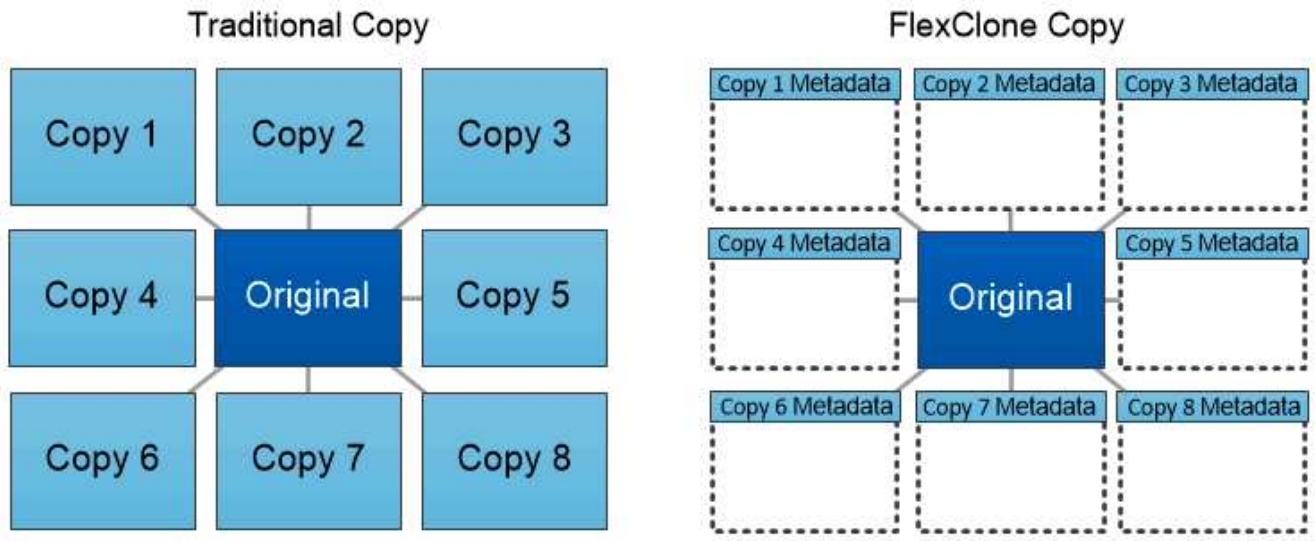

FlexClone copies share data blocks with their parents, consuming no storage except what is required for metadata.

Technologie de réplication des données NetApp SnapMirror

Le logiciel NetApp SnapMirror est une solution de réplication unifiée économique et facile à utiliser dans l'environnement Data Fabric. Il réplique les données à haute vitesse sur un WAN ou un LAN. Elle vous assure haute disponibilité et une réplication rapide des données pour les applications de tous types, y compris les applications stratégiques dans les environnements classiques et virtuels. En répliquant vos données sur un ou plusieurs systèmes de stockage NetApp, puis en les mettant régulièrement à jour, vous disposez de données actualisées et accessibles dès que vous en avez besoin. Aucun serveur de réplication externe n'est requis. Voir la figure suivante pour un exemple d'architecture exploitant la technologie SnapMirror.

Le logiciel SnapMirror valorise l'efficacité du stockage NetApp ONTAP en n'envoyant que les blocs modifiés sur le réseau. Il utilise également la compression réseau intégrée pour accélérer le transfert de données et réduire l'utilisation de la bande passante jusqu'à 70 %. Avec la technologie SnapMirror, vous pouvez exploiter un flux de données de réplication fine pour créer un référentiel unique qui administre les copies du miroir actif et les copies instantanées antérieures, réduisant ainsi le trafic du réseau jusqu'à 50 %.

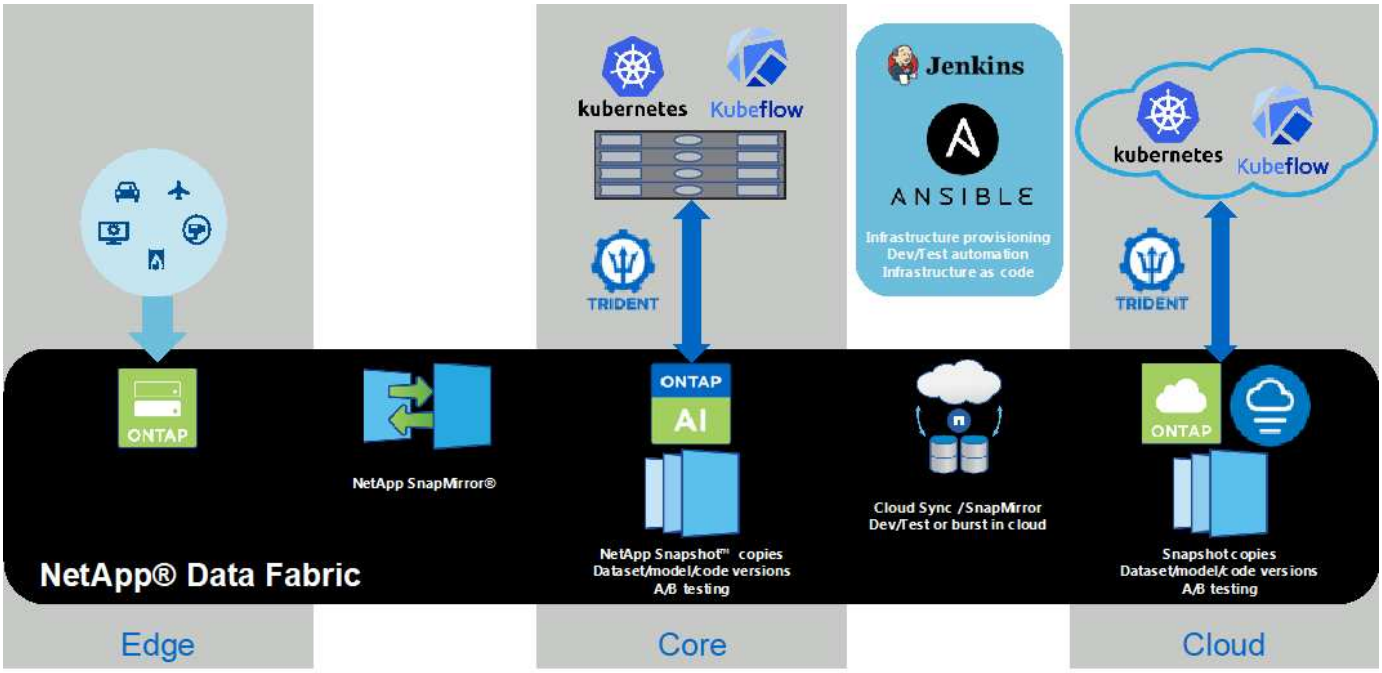

NetApp Cloud Sync

Cloud Sync est un service NetApp qui permet une synchronisation sûre et rapide des données. Qu'il s'agisse de transférer des fichiers entre des partages de fichiers NFS ou SMB sur site, NetApp StorageGRID, NetApp ONTAP S3, NetApp Cloud Volumes Service, Azure NetApp Files, AWS S3, AWS EFS, Azure Blob, Google Cloud Storage ou IBM Cloud Object Storage, Cloud Sync déplace les fichiers là où vous en avez besoin, rapidement et de manière sécurisée.

Une fois vos données transférées, elles peuvent être utilisées à la source et à la cible. Cloud Sync synchronise les données à la demande lorsqu'une mise à jour est déclenchée ou que les données sont continuellement synchronisées en fonction d'un planning prédéfini. Toutefois, Cloud Sync déplace uniquement les données modifiées, le temps et les coûts liés à la réplication des données sont donc réduits.

Cloud Sync est un outil SaaS extrêmement simple à configurer et à utiliser. Les transferts de données déclenchés par Cloud Sync sont effectués par des courtiers de données. Les courtiers de données Cloud Sync peuvent être déployés sur site, sur AWS, Azure, Google Cloud Platform ou sur site.

NetApp XCP

NetApp XCP est un logiciel client pour les migrations de données et les informations relatives au système de fichiers de tout type à NetApp et NetApp à NetApp. XCP a été conçu pour évoluer et atteindre des performances maximales en exploitant toutes les ressources système disponibles pour gérer des datasets à grand volume et des migrations haute performance. XCP vous aide à obtenir une visibilité complète sur le système de fichiers avec la possibilité de générer des rapports.

NetApp XCP est disponible dans un pack unique qui prend en charge les protocoles NFS et SMB. XCP inclut un binaire Linux pour les jeux de données NFS et un exécutable Windows pour les jeux de données SMB.

NetApp XCP File Analytics est un logiciel basé sur l'hôte qui détecte les partages de fichiers, exécute les analyses sur le système de fichiers et fournit un tableau de bord pour l'analytique des fichiers. XCP File Analytics est compatible avec les systèmes NetApp et non NetApp et s'exécute sur des hôtes Linux ou Windows pour fournir des analyses des systèmes de fichiers exportés NFS et SMB.

NetApp ONTAP FlexGroup volumes

Un dataset d'entraînement peut être un ensemble de milliards de fichiers. Les fichiers peuvent inclure du texte, de l'audio, de la vidéo et d'autres formes de données non structurées qui doivent être stockées et traitées pour être lues en parallèle. Le système de stockage doit stocker un grand nombre de petits fichiers et doit lire ces fichiers en parallèle pour les E/S séquentielles et aléatoires

Un volume FlexGroup est un namespace unique qui comprend plusieurs volumes de membres constitutifs, comme illustré dans la figure suivante. Du point de vue de l'administrateur de stockage, un volume FlexGroup est géré et agit comme un volume NetApp FlexVol. Les fichiers du volume FlexGroup sont alloués aux volumes de membres individuels,et non répartis entre les volumes ou les nœuds. Ils présentent de nombreux atouts :

- Les volumes FlexGroup fournissent une capacité de plusieurs pétaoctets et une faible latence prévisible pour les charges de travail comportant un grand nombre de métadonnées.
- Ils prennent en charge jusqu'à 400 milliards de fichiers dans le même namespace.
- Ils prennent en charge les opérations parallélisées dans les charges de travail NAS sur les processeurs, les nœuds, les agrégats et les volumes FlexVol constitutifs.

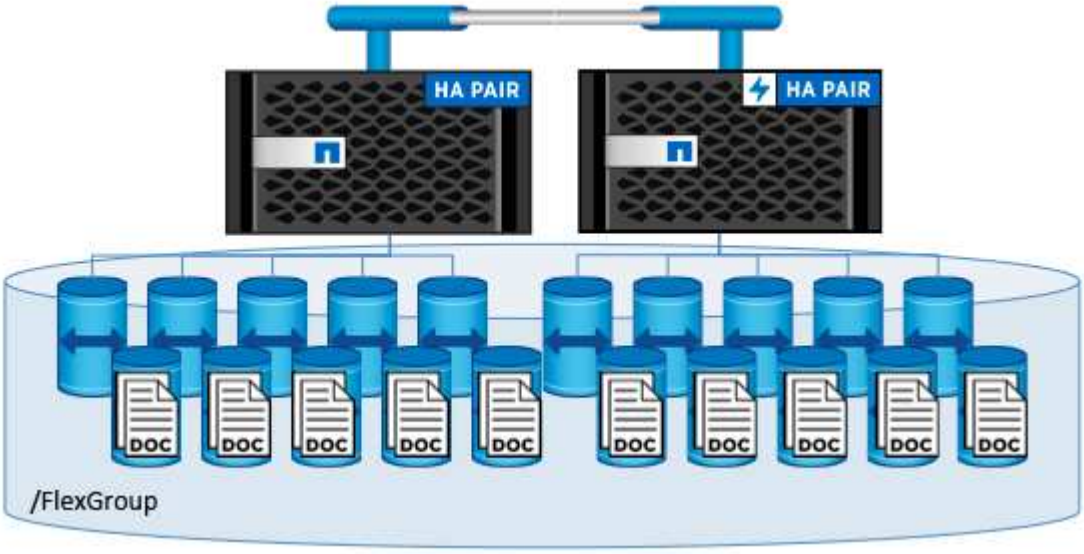

"Suivant : configuration matérielle et logicielle requise."

Configuration matérielle et logicielle requise

La solution NetApp ai Control plane ne dépend pas de ce matériel spécifique. La solution est compatible avec toute appliance de stockage physique, instance Software-defined ou service cloud NetApp, prise en charge par Trident. À titre d'exemple, on peut citer un système de stockage NetApp AFF, Azure NetApp Files, NetApp Cloud Volumes Service, une instance de stockage Software-defined NetApp ONTAP Select ou une instance NetApp Cloud Volumes ONTAP. De plus, la solution peut être implémentée sur n'importe quel cluster Kubernetes, tant que la version Kubernetes utilisée est prise en charge par Kubeflow et NetApp Trident. Pour obtenir la liste des versions Kubernetes prises en charge par Kubeflow, voir la "Documentation officielle Kubeflow". Pour obtenir la liste des versions de Kubernetes prises en charge par Trident, consultez le "Documentation

Trident". Pour plus de détails sur l'environnement utilisé pour valider la solution, reportez-vous aux tableaux suivants.

Composant d'infrastructure	Quantité	Détails	Système d'exploitation
Hôte de démarrage du déploiement	1	VM	Ubuntu 20.04.2 LTS
Nœuds maîtres Kubernetes	1	VM	Ubuntu 20.04.2 LTS
Nœuds workers Kubernetes	2	VM	Ubuntu 20.04.2 LTS
Nœuds workers GPU Kubernetes	2	NVIDIA DGX-1 (bare-Metal)	NVIDIA DGX OS 4.0.5 (basé sur Ubuntu 18.04.2 LTS)
Stockage	1 paire HA	Avec AFF A220	NetApp ONTAP 9.7 P6

Composant logiciel	Version
Débit d'air Apache	2.0.1
Graphique Helm à flux d'air Apache	8.0.8
Docker	19.03.12
Kubeflow	1.2
Kubernetes	1.18.9
NetApp Trident	21.01.2
NVIDIA DeepOps	Fonctionnalité de déploiement Trident depuis la succursale maître à compter de la validation "61898cdfda"; Toutes les autres fonctionnalités de la version 21.03

Assistance

NetApp ne propose pas de support pour les flux d'air Apache, Docker, Kubeflow, Kubernetes ou NVIDIA DeepOps. Si vous souhaitez une solution entièrement prise en charge avec des fonctionnalités similaires à la solution NetApp ai Control plane, "Contactez NetApp" À propos des solutions d'IA/ML entièrement prises en charge que NetApp propose conjointement avec ses partenaires.

"Suivant : déploiement Kubernetes."

Déploiement Kubernetes

Cette section décrit les tâches que vous devez réaliser pour déployer un cluster Kubernetes dans lequel implémenter la solution NetApp ai Control plane. Si vous disposez déjà d'un cluster Kubernetes, vous pouvez ignorer cette section tant que vous exécutez une version de Kubernetes prise en charge par Kubeflow et NetApp Trident. Pour obtenir la liste des versions Kubernetes prises en charge par Kubeflow, voir la

"Documentation officielle Kubeflow". Pour obtenir la liste des versions de Kubernetes prises en charge par Trident, consultez le "Documentation Trident".

Pour les déploiements Kubernetes sur site intégrant des nœuds bare-Metal avec processeurs graphiques NVIDIA, NetApp recommande l'utilisation de l'outil de déploiement DeepOps Kubernetes de NVIDIA. Cette section décrit le déploiement d'un cluster Kubernetes avec DeepOps.

Prérequis

Avant d'effectuer l'exercice de déploiement décrit dans cette section, nous supposons que vous avez déjà effectué les tâches suivantes :

1. Vous avez déjà configuré des nœuds Kubernetes bare-Metal (par exemple, un système NVIDIA DGX qui fait partie d'un pod ONTAP ai) conformément aux instructions de configuration standard.
2. Vous avez installé un système d'exploitation pris en charge sur tous les nœuds maîtres et workers Kubernetes et sur un hôte de démarrage du déploiement. Pour obtenir la liste des systèmes d'exploitation pris en charge par DeepOps, reportez-vous au "Site GitHub DeepOps".

Utilisez NVIDIA DeepOps pour installer et configurer Kubernetes

Pour déployer et configurer votre cluster Kubernetes avec NVIDIA DeepOps, effectuez les tâches suivantes à partir d'un hôte de démarrage du déploiement :

1. Téléchargez NVIDIA DeepOps en suivant les instructions sur le "Page de démarrage" Sur le site GitHub NVIDIA DeepOps.
2. Déployez Kubernetes dans votre cluster en suivant les instructions du "Page Guide de déploiement Kubernetes" Sur le site GitHub NVIDIA DeepOps.

"Ensuite : présentation du déploiement et de la configuration de NetApp Trident."

Déploiement et configuration de NetApp Trident

Cette section décrit les tâches que vous devez effectuer pour installer et configurer NetApp Trident dans votre cluster Kubernetes.

Prérequis

Avant d'effectuer l'exercice de déploiement décrit dans cette section, nous supposons que vous avez déjà effectué les tâches suivantes :

1. Vous disposez déjà d'un cluster Kubernetes opérationnel, et vous exécutez une version de Kubernetes prise en charge par Trident. Pour obtenir la liste des versions prises en charge, reportez-vous à la section "Documentation Trident".
2. Vous disposez déjà d'un dispositif de stockage NetApp, d'une instance Software-defined ou d'un service de stockage cloud, pris en charge par Trident.

Installation de Trident

Pour installer et configurer NetApp Trident dans votre cluster Kubernetes, effectuez les tâches suivantes à partir de l'hôte de démarrage du déploiement :

1. Déployez Trident selon l'une des méthodes suivantes :

- Si vous avez utilisé NVIDIA DeepOps pour déployer votre cluster Kubernetes, vous pouvez également utiliser NVIDIA DeepOps pour déployer Trident dans votre cluster Kubernetes. Pour déployer Trident avec DeepOps, suivez le "Instructions de déploiement de Trident" Sur le site GitHub NVIDIA DeepOps.
- Si vous n'avez pas utilisé NVIDIA DeepOps pour déployer votre cluster Kubernetes ou si vous préférez simplement déployer Trident manuellement, vous pouvez déployer Trident en suivant les instructions du "instructions de déploiement" Dans la documentation Trident. Veillez à créer au moins un système back-end Trident et au moins une classe de stockage Kubernetes pour plus d'informations sur la configuration "Systèmes back-end" et "Les classes de stockage" Consultez les sous-sections liées dans NetApp Docs.

> Si vous déployez la solution NetApp ai Control plane sur un pod ONTAP ai, consultez la "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP" Pour certains exemples de systèmes back-end Trident, vous pouvez créer et "Exemple de Kubernetes Storageclasse pour les déploiements d'IA ONTAP" Vous voudrez peut-être créer des exemples de classes de stockage Kubernetes différentes.

"Ensuite, par exemple, Trident systèmes back-end pour les déploiements d'IA de ONTAP."

Déploiement et configuration de NetApp Trident

Cette section décrit les tâches que vous devez effectuer pour installer et configurer NetApp Trident dans votre cluster Kubernetes.

Prérequis

Avant d'effectuer l'exercice de déploiement décrit dans cette section, nous supposons que vous avez déjà effectué les tâches suivantes :

1. Vous disposez déjà d'un cluster Kubernetes opérationnel, et vous exécutez une version de Kubernetes prise en charge par Trident. Pour obtenir la liste des versions prises en charge, reportez-vous à la section "Documentation Trident".
2. Vous disposez déjà d'un dispositif de stockage NetApp, d'une instance Software-defined ou d'un service de stockage cloud, pris en charge par Trident.

Installation de Trident

Pour installer et configurer NetApp Trident dans votre cluster Kubernetes, effectuez les tâches suivantes à partir de l'hôte de démarrage du déploiement :

1. Déployez Trident selon l'une des méthodes suivantes :
   - Si vous avez utilisé NVIDIA DeepOps pour déployer votre cluster Kubernetes, vous pouvez également utiliser NVIDIA DeepOps pour déployer Trident dans votre cluster Kubernetes. Pour déployer Trident avec DeepOps, suivez le "Instructions de déploiement de Trident" Sur le site GitHub NVIDIA DeepOps.
   - Si vous n'avez pas utilisé NVIDIA DeepOps pour déployer votre cluster Kubernetes ou si vous préférez simplement déployer Trident manuellement, vous pouvez déployer Trident en suivant les instructions du "instructions de déploiement" Dans la documentation Trident. Veillez à créer au moins un système back-end Trident et au moins une classe de stockage Kubernetes pour plus d'informations sur la configuration "Systèmes back-end" et "Les classes de stockage" Consultez les sous-sections liées dans NetApp Docs.

Si vous déployez la solution NetApp ai Control plane sur un pod ONTAP ai, consultez la "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP" Pour certains exemples de systèmes back-end Trident, vous pouvez créer et "Exemple de Kubernetes Storageclasse pour les déploiements d'IA ONTAP" Vous voudrez peut-être créer des exemples de classes de stockage Kubernetes différentes.

"Ensuite, par exemple, Trident systèmes back-end pour les déploiements d'IA de ONTAP."

Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP

Avant de pouvoir utiliser Trident pour provisionner dynamiquement les ressources de stockage dans votre cluster Kubernetes, vous devez créer un ou plusieurs systèmes back-end Trident. Les exemples suivants représentent différents types de systèmes back-end que vous pouvez créer si vous déployez la solution NetApp ai Control plane sur un pod ONTAP ai. Pour plus d'informations sur les systèmes back-end, reportez-vous au "Documentation Trident".

1. NetApp recommande de créer un système back-end Trident compatible avec FlexGroup pour chaque LIF de données (interface réseau logique offrant un accès aux données) que vous souhaitez utiliser sur votre système NetApp AFF. Vous pourrez ainsi équilibrer les montages de volumes entre les LIF

   Les exemples de commandes ci-dessous montrent la création de deux backends Trident compatibles avec FlexGroup pour deux LIF de données différentes associées à un même SVM (Storage Virtual machine) ONTAP. Ces extrémités arrière utilisent le `ontap-nas-flexgroup` pilote de stockage ONTAP prend en charge deux principaux types de volumes de données : FlexVol et FlexGroup. La taille des volumes FlexVol est limitée (à compter de cette écriture, la taille maximale dépend du déploiement spécifique). Au contraire, les volumes FlexGroup peuvent évoluer de manière linéaire jusqu'à 20 po et 400 milliards de fichiers, fournissant un espace de nom unique qui simplifie considérablement la gestion des données. Par conséquent, les volumes FlexGroup sont optimaux pour les workloads d'IA et DE ML qui s'appuient sur des quantités importantes de données.

   Si vous travaillez avec un volume de données réduit et que vous souhaitez utiliser des volumes FlexVol plutôt que des volumes FlexGroup, vous pouvez créer des systèmes back-end Trident qui utilisent le `ontap-nas` pilote de stockage au lieu du `ontap-nas-flexgroup` pilote de stockage

```
$ cat << EOF > ./trident-backend-ontap-ai-flexgroups-iface1.json
{
    "version": 1,
    "storageDriverName": "ontap-nas-flexgroup",
    "backendName": "ontap-ai-flexgroups-iface1",
    "managementLIF": "10.61.218.100",
    "dataLIF": "192.168.11.11",
    "svm": "ontapai_nfs",
    "username": "admin",
    "password": "ontapai"
}
EOF
$ tridentctl create backend -f ./trident-backend-ontap-ai-flexgroups-
iface1.json -n trident
```

```
+----------------------------+---------------------
+--------------------------------------+--------+---------+
|            NAME            |   STORAGE DRIVER    |
UUID                 | STATE  | VOLUMES |
+----------------------------+---------------------
+--------------------------------------+--------+---------+
| ontap-ai-flexgroups-iface1 | ontap-nas-flexgroup | b74cbddb-e0b8-40b7-
b263-b6da6dec0bdd | online |       0 |
+----------------------------+---------------------
+--------------------------------------+--------+---------+
$ cat << EOF > ./trident-backend-ontap-ai-flexgroups-iface2.json
{
    "version": 1,
    "storageDriverName": "ontap-nas-flexgroup",
    "backendName": "ontap-ai-flexgroups-iface2",
    "managementLIF": "10.61.218.100",
    "dataLIF": "192.168.12.12",
    "svm": "ontapai_nfs",
    "username": "admin",
    "password": "ontapai"
}
EOF
$ tridentctl create backend -f ./trident-backend-ontap-ai-flexgroups-
iface2.json -n trident
+----------------------------+---------------------
+--------------------------------------+--------+---------+
|            NAME            |   STORAGE DRIVER    |
UUID                 | STATE  | VOLUMES |
+----------------------------+---------------------
+--------------------------------------+--------+---------+
| ontap-ai-flexgroups-iface2 | ontap-nas-flexgroup | 61814d48-c770-436b-
9cb4-cf7ee661274d | online |       0 |
+----------------------------+---------------------
+--------------------------------------+--------+---------+
$ tridentctl get backend -n trident
+----------------------------+---------------------
+--------------------------------------+--------+---------+
|            NAME            |   STORAGE DRIVER    |
UUID                 | STATE  | VOLUMES |
+----------------------------+---------------------
+--------------------------------------+--------+---------+
| ontap-ai-flexgroups-iface1 | ontap-nas-flexgroup | b74cbddb-e0b8-40b7-
b263-b6da6dec0bdd | online |       0 |
| ontap-ai-flexgroups-iface2 | ontap-nas-flexgroup | 61814d48-c770-436b-
9cb4-cf7ee661274d | online |       0 |
+----------------------------+---------------------
```

```
+-------------------------------------+---------+----------+
```

2. NetApp recommande également de créer un ou plusieurs systèmes back-end Trident compatibles avec FlexVol. Si vous utilisez les volumes FlexGroup pour le stockage des jeux de données d'entraînement, vous pouvez utiliser les volumes FlexVol pour stocker les résultats, les résultats, les informations de débogage, etc. Si vous souhaitez utiliser des volumes FlexVol, vous devez créer un ou plusieurs systèmes back-end Trident compatibles avec FlexVol. Les exemples de commandes ci-dessous montrent la création d'un système back-end Trident compatible avec FlexVol utilisant un seul LIF de données.

```
$ cat << EOF > ./trident-backend-ontap-ai-flexvols.json
{
    "version": 1,
    "storageDriverName": "ontap-nas",
    "backendName": "ontap-ai-flexvols",
    "managementLIF": "10.61.218.100",
    "dataLIF": "192.168.11.11",
    "svm": "ontapai_nfs",
    "username": "admin",
    "password": "ontapai"
}
EOF
$ tridentctl create backend -f ./trident-backend-ontap-ai-flexvols.json -n
trident
+----------------------------+--------------------
+--------------------------------------+--------+---------+
|            NAME            |   STORAGE DRIVER    |                 UUID
| STATE  | VOLUMES |
+----------------------------+--------------------
+--------------------------------------+--------+---------+
| ontap-ai-flexvols          | ontap-nas           | 52bdb3b1-13a5-4513-
a9c1-52a69657fabe | online |       0 |
+----------------------------+--------------------
+--------------------------------------+--------+---------+
$ tridentctl get backend -n trident
+----------------------------+--------------------
+--------------------------------------+--------+---------+
|            NAME            |   STORAGE DRIVER    |                 UUID
| STATE  | VOLUMES |
+----------------------------+--------------------
+--------------------------------------+--------+---------+
| ontap-ai-flexvols          | ontap-nas           | 52bdb3b1-13a5-4513-
a9c1-52a69657fabe | online |       0 |
| ontap-ai-flexgroups-iface1 | ontap-nas-flexgroup | b74cbddb-e0b8-40b7-
b263-b6da6dec0bdd | online |       0 |
| ontap-ai-flexgroups-iface2 | ontap-nas-flexgroup | 61814d48-c770-436b-
9cb4-cf7ee661274d | online |       0 |
+----------------------------+--------------------
+--------------------------------------+--------+---------+
```

"Ensuite, exemple de stockage Kubernetes Storageclasses pour les déploiements d'IA ONTAP."

Exemple de classes de stockage Kubernetes pour les déploiements d'IA ONTAP

Avant de pouvoir utiliser Trident pour provisionner les ressources de stockage de façon

dynamique dans votre cluster Kubernetes, vous devez créer une ou plusieurs classes de stockage Kubernetes. Les exemples ci-dessous représentent les différents types de classes de stockage que vous pourriez souhaiter créer si vous déployez la solution NetApp ai Control plane sur un pod ONTAP ai. Pour plus d'informations sur les classes de stockage, consultez le "Documentation Trident".

1. NetApp recommande de créer une classe de stockage distincte pour chaque système back-end Trident compatible avec FlexGroup que vous avez créé dans la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 1. Ces classes de stockage granulaire vous permettent d'ajouter des montages NFS qui correspondent à des LIF spécifiques (les LIF que vous avez spécifiées lors de la création des backends Trident) en tant que système back-end spécifique spécifié dans le fichier des spécifications de classe de stockage. Les exemples de commandes qui suivent montrent la création de deux classes de stockage qui correspondent aux deux exemples de backends créés dans la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 1. Pour plus d'informations sur les classes de stockage, consultez le "Documentation Trident".

   Pour qu'un volume persistant ne soit pas supprimé lorsque la demande de volume persistant correspondante est supprimée, l'exemple suivant utilise une `reclaimPolicy` valeur de `Retain`. Pour plus d'informations sur le `reclaimPolicy` consultez le champ officiel "Documentation Kubernetes".

```
$ cat << EOF > ./storage-class-ontap-ai-flexgroups-retain-iface1.yaml
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: ontap-ai-flexgroups-retain-iface1
provisioner: netapp.io/trident
parameters:
  backendType: "ontap-nas-flexgroup"
  storagePools: "ontap-ai-flexgroups-iface1:.*"
reclaimPolicy: Retain
EOF
$ kubectl create -f ./storage-class-ontap-ai-flexgroups-retain-
iface1.yaml
storageclass.storage.k8s.io/ontap-ai-flexgroups-retain-iface1 created
$ cat << EOF > ./storage-class-ontap-ai-flexgroups-retain-iface2.yaml
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: ontap-ai-flexgroups-retain-iface2
provisioner: netapp.io/trident
parameters:
  backendType: "ontap-nas-flexgroup"
  storagePools: "ontap-ai-flexgroups-iface2:.*"
reclaimPolicy: Retain
EOF
$ kubectl create -f ./storage-class-ontap-ai-flexgroups-retain-
iface2.yaml
storageclass.storage.k8s.io/ontap-ai-flexgroups-retain-iface2 created
$ kubectl get storageclass
NAME                                PROVISIONER         AGE
ontap-ai-flexgroups-retain-iface1   netapp.io/trident   0m
ontap-ai-flexgroups-retain-iface2   netapp.io/trident   0m
```

2. NetApp recommande également de créer une classe de stockage correspondant au système back-end Trident activé pour FlexVol que vous avez créé dans la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 2. Les exemples de commandes ci-dessous montrent la création d'une classe de stockage unique pour les volumes FlexVol.

   Dans l'exemple suivant, un système back-end particulier n'est pas spécifié dans le fichier de définition StorageClass car un seul système back-end Trident activé pour FlexVol a été créé. Lorsque vous utilisez Kubernetes pour administrer des volumes qui utilisent cette classe de stockage, Trident tente d'utiliser tout back-end disponible qui utilise le `ontap-nas` conducteur.

```
$ cat << EOF > ./storage-class-ontap-ai-flexvols-retain.yaml
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: ontap-ai-flexvols-retain
provisioner: netapp.io/trident
parameters:
  backendType: "ontap-nas"
reclaimPolicy: Retain
EOF
$ kubectl create -f ./storage-class-ontap-ai-flexvols-retain.yaml
storageclass.storage.k8s.io/ontap-ai-flexvols-retain created
$ kubectl get storageclass
NAME                                PROVISIONER         AGE
ontap-ai-flexgroups-retain-iface1   netapp.io/trident   1m
ontap-ai-flexgroups-retain-iface2   netapp.io/trident   1m
ontap-ai-flexvols-retain            netapp.io/trident   0m
```

3. NetApp recommande également de créer une classe de stockage générique pour les volumes FlexGroup. Les exemples de commandes suivants montrent la création d'une classe de stockage générique pour les volumes FlexGroup.

   Notez qu'un back-end particulier n'est pas spécifié dans le fichier de définition de classe de stockage. Par conséquent, lorsque vous utilisez Kubernetes pour gérer des volumes qui utilisent cette classe de stockage, Trident tente d'utiliser tout back-end disponible qui utilise le `ontap-nas-flexgroup` conducteur.

```
$ cat << EOF > ./storage-class-ontap-ai-flexgroups-retain.yaml
apiVersion: storage.k8s.io/v1
kind: StorageClass
metadata:
  name: ontap-ai-flexgroups-retain
provisioner: netapp.io/trident
parameters:
  backendType: "ontap-nas-flexgroup"
reclaimPolicy: Retain
EOF
$ kubectl create -f ./storage-class-ontap-ai-flexgroups-retain.yaml
storageclass.storage.k8s.io/ontap-ai-flexgroups-retain created
$ kubectl get storageclass
NAME                                PROVISIONER         AGE
ontap-ai-flexgroups-retain          netapp.io/trident   0m
ontap-ai-flexgroups-retain-iface1   netapp.io/trident   2m
ontap-ai-flexgroups-retain-iface2   netapp.io/trident   2m
ontap-ai-flexvols-retain            netapp.io/trident   1m
```

"Next : présentation du déploiement Kubeflow."

Déploiement Kubeflow

Cette section décrit les tâches à effectuer pour déployer Kubeflow dans votre cluster Kubernetes.

Prérequis

Avant d'effectuer l'exercice de déploiement décrit dans cette section, nous supposons que vous avez déjà effectué les tâches suivantes :

1. Vous disposez déjà d'un cluster Kubernetes opérationnel, et vous exécutez une version de Kubernetes prise en charge par Kubeflow. Pour obtenir la liste des versions prises en charge, reportez-vous à la section "Documentation officielle Kubeflow".
2. Vous avez déjà installé et configuré NetApp Trident dans votre cluster Kubernetes, comme indiqué dans la "Déploiement et configuration de Trident".

Définissez la classe de stockage Kubernetes par défaut

Avant de déployer Kubeflow, vous devez désigner une classe de stockage par défaut dans votre cluster Kubernetes. Le processus de déploiement Kubeflow tente de provisionner de nouveaux volumes persistants à l'aide de la classe de stockage par défaut. Si aucune classe de stockage n'est désignée comme classe de stockage par défaut, le déploiement échoue. Pour désigner une classe de stockage par défaut dans votre cluster, effectuez la tâche suivante à partir de l'hôte de démarrage du déploiement. Si vous avez déjà désigné une classe de stockage par défaut dans votre cluster, vous pouvez ignorer cette étape.

1. Désignez une des classes de stockage existantes comme classe de stockage par défaut. Les exemples de commandes ci-dessous montrent la désignation d'une classe de stockage nommée `ontap-ai-`

`flexvols-retain` Comme classe de stockage par défaut.

> Le `ontap-nas-flexgroup` Le type de volume interne Trident a une taille de volume persistant minimale et est relativement élevée. Par défaut, Kubeflow tente de provisionner des demandes de volume qui n'ont que quelques Go. Par conséquent, vous ne devez pas désigner une classe de stockage utilisant le `ontap-nas-flexgroup` Taper back-end comme classe de stockage par défaut pour le déploiement Kubeflow.

```
$ kubectl get sc
NAME                                  PROVISIONER             AGE
ontap-ai-flexgroups-retain            csi.trident.netapp.io   25h
ontap-ai-flexgroups-retain-iface1     csi.trident.netapp.io   25h
ontap-ai-flexgroups-retain-iface2     csi.trident.netapp.io   25h
ontap-ai-flexvols-retain              csi.trident.netapp.io   3s
$ kubectl patch storageclass ontap-ai-flexvols-retain -p '{"metadata":
{"annotations":{"storageclass.kubernetes.io/is-default-class":"true"}}}'
storageclass.storage.k8s.io/ontap-ai-flexvols-retain patched
$ kubectl get sc
NAME                                   PROVISIONER             AGE
ontap-ai-flexgroups-retain             csi.trident.netapp.io   25h
ontap-ai-flexgroups-retain-iface1      csi.trident.netapp.io   25h
ontap-ai-flexgroups-retain-iface2      csi.trident.netapp.io   25h
ontap-ai-flexvols-retain (default)     csi.trident.netapp.io   54s
```

Utilisez NVIDIA DeepOps pour déployer Kubeflow

NetApp recommande d'utiliser l'outil de déploiement Kubeflow qui est fourni par NVIDIA DeepOps. Pour déployer Kubeflow dans votre cluster Kubernetes à l'aide de l'outil de déploiement DeepOps, effectuez les tâches suivantes à partir de l'hôte de démarrage du déploiement.

> Vous pouvez également déployer Kubeflow manuellement en suivant les options "instructions d'installation" Dans la documentation officielle Kubeflow

1. Déployez Kubeflow dans votre cluster en suivant les options "Instructions de déploiement Kubeflow" Sur le site GitHub NVIDIA DeepOps.
2. Notez l'URL du tableau de bord Kubeflow que fournit l'outil de déploiement DeepOps Kubeflow.

```
$ ./scripts/k8s/deploy_kubeflow.sh -x
…
INFO[0007] Applied the configuration Successfully!
filename="cmd/apply.go:72"
Kubeflow app installed to: /home/ai/kubeflow
It may take several minutes for all services to start. Run 'kubectl get
pods -n kubeflow' to verify
To remove (excluding CRDs, istio, auth, and cert-manager), run:
./scripts/k8s_deploy_kubeflow.sh -d
To perform a full uninstall : ./scripts/k8s_deploy_kubeflow.sh -D
Kubeflow Dashboard (HTTP NodePort): http://10.61.188.111:31380
```

3. Vérifier que tous les pods déployés dans l'espace de noms Kubeflow affichent un `STATUS` de `Running` et assurez-vous qu'aucun composant déployé dans le namespace n'est à l'état d'erreur. Le démarrage des modules peut prendre plusieurs minutes.

```
$ kubectl get all -n kubeflow
NAME                                                              READY
STATUS    RESTARTS   AGE
pod/admission-webhook-bootstrap-stateful-set-0                    1/1
Running   0          95s
pod/admission-webhook-deployment-6b89c84c98-vrtbh                 1/1
Running   0          91s
pod/application-controller-stateful-set-0                         1/1
Running   0          98s
pod/argo-ui-5dcf5d8b4f-m2wn4                                      1/1
Running   0          97s
pod/centraldashboard-cf4874ddc-7hcr8                              1/1
Running   0          97s
pod/jupyter-web-app-deployment-685b455447-gjhh7                   1/1
Running   0          96s
pod/katib-controller-88c97d85c-kgq66                              1/1
Running   1          95s
pod/katib-db-8598468fd8-5jw2c                                     1/1
Running   0          95s
pod/katib-manager-574c8c67f9-wtrf5                                1/1
Running   1          95s
pod/katib-manager-rest-778857c989-fjbzn                           1/1
Running   0          95s
pod/katib-suggestion-bayesianoptimization-65df4d7455-qthmw        1/1
Running   0          94s
pod/katib-suggestion-grid-56bf69f597-98vwn                        1/1
Running   0          94s
pod/katib-suggestion-hyperband-7777b76cb9-9v6dq                   1/1
Running   0          93s
```

```
pod/katib-suggestion-nasrl-77f6f9458c-2qzxq                    1/1
Running   0          93s
pod/katib-suggestion-random-77b88b5c79-l64j9                   1/1
Running   0          93s
pod/katib-ui-7587c5b967-nd629                                  1/1
Running   0          95s
pod/metacontroller-0                                           1/1
Running   0          96s
pod/metadata-db-5dd459cc-swzkm                                 1/1
Running   0          94s
pod/metadata-deployment-6cf77db994-69fk7                       1/1
Running   3          93s
pod/metadata-deployment-6cf77db994-mpbjt                       1/1
Running   3          93s
pod/metadata-deployment-6cf77db994-xg7tz                       1/1
Running   3          94s
pod/metadata-ui-78f5b59b56-qb6kr                               1/1
Running   0          94s
pod/minio-758b769d67-llvdr                                     1/1
Running   0          91s
pod/ml-pipeline-5875b9db95-g8t2k                               1/1
Running   0          91s
pod/ml-pipeline-persistenceagent-9b69ddd46-bt9r9               1/1
Running   0          90s
pod/ml-pipeline-scheduledworkflow-7b8d756c76-7x56s             1/1
Running   0          90s
pod/ml-pipeline-ui-79ffd9c76-fcwpd                             1/1
Running   0          90s
pod/ml-pipeline-viewer-controller-deployment-5fdc87f58-b2t9r   1/1
Running   0          90s
pod/mysql-657f87857d-l5k9z                                     1/1
Running   0          91s
pod/notebook-controller-deployment-56b4f59bbf-8bvnr            1/1
Running   0          92s
pod/profiles-deployment-6bc745947-mrdkh                        2/2
Running   0          90s
pod/pytorch-operator-77c97f4879-hmlrv                          1/1
Running   0          92s
pod/seldon-operator-controller-manager-0                       1/1
Running   1          91s
pod/spartakus-volunteer-5fdfddb779-l7qkm                       1/1
Running   0          92s
pod/tensorboard-6544748d94-nh8b2                               1/1
Running   0          92s
pod/tf-job-dashboard-56f79c59dd-6w59t                          1/1
Running   0          92s
```

```
pod/tf-job-operator-79cbfd6dbc-rb58c                          1/1
Running   0          91s
pod/workflow-controller-db644d554-cwrnb                       1/1
Running   0          97s
NAME                                                     TYPE
CLUSTER-IP      EXTERNAL-IP   PORT(S)              AGE
service/admission-webhook-service                        ClusterIP
10.233.51.169   <none>        443/TCP              97s
service/application-controller-service                   ClusterIP
10.233.4.54     <none>        443/TCP              98s
service/argo-ui                                          NodePort
10.233.47.191   <none>        80:31799/TCP         97s
service/centraldashboard                                 ClusterIP
10.233.8.36     <none>        80/TCP               97s
service/jupyter-web-app-service                          ClusterIP
10.233.1.42     <none>        80/TCP               97s
service/katib-controller                                 ClusterIP
10.233.25.226   <none>        443/TCP              96s
service/katib-db                                         ClusterIP
10.233.33.151   <none>        3306/TCP             97s
service/katib-manager                                    ClusterIP
10.233.46.239   <none>        6789/TCP             96s
service/katib-manager-rest                               ClusterIP
10.233.55.32    <none>        80/TCP               96s
service/katib-suggestion-bayesianoptimization            ClusterIP
10.233.49.191   <none>        6789/TCP             95s
service/katib-suggestion-grid                            ClusterIP
10.233.9.105    <none>        6789/TCP             95s
service/katib-suggestion-hyperband                       ClusterIP
10.233.22.2     <none>        6789/TCP             95s
service/katib-suggestion-nasrl                           ClusterIP
10.233.63.73    <none>        6789/TCP             95s
service/katib-suggestion-random                          ClusterIP
10.233.57.210   <none>        6789/TCP             95s
service/katib-ui                                         ClusterIP
10.233.6.116    <none>        80/TCP               96s
service/metadata-db                                      ClusterIP
10.233.31.2     <none>        3306/TCP             96s
service/metadata-service                                 ClusterIP
10.233.27.104   <none>        8080/TCP             96s
service/metadata-ui                                      ClusterIP
10.233.57.177   <none>        80/TCP               96s
service/minio-service                                    ClusterIP
10.233.44.90    <none>        9000/TCP             94s
service/ml-pipeline                                      ClusterIP
10.233.41.201   <none>        8888/TCP,8887/TCP    94s
```

```
service/ml-pipeline-tensorboard-ui                   ClusterIP
10.233.36.207   <none>        80/TCP              93s
service/ml-pipeline-ui                               ClusterIP
10.233.61.150   <none>        80/TCP              93s
service/mysql                                        ClusterIP
10.233.55.117   <none>        3306/TCP            94s
service/notebook-controller-service                  ClusterIP
10.233.10.166   <none>        443/TCP             95s
service/profiles-kfam                                ClusterIP
10.233.33.79    <none>        8081/TCP            92s
service/pytorch-operator                             ClusterIP
10.233.37.112   <none>        8443/TCP            95s
service/seldon-operator-controller-manager-service   ClusterIP
10.233.30.178   <none>        443/TCP             92s
service/tensorboard                                  ClusterIP
10.233.58.151   <none>        9000/TCP            94s
service/tf-job-dashboard                             ClusterIP
10.233.4.17     <none>        80/TCP              94s
service/tf-job-operator                              ClusterIP
10.233.60.32    <none>        8443/TCP            94s
service/webhook-server-service                       ClusterIP
10.233.32.167   <none>        443/TCP             87s
NAME                                                      READY   UP-
TO-DATE   AVAILABLE   AGE
deployment.apps/admission-webhook-deployment              1/1     1
1           97s
deployment.apps/argo-ui                                   1/1     1
1           97s
deployment.apps/centraldashboard                          1/1     1
1           97s
deployment.apps/jupyter-web-app-deployment                1/1     1
1           97s
deployment.apps/katib-controller                          1/1     1
1           96s
deployment.apps/katib-db                                  1/1     1
1           97s
deployment.apps/katib-manager                             1/1     1
1           96s
deployment.apps/katib-manager-rest                        1/1     1
1           96s
deployment.apps/katib-suggestion-bayesianoptimization     1/1     1
1           95s
deployment.apps/katib-suggestion-grid                     1/1     1
1           95s
deployment.apps/katib-suggestion-hyperband                1/1     1
1           95s
```

```
deployment.apps/katib-suggestion-nasrl                     1/1     1
1           95s
deployment.apps/katib-suggestion-random                    1/1     1
1           95s
deployment.apps/katib-ui                                   1/1     1
1           96s
deployment.apps/metadata-db                                1/1     1
1           96s
deployment.apps/metadata-deployment                        3/3     3
3           96s
deployment.apps/metadata-ui                                1/1     1
1           96s
deployment.apps/minio                                      1/1     1
1           94s
deployment.apps/ml-pipeline                                1/1     1
1           94s
deployment.apps/ml-pipeline-persistenceagent               1/1     1
1           93s
deployment.apps/ml-pipeline-scheduledworkflow              1/1     1
1           93s
deployment.apps/ml-pipeline-ui                             1/1     1
1           93s
deployment.apps/ml-pipeline-viewer-controller-deployment   1/1     1
1           93s
deployment.apps/mysql                                      1/1     1
1           94s
deployment.apps/notebook-controller-deployment             1/1     1
1           95s
deployment.apps/profiles-deployment                        1/1     1
1           92s
deployment.apps/pytorch-operator                           1/1     1
1           95s
deployment.apps/spartakus-volunteer                        1/1     1
1           94s
deployment.apps/tensorboard                                1/1     1
1           94s
deployment.apps/tf-job-dashboard                           1/1     1
1           94s
deployment.apps/tf-job-operator                            1/1     1
1           94s
deployment.apps/workflow-controller                        1/1     1
1           97s
NAME
DESIRED   CURRENT   READY   AGE
replicaset.apps/admission-webhook-deployment-6b89c84c98              1
1         1       97s
```

```
replicaset.apps/argo-ui-5dcf5d8b4f                                  1
1         1       97s
replicaset.apps/centraldashboard-cf4874ddc                          1
1         1       97s
replicaset.apps/jupyter-web-app-deployment-685b455447               1
1         1       97s
replicaset.apps/katib-controller-88c97d85c                          1
1         1       96s
replicaset.apps/katib-db-8598468fd8                                 1
1         1       97s
replicaset.apps/katib-manager-574c8c67f9                            1
1         1       96s
replicaset.apps/katib-manager-rest-778857c989                       1
1         1       96s
replicaset.apps/katib-suggestion-bayesianoptimization-65df4d7455    1
1         1       95s
replicaset.apps/katib-suggestion-grid-56bf69f597                    1
1         1       95s
replicaset.apps/katib-suggestion-hyperband-7777b76cb9               1
1         1       95s
replicaset.apps/katib-suggestion-nasrl-77f6f9458c                   1
1         1       95s
replicaset.apps/katib-suggestion-random-77b88b5c79                  1
1         1       95s
replicaset.apps/katib-ui-7587c5b967                                 1
1         1       96s
replicaset.apps/metadata-db-5dd459cc                                1
1         1       96s
replicaset.apps/metadata-deployment-6cf77db994                      3
3         3       96s
replicaset.apps/metadata-ui-78f5b59b56                              1
1         1       96s
replicaset.apps/minio-758b769d67                                    1
1         1       93s
replicaset.apps/ml-pipeline-5875b9db95                              1
1         1       93s
replicaset.apps/ml-pipeline-persistenceagent-9b69ddd46              1
1         1       92s
replicaset.apps/ml-pipeline-scheduledworkflow-7b8d756c76            1
1         1       91s
replicaset.apps/ml-pipeline-ui-79ffd9c76                            1
1         1       91s
replicaset.apps/ml-pipeline-viewer-controller-deployment-5fdc87f58  1
1         1       91s
replicaset.apps/mysql-657f87857d                                    1
1         1       92s
```

```
replicaset.apps/notebook-controller-deployment-56b4f59bbf            1
1         1       94s
replicaset.apps/profiles-deployment-6bc745947                        1
1         1       91s
replicaset.apps/pytorch-operator-77c97f4879                          1
1         1       94s
replicaset.apps/spartakus-volunteer-5fdfddb779                       1
1         1       94s
replicaset.apps/tensorboard-6544748d94                               1
1         1       93s
replicaset.apps/tf-job-dashboard-56f79c59dd                          1
1         1       93s
replicaset.apps/tf-job-operator-79cbfd6dbc                           1
1         1       93s
replicaset.apps/workflow-controller-db644d554                        1
1         1       97s
NAME                                                        READY   AGE
statefulset.apps/admission-webhook-bootstrap-stateful-set   1/1     97s
statefulset.apps/application-controller-stateful-set        1/1     98s
statefulset.apps/metacontroller                             1/1     98s
statefulset.apps/seldon-operator-controller-manager         1/1     92s
$ kubectl get pvc -n kubeflow
NAME             STATUS   VOLUME
CAPACITY   ACCESS MODES   STORAGECLASS               AGE
katib-mysql      Bound    pvc-b07f293e-d028-11e9-9b9d-00505681a82d
10Gi       RWO            ontap-ai-flexvols-retain   27m
metadata-mysql   Bound    pvc-b0f3f032-d028-11e9-9b9d-00505681a82d
10Gi       RWO            ontap-ai-flexvols-retain   27m
minio-pv-claim   Bound    pvc-b22727ee-d028-11e9-9b9d-00505681a82d
20Gi       RWO            ontap-ai-flexvols-retain   27m
mysql-pv-claim   Bound    pvc-b2429afd-d028-11e9-9b9d-00505681a82d
20Gi       RWO            ontap-ai-flexvols-retain   27m
```

4. Dans votre navigateur web, accédez au tableau de bord central Kubeflow en accédant à l'URL que vous avez notée à l'étape 2.

   Le nom d'utilisateur par défaut est `admin@kubeflow.org`, et le mot de passe par défaut est `12341234`. Pour créer d'autres utilisateurs, suivez les instructions de la section "Documentation officielle Kubeflow".

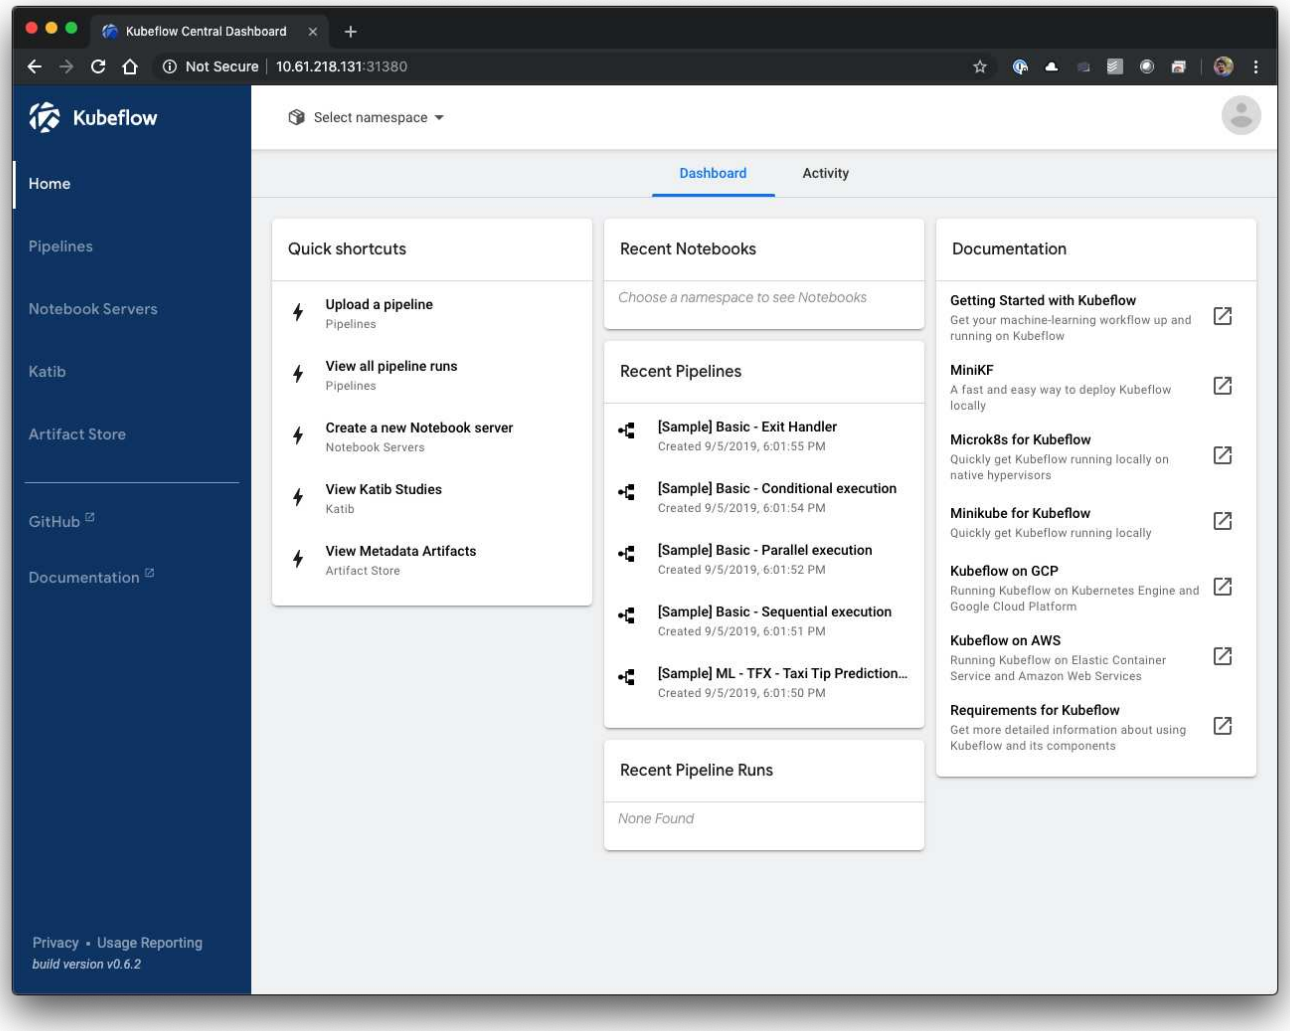

"Ensuite, exemple Kubeflow Operations and Tasks."

Exemple d'opérations et de tâches Kubeflow

Cette section fournit des exemples de diverses opérations et tâches que vous pouvez exécuter avec Kubeflow.

"Suivant : Provision a Jupyter Notebook Workspace for Data Scientist ou Developer Use."

Exemple d'opérations et de tâches Kubeflow

Cette section fournit des exemples de diverses opérations et tâches que vous pouvez exécuter avec Kubeflow.

"Suivant : Provision a Jupyter Notebook Workspace for Data Scientist ou Developer Use."

Provisionner un espace de travail Jupyter Notebook pour un usage Data Scientist ou Developer

Kubeflow est capable de provisionner rapidement de nouveaux serveurs Jupyter Notebook pour agir en tant qu'espaces de travail de data Scientist. Pour provisionner un nouveau serveur Jupyter Notebook avec

Kubeflow, effectuez les tâches suivantes. Pour plus d'informations sur les ordinateurs portables Jupyter dans le contexte Kubeflow, reportez-vous au "Documentation officielle Kubeflow".

1. Dans le tableau de bord central Kubeflow, cliquez sur serveurs portables dans le menu principal pour accéder à la page d'administration des serveurs Jupyter Notebook.

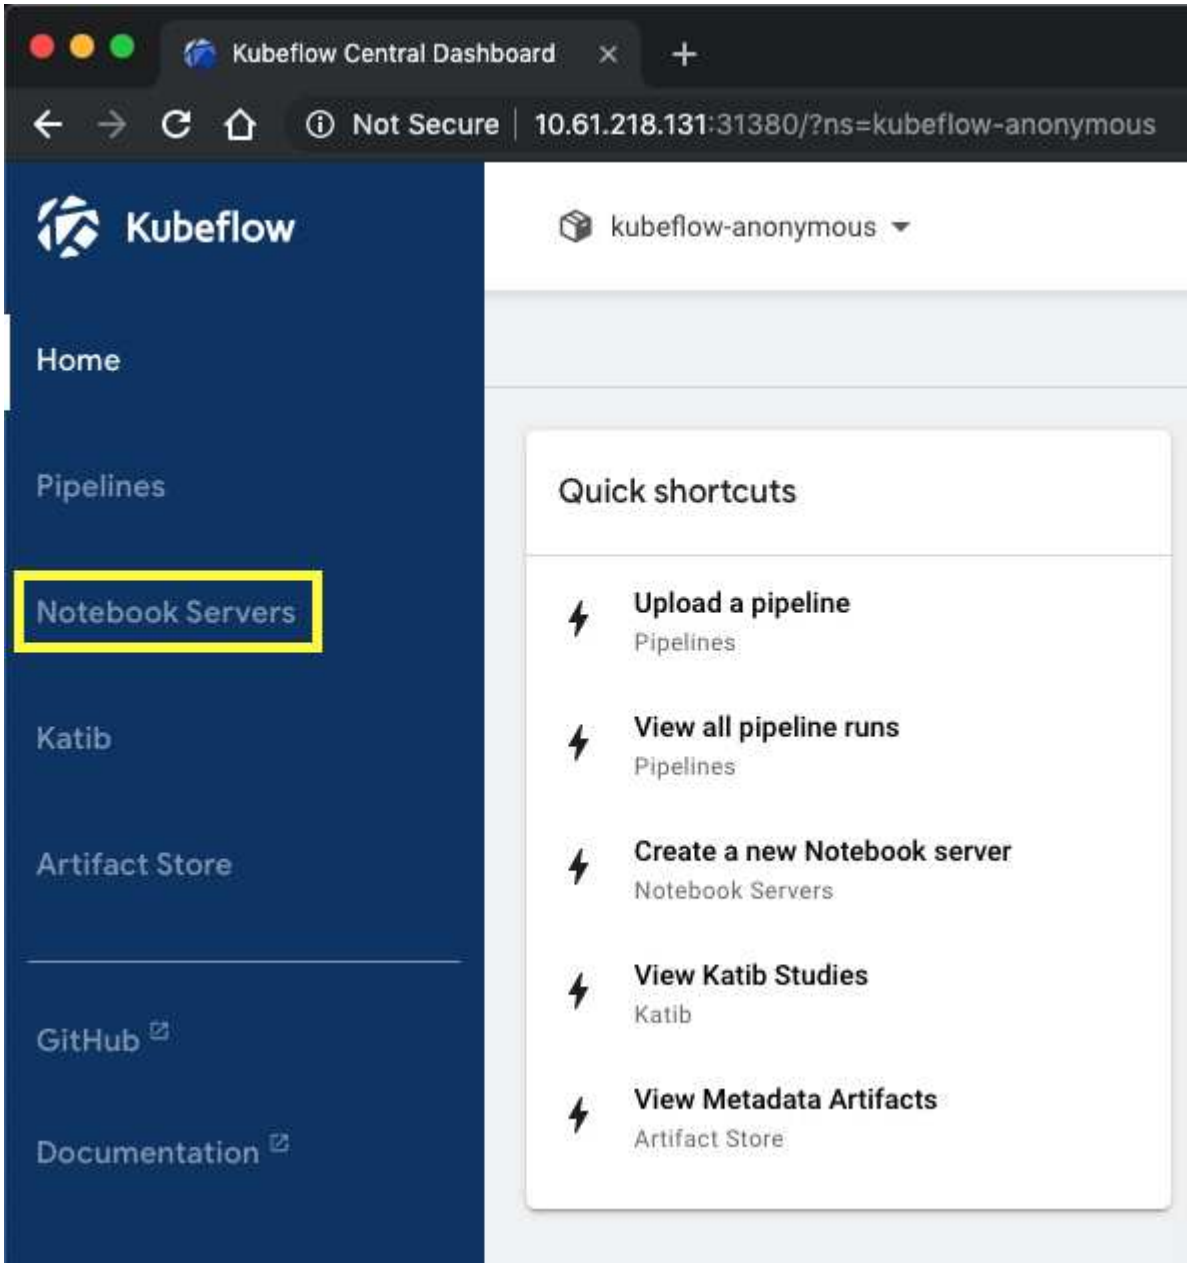

2. Cliquez sur Nouveau serveur pour provisionner un nouveau serveur Jupyter Notebook.

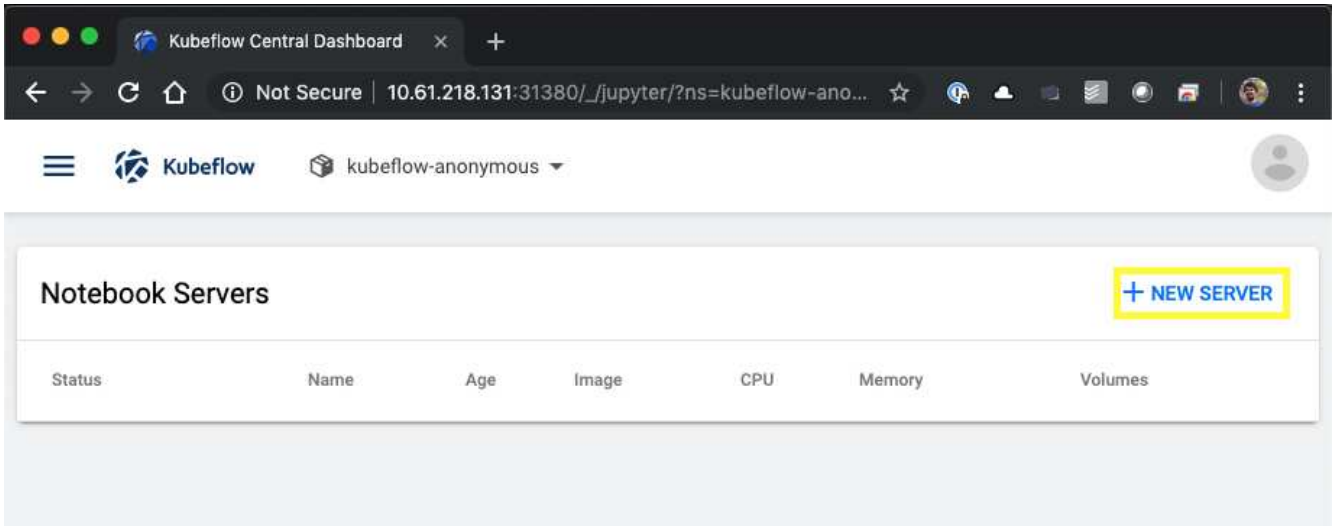

3. Donnez un nom à votre nouveau serveur, choisissez l'image Docker sur laquelle vous voulez que votre serveur soit basé, et spécifiez la quantité de CPU et de RAM à réserver par votre serveur. Si le champ espace de noms est vide, utilisez le menu Sélectionner espace de noms dans l'en-tête de la page pour choisir un espace de noms. Le champ espace de noms est alors automatiquement renseigné avec l'espace de noms choisi.

   Dans l'exemple suivant, le `kubeflow-anonymous` l'espace de noms est choisi. En outre, les valeurs par défaut pour l'image Docker, la CPU et la RAM sont acceptées.

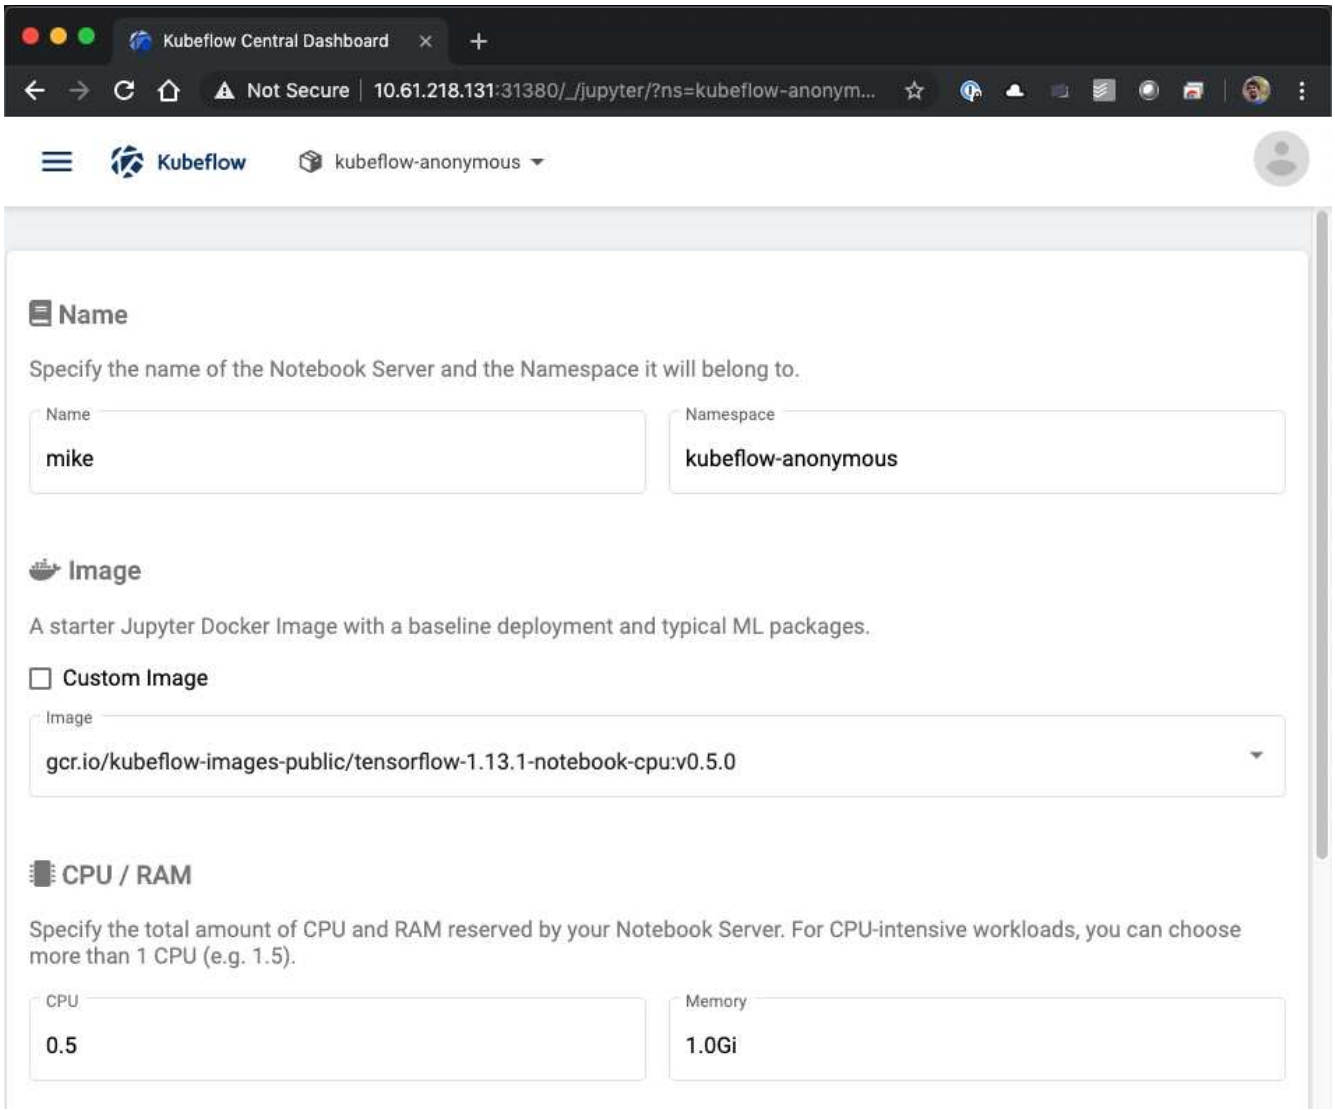

4. Spécifiez les détails du volume de l'espace de travail. Si vous choisissez de créer un nouveau volume, ce volume ou cette demande de volume persistant est provisionné à l'aide de la classe de stockage par défaut. Comme une classe de stockage utilisant Trident a été désignée comme classe de stockage par défaut dans la section "Déploiement Kubeflow", Le volume ou la demande de volume persistant est provisionné avec Trident. Ce volume est automatiquement monté comme espace de travail par défaut dans le conteneur Jupyter Notebook Server. Tous les ordinateurs portables créés par un utilisateur sur le serveur qui ne sont pas enregistrés dans un volume de données distinct sont automatiquement enregistrés dans ce volume d'espace de travail. Par conséquent, les ordinateurs portables sont persistants entre les redémarrages.

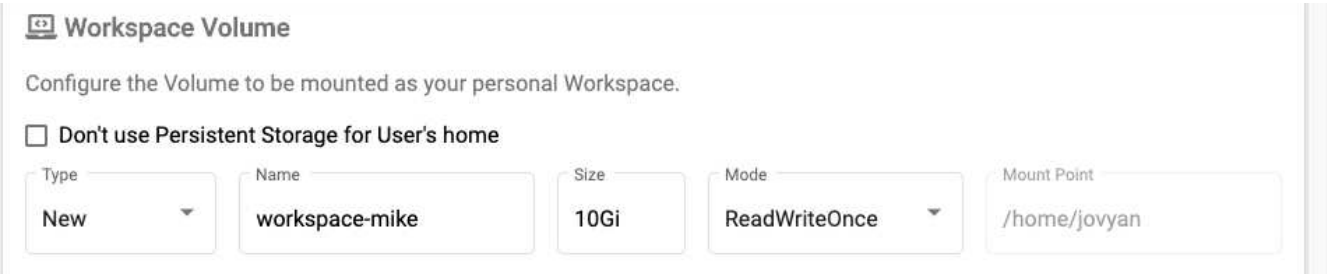

5. Ajout de volumes de données. L'exemple suivant indique un PVC existant nommé 'pb-fg-all' et accepte le point de montage par défaut.

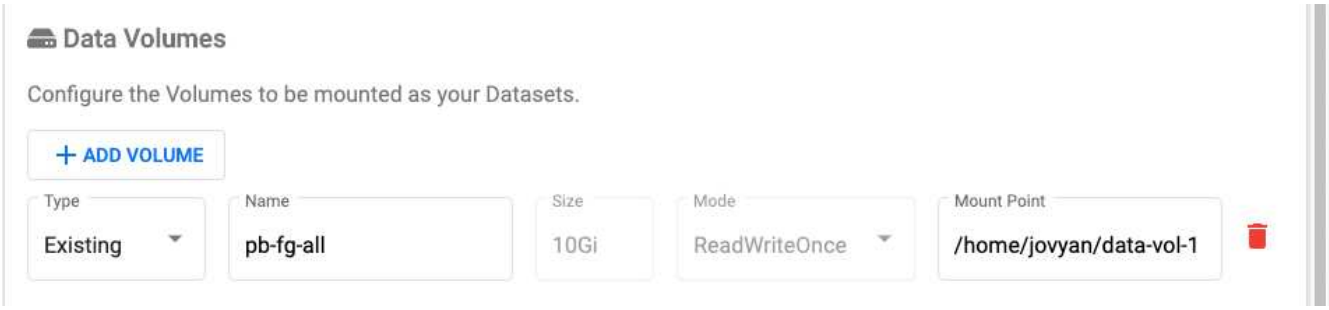

6. **Facultatif:** Demandez que le nombre de processeurs graphiques souhaité soit alloué à votre serveur d'ordinateur portable. Dans l'exemple suivant, un GPU est demandé.

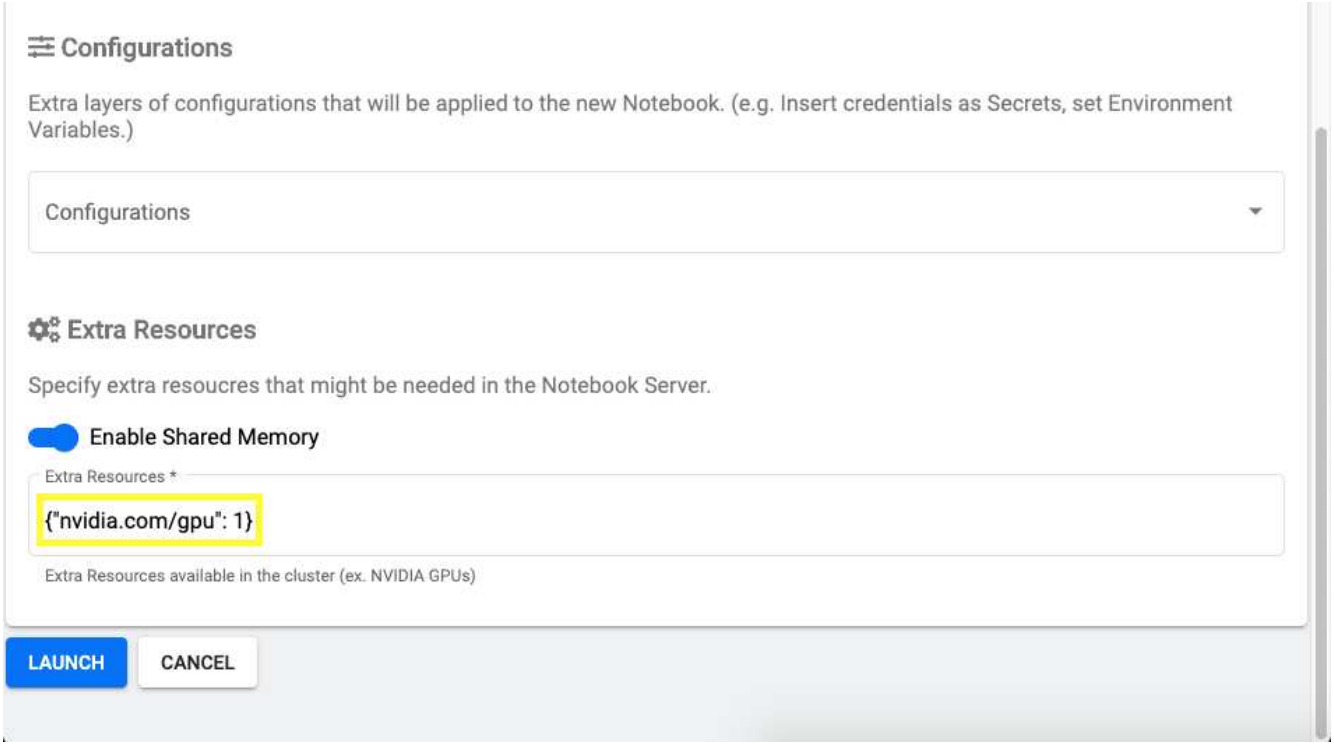

7. Cliquez sur lancer pour approvisionner votre nouveau serveur d'ordinateur portable.
8. Attendez que le serveur de votre ordinateur portable soit entièrement approvisionné. Cette opération peut prendre plusieurs minutes si vous n'avez jamais provisionné de serveur à l'aide de l'image Docker que vous avez spécifiée, car l'image doit être téléchargée. Lorsque votre serveur a été entièrement provisionné, une coche verte s'affiche dans la colonne État de la page d'administration du serveur Jupyter Notebook.

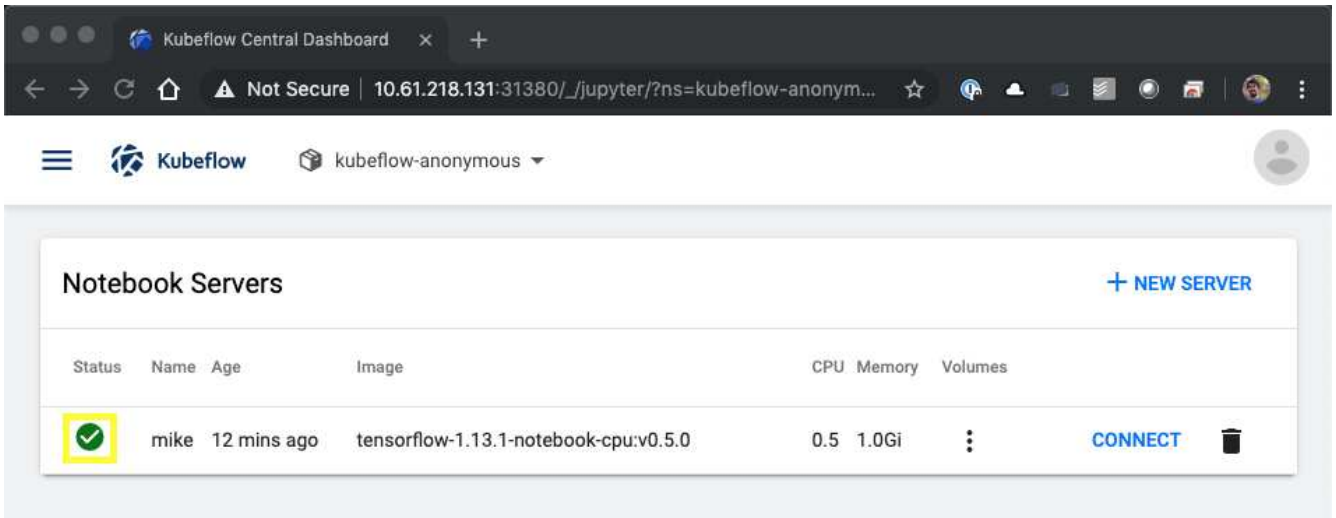

9. Cliquez sur connexion pour vous connecter à votre nouvelle interface Web de serveur.
10. Vérifiez que le volume du dataset spécifié à l'étape 6 est monté sur le serveur. Notez que ce volume est monté par défaut dans l'espace de travail par défaut. Du point de vue de l'utilisateur, ce n'est qu'un autre dossier dans l'espace de travail. L'utilisateur, qui est probablement un spécialiste des données et non un expert en infrastructure, n'a pas besoin de posséder de compétences en stockage pour utiliser ce volume.

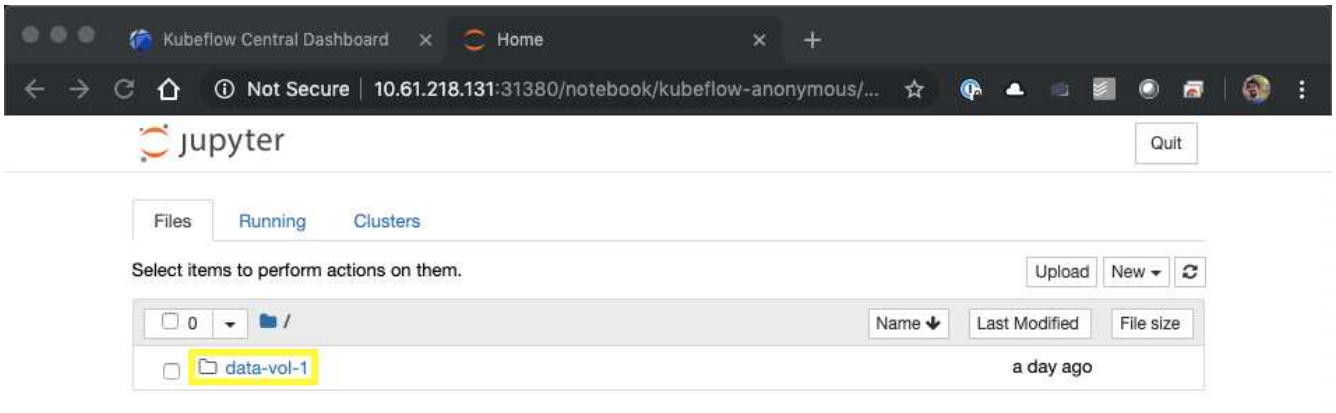

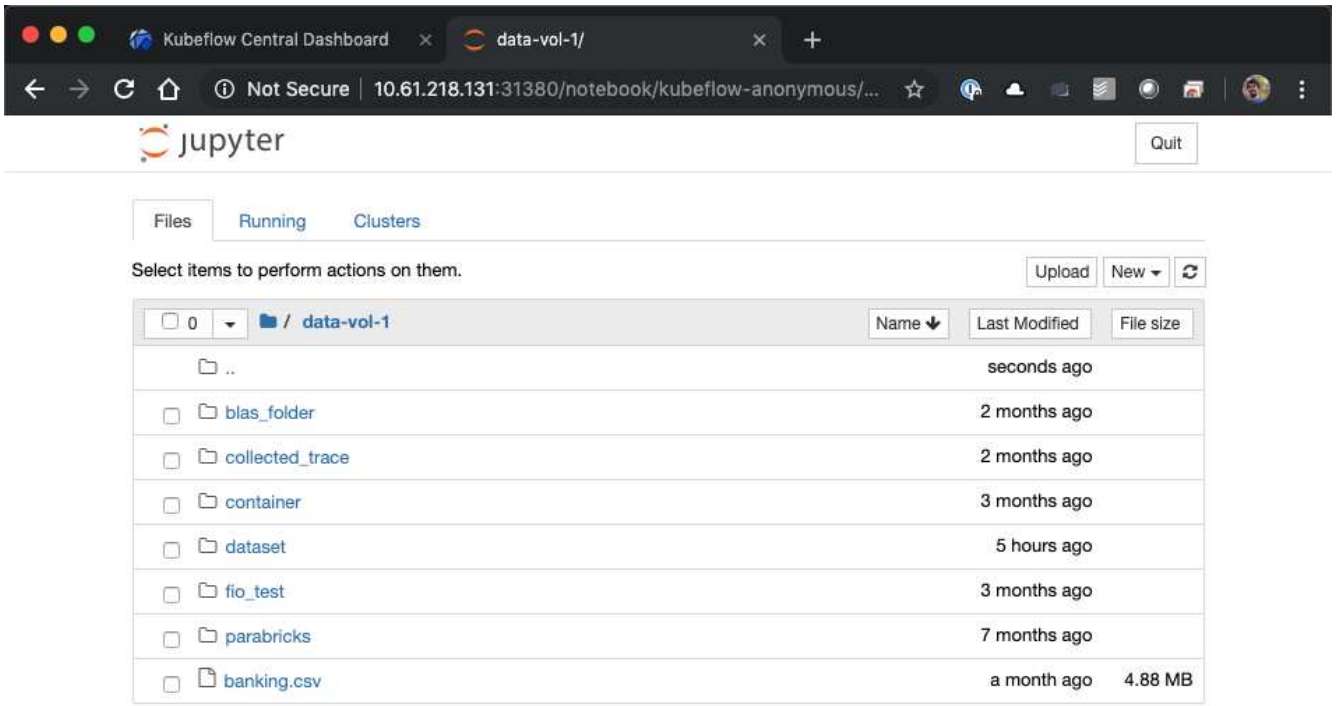

11. Ouvrez un terminal et, en supposant qu'un nouveau volume a été demandé à l'étape 5, exécutez `df -h` Pour confirmer qu'un nouveau volume persistant provisionné avec Trident est monté en tant qu'espace de travail par défaut.

    Le répertoire d'espace de travail par défaut est le répertoire de base avec lequel vous êtes présenté lorsque vous accédez pour la première fois à l'interface Web du serveur. Par conséquent, tout artefact que vous créez via l'interface Web est stocké sur ce volume persistant provisionné par Trident.

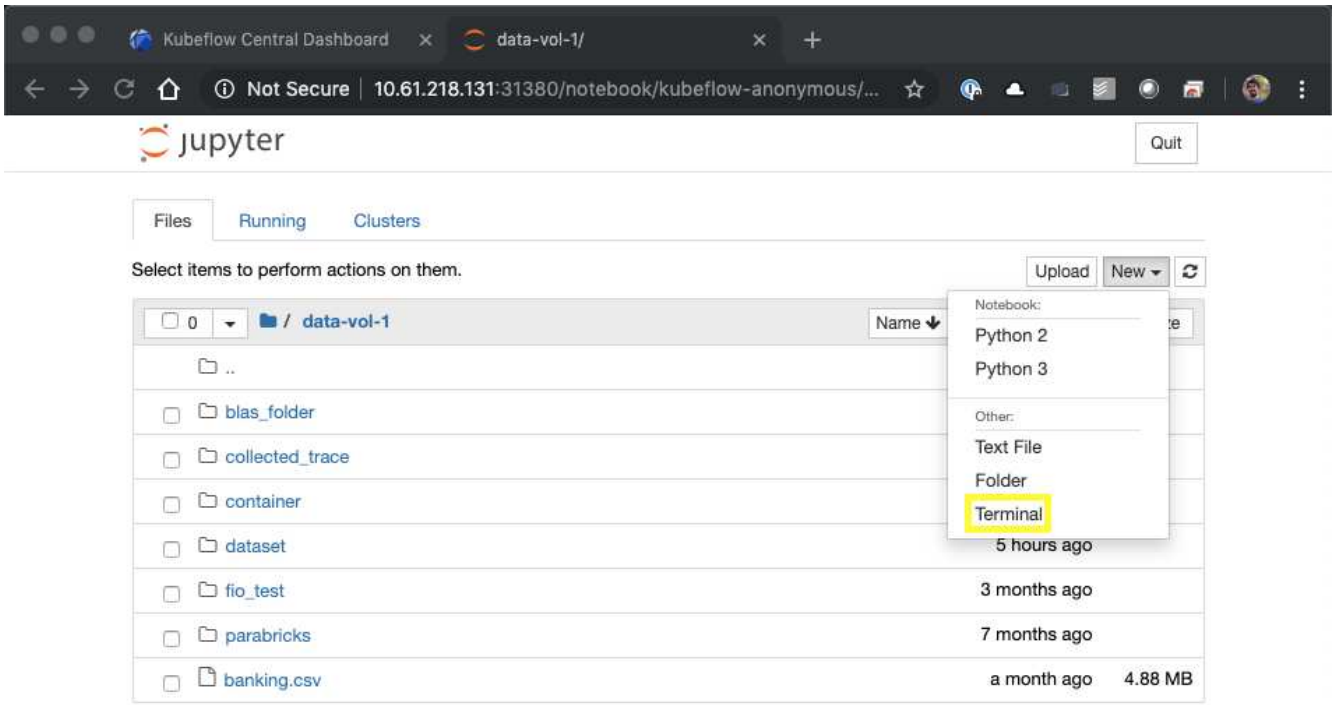

```
$ df -h
Filesystem                                                  Size  Used Avail
Use% Mounted on
overlay                                                     439G   34G  382G
  9% /
tmpfs                                                        64M     0   64M
  0% /dev
tmpfs                                                       252G     0  252G
  0% /sys/fs/cgroup
/dev/sda2                                                   439G   34G  382G
  9% /etc/hosts
192.168.11.11:/trident_pvc_3dcfe7e5_d5a9_11e9_9b9d_00505681a82d   10G  320K   10G
  1% /home/jovyan
tmpfs                                                       252G     0  252G
  0% /dev/shm
192.168.11.11:/pb_fg_all                                     10T   10T   47G
100% /home/jovyan/data-vol-1
tmpfs                                                       252G   12K  252G
  1% /run/secrets/kubernetes.io/serviceaccount
tmpfs                                                       252G   12K  252G
  1% /proc/driver/nvidia
tmpfs                                                        51G  4.9M   51G
  1% /run/nvidia-persistenced/socket
udev                                                        252G     0  252G
  0% /dev/nvidia5
tmpfs                                                       252G     0  252G
  0% /proc/acpi
tmpfs                                                       252G     0  252G
  0% /proc/scsi
tmpfs                                                       252G     0  252G
  0% /sys/firmware
$
```

12. À l'aide du terminal, exécutez `nvidia-smi` Pour vérifier que le nombre correct de GPU a été attribué au serveur d'ordinateur portable. Dans l'exemple suivant, un GPU a été affecté au serveur d'ordinateurs portables comme demandé à l'étape 7.

```
$ nvidia-smi
Fri Sep 13 13:52:15 2019
+-----------------------------------------------------------------------------+
| NVIDIA-SMI 410.104      Driver Version: 410.104      CUDA Version: N/A      |
|-------------------------------+----------------------+----------------------+
| GPU  Name        Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp  Perf  Pwr:Usage/Cap|         Memory-Usage | GPU-Util  Compute M. |
|===============================+======================+======================|
|   0  Tesla V100-SXM2...  On   | 00000000:86:00.0 Off |                    0 |
| N/A   38C    P0    46W / 300W |      0MiB / 32480MiB |      0%      Default |
+-------------------------------+----------------------+----------------------+

+-----------------------------------------------------------------------------+
| Processes:                                                       GPU Memory |
|  GPU       PID   Type   Process name                             Usage      |
|=============================================================================|
|  No running processes found                                                 |
+-----------------------------------------------------------------------------+
$
```

"Suivant : exemple de carnets et de pipelines."

Exemple de carnets de bord et de pipelines

Le "Kit NetApp Data Science Toolkit pour Kubernetes" Peut être utilisé avec Kubeflow. Grâce au kit NetApp Data Science Toolkit avec Kubeflow, il offre les avantages suivants :

- Les data Scientists peuvent effectuer des opérations avancées de gestion des données NetApp directement depuis un ordinateur portable Jupyter.
- Les opérations avancées de gestion des données NetApp peuvent être intégrées aux workflows automatisés grâce à la structure Kubeflow pipelines.

Reportez-vous à la "Exemples Kubeflow" Section du référentiel GitHub pour le kit NetApp Data Science pour plus d'informations sur l'utilisation du kit avec Kubeflow.

"Suivant : déploiement du flux d'air Apache."

Déploiement du flux d'air Apache

NetApp recommande d'exécuter le flux d'air Apache sur Kubernetes. Cette section décrit les tâches à effectuer pour déployer l'air dans votre cluster Kubernetes.

> Il est possible de déployer du flux d'air sur d'autres plateformes que Kubernetes. Le déploiement de flux d'air sur des plateformes autres que Kubernetes ne fait pas partie du cadre de cette solution.

Prérequis

Avant d'effectuer l'exercice de déploiement décrit dans cette section, nous supposons que vous avez déjà effectué les tâches suivantes :

1. Vous disposez déjà d'un cluster Kubernetes fonctionnel.
2. Vous avez déjà installé et configuré NetApp Trident dans votre cluster Kubernetes comme décrit dans la section « déploiement et configuration de NetApp Trident ».

Installer Helm

Le flux d'air est déployé à l'aide de Helm, un gestionnaire de packages populaire pour Kubernetes. Avant de déployer le flux d'air, vous devez installer Helm sur l'hôte de démarrage à déploiement rapide. Pour installer Helm sur l'hôte de saut de déploiement, suivez le "instructions d'installation" Dans la documentation officielle Helm.

Définissez la classe de stockage Kubernetes par défaut

Avant de déployer le flux d'air, vous devez désigner une classe de stockage par défaut dans votre cluster Kubernetes. Le processus de déploiement du flux d'air tente de provisionner de nouveaux volumes persistants à l'aide de la classe de stockage par défaut. Si aucune classe de stockage n'est désignée comme classe de stockage par défaut, le déploiement échoue. Pour désigner une classe de stockage par défaut au sein de votre cluster, suivez les instructions de la section "Déploiement Kubeflow". Si vous avez déjà désigné une classe de stockage par défaut dans votre cluster, vous pouvez ignorer cette étape.

Utilisez Helm pour déployer le flux d'air

Pour déployer le flux d'air dans votre cluster Kubernetes à l'aide de Helm, effectuez les tâches suivantes à partir de l'hôte saut de déploiement :

1. Déployer le flux d'air à l'aide de Helm en suivant le "instructions de déploiement" Pour le tableau de débit d'air officiel sur le concentrateur d'artefacts. Les exemples de commandes qui suivent montrent le déploiement du flux d'air à l'aide de Helm. Modifiez, ajoutez et/ou supprimez des valeurs dans `custom-values.yaml` fichier selon votre environnement et la configuration de votre choix.

```
$ cat << EOF > custom-values.yaml
#####################################
# Airflow - Common Configs
#####################################
airflow:
  ## the airflow executor type to use
  ##
  executor: "CeleryExecutor"
  ## environment variables for the web/scheduler/worker Pods (for
airflow configs)
  ##
  #
#####################################
# Airflow - WebUI Configs
#####################################
web:
  ## configs for the Service of the web Pods
  ##
  service:
    type: NodePort
#####################################
# Airflow - Logs Configs
#####################################
logs:
  persistence:
    enabled: true
#####################################
# Airflow - DAGs Configs
#####################################
dags:
  ## configs for the DAG git repository & sync container
  ##
  gitSync:
    enabled: true
    ## url of the git repository
    ##
    repo: "git@github.com:mboglesby/airflow-dev.git"
    ## the branch/tag/sha1 which we clone
    ##
    branch: master
    revision: HEAD
```

```
    ## the name of a pre-created secret containing files for ~/.ssh/
    ##
    ## NOTE:
    ## - this is ONLY RELEVANT for SSH git repos
    ## - the secret commonly includes files: id_rsa, id_rsa.pub,
known_hosts
    ## - known_hosts is NOT NEEDED if `git.sshKeyscan` is true
    ##
    sshSecret: "airflow-ssh-git-secret"
    ## the name of the private key file in your `git.secret`
    ##
    ## NOTE:
    ## - this is ONLY RELEVANT for PRIVATE SSH git repos
    ##
    sshSecretKey: id_rsa
    ## the git sync interval in seconds
    ##
    syncWait: 60
EOF
$ helm install airflow airflow-stable/airflow -n airflow --version 8.0.8
--values ./custom-values.yaml
...
Congratulations. You have just deployed Apache Airflow!
1. Get the Airflow Service URL by running these commands:
   export NODE_PORT=$(kubectl get --namespace airflow -o
jsonpath="{.spec.ports[0].nodePort}" services airflow-web)
   export NODE_IP=$(kubectl get nodes --namespace airflow -o
jsonpath="{.items[0].status.addresses[0].address}")
   echo http://$NODE_IP:$NODE_PORT/
2. Open Airflow in your web browser
```

2. Assurez-vous que tous les modules de ventilation sont opérationnels. Le démarrage des modules peut prendre quelques minutes.

```
$ kubectl -n airflow get pod
NAME                                READY   STATUS    RESTARTS   AGE
airflow-flower-b5656d44f-h8qjk      1/1     Running   0          2h
airflow-postgresql-0                1/1     Running   0          2h
airflow-redis-master-0              1/1     Running   0          2h
airflow-scheduler-9d95fcdf9-clf4b   2/2     Running   2          2h
airflow-web-59c94db9c5-z7rg4        1/1     Running   0          2h
airflow-worker-0                    2/2     Running   2          2h
```

3. Pour obtenir l'URL du service Web de flux d'air, suivez les instructions qui ont été imprimées sur la console lorsque vous avez déployé du flux d'air à l'aide de Helm à l'étape 1.

```
$ export NODE_PORT=$(kubectl get --namespace airflow -o
jsonpath="{.spec.ports[0].nodePort}" services airflow-web)
$ export NODE_IP=$(kubectl get nodes --namespace airflow -o
jsonpath="{.items[0].status.addresses[0].address}")
$ echo http://$NODE_IP:$NODE_PORT/
```

4. Confirmez que vous pouvez accéder au service Web de débit d'air.

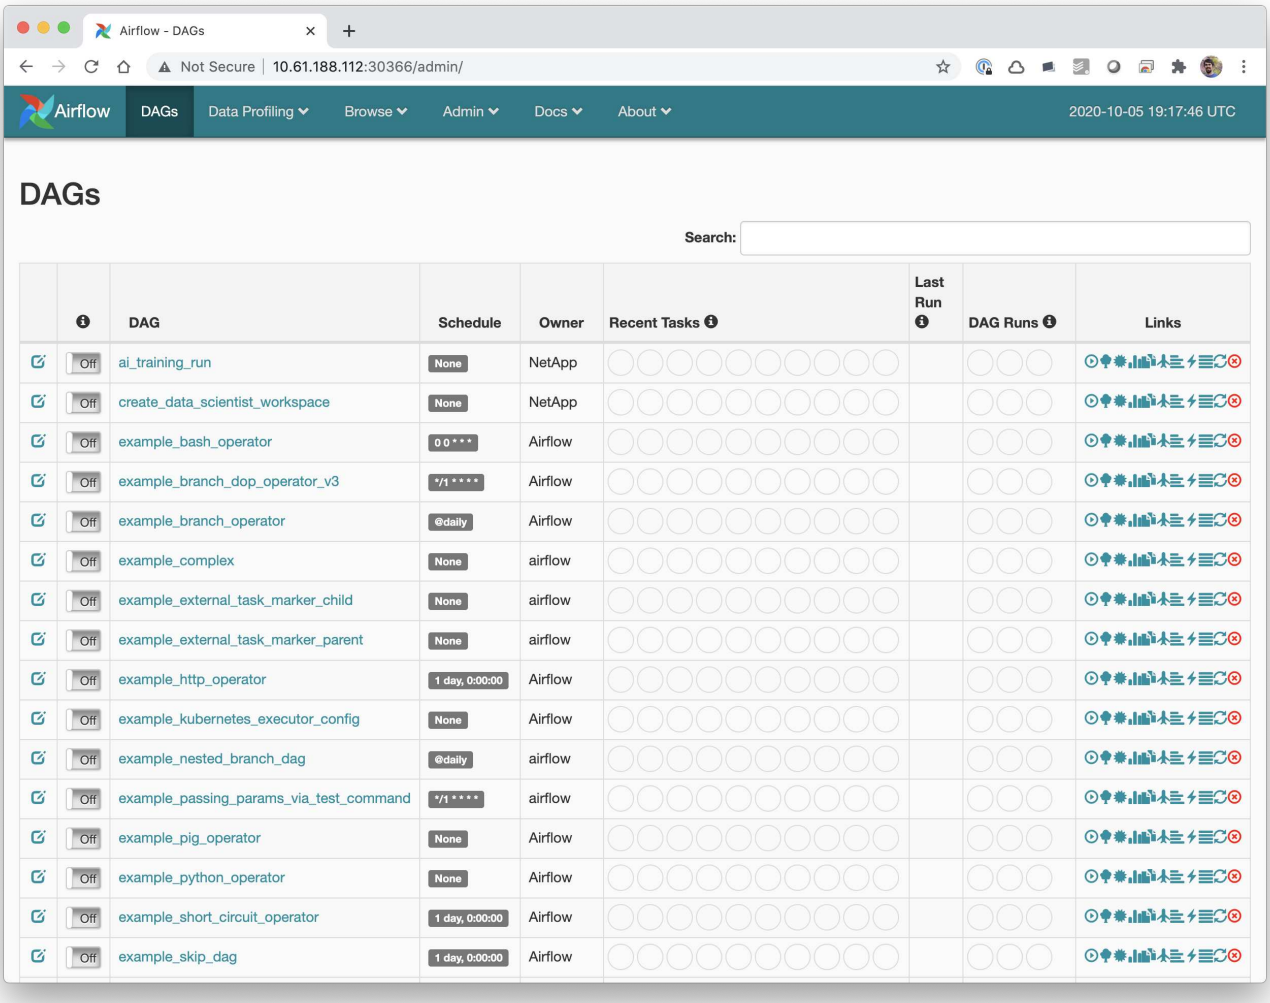

"Suivant : exemple de flux de production du flux d'air Apache."

Exemple de flux de production de flux d'air Apache

Le "Kit NetApp Data Science Toolkit pour Kubernetes" Peut être utilisé en conjonction avec le débit d'air. Grâce au kit NetApp Data Science Toolkit et à la circulation de l'air, vous pouvez incorporer les opérations de gestion des données NetApp dans des workflows automatisés orchestrés par le flux de production d'air.

Reportez-vous à la "Exemples de débit d'air" Section du référentiel GitHub NetApp Data Science Toolkit pour

plus d'informations sur l'utilisation du kit avec flux d'air.

"Ensuite, exemple d'opérations Trident."

Exemple d'opérations Trident

Cette section comprend des exemples d'opérations que vous pouvez effectuer avec Trident.

Importer un volume existant

Si votre système/plateforme de stockage NetApp contient des volumes que vous souhaitez monter sur des conteneurs au sein de votre cluster Kubernetes, mais qui ne sont pas liés aux demandes de volume persistant dans le cluster, vous devez importer ces volumes. Vous pouvez utiliser la fonctionnalité d'importation de volumes Trident pour importer ces volumes.

Les exemples de commandes ci-dessous montrent l'importation du même volume, nommé `pb_fg_all`, Deux fois, une fois pour chaque système back-end Trident créé dans l'exemple de la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 1. Si vous importez le même volume deux fois de cette manière, vous pouvez monter le volume (un volume FlexGroup existant) plusieurs fois sur plusieurs LIF, comme décrit dans la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 1. Pour plus d'informations sur les ESV, consultez le "Documentation officielle Kubernetes". Pour plus d'informations sur la fonctionnalité d'importation de volume, reportez-vous à la section "Documentation Trident".

An `accessModes` valeur de `ReadOnlyMany` Est spécifié dans les fichiers de spécifications PVC d'exemple. Pour plus d'informations sur le `accessMode` voir "Documentation officielle Kubernetes".

> Les noms de back-end spécifiés dans l'exemple de commandes d'importation suivant correspondent aux Backend créés dans l'exemple de la section "Exemple de systèmes back-end Trident pour les déploiements d'IA de ONTAP", étape 1. Les noms de classes de stockage spécifiés dans les exemples de fichiers de définition de PVC suivants correspondent aux classes de stockage créées dans l'exemple de la section "Exemple de classes de stockage Kubernetes pour les déploiements d'IA ONTAP", étape 1.

```
$ cat << EOF > ./pvc-import-pb_fg_all-iface1.yaml
kind: PersistentVolumeClaim
apiVersion: v1
metadata:
  name: pb-fg-all-iface1
  namespace: default
spec:
  accessModes:
    - ReadOnlyMany
  storageClassName: ontap-ai-flexgroups-retain-iface1
EOF
$ tridentctl import volume ontap-ai-flexgroups-iface1 pb_fg_all -f ./pvc-
import-pb_fg_all-iface1.yaml -n trident
+--------------------------------+--------
+-----------------------------------+----------
```

```
+-------------------------------------------+--------+---------+
|          NAME                  |  SIZE  |       STORAGE CLASS
| PROTOCOL |             BACKEND UUID                          | STATE  |
MANAGED |
+---------------------------------+--------
+-----------------------------------+----------
+-------------------------------------------+--------+---------+
| default-pb-fg-all-iface1-7d9f1 | 10 TiB | ontap-ai-flexgroups-retain-
iface1 | file     | b74cbddb-e0b8-40b7-b263-b6da6dec0bdd | online | true
|
+---------------------------------+--------
+-----------------------------------+----------
+-------------------------------------------+--------+---------+
$ cat << EOF > ./pvc-import-pb_fg_all-iface2.yaml
kind: PersistentVolumeClaim
apiVersion: v1
metadata:
  name: pb-fg-all-iface2
  namespace: default
spec:
  accessModes:
    - ReadOnlyMany
  storageClassName: ontap-ai-flexgroups-retain-iface2
EOF
$ tridentctl import volume ontap-ai-flexgroups-iface2 pb_fg_all -f ./pvc-
import-pb_fg_all-iface2.yaml -n trident
+---------------------------------+--------
+-----------------------------------+----------
+-------------------------------------------+--------+---------+
|          NAME                  |  SIZE  |       STORAGE CLASS
| PROTOCOL |             BACKEND UUID                          | STATE  |
MANAGED |
+---------------------------------+--------
+-----------------------------------+----------
+-------------------------------------------+--------+---------+
| default-pb-fg-all-iface2-85aee | 10 TiB | ontap-ai-flexgroups-retain-
iface2 | file     | 61814d48-c770-436b-9cb4-cf7ee661274d | online | true
|
+---------------------------------+--------
+-----------------------------------+----------
+-------------------------------------------+--------+---------+
$ tridentctl get volume -n trident
+-----------------------------------+---------
+-----------------------------------+----------
+---------------------------------------+--------+---------+
|               NAME               |  SIZE   |           STORAGE CLASS
```

```
| PROTOCOL |             BACKEND UUID             | STATE   | MANAGED |
+-----------------------------------+---------
+-----------------------------------+----------
+--------------------------------------+--------+---------+
| default-pb-fg-all-iface1-7d9f1   | 10 TiB  | ontap-ai-flexgroups-retain-
iface1 | file     | b74cbddb-e0b8-40b7-b263-b6da6dec0bdd | online | true
|
| default-pb-fg-all-iface2-85aee   | 10 TiB  | ontap-ai-flexgroups-retain-
iface2 | file     | 61814d48-c770-436b-9cb4-cf7ee661274d | online | true
|
+-----------------------------------+---------
+-----------------------------------+----------
+--------------------------------------+--------+---------+
$ kubectl get pvc
NAME                 STATUS   VOLUME                              CAPACITY
ACCESS MODES   STORAGECLASS                       AGE
pb-fg-all-iface1     Bound    default-pb-fg-all-iface1-7d9f1
10995116277760   ROX            ontap-ai-flexgroups-retain-iface1   25h
pb-fg-all-iface2     Bound    default-pb-fg-all-iface2-85aee
10995116277760   ROX            ontap-ai-flexgroups-retain-iface2   25h
```

Provisionner un nouveau volume

Vous pouvez utiliser Trident pour provisionner un nouveau volume sur votre système ou plateforme de stockage NetApp. L'exemple suivant montre le provisionnement d'un nouveau volume FlexVol. Dans cet exemple, le volume est provisionné à l'aide de la classe de stockage créée dans l'exemple de la section "Exemple de classes de stockage Kubernetes pour les déploiements d'IA ONTAP", étape 2.

An `accessModes` valeur de `ReadWriteMany` Est spécifié dans l'exemple de fichier de définition de PVC suivant. Pour plus d'informations sur le `accessMode` voir "Documentation officielle Kubernetes".

```
$ cat << EOF > ./pvc-tensorflow-results.yaml
kind: PersistentVolumeClaim
apiVersion: v1
metadata:
  name: tensorflow-results
spec:
  accessModes:
    - ReadWriteMany
  resources:
    requests:
      storage: 1Gi
  storageClassName: ontap-ai-flexvols-retain
EOF
$ kubectl create -f ./pvc-tensorflow-results.yaml
persistentvolumeclaim/tensorflow-results created
$ kubectl get pvc
NAME                                STATUS    VOLUME
CAPACITY         ACCESS MODES   STORAGECLASS                        AGE
pb-fg-all-iface1                    Bound     default-pb-fg-all-iface1-7d9f1
10995116277760   ROX            ontap-ai-flexgroups-retain-iface1   26h
pb-fg-all-iface2                    Bound     default-pb-fg-all-iface2-85aee
10995116277760   ROX            ontap-ai-flexgroups-retain-iface2   26h
tensorflow-results                  Bound     default-tensorflow-results-
2fd60   1073741824       RWX            ontap-ai-flexvols-retain
25h
```

"Next : exemple - Présentation des tâches hautes performances pour les déploiements d'IA ONTAP."

Exemple d'tâches hautes performances pour les déploiements d'IA ONTAP

Cette section comprend des exemples de tâches haute performance pouvant être exécutées lorsque Kubernetes est déployé sur un pod ONTAP ai.

"Next : exécutez un workload d'IA à un seul nœud."

Exemple d'tâches hautes performances pour les déploiements d'IA ONTAP

Cette section comprend des exemples de tâches haute performance pouvant être exécutées lorsque Kubernetes est déployé sur un pod ONTAP ai.

"Next : exécutez un workload d'IA à un seul nœud."

Exécutez un workload d'IA à un seul nœud

Pour exécuter une tâche d'IA et DE ML à un seul nœud dans votre cluster Kubernetes, effectuez les tâches suivantes à partir de l'hôte de démarrage du déploiement. Trident

vous permet de faire rapidement et facilement un volume de données, potentiellement contenant des pétaoctets de données, accessibles pour un workload Kubernetes. Pour rendre ce volume de données accessible depuis un pod Kubernetes, il vous suffit de spécifier une demande de volume persistant dans la définition du pod. Cette étape est une opération Kubernetes native ; aucune expertise de NetApp n'est requise.

> Dans cette section, vous devez déjà avoir conteneurisé (au format du conteneur Docker) le workload d'IA et DE ML spécifique que vous essayez d'exécuter dans votre cluster Kubernetes.

1. L'exemple de commandes suivant montre la création d'un travail Kubernetes pour un workload de banc d'essai TensorFlow qui utilise le dataset ImageNet. Pour plus d'informations sur le dataset ImageNet, reportez-vous à la "Site Web ImageNET".

   Cet exemple de tâche nécessite huit GPU, soit un nœud worker doté d'au moins huit GPU. Cet exemple de tâche peut être envoyée dans un cluster pour lequel un nœud worker doté d'au moins huit GPU n'est pas présent ou est actuellement occupé par une autre charge de travail. Si c'est le cas, le travail reste à l'état en attente jusqu'à ce qu'un nœud de travail soit disponible.

   En outre, pour optimiser la bande passante de stockage, le volume contenant les données d'entraînement requises est monté deux fois dans le pod que cette tâche crée. Un autre volume est également monté dans le pod. Ce deuxième volume sera utilisé pour stocker les résultats et les mesures. Ces volumes sont référencés dans la définition de travail en utilisant les noms des ESV. Pour plus d'informations sur les tâches Kubernetes, consultez le "Documentation officielle Kubernetes".

   An `emptyDir` volume avec un `medium` valeur de `Memory` est monté sur `/dev/shm` dans le pod créé par cet exemple de travail. La taille par défaut du `/dev/shm` Le volume virtuel créé automatiquement par le runtime des conteneurs Docker peut parfois manquer pour TensorFlow. Montage d'un `emptyDir` comme dans l'exemple suivant, le volume est suffisamment grand `/dev/shm` volume virtuel. Pour plus d'informations sur `emptyDir` les volumes, voir "Documentation officielle Kubernetes".

   Le conteneur unique spécifié dans cet exemple de définition de travail est donné un `securityContext > privileged` valeur de `true`. Cette valeur signifie que le conteneur dispose d'un accès racine sur l'hôte. Cette annotation est utilisée dans ce cas, car la charge de travail spécifique exécutée nécessite un accès racine. Plus précisément, une opération de mise en cache claire exécutée par la charge de travail nécessite un accès racine. Si cela est ou non `privileged: true` l'annotation est nécessaire dépend des exigences de la charge de travail spécifique que vous exécutez.

```
$ cat << EOF > ./netapp-tensorflow-single-imagenet.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: netapp-tensorflow-single-imagenet
spec:
  backoffLimit: 5
  template:
    spec:
      volumes:
      - name: dshm
        emptyDir:
          medium: Memory
```

```
      - name: testdata-iface1
        persistentVolumeClaim:
          claimName: pb-fg-all-iface1
      - name: testdata-iface2
        persistentVolumeClaim:
          claimName: pb-fg-all-iface2
      - name: results
        persistentVolumeClaim:
          claimName: tensorflow-results
      containers:
      - name: netapp-tensorflow-py2
        image: netapp/tensorflow-py2:19.03.0
        command: ["python", "/netapp/scripts/run.py", "--
dataset_dir=/mnt/mount_0/dataset/imagenet", "--dgx_version=dgx1", "--
num_devices=8"]
        resources:
          limits:
            nvidia.com/gpu: 8
        volumeMounts:
        - mountPath: /dev/shm
          name: dshm
        - mountPath: /mnt/mount_0
          name: testdata-iface1
        - mountPath: /mnt/mount_1
          name: testdata-iface2
        - mountPath: /tmp
          name: results
        securityContext:
          privileged: true
      restartPolicy: Never
EOF
$ kubectl create -f ./netapp-tensorflow-single-imagenet.yaml
job.batch/netapp-tensorflow-single-imagenet created
$ kubectl get jobs
NAME                                      COMPLETIONS   DURATION   AGE
netapp-tensorflow-single-imagenet         0/1           24s        24s
```

2. Vérifiez que le travail que vous avez créé à l'étape 1 fonctionne correctement. L'exemple de commande suivant confirme qu'un seul pod a été créé pour le travail, comme spécifié dans la définition du travail, et que ce pod s'exécute actuellement sur l'un des nœuds workers GPU.

```
$ kubectl get pods -o wide
NAME                                                READY   STATUS
RESTARTS   AGE
IP              NODE            NOMINATED NODE
netapp-tensorflow-single-imagenet-m7x92          1/1     Running     0
3m    10.233.68.61    10.61.218.154   <none>
```

3. Vérifiez que le travail que vous avez créé à l'étape 1 s'est terminé avec succès. L'exemple de commandes suivant confirme que le travail a été terminé avec succès.

```
$ kubectl get jobs
NAME                                          COMPLETIONS   DURATION
AGE
netapp-tensorflow-single-imagenet             1/1           5m42s
10m
$ kubectl get pods
NAME                                                  READY   STATUS
RESTARTS   AGE
netapp-tensorflow-single-imagenet-m7x92               0/1     Completed
0          11m
$ kubectl logs netapp-tensorflow-single-imagenet-m7x92
[netapp-tensorflow-single-imagenet-m7x92:00008] PMIX ERROR: NO-
PERMISSIONS in file gds_dstore.c at line 702
[netapp-tensorflow-single-imagenet-m7x92:00008] PMIX ERROR: NO-
PERMISSIONS in file gds_dstore.c at line 711
Total images/sec = 6530.59125
================ Clean Cache !!! ==================
mpirun -allow-run-as-root -np 1 -H localhost:1 bash -c 'sync; echo 1 >
/proc/sys/vm/drop_caches'
==========================================
mpirun -allow-run-as-root -np 8 -H localhost:8 -bind-to none -map-by
slot -x NCCL_DEBUG=INFO -x LD_LIBRARY_PATH -x PATH python
/netapp/tensorflow/benchmarks_190205/scripts/tf_cnn_benchmarks/tf_cnn_be
nchmarks.py --model=resnet50 --batch_size=256 --device=gpu
--force_gpu_compatible=True --num_intra_threads=1 --num_inter_threads=48
--variable_update=horovod --batch_group_size=20 --num_batches=500
--nodistortions --num_gpus=1 --data_format=NCHW --use_fp16=True
--use_tf_layers=False --data_name=imagenet --use_datasets=True
--data_dir=/mnt/mount_0/dataset/imagenet
--datasets_parallel_interleave_cycle_length=10
--datasets_sloppy_parallel_interleave=False --num_mounts=2
--mount_prefix=/mnt/mount_%d --datasets_prefetch_buffer_size=2000
--datasets_use_prefetch=True --datasets_num_private_threads=4
--horovod_device=gpu >
/tmp/20190814_105450_tensorflow_horovod_rdma_resnet50_gpu_8_256_b500_ima
genet_nodistort_fp16_r10_m2_nockpt.txt 2>&1
```

4. **Facultatif:** nettoyer les artefacts de travail. Les exemples de commandes suivants montrent la suppression de l'objet de travail créé à l'étape 1.

   Lorsque vous supprimez l'objet travail, Kubernetes supprime automatiquement les pods associés.

```
$ kubectl get jobs
NAME                                                COMPLETIONS   DURATION
AGE
netapp-tensorflow-single-imagenet                   1/1           5m42s
10m
$ kubectl get pods
NAME                                                      READY   STATUS
RESTARTS   AGE
netapp-tensorflow-single-imagenet-m7x92                   0/1     Completed
0          11m
$ kubectl delete job netapp-tensorflow-single-imagenet
job.batch "netapp-tensorflow-single-imagenet" deleted
$ kubectl get jobs
No resources found.
$ kubectl get pods
No resources found.
```

"Ensuite : exécuter un workload d'IA distribué synchrone."

Exécutez un workload d'IA distribué synchrone

Pour exécuter une tâche d'IA et DE ML à plusieurs nœuds synchrones dans votre cluster Kubernetes, exécutez les tâches suivantes sur l'hôte de démarrage du déploiement. Ce processus vous permet de exploiter les données stockées sur un volume NetApp et d'utiliser plus de GPU que n'en fournir un seul nœud de travail. Reportez-vous à la figure suivante pour obtenir une description d'une tâche d'IA distribuée synchrone.

> Les tâches distribuées synchrones permettent d'améliorer les performances et la précision de l'entraînement par rapport aux tâches distribuées asynchrones. Un examen des avantages et inconvénients des emplois synchrones par rapport aux emplois asynchrones est hors du champ d'application de ce document.

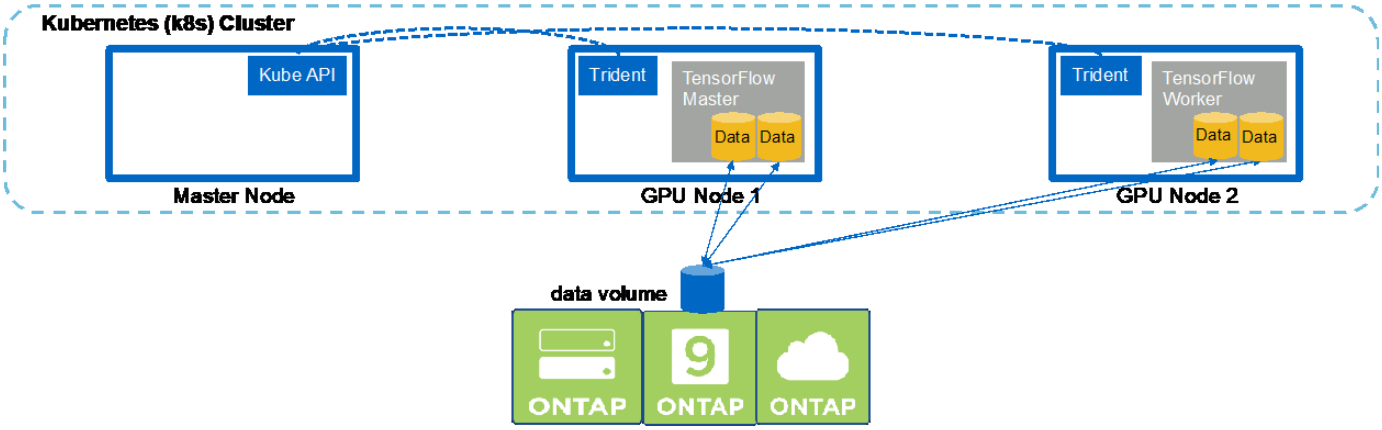

1. Les commandes d'exemple suivantes montrent la création d'un travailleur qui participe à l'exécution distribuée synchrone du même travail de banc d'essai TensorFlow qui a été exécuté sur un seul nœud

dans l'exemple de la section "Exécutez un workload d'IA à un seul nœud". Dans cet exemple spécifique, seul un travailleur est déployé car le travail est exécuté sur deux nœuds worker.

Cet exemple de déploiement utilisateur nécessite huit GPU, et peut donc s'exécuter sur un seul nœud worker GPU doté d'au moins huit GPU. Si les nœuds workers GPU disposent de plus de huit GPU, afin d'optimiser les performances, il est possible que vous souhaitiez augmenter ce nombre afin qu'il soit égal au nombre de GPU dont bénéficient les nœuds workers. Pour en savoir plus sur les déploiements Kubernetes, rendez-vous sur le "Documentation officielle Kubernetes".

Un déploiement Kubernetes est créé dans cet exemple, car ce travailleur conteneurisé ne s'en serait jamais achevé seul. C'est pourquoi il n'est pas logique de le déployer via la construction de tâches Kubernetes. Si votre travailleur est conçu ou écrit de manière à le compléter seul, il peut être judicieux d'utiliser la structure de travail pour déployer votre travailleur.

Le pod spécifié dans cet exemple de spécification de déploiement est donné un `hostNetwork` valeur de `true`. Cette valeur signifie que le pod utilise la pile réseau du nœud du worker hôte au lieu de la pile de réseau virtuel que Kubernetes crée habituellement pour chaque pod. Cette annotation est utilisée dans ce cas car la charge de travail spécifique repose sur Open MPI, NCCL et Horovod pour exécuter la charge de travail de façon synchrone distribuée. Par conséquent, elle nécessite l'accès à la pile réseau de l'hôte. Une discussion sur Open MPI, NCCL et Horovod n'est pas dans le cadre du présent document. Si cela est ou non `hostNetwork: true` l'annotation est nécessaire dépend des exigences de la charge de travail spécifique que vous exécutez. Pour plus d'informations sur le `hostNetwork` voir "Documentation officielle Kubernetes".

```
$ cat << EOF > ./netapp-tensorflow-multi-imagenet-worker.yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: netapp-tensorflow-multi-imagenet-worker
spec:
  replicas: 1
  selector:
    matchLabels:
      app: netapp-tensorflow-multi-imagenet-worker
  template:
    metadata:
      labels:
        app: netapp-tensorflow-multi-imagenet-worker
    spec:
      hostNetwork: true
      volumes:
      - name: dshm
        emptyDir:
          medium: Memory
      - name: testdata-iface1
        persistentVolumeClaim:
          claimName: pb-fg-all-iface1
      - name: testdata-iface2
        persistentVolumeClaim:
```

```
          claimName: pb-fg-all-iface2
      - name: results
        persistentVolumeClaim:
          claimName: tensorflow-results
      containers:
      - name: netapp-tensorflow-py2
        image: netapp/tensorflow-py2:19.03.0
        command: ["bash", "/netapp/scripts/start-slave-multi.sh",
"22122"]
        resources:
          limits:
            nvidia.com/gpu: 8
        volumeMounts:
        - mountPath: /dev/shm
          name: dshm
        - mountPath: /mnt/mount_0
          name: testdata-iface1
        - mountPath: /mnt/mount_1
          name: testdata-iface2
        - mountPath: /tmp
          name: results
        securityContext:
          privileged: true
EOF
$ kubectl create -f ./netapp-tensorflow-multi-imagenet-worker.yaml
deployment.apps/netapp-tensorflow-multi-imagenet-worker created
$ kubectl get deployments
NAME                                      DESIRED   CURRENT   UP-TO-DATE
AVAILABLE   AGE
netapp-tensorflow-multi-imagenet-worker   1         1         1
1           4s
```

2. Confirmez que le déploiement de collaborateur que vous avez créé à l'étape 1 a été lancé avec succès. Les exemples de commandes suivants confirment qu'un seul pod worker a été créé pour le déploiement, comme indiqué dans la définition du déploiement, et que ce pod s'exécute actuellement sur l'un des nœuds workers GPU.

```
$ kubectl get pods -o wide
NAME                                                      READY
STATUS    RESTARTS   AGE
IP              NODE            NOMINATED NODE
netapp-tensorflow-multi-imagenet-worker-654fc7f486-v6725   1/1
Running   0          60s   10.61.218.154   10.61.218.154   <none>
$ kubectl logs netapp-tensorflow-multi-imagenet-worker-654fc7f486-v6725
22122
```

3. Créez un travail Kubernetes pour un master qui démarre, participe et suit l'exécution du travail multinœud synchrone. Les commandes d'exemple suivantes créent un master qui démarre, participe à et assure le suivi de l'exécution distribuée synchrone du même travail de banc d'essai TensorFlow qui a été exécuté sur un seul nœud dans l'exemple de la section "Exécutez un workload d'IA à un seul nœud".

   Cet exemple de tâche maître demande huit GPU, puis peut être exécuté sur un seul nœud worker GPU doté d'au moins huit GPU. Si les nœuds workers GPU disposent de plus de huit GPU, afin d'optimiser les performances, il est possible que vous souhaitiez augmenter ce nombre afin qu'il soit égal au nombre de GPU dont bénéficient les nœuds workers.

   Le pod maître spécifié dans cet exemple de définition de travail est donné un `hostNetwork` valeur de `true`, tout comme le pod de travailleur a été donné `hostNetwork` valeur de `true` à l'étape 1. Voir l'étape 1 pour plus de détails sur la raison pour laquelle cette valeur est nécessaire.

```
$ cat << EOF > ./netapp-tensorflow-multi-imagenet-master.yaml
apiVersion: batch/v1
kind: Job
metadata:
  name: netapp-tensorflow-multi-imagenet-master
spec:
  backoffLimit: 5
  template:
    spec:
      hostNetwork: true
      volumes:
      - name: dshm
        emptyDir:
          medium: Memory
      - name: testdata-iface1
        persistentVolumeClaim:
          claimName: pb-fg-all-iface1
      - name: testdata-iface2
        persistentVolumeClaim:
          claimName: pb-fg-all-iface2
      - name: results
        persistentVolumeClaim:
          claimName: tensorflow-results
      containers:
      - name: netapp-tensorflow-py2
        image: netapp/tensorflow-py2:19.03.0
        command: ["python", "/netapp/scripts/run.py", "--
dataset_dir=/mnt/mount_0/dataset/imagenet", "--port=22122", "--
num_devices=16", "--dgx_version=dgx1", "--
nodes=10.61.218.152,10.61.218.154"]
        resources:
          limits:
            nvidia.com/gpu: 8
        volumeMounts:
```

```
        - mountPath: /dev/shm
          name: dshm
        - mountPath: /mnt/mount_0
          name: testdata-iface1
        - mountPath: /mnt/mount_1
          name: testdata-iface2
        - mountPath: /tmp
          name: results
        securityContext:
          privileged: true
      restartPolicy: Never
EOF
$ kubectl create -f ./netapp-tensorflow-multi-imagenet-master.yaml
job.batch/netapp-tensorflow-multi-imagenet-master created
$ kubectl get jobs
NAME                                      COMPLETIONS   DURATION   AGE
netapp-tensorflow-multi-imagenet-master   0/1           25s        25s
```

4. Vérifiez que le travail principal que vous avez créé à l'étape 3 fonctionne correctement. L'exemple de commande suivant confirme qu'un module maître unique a été créé pour le travail, comme indiqué dans la définition du travail, et que ce pod s'exécute actuellement sur l'un des nœuds workers GPU. Vous devriez également voir que le pod de worker que vous avez initialement vu à l'étape 1 est toujours en cours d'exécution et que les pods master et worker exécutent sur différents nœuds.

```
$ kubectl get pods -o wide
NAME                                                        READY
STATUS    RESTARTS   AGE
IP              NODE            NOMINATED NODE
netapp-tensorflow-multi-imagenet-master-ppwwj               1/1
Running   0          45s   10.61.218.152   10.61.218.152   <none>
netapp-tensorflow-multi-imagenet-worker-654fc7f486-v6725   1/1
Running   0          26m   10.61.218.154   10.61.218.154   <none>
```

5. Confirmez que le travail principal que vous avez créé à l'étape 3 s'est terminé avec succès. L'exemple de commandes suivant confirme que le travail a été terminé avec succès.

```
$ kubectl get jobs
NAME                                      COMPLETIONS   DURATION   AGE
netapp-tensorflow-multi-imagenet-master   1/1           5m50s      9m18s
$ kubectl get pods
NAME                                                        READY
STATUS      RESTARTS   AGE
netapp-tensorflow-multi-imagenet-master-ppwwj               0/1
Completed   0          9m38s
netapp-tensorflow-multi-imagenet-worker-654fc7f486-v6725   1/1
```

```
Running     0          35m
$ kubectl logs netapp-tensorflow-multi-imagenet-master-ppwwj
[10.61.218.152:00008] WARNING: local probe returned unhandled
shell:unknown assuming bash
rm: cannot remove '/lib': Is a directory
[10.61.218.154:00033] PMIX ERROR: NO-PERMISSIONS in file gds_dstore.c at
line 702
[10.61.218.154:00033] PMIX ERROR: NO-PERMISSIONS in file gds_dstore.c at
line 711
[10.61.218.152:00008] PMIX ERROR: NO-PERMISSIONS in file gds_dstore.c at
line 702
[10.61.218.152:00008] PMIX ERROR: NO-PERMISSIONS in file gds_dstore.c at
line 711
Total images/sec = 12881.33875
================ Clean Cache !!! ==================
mpirun -allow-run-as-root -np 2 -H 10.61.218.152:1,10.61.218.154:1 -mca
pml ob1 -mca btl ^openib -mca btl_tcp_if_include enp1s0f0 -mca
plm_rsh_agent ssh -mca plm_rsh_args "-p 22122" bash -c 'sync; echo 1 >
/proc/sys/vm/drop_caches'
==========================================
mpirun -allow-run-as-root -np 16 -H 10.61.218.152:8,10.61.218.154:8
-bind-to none -map-by slot -x NCCL_DEBUG=INFO -x LD_LIBRARY_PATH -x PATH
-mca pml ob1 -mca btl ^openib -mca btl_tcp_if_include enp1s0f0 -x
NCCL_IB_HCA=mlx5 -x NCCL_NET_GDR_READ=1 -x NCCL_IB_SL=3 -x
NCCL_IB_GID_INDEX=3 -x
NCCL_SOCKET_IFNAME=enp5s0.3091,enp12s0.3092,enp132s0.3093,enp139s0.3094
-x NCCL_IB_CUDA_SUPPORT=1 -mca orte_base_help_aggregate 0 -mca
plm_rsh_agent ssh -mca plm_rsh_args "-p 22122" python
/netapp/tensorflow/benchmarks_190205/scripts/tf_cnn_benchmarks/tf_cnn_be
nchmarks.py --model=resnet50 --batch_size=256 --device=gpu
--force_gpu_compatible=True --num_intra_threads=1 --num_inter_threads=48
--variable_update=horovod --batch_group_size=20 --num_batches=500
--nodistortions --num_gpus=1 --data_format=NCHW --use_fp16=True
--use_tf_layers=False --data_name=imagenet --use_datasets=True
--data_dir=/mnt/mount_0/dataset/imagenet
--datasets_parallel_interleave_cycle_length=10
--datasets_sloppy_parallel_interleave=False --num_mounts=2
--mount_prefix=/mnt/mount_%d --datasets_prefetch_buffer_size=2000 --
datasets_use_prefetch=True --datasets_num_private_threads=4
--horovod_device=gpu >
/tmp/20190814_161609_tensorflow_horovod_rdma_resnet50_gpu_16_256_b500_im
agenet_nodistort_fp16_r10_m2_nockpt.txt 2>&1
```

6. Supprimez le déploiement de collaborateur lorsque vous n'en avez plus besoin. L'exemple de commandes suivant montre la suppression de l'objet de déploiement de travail qui a été créé à l'étape 1.

Lorsque vous supprimez l'objet de déploiement worker, Kubernetes supprime automatiquement les pods workers associés.

```
$ kubectl get deployments
NAME                                        DESIRED   CURRENT   UP-TO-DATE
AVAILABLE   AGE
netapp-tensorflow-multi-imagenet-worker   1         1         1
1           43m
$ kubectl get pods
NAME                                                        READY
STATUS      RESTARTS   AGE
netapp-tensorflow-multi-imagenet-master-ppwwj              0/1
Completed   0          17m
netapp-tensorflow-multi-imagenet-worker-654fc7f486-v6725   1/1
Running     0          43m
$ kubectl delete deployment netapp-tensorflow-multi-imagenet-worker
deployment.extensions "netapp-tensorflow-multi-imagenet-worker" deleted
$ kubectl get deployments
No resources found.
$ kubectl get pods
NAME                                            READY   STATUS
RESTARTS   AGE
netapp-tensorflow-multi-imagenet-master-ppwwj   0/1     Completed   0
18m
```

7. **Facultatif:** nettoyez les artefacts du travail principal. Les exemples de commandes suivants montrent la suppression de l'objet de travail maître créé à l'étape 3.

   Lorsque vous supprimez l'objet de travail maître, Kubernetes supprime automatiquement les modules maîtres associés.

```
$ kubectl get jobs
NAME                                        COMPLETIONS   DURATION   AGE
netapp-tensorflow-multi-imagenet-master   1/1           5m50s      19m
$ kubectl get pods
NAME                                            READY   STATUS
RESTARTS   AGE
netapp-tensorflow-multi-imagenet-master-ppwwj   0/1     Completed   0
19m
$ kubectl delete job netapp-tensorflow-multi-imagenet-master
job.batch "netapp-tensorflow-multi-imagenet-master" deleted
$ kubectl get jobs
No resources found.
$ kubectl get pods
No resources found.
```

"Suivant : test des performances."

Test des performances

Nous avons effectué une comparaison simple des performances dans le cadre de la création de cette solution. Nous avons exécuté plusieurs tâches standard de banc d'essai NetApp ai avec Kubernetes, et nous avons comparé les résultats du banc d'essai avec les sous-activités qui ont été réalisées à l'aide d'une simple commande Docker run. Nous n'avons pas constaté de différence notable au niveau des performances. Nous en avons donc conclu que l'utilisation de Kubernetes pour orchestrer les tâches d'entraînement d'IA conteneurisées n'avait pas de conséquences négatives sur les performances. Pour consulter les résultats de cette comparaison, consultez le tableau suivant.

Banc d'essai	Jeu de données	Docker Run (images/s)	Kubernetes (images/s)
TensorFlow à un nœud	Données synthétiques	6,667.2475	6,661.93125
TensorFlow à un nœud	ImageNet	6,570.2025	6,530.59125
TensorFlow distribué synchrone à deux nœuds	Données synthétiques	13,213.70625	13,218.288125
TensorFlow distribué synchrone à deux nœuds	ImageNet	12,941.69125	12,881.33875

"Suivant: Conclusion."

Conclusion

Toutes les entreprises, quelle que soit leur taille et tous les secteurs, se tournent vers l'intelligence artificielle (IA), le machine learning (ML) et le deep learning (DL) pour résoudre des problèmes concrets, proposer des produits et des services innovants et se démarquer sur un marché de plus en plus concurrentiel. Alors que les entreprises ont de plus en plus recours à l'IA, AU ML et au DL, elles sont confrontées à de nombreux défis, notamment l'évolutivité des workloads et la disponibilité des données. Ces difficultés peuvent être résolues via l'utilisation de la solution NetApp ai Control plane.

Cette solution permet de cloner rapidement un espace de noms de données. Vous pouvez par ailleurs définir et implémenter des workflows d'entraînement d'IA, DE ML et de DL pour intégrer la création quasi instantanée de données et de modèles de base à des fins de traçabilité et de gestion des versions. Avec cette solution, vous pouvez suivre l'entraînement de chaque modèle individuel sur le(s) dataset(s) exact(s) auquel le modèle a été entraîné et/ou validé. Enfin, cette solution vous permet de provisionner rapidement des espaces de travail Jupyter Notebook avec un accès à des jeux de données volumineux.

Cette solution cible les data Scientists et les ingénieurs de données, une expertise minimale de NetApp ou de NetApp ONTAP est requise. Avec cette solution, les fonctions de gestion des données peuvent être exécutées à l'aide d'outils et d'interfaces simples et familiers. De plus, cette solution utilise des composants entièrement open source et libres. Par conséquent, si vous disposez déjà d'un système de stockage NetApp dans votre environnement, vous pouvez implémenter cette solution dès aujourd'hui. Si vous souhaitez essayer cette solution, mais que vous ne disposez pas encore de système de stockage NetApp, rendez-vous sur "cloud.netapp.com", Et vous pouvez être opérationnel avec une solution de stockage NetApp basée sur le cloud en un rien de temps.

Pipeline MLRun avec Iguazio

Tr-4834 : NetApp et Iguazio pour le pipeline MLRun

Rick Huang, David Arnette, NetApp Marcelo Litovsky, Iguazio

Ce document présente en détail le pipeline MLRun utilisant NetApp ONTAP ai, NetApp ai Control plane, le logiciel NetApp Cloud volumes et la plateforme data Science Iguazio. Nous utilisons la fonction sans serveur Nucio, Kubernetes persistent volumes, NetApp Cloud volumes, les copies NetApp Snapshot, le tableau de bord Grafana, Et d'autres services sur la plate-forme Iguazio pour créer un pipeline de données de bout en bout pour la simulation de la détection des défaillances réseau. Nous avons intégré les technologies Iguazio et NetApp afin de permettre un déploiement rapide des modèles, la réplication des données et la surveillance de la production, sur site comme dans le cloud.

Le travail d'un data Scientist doit se concentrer sur l'entraînement et l'ajustement des modèles de machine learning (ML) et d'intelligence artificielle (IA). Toutefois, selon une étude Google, les data Scientists consacrent environ 80 % de leur temps à déterminer comment exploiter leurs modèles pour s'exécuter à grande échelle et dans des applications d'entreprise, comme l'illustre l'image suivante illustrant le développement de modèles dans le workflow d'IA/DE ML.

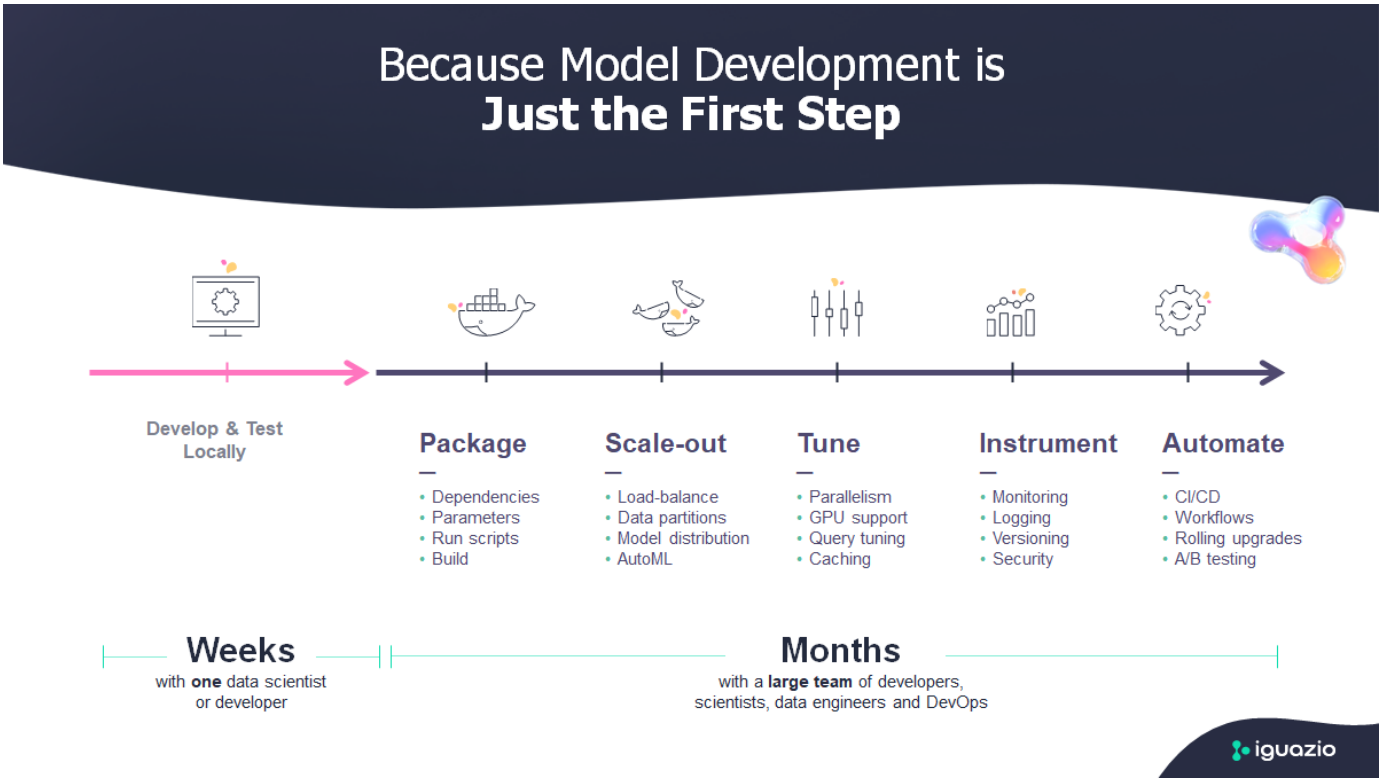

Pour gérer des projets d'IA et DE ML de bout en bout, il faut avoir une vision plus large des composants de l'entreprise. Bien que le DevOps ait terminé la définition, l'intégration et le déploiement de ces types de composants, les opérations de machine learning ciblent un flux similaire qui inclut les projets d'IA/ML. Pour découvrir ce qu'un pipeline IA/ML de bout en bout touche dans l'entreprise, consultez la liste suivante de composants :

- Stockage
- Mise en réseau
- Les bases de données

- Systèmes de fichiers
- Conteneurs
- Intégration continue et pipeline de déploiement continu (ci/CD)
- Environnement de développement intégré (IDE)
- Sécurité
- Règles d’accès aux données
- Sous-jacent
- Le cloud
- Virtualisation
- Bibliothèques et jeux d’outils de science des données

Dans ce document, nous avons démontré que le partenariat entre NetApp et Iguazio simplifie considérablement le développement d’un pipeline IA/ML de bout en bout. Cette simplification accélère le time-to-market de toutes vos applications d’IA/ML.

Public visé

L’univers de la science des données touche de nombreuses disciplines en informatique et en affaires.

- Les data Scientists doivent donc pouvoir utiliser leurs outils et leurs bibliothèques de choix.
- L’ingénieur doit savoir comment les données circulent et où elles résident.
- Un ingénieur DevOps doit disposer des outils nécessaires pour intégrer les nouvelles applications d’IA et DE ML dans son pipeline ci/CD.
- Les utilisateurs professionnels veulent avoir accès aux applications d’IA et DE ML. Nous décrivons comment NetApp et Iguazio aident chacun de ces rôles à apporter de la valeur ajoutée à nos plateformes.

Présentation de la solution

Cette solution suit le cycle de vie d’une application d’IA/DE ML. Nous commençons par le travail des data Scientists pour définir les différentes étapes requises pour préparer les données, et entraîner et déployer les modèles. Nous travaillons avec les tâches nécessaires pour créer un pipeline complet, capable de suivre les artéfacts, de réaliser des tests et de déployer avec Kubeflow. Pour terminer le cycle complet, nous avons intégré le pipeline avec NetApp Cloud volumes pour faciliter le contrôle des versions des données, comme illustré dans l’image suivante.

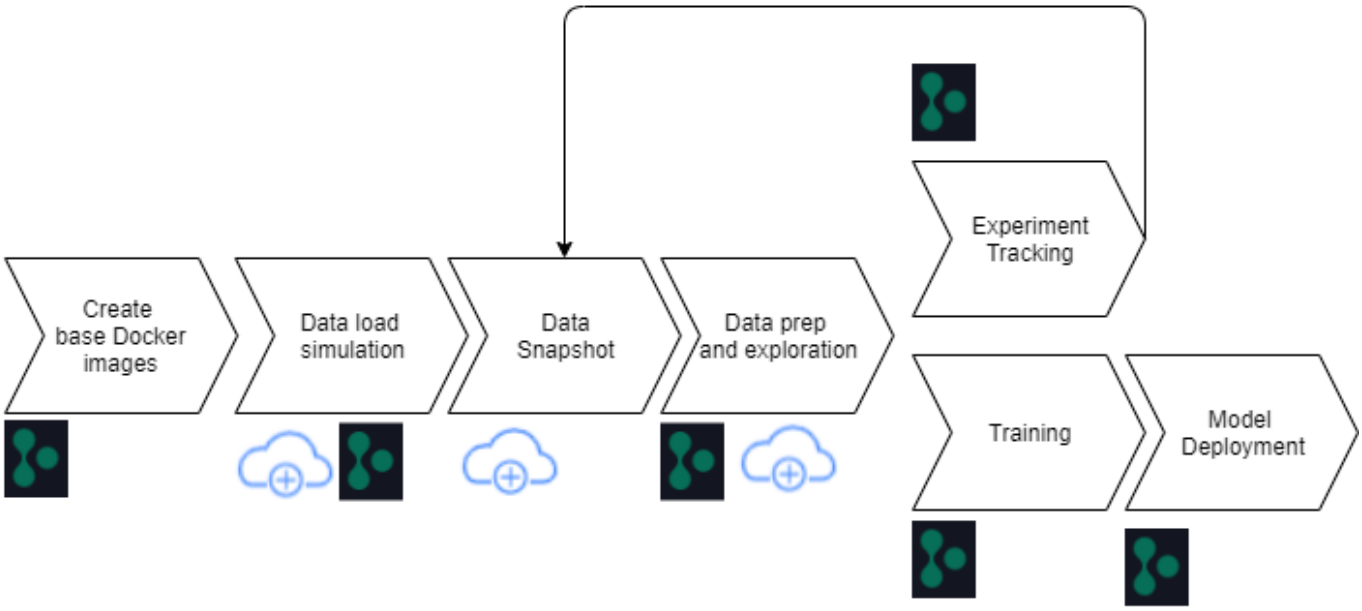

iguazio

Cloud Volumes ONTAP

"Suivant : présentation de la technologie"

Présentation de la technologie

Présentation de NetApp

NetApp est la référence en matière de gestion des données dans le cloud hybride NetApp propose une gamme complète de services qui simplifient la gestion des applications et des données dans les environnements cloud et sur site afin d'accélérer la transformation digitale. Avec ses partenaires, NetApp permet aux entreprises d'envergure mondiale d'exploiter tout le potentiel de leurs données afin de multiplier les points de contact avec les clients, de favoriser l'innovation et d'optimiser leurs opérations.

NetApp ONTAP ai

NetApp ONTAP ai, optimisé par les systèmes NVIDIA DGX et le stockage 100 % Flash connecté au cloud NetApp, rationalise le flux des données en toute fiabilité et accélère l'analytique, l'entraînement et l'inférence avec votre Data Fabric qui s'étend de la périphérie, au cœur jusqu'au cloud. Et présente plusieurs avantages pour les services IT :

- Simplifie la conception
- Offre une évolutivité indépendante des ressources de calcul et de stockage
- Possibilité de faire évoluer de manière fluide une infrastructure initiale de petite taille
- NetApp ONTAP ai propose toute une gamme d'options de stockage pour répondre à différents besoins de performance et de costesNetApp ai propose des piles d'infrastructure convergée intégrant NVIDIA DGX-1, un système d'IA à l'échelle du pétaflop, et des switchs Ethernet haute performance NVIDIA Mellanox pour unifier les workloads d'IA, simplifier le déploiement et accélérer le retour sur investissement. Nous avons utilisé ONTAP ai avec un DGX-1 et un système de stockage NetApp AFF A800 pour obtenir ce rapport technique. L'image suivante montre la topologie de ONTAP ai avec le système DGX-1 utilisé dans cette

validation.

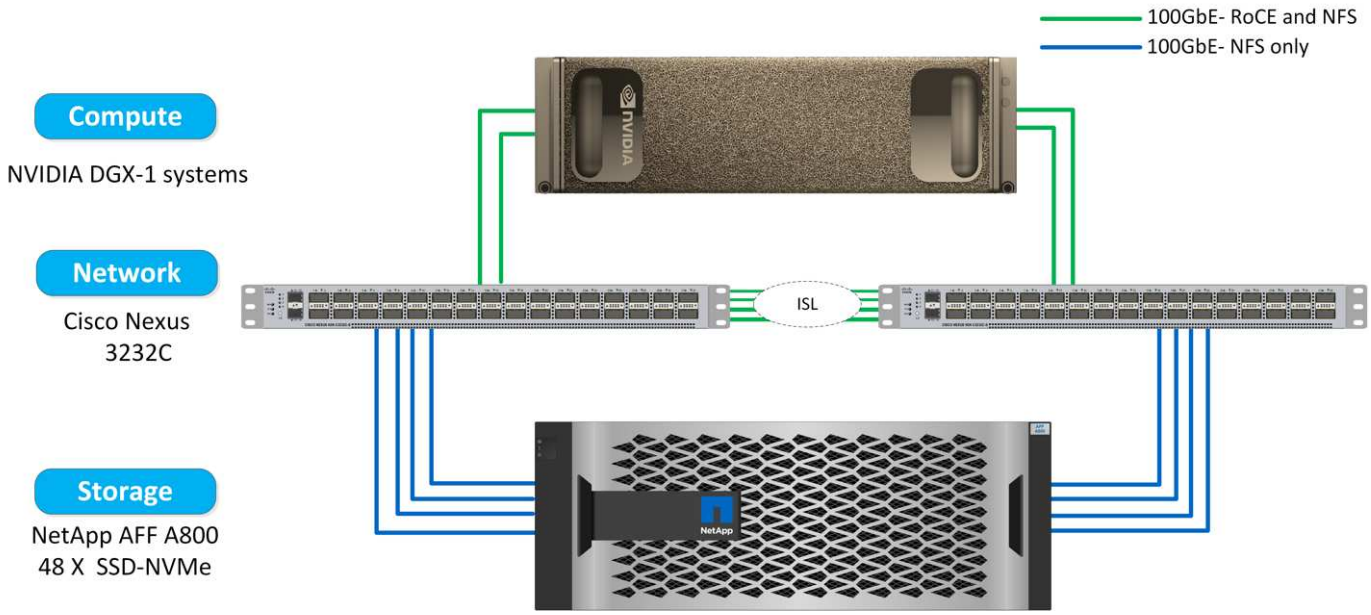

Plan de contrôle d'IA NetApp

NetApp ai Control plane vous permet de libérer le potentiel de l'IA et DE L'AM avec une solution qui offre une évolutivité extrême, des déploiements rationalisés et une disponibilité continue des données. La solution ai Control plane intègre Kubernetes et Kubeflow avec une Data Fabric NetApp. Kubernetes, la plateforme standard d'orchestration de conteneurs pour les déploiements cloud, assure l'évolutivité et la portabilité des workloads. Kubeflow est une plateforme de machine learning open-source qui simplifie la gestion et les déploiements, et permet aux développeurs d'optimiser leurs activités de data science. Une Data Fabric NetApp fournit une disponibilité et une portabilité optimales des données pour s'assurer que vos données sont accessibles dans l'ensemble du pipeline, de la périphérie au cœur et jusqu'au cloud. Ce rapport technique utilise le plan de contrôle NetApp ai dans un pipeline MLRun. L'image suivante présente la page de gestion de cluster Kubernetes dans laquelle vous pouvez avoir des terminaux différents pour chaque cluster. Nous avons connecté des volumes persistants NFS au cluster Kubernetes. Les images suivantes montrent un volume persistant connecté au cluster, où "NetApp Trident" offre une prise en charge du stockage persistant et des fonctionnalités de gestion des données.

Kubernetes Clusters

Discover Cluster

4 Kubernetes Clusters

kubernetes

https://3.20.111.39:6443
Cluster Endpoint

v1.15.5
Cluster Version

19.07.1
Trident Version

0
Working Environments

kubernetes

https://172.31.14.31:6443
Cluster Endpoint

v1.15.5
Cluster Version

19.07.1
Trident Version

1
Working Environments

Persistent Volumes for Kubernetes

Connected with Kubernetes Cluster

Cloud Volumes ONTAP is connected to 1 Kubernetes cluster. View Cluster

You can connect another Kubernetes cluster to this Cloud Volumes ONTAP system. If the Kubernetes cluster is in a different network than Cloud Volumes ONTAP, specify a custom export policy to provide access to clients.

Kubernetes Cluster

Select Kubernetes Cluster

kubernetes

Custom Export Policy *(Optional)*

Custom Export Policy

172.31.0.0/16

☑ Set as default storage class

◉ NFS ○ iSCSI

Connect

Cancel

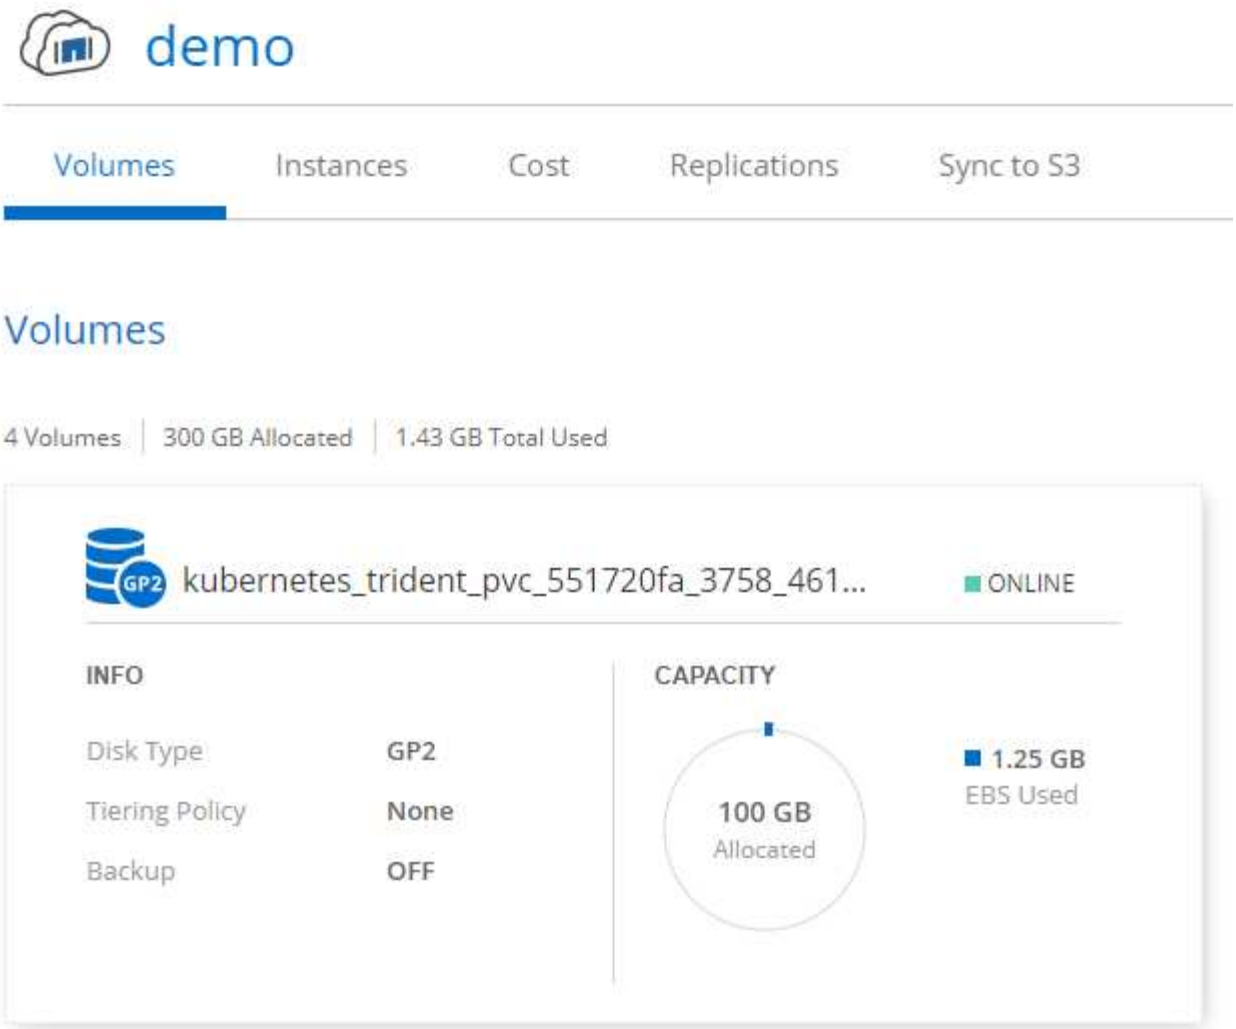

Vue d'ensemble d'Iguazio

Iguazio Data Science Platform est une plateforme de services en tant que service (PaaS) entièrement intégrée et sécurisée qui simplifie le développement, accélère les performances, facilite la collaboration et répond aux défis opérationnels. Cette plate-forme intègre les composants suivants, et la plate-forme Iguazio pour la science des données est présentée dans l'image suivante :

- Un atelier Data-science qui comprend des ordinateurs portables Jupyter, des moteurs d'analyse intégrés et des solutions Python
- Gestion des modèles avec suivi des expériences et fonctionnalités de pipeline automatisées
- Gérer des données et des services DE ML sur un cluster Kubernetes évolutif
- Nucio, une structure de fonctions sans serveur en temps réel
- Couche de données extrêmement rapide et sécurisée qui prend en charge SQL, NoSQL, les bases de données de séries chronologiques, les fichiers (objets simples) et la diffusion en continu
- Intégration avec les bases de données tierces telles que NetApp, Amazon S3, HDFS, SQL et les protocoles de streaming ou de messagerie
- Tableaux de bord en temps réel basés sur Grafana

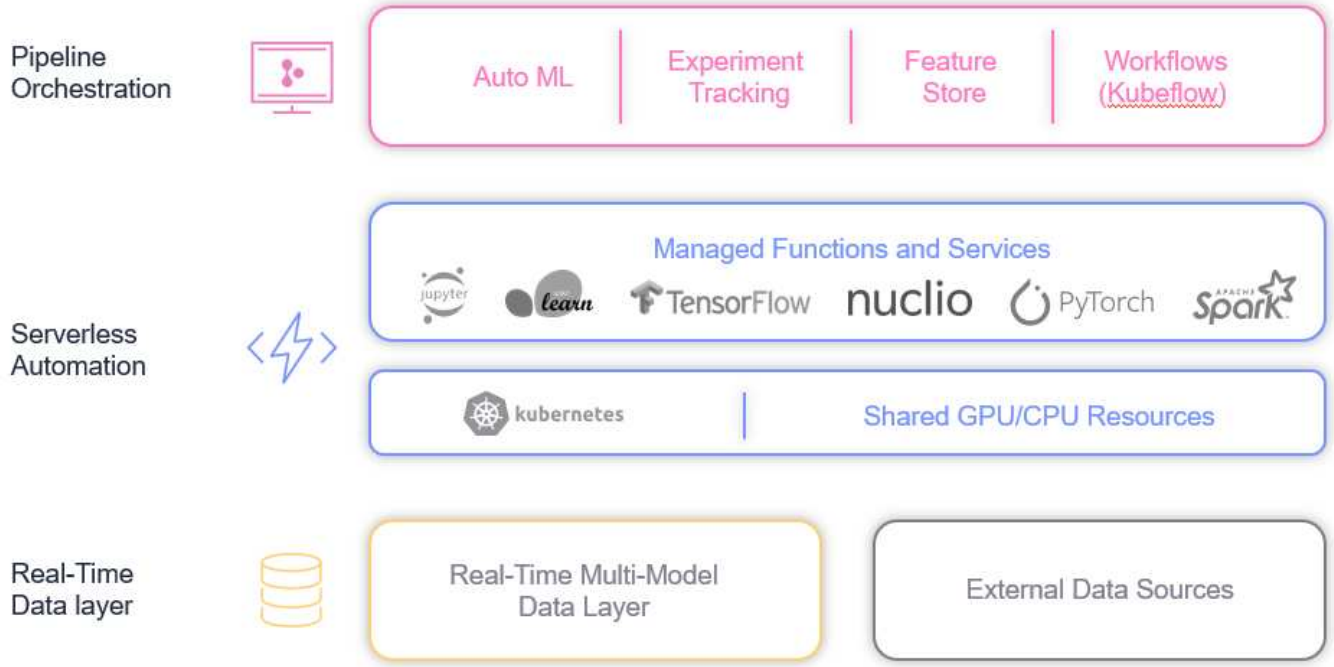

"Ensuite : configuration logicielle et matérielle requise"

Configuration logicielle et matérielle requise

Configuration du réseau

Voici les exigences de configuration réseau pour la configuration dans le cloud :

- Le cluster Iguazio et NetApp Cloud volumes doivent se trouver dans le même cloud privé virtuel.
- Le responsable cloud doit avoir accès au port 6443 sur les nœuds applicatifs Iguazio.
- Nous avons utilisé Amazon Web Services dans ce rapport technique. Toutefois, les utilisateurs peuvent déployer la solution auprès de n'importe quel fournisseur cloud.pour les tests sur site de ONTAP ai avec NVIDIA DGX-1, nous avons utilisé le service DNS hébergé d'Iguazio pour des raisons de commodité.

Les clients doivent pouvoir accéder aux domaines DNS créés de manière dynamique. Les clients peuvent utiliser leur propre DNS si nécessaire.

Configuration matérielle requise

Vous pouvez installer Iguazio sur site dans votre propre cluster. Nous avons vérifié la solution dans NetApp ONTAP ai avec un système NVIDIA DGX-1. Le tableau suivant répertorie le matériel utilisé pour tester cette solution.

Sous-jacent	Quantité
Systèmes DGX-1	1
Système NetApp AFF A800	1 paire haute disponibilité (HA), comprend 2 contrôleurs et 48 SSD NVMe (3,8 To ou plus)
Switchs réseau Cisco Nexus 3232C	2

Le tableau suivant répertorie les composants logiciels requis pour les tests sur site :

Logiciel	Version ou autres informations
Le logiciel de gestion des données NetApp ONTAP	9.7
Firmware du switch Cisco NX-OS	7.0(3)I6(1)
SYSTÈME D'EXPLOITATION NVIDIA DGX	4.4 - Ubuntu 18.04 LTS
Plateforme de conteneurisation Docker	19.03.5
Version du conteneur	20.01-tf1-py2
Framework de machine learning	TensorFlow 1.15.0
Iguazio	Version 2.8+
Serveur ESX	6.5

Cette solution a été entièrement testée avec Iguazio version 2.5 et NetApp Cloud Volumes ONTAP pour AWS. Le cluster Iguazio et le logiciel NetApp s'exécutent tous les deux sur AWS.

Logiciel	Version ou type
Iguazio	Version 2.8+
Nœud d'application	M5.4xlarge
Nœud de données	I3,4xlarge

"Suivant : Résumé des cas d'utilisation de la prédiction d'échec du périphérique réseau"

Résumé de cas d'utilisation de la prédiction de défaillance du périphérique réseau

Ce cas d'utilisation est basé sur un client d'Iguazio dans le secteur des télécommunications en Asie. Avec 100 000 clients grands comptes et 125 000 pannes réseau par an, il était essentiel de prévoir et d'agir de manière proactive pour éviter que les défaillances réseau n'affectent les clients. Cette solution a apporté à l'entreprise les avantages suivants :

- Analyses prédictives pour les défaillances réseau
- Intégration avec un système de gestion des tickets
- En prenant des mesures proactives pour prévenir les défaillances réseau suite à cette mise en œuvre d'Iguazio, 60% des échecs ont été évités de manière proactive.

"Suivant : présentation de la configuration"

Présentation de la configuration

Installation d'Iguazio

Iguazio peut être installé sur site ou sur un fournisseur cloud. Le provisionnement peut être effectué à la demande et géré par Iguazio ou par le client. Iguazio propose, dans les deux cas, une application de déploiement (Provazio) pour déployer et gérer des clusters.

Pour une installation sur site, reportez-vous à la section "NVA-1121" pour la configuration des ressources de calcul, de réseau et de stockage. Le déploiement sur site d'Iguazio est assuré par Iguazio sans frais supplémentaires pour le client. Voir "cette page" Pour les configurations de serveurs DNS et SMTP. La page d'installation de Provazio est illustrée ci-dessous.

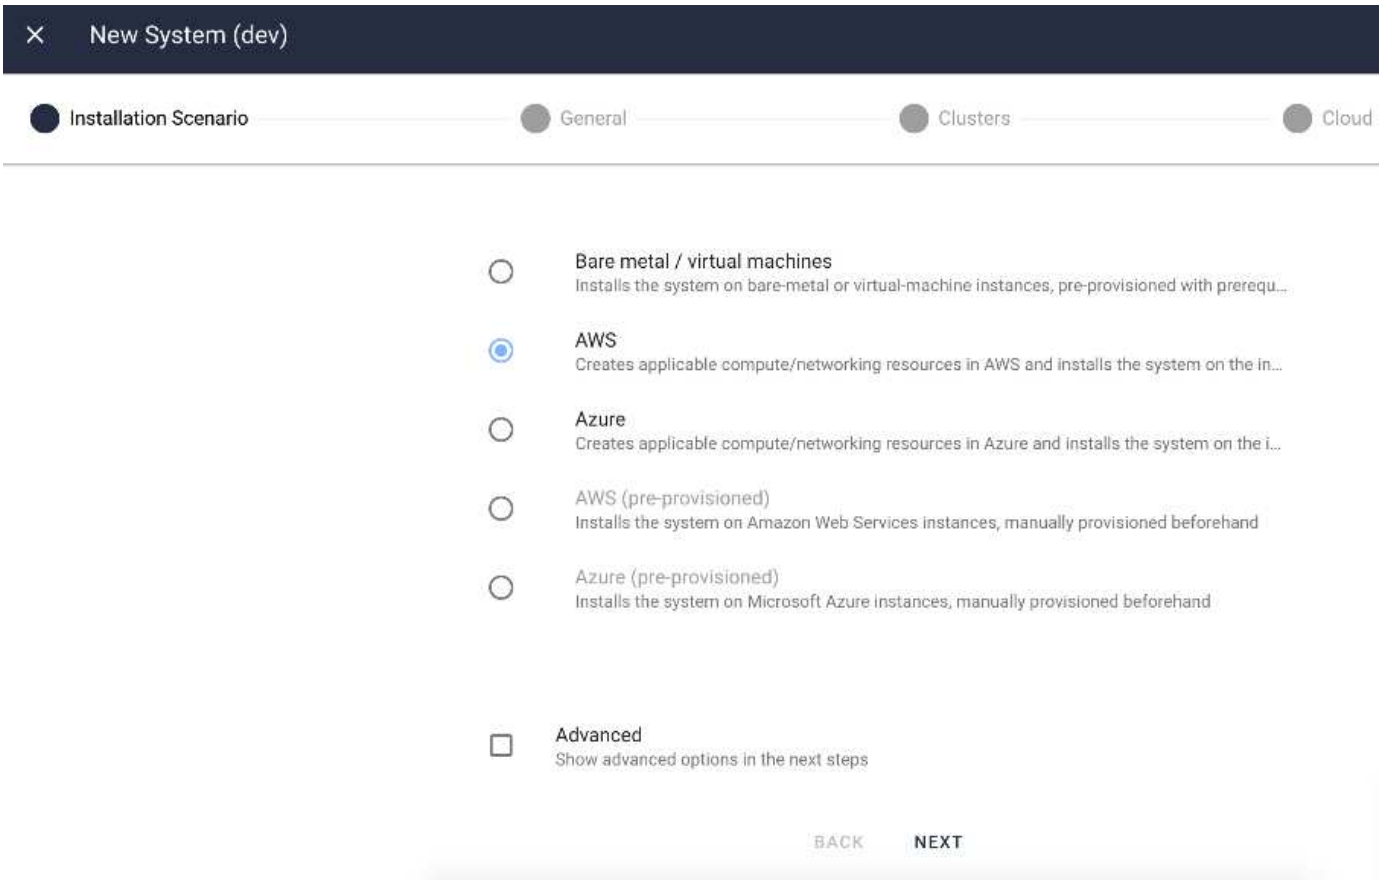

"Suivant : configuration du cluster Kubernetes"

Configuration du cluster Kubernetes

Cette section comprend deux parties pour le déploiement dans le Cloud et sur site, respectivement.

Configuration de Cloud Deployment Kubernetes

Grâce à NetApp Cloud Manager, vous pouvez définir la connexion au cluster Iguazio Kubernetes. Trident requiert l'accès à plusieurs ressources au sein du cluster pour rendre le volume disponible.

1. Pour activer l'accès, procurez-vous le fichier de configuration Kubernetes à partir d'un des nœuds Iguazio. Le fichier se trouve sous `/home/Iguazio/.kube/config`. Téléchargez ce fichier sur votre bureau.
2. Accédez à découverte du cluster à configurer.

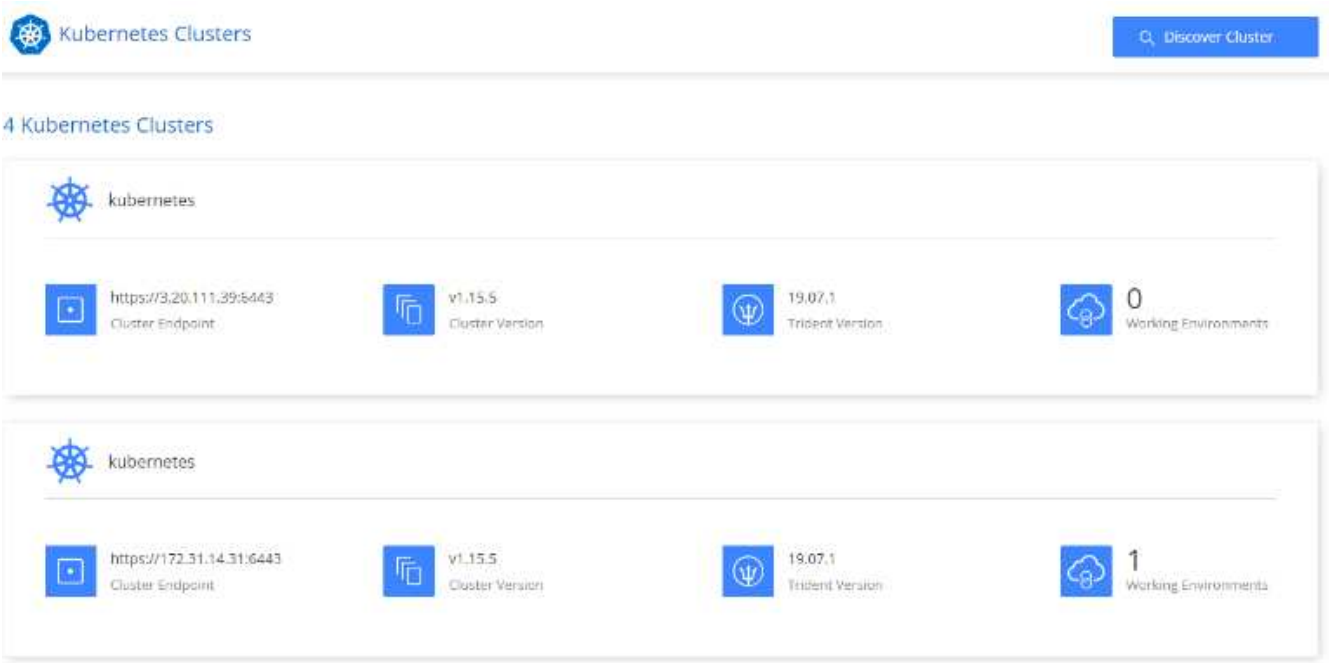

3. Téléchargez le fichier de configuration Kubernetes. Voir l'image suivante.

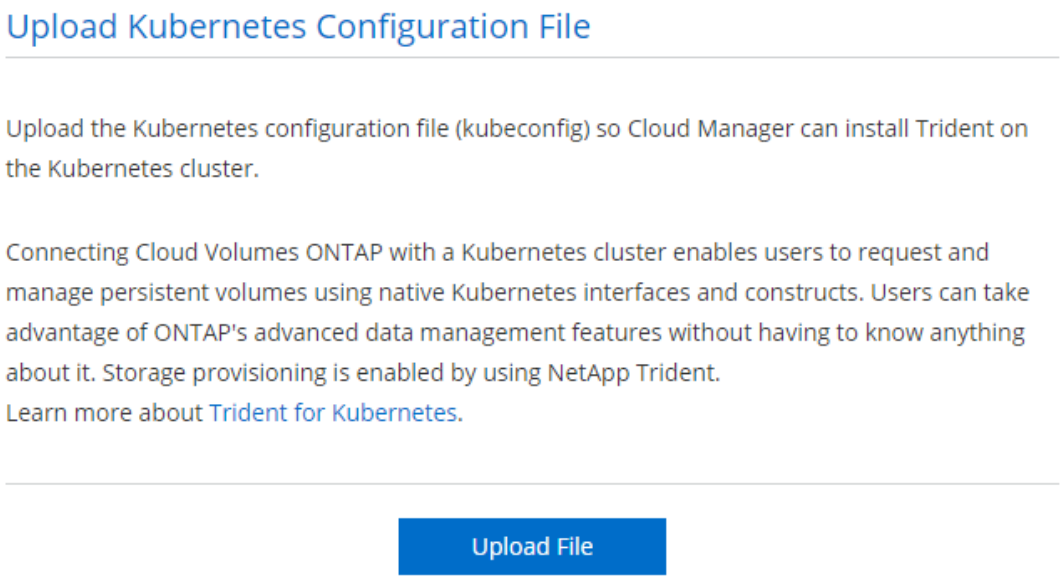

4. Déployez Trident et associez un volume au cluster. Consultez l'image suivante sur la définition et l'attribution d'un volume persistant au cluster Iguazio.ce processus crée un volume persistant dans le cluster Kubernetes d'Iguazio. Avant de pouvoir l'utiliser, vous devez définir une demande de volume persistant.

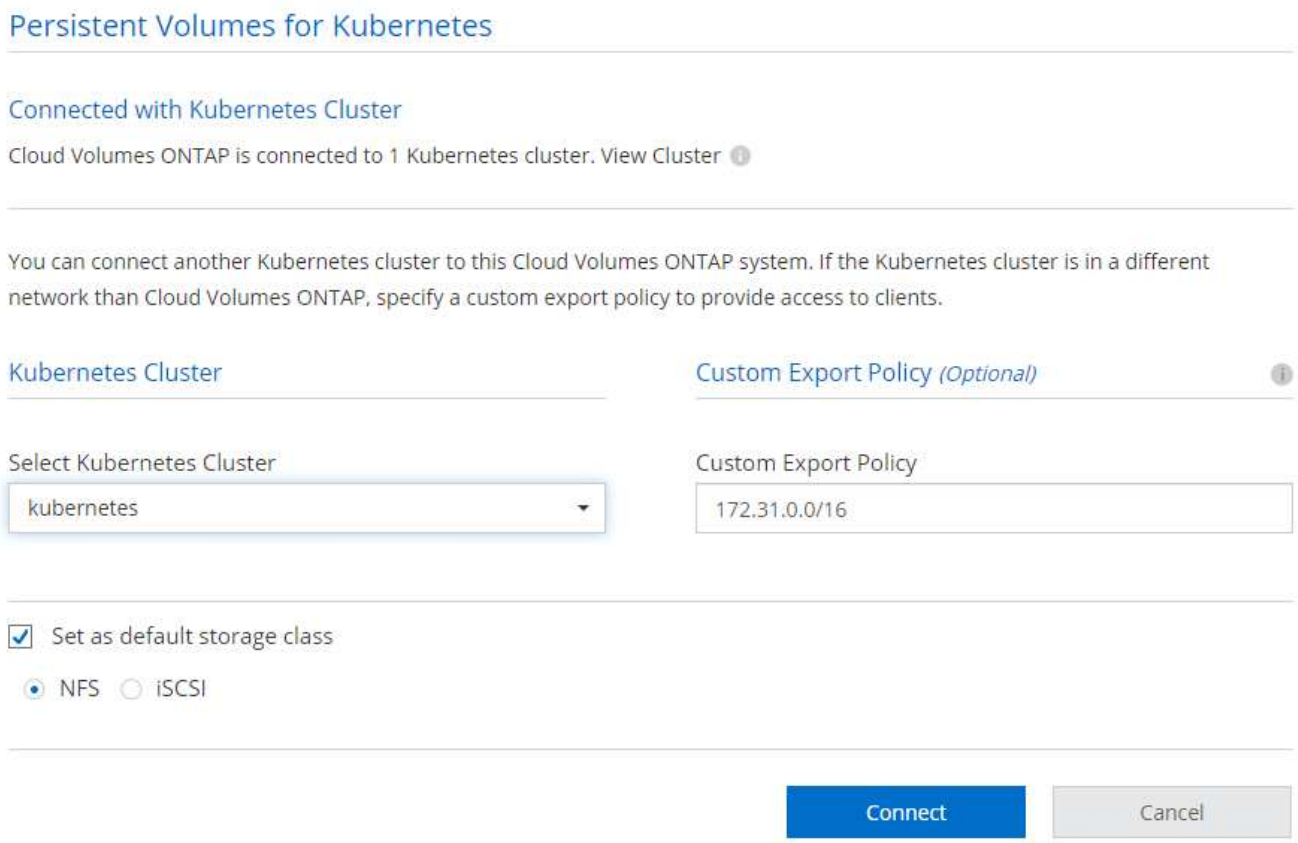

Configuration Kubernetes de déploiement sur site

Pour l'installation sur site de NetApp Trident, consultez la section "TR-4798" pour plus d'informations. Une fois votre cluster Kubernetes configuré et installé NetApp Trident, vous pouvez vous connecter à Trident au cluster Iguazio pour activer les fonctionnalités de gestion des données NetApp, comme l'utilisation de copies Snapshot de vos données et de votre modèle.

"Suivant : définissez une demande de volume persistant"

Définition de la demande de volume persistant

1. Enregistrez le YAML suivant dans un fichier pour créer un PVC de type Basic.

```
kind: PersistentVolumeClaim
apiVersion: v1
metadata:
  name: basic
spec:
  accessModes:
    - ReadWriteOnce
  resources:
    requests:
      storage: 100Gi
  storageClassName: netapp-file
```

2. Appliquez le fichier YAML sur votre cluster Kubernetes Iguazio.

```
Kubectl -n default-tenant apply -f <your yaml file>
```

Relier un volume NetApp au bloc-notes Jupyter

Iguazio propose plusieurs services gérés afin de fournir aux data Scientists une pile complète pour le développement et le déploiement d'applications d'IA/ML. Pour en savoir plus sur ces composants, consultez le "Iguazio Présentation des services et outils d'application".

Jupyter Notebook est l'un des services gérés. Chaque développeur a son propre déploiement d'un conteneur d'ordinateur portable avec les ressources dont il a besoin pour le développement. Pour leur donner accès à NetApp Cloud Volume, vous pouvez attribuer le volume à leur container et à leur allocation des ressources, exécuter les paramètres des utilisateurs et des variables d'environnement pour les demandes de volume persistant. Cette image présente.

Pour une configuration sur site, vous pouvez vous reporter à "TR-4798" Vous configurez Trident pour activer les fonctionnalités de gestion des données de NetApp ONTAP, comme l'exécution de copies Snapshot de vos données ou un modèle pour le contrôle des versions. Ajoutez la ligne suivante dans votre fichier de configuration back-end Trident pour rendre les répertoires Snapshot visibles :

```
{
    …
    "defaults": {
        "snapshotDir": "true"
    }
}
```

Vous devez créer un fichier de configuration back-end Trident au format JSON, puis exécuter la commande suivante "Commande Trident" pour la référencer :

```
tridentctl create backend -f <backend-file>
```

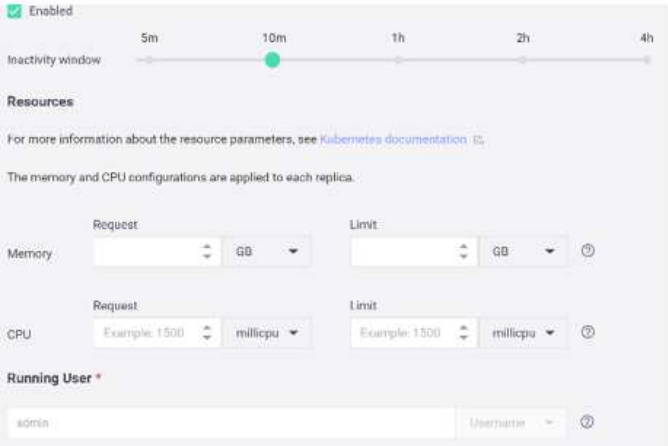

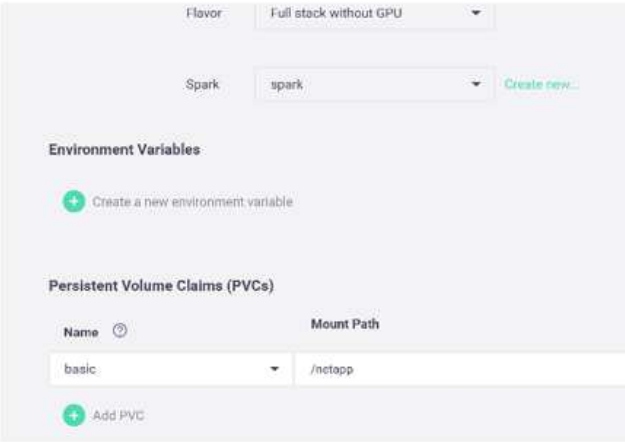

"Suivant : déploiement de l'application"

Déploiement de l'application

Les sections suivantes décrivent comment installer et déployer l'application.

"Suivant : procurez-vous le code sur GitHub".

Obtenir le code à partir de GitHub

Maintenant que le volume NetApp Cloud Volume ou NetApp Trident est disponible pour le cluster Iguazio et l'environnement de développement, vous pouvez passer en revue l'application.

Les utilisateurs ont leur propre espace de travail (répertoire). Sur chaque ordinateur portable, le chemin d'accès au répertoire de l'utilisateur est `/User`. La plateforme Iguazio gère le répertoire. Si vous suivez les instructions ci-dessus, le volume NetApp Cloud est disponible dans le `/netapp` répertoire.

Obtenir le code à partir de GitHub à l'aide d'un terminal Jupyter.

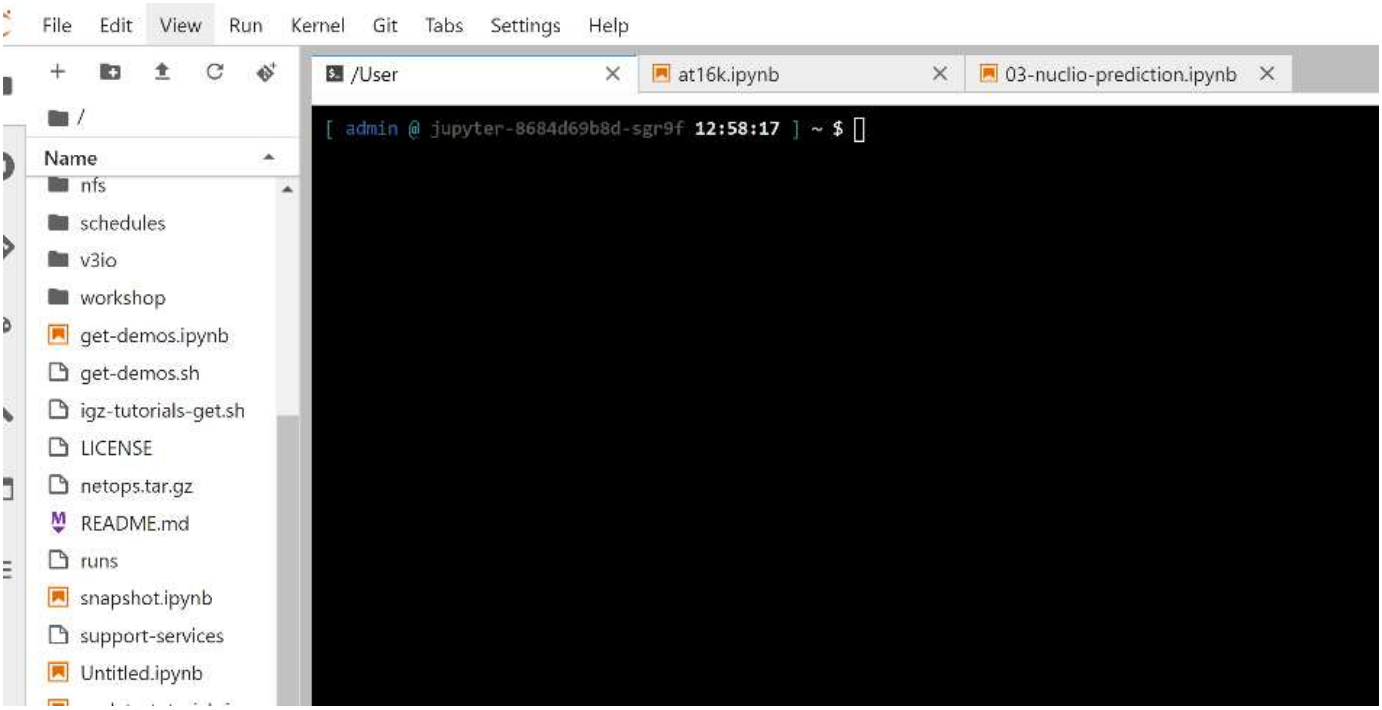

À l'invite du terminal Jupyter, clonez le projet.

```
cd /User
git clone .
```

Vous devriez maintenant voir le `netops- netapp` Dans l'arborescence des fichiers de l'espace de travail Jupyter.

"Suivant : configurer l'environnement de travail"

Configurer l'environnement de travail

Copiez le `Notebook set_env-Example.ipynb` comme `set_env.ipynb`. Ouvrez et modifiez `set_env.ipynb`. Ce bloc-notes définit des variables pour les informations d'identification, l'emplacement des fichiers et les pilotes d'exécution.

Si vous suivez les instructions ci-dessus, les seules modifications à apporter sont les suivantes :

1. Pour bénéficier de cette valeur, nous vous leguazio : `docker_registry`

   Exemple : `docker-registry.default-tenant.app.clusterq.iguaziodev.com:80`

2. Changer `admin` Pour votre nom d'utilisateur Iguazio :

   ```
   IGZ_CONTAINER_PATH = '/users/admin'
   ```

   Détails de connexion du système ONTAP : Incluez le nom du volume généré lors de l'installation de Trident. Le paramètre suivant est défini pour un cluster ONTAP sur site :

   ```
   ontapClusterMgmtHostname = '0.0.0.0'
   ontapClusterAdminUsername = 'USER'
   ontapClusterAdminPassword = 'PASSWORD'
   sourceVolumeName = 'SOURCE VOLUME'
   ```

   Le paramètre suivant est pour Cloud Volumes ONTAP :

```
MANAGER=ontapClusterMgmtHostname
svm='svm'
email='email'
password=ontapClusterAdminPassword
weid="weid"
volume=sourceVolumeName
```

Créer des images Docker de base

Tout ce dont vous avez besoin pour créer un pipeline DE ML est inclus dans la plateforme Iguazio. Le développeur peut définir les spécifications des images Docker nécessaires à l'exécution du pipeline et à l'exécution de la création d'images à partir de Jupyter Notebook. Ouvrez le bloc-notes `create-images.ipynb` Et exécuter toutes les cellules.

Ce bloc-notes crée deux images que nous utilisons dans le pipeline.

- `iguazio/netapp.` Utilisé pour traiter les tâches DE ML.

Create image for training pipeline

```
[4]: fn.build_config(image=docker_registry+'/iguazio/netapp', commands=['pip install \
     v3io_frames fsspec>=0.3.3 PyYAML==5.1.2 pyarrow==0.15.1 pandas==0.25.3 matplotlib seaborn yellowb
     fn.deploy()
```

- `netapp/pipeline`. Contient des utilitaires pour la gestion des copies NetApp Snapshot.

Create image for Ontap utilitites

```
[9]: fn.build_config(image=docker_registry + '/netapp/pipeline:latest',commands=['apt -y update','pip install v3io_frames netapp_ontap'
     fn.deploy()
```

Examinez les ordinateurs portables Jupyter individuels

Le tableau suivant répertorie les bibliothèques et les structures que nous avons utilisées pour créer cette tâche. Tous ces composants ont été pleinement intégrés aux contrôles d'accès et de sécurité basés sur les rôles d'Iguazio.

Bibliothèques/Framework	Description
MLRun	Géré par Iguazio pour l'assemblage, l'exécution et le contrôle d'un pipeline DE ML/IA.
Nucio	Un cadre de fonctions sans serveur intégré à Iguazio. Également disponible en tant que projet open source géré par Iguazio.
Kubeflow	Framework basé sur Kubernetes pour déployer le pipeline. Il s'agit également d'un projet open-source auquel Iguazio contribue. Il est intégré à Iguazio pour renforcer la sécurité et l'intégration avec le reste de l'infrastructure.
Docker	Un registre Docker fonctionne à la demande sur la plateforme Iguazio. Vous pouvez également le modifier pour vous connecter à votre registre.
NetApp Cloud volumes	Les systèmes Cloud volumes exécutés sur AWS nous permettent d'accéder à d'importants volumes de données et de créer des copies Snapshot pour les datasets utilisés à des fins d'entraînement.
Trident	Trident est un projet open source géré par NetApp. Il facilite l'intégration aux ressources de stockage et de calcul dans Kubernetes.

Nous avons utilisé plusieurs ordinateurs portables pour construire le pipeline DE ML. Chaque ordinateur portable peut être testé individuellement avant d'être rassemblé dans le pipeline. Nous abordons chaque ordinateur portable individuellement après le processus de déploiement de cette application de démonstration.

Le résultat souhaité est un pipeline qui forme un modèle basé sur une copie Snapshot des données et déploie le modèle pour l'inférence. Un schéma fonctionnel d'un pipeline MLRun terminé est présenté dans l'image suivante.

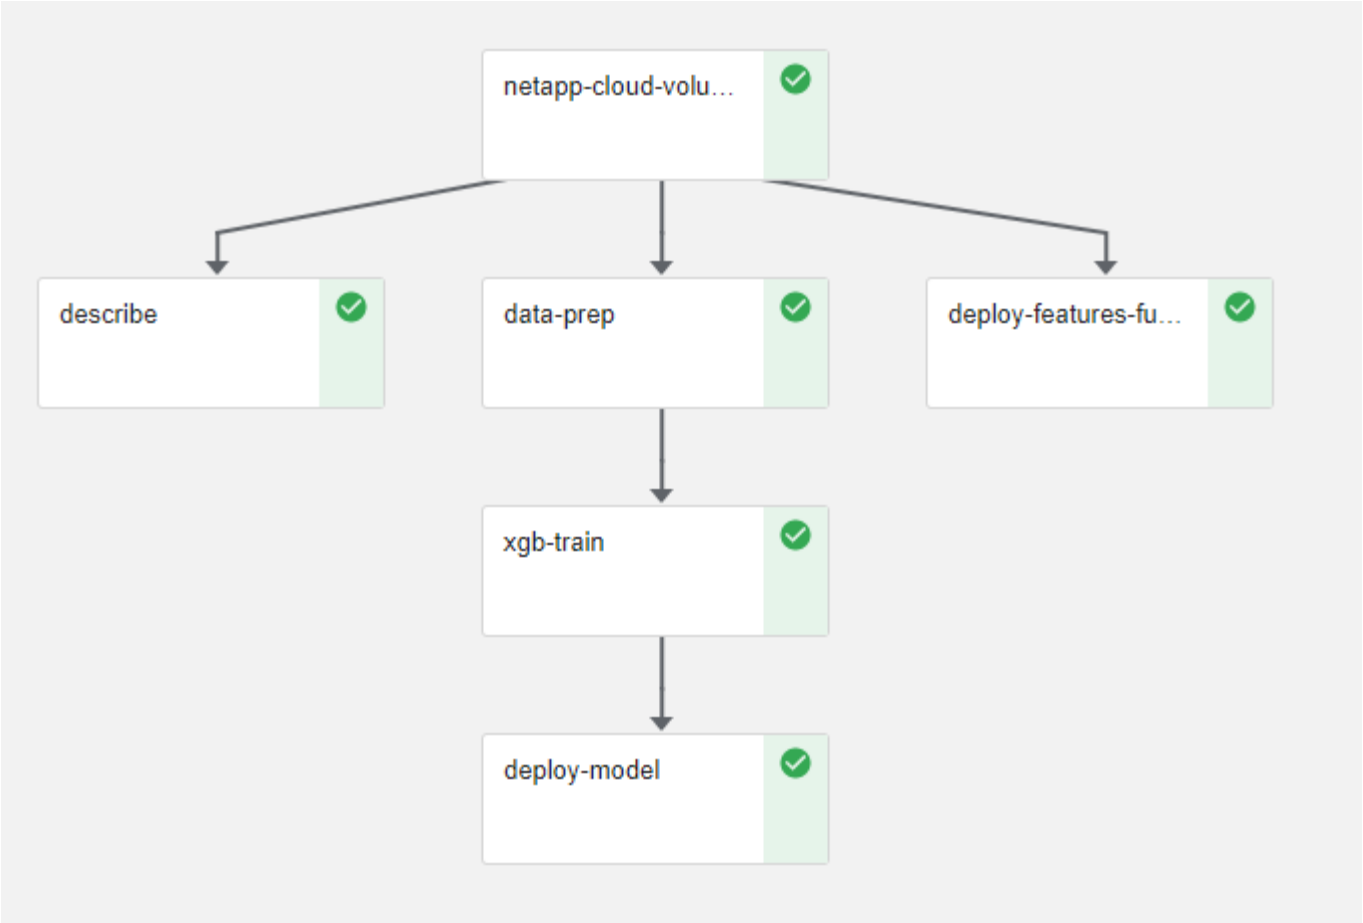

Déployer la fonction Data Generation

Cette section décrit comment nous avons utilisé les fonctions sans serveur Nucio pour générer des données de périphériques réseau. L'utilisation est adaptée à partir d'un client Iguazio qui a déployé le pipeline et utilisé les services Iguazio pour surveiller et prévoir les défaillances des périphériques réseau.

Nous avons simulé des données provenant de périphériques réseau. Exécution du bloc-notes Jupyter `data-generator.ipynb` Crée une fonction sans serveur qui s'exécute toutes les 10 minutes et génère un fichier parquet avec de nouvelles données. Pour déployer la fonction, exécutez toutes les cellules de ce bloc-notes. Voir la "Site Web de Nucio" pour passer en revue les composants inconnus de cet ordinateur portable.

Une cellule avec le commentaire suivant est ignorée lors de la génération de la fonction. Chaque cellule de l'ordinateur portable est supposée faire partie de la fonction. Importez le module Nucio pour l'activer `%nuclio magic`.

```
# nuclio: ignore
import nuclio
```

Dans la spécification de la fonction, nous avons défini l'environnement dans lequel la fonction s'exécute, la façon dont elle est déclenchée et les ressources qu'elle consomme.

```
spec = nuclio.ConfigSpec(config={"spec.triggers.inference.kind":"cron",

"spec.triggers.inference.attributes.interval" :"10m",
                                "spec.readinessTimeoutSeconds" : 60,
                                "spec.minReplicas" : 1},……
```

Le `init_context` La fonction est appelée par Nucio framework lors de l'initialisation de la fonction.

```
def init_context(context):
    ….
```

Tout code qui ne figure pas dans une fonction est appelé lors de l'initialisation de la fonction. Lorsque vous l'appelez, une fonction de gestionnaire est exécutée. Vous pouvez modifier le nom du gestionnaire et le spécifier dans la spécification de fonction.

```
def handler(context, event):
            …
```

Vous pouvez tester la fonction à partir de l'ordinateur portable avant le déploiement.

```
%%time
# nuclio: ignore
init_context(context)
event = nuclio.Event(body='')
output = handler(context, event)
output
```

La fonction peut être déployée à partir de l'ordinateur portable ou déployée à partir d'un pipeline ci/CD (adaptation de ce code).

```
addr = nuclio.deploy_file(name='generator',project='netops',spec=spec,
tag='v1.1')
```

Ordinateurs portables Pipeline

Ces ordinateurs portables ne sont pas conçus pour être exécutés individuellement pour cette configuration. Il s'agit simplement d'un examen de chaque ordinateur portable. Nous les avons appelés dans le cadre du pipeline. Pour les exécuter individuellement, consultez la documentation MLRun pour les exécuter en tant que travaux Kubernetes.

snap_cv.ipynb

Cet ordinateur portable gère les copies Snapshot Cloud Volume au début du pipeline. Elle transmet le nom du

volume au contexte du pipeline. Cet ordinateur portable appelle un script shell pour gérer la copie Snapshot. Lors de l'exécution dans le pipeline, le contexte d'exécution contient des variables qui aident à localiser tous les fichiers nécessaires à l'exécution. Lors de l'écriture de ce code, le développeur n'a pas à s'inquiéter de l'emplacement du fichier dans le conteneur qui l'exécute. Comme décrit plus loin, cette application est déployée avec toutes ses dépendances, et c'est la définition des paramètres de pipeline qui fournit le contexte d'exécution.

```
command = os.path.join(context.get_param('APP_DIR'),"snap_cv.sh")
```

L'emplacement de copie Snapshot créé est placé dans le contexte MLRun pour être utilisé par étapes dans le pipeline.

```
context.log_result('snapVolumeDetails',snap_path)
```

Les trois ordinateurs portables suivants sont exécutés en parallèle.

data-prep.ipynb

Les metrics brutes doivent être intégrés à des fonctionnalités pour permettre l'entraînement des modèles. Cet ordinateur portable lit les mesures brutes du répertoire Snapshot et écrit les fonctionnalités d'entraînement des modèles dans le volume NetApp.

Lors de l'exécution dans le contexte du pipeline, l'entrée `DATA_DIR` Contient l'emplacement de la copie Snapshot.

```
metrics_table = os.path.join(str(mlruncontext.get_input('DATA_DIR',
os.getenv('DATA_DIR','/netpp'))),
                             mlruncontext.get_param('metrics_table',
os.getenv('metrics_table','netops_metrics_parquet')))
```

description.ipynb

Pour visualiser les mesures entrantes, nous déployons une étape de pipeline qui fournit des tracés et des graphiques disponibles via les UI Kubeflow et MLRun. Chaque exécution a sa propre version de cet outil de visualisation.

```
ax.set_title("features correlation")
plt.savefig(os.path.join(base_path, "plots/corr.png"))
context.log_artifact(PlotArtifact("correlation",  body=plt.gcf()),
local_path="plots/corr.html")
```

deploy-feature-function.ipynb

Nous surveillons en permanence les indicateurs des anomalies pour y détecter des anomalies. Cet ordinateur portable crée une fonction sans serveur qui génère les fonctionnalités qui doivent exécuter la prédiction des mesures entrantes. Ce bloc-notes appelle la création de la fonction. Le code de fonction se trouve dans le

bloc-notes `data- prep.ipynb`. Notez que nous utilisons le même bloc-notes qu'une étape dans le pipeline à cette fin.

formation.ipynb

Une fois les fonctions créées, nous déclenchements l'entraînement du modèle. Cette étape permet d'utiliser le modèle à utiliser pour l'inférence. Nous recueillons également des statistiques pour garder le suivi de chaque exécution (expérience).

Par exemple, la commande suivante saisit le score de précision dans le contexte de cette expérience. Cette valeur est visible dans Kubeflow et MLRun.

```
context.log_result('accuracy',score)
```

déploiement-inférence-fonction.ipynb

La dernière étape du pipeline consiste à déployer le modèle comme une fonction sans serveur pour l'inférence continue. Ce bloc-notes appelle la création de la fonction sans serveur définie dans `nuclio-inference-function.ipynb`.

Examiner et créer le pipeline

La combinaison de l'exécution de tous les ordinateurs portables dans un pipeline permet à la série d'expériences continue de réévaluer la précision du modèle par rapport aux nouvelles mesures. Tout d'abord, ouvrez le `pipeline.ipynb` bloc-notes. Nous vous montrerons comment NetApp et Iguazio simplifient le déploiement de ce pipeline DE ML.

Nous utilisons MLRun pour fournir un contexte et gérer l'allocation des ressources à chaque étape du pipeline. Le service MLRun API s'exécute dans la plateforme Iguazio et constitue le point d'interaction avec les ressources Kubernetes. Chaque développeur ne peut pas demander des ressources directement ; l'API traite les demandes et active les contrôles d'accès.

```
# MLRun API connection definition
mlconf.dbpath = 'http://mlrun-api:8080'
```

Le pipeline peut fonctionner avec NetApp Cloud volumes et les volumes sur site. Cette démonstration a été conçue pour utiliser Cloud volumes, mais vous pouvez voir dans le code l'option d'exécution sur site.

```
# Initialize the NetApp snap fucntion once for all functions in a notebook
if [ NETAPP_CLOUD_VOLUME ]:
    snapfn =
code_to_function('snap',project='NetApp',kind='job',filename="snap_cv.ipyn
b").apply(mount_v3io())
    snap_params = {
    "metrics_table" : metrics_table,
    "NETAPP_MOUNT_PATH" : NETAPP_MOUNT_PATH,
    'MANAGER' : MANAGER,
    'svm' : svm,
    'email': email,
    'password': password ,
    'weid': weid,
    'volume': volume,
    "APP_DIR" : APP_DIR
       }
else:
    snapfn =
code_to_function('snap',project='NetApp',kind='job',filename="snapshot.ipy
nb").apply(mount_v3io())
….
snapfn.spec.image = docker_registry + '/netapp/pipeline:latest'
snapfn.spec.volume_mounts =
[snapfn.spec.volume_mounts[0],netapp_volume_mounts]
      snapfn.spec.volumes = [ snapfn.spec.volumes[0],netapp_volumes]
```

La première action nécessaire pour transformer un bloc-notes Jupyter en étape Kubeflow consiste à transformer le code en une fonction. Une fonction présente toutes les caractéristiques requises pour exécuter cet ordinateur portable. Lorsque vous faites défiler le bloc-notes, vous pouvez voir que nous définissons une fonction pour chaque étape du pipeline.

Partie du bloc-notes	Description
<code_to_function> (partie du module MLRun)	Nom de la fonction : nom du projet. permet d'organiser tous les artefacts du projet. Ceci est visible dans l'interface utilisateur MLRun. Nature. Dans ce cas, une tâche Kubernetes. Il peut s'agir de DASK, mpi, sparkk8s, et plus encore. Voir la documentation MLRun pour plus de détails. Fichier. Nom du bloc-notes. Ce peut également être un emplacement dans Git (HTTP).
image	Nom de l'image Docker utilisée à cette étape. Nous avons créé ceci précédemment avec le bloc-notes create-image.ipynb.
volume_montages et volumes	Informations détaillées sur le montage de NetApp Cloud Volume au moment de l'exécution.

Nous définissons également des paramètres pour les étapes.

```
params={   "FEATURES_TABLE":FEATURES_TABLE,
           "SAVE_TO" : SAVE_TO,
           "metrics_table" : metrics_table,
           'FROM_TSDB': 0,
           'PREDICTIONS_TABLE': PREDICTIONS_TABLE,
           'TRAIN_ON_LAST': '1d',
           'TRAIN_SIZE':0.7,
           'NUMBER_OF_SHARDS' : 4,
           'MODEL_FILENAME' : 'netops.v3.model.pickle',
           'APP_DIR' : APP_DIR,
           'FUNCTION_NAME' : 'netops-inference',
           'PROJECT_NAME' : 'netops',
           'NETAPP_SIM' : NETAPP_SIM,
           'NETAPP_MOUNT_PATH': NETAPP_MOUNT_PATH,
           'NETAPP_PVC_CLAIM' : NETAPP_PVC_CLAIM,
           'IGZ_CONTAINER_PATH' : IGZ_CONTAINER_PATH,
           'IGZ_MOUNT_PATH' : IGZ_MOUNT_PATH
            }
```

Une fois que vous avez défini la fonction pour toutes les étapes, vous pouvez construire le pipeline. Nous utilisons le `kfp` module pour définir cette définition. La différence entre l'utilisation de MLRun et le développement de votre propre bâtiment réside dans la simplification et le raccourcissement du codage.

Les fonctions que nous avons définies sont converties en composants STEP à l'aide du `as_step` Fonction de MLRun.

Définition de l'étape d'instantané

Lancez une fonction Snapshot, sortez et montez le v3io comme source :

```
snap = snapfn.as_step(NewTask(handler='handler',params=snap_params),
name='NetApp_Cloud_Volume_Snapshot',outputs=['snapVolumeDetails','training
_parquet_file']).apply(mount_v3io())
```

Paramètres	Détails
Nouvelle tâche	NewTask est la définition de l'exécution de la fonction.
(Module MLRun)	Gestionnaire. Nom de la fonction Python à appeler. Nous avons utilisé le gestionnaire de noms dans l'ordinateur portable, mais il n'est pas nécessaire. params. Les paramètres que nous avons transmis à l'exécution. Dans notre code, nous utilisons Context.get_param («PARAMÈTRE») pour obtenir les valeurs.

Paramètres	Détails
as_step	Nom. Nom de l'étape du pipeline Kubeflow. sorties. Il s'agit des valeurs que l'étape ajoute au dictionnaire à la fin de l'étude. Regardez le bloc-notes Snap_cv.ipynb. mount_v3io(). Cette opération permet de configurer l'étape pour monter /User pour l'utilisateur exécutant le pipeline.

```
prep = data_prep.as_step(name='data-prep',
handler='handler',params=params,
                          inputs = {'DATA_DIR':
snap.outputs['snapVolumeDetails']} ,

out_path=artifacts_path).apply(mount_v3io()).after(snap)
```

Paramètres	Détails
entrées	Vous pouvez passer à une étape les sorties d'une étape précédente. Dans ce cas, snap.outputs['napVolumeDetails'] correspond au nom de la copie Snapshot que nous avons créée à l'étape d'instantané.
chemin_sortie	Emplacement permettant de placer des artefacts générant à l'aide du module MLRun log_artefacts.

Vous pouvez exécuter `pipeline.ipynb` de haut en bas. Vous pouvez ensuite accéder à l'onglet pipelines à partir du tableau de bord Iguazio pour contrôler la progression comme indiqué dans l'onglet Iguazio Dashboard pipelines.

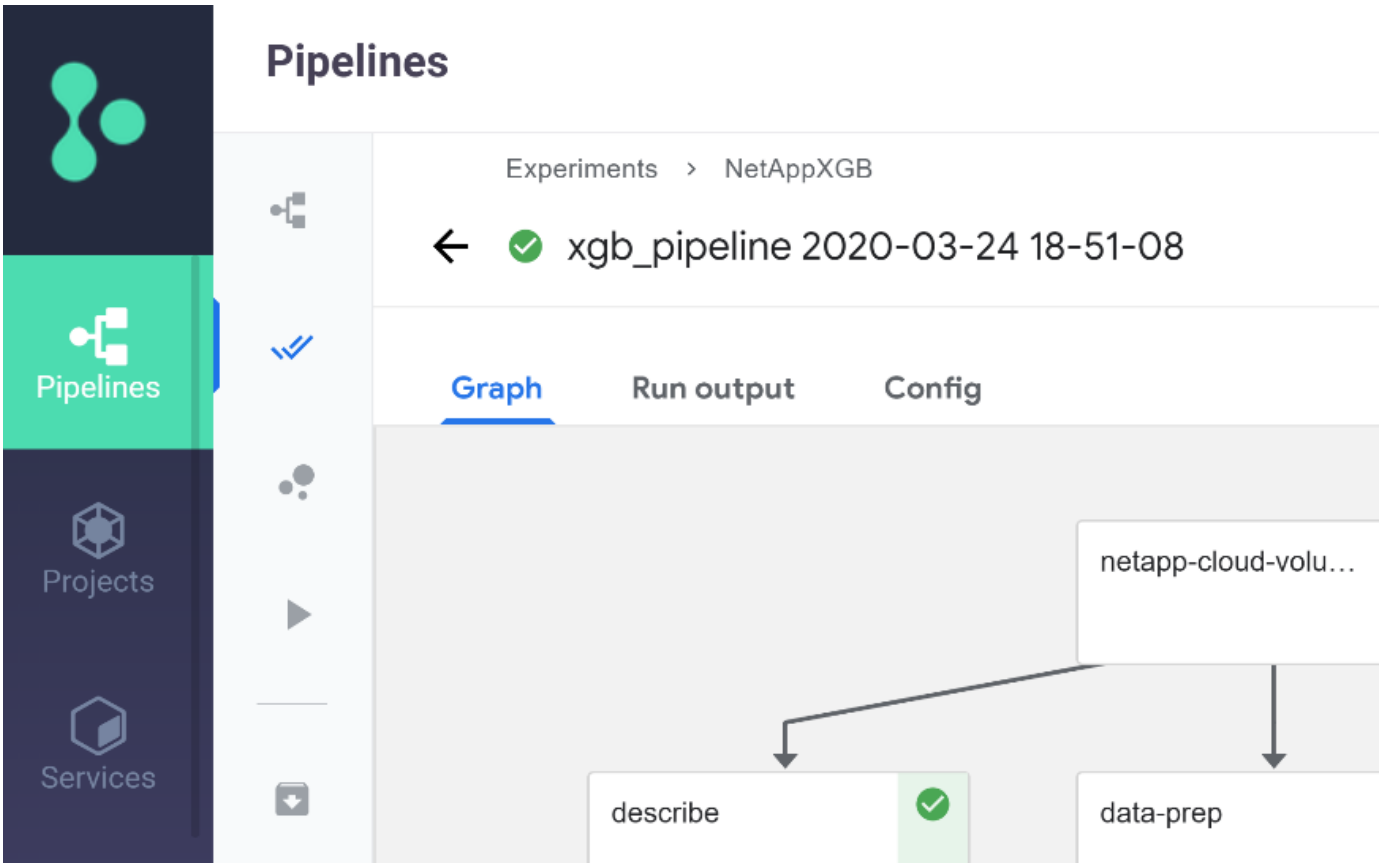

Comme nous avons enregistré la précision de l'étape d'entraînement à chaque série, nous avons un dossier de précision pour chaque expérience, tel qu'indiqué dans le dossier de précision de l'entraînement.

Run name	Status	Duration	Pipeline Version	Recurring ...	Start time	accuracy
xgb_pipeline 2020-03-24 18-51-...	✓	0:08:43	[View pipeline]	-	3/24/2020, 2:51:09 PM	0.985
xgb_pipeline 2020-03-19 13-31-...	✓	0:08:14	[View pipeline]	-	3/19/2020, 9:31:19 AM	0.980
xgb_pipeline 2020-03-18 12-56-...	✓	0:08:11	[View pipeline]	-	3/18/2020, 8:56:08 AM	0.990
xgb_pipeline 2020-03-17 19-49-...	✓	0:08:03	[View pipeline]	-	3/17/2020, 3:49:31 PM	0.985
xgb_pipeline 2020-03-17 18-34-...	✓	0:05:54	[View pipeline]	-	3/17/2020, 2:34:56 PM	0.980
xgb_pipeline 2020-03-17 17-34-...	✓	0:04:48	[View pipeline]	-	3/17/2020, 1:34:16 PM	0.982
xgb_pipeline 2020-03-17 17-01-...	✓	0:05:25	[View pipeline]	-	3/17/2020, 1:01:58 PM	0.987
xgb_pipeline 2020-03-16 16-47-...	✓	0:06:08	[View pipeline]	-	3/16/2020, 12:47:19 ...	0.983
xgb_pipeline 2020-03-16 13-57-...	✓	0:05:18	[View pipeline]	-	3/16/2020, 9:57:03 AM	0.980

Si vous sélectionnez l'étape Snapshot, le nom de la copie Snapshot utilisée pour exécuter cette expérience s'affiche.

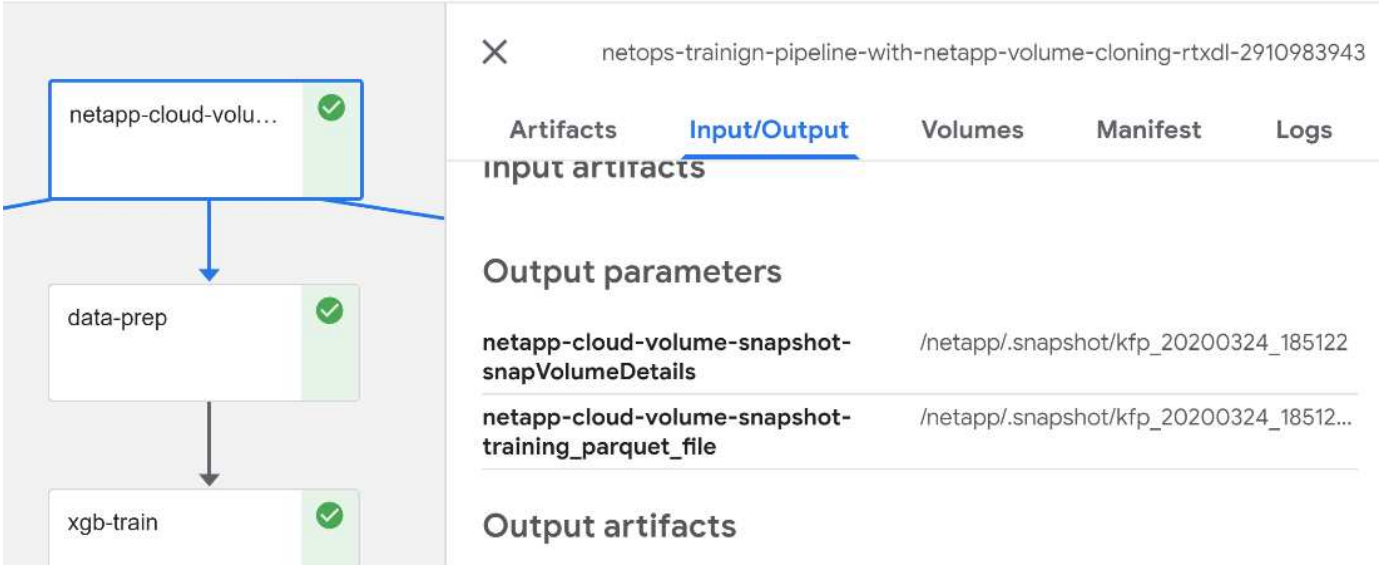

L'étape décrite présente des artéfacts visuels pour explorer les mesures que nous avons utilisées. Vous pouvez développer pour afficher le tracé complet comme illustré dans l'image suivante.

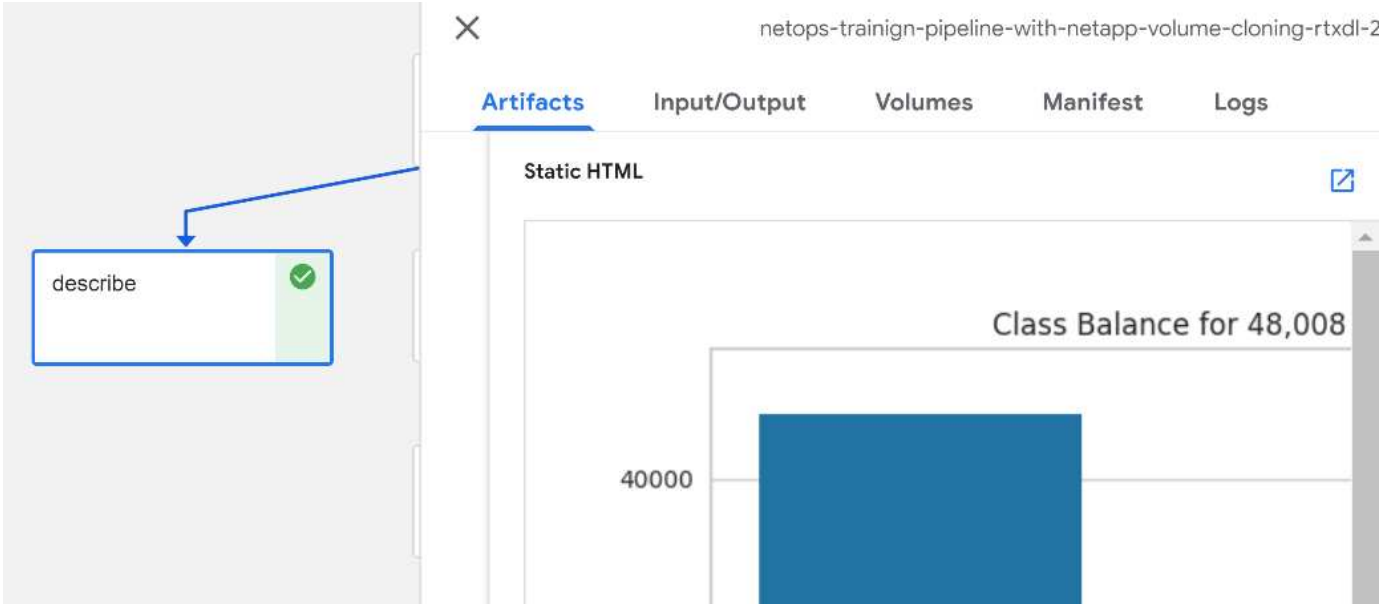

La base de données de l'API MLRun assure également le suivi des entrées, des sorties et des artefacts pour chaque exécution organisée par projet. L'image suivante présente un exemple d'entrées, de sorties et d'artefacts pour chaque séquence.

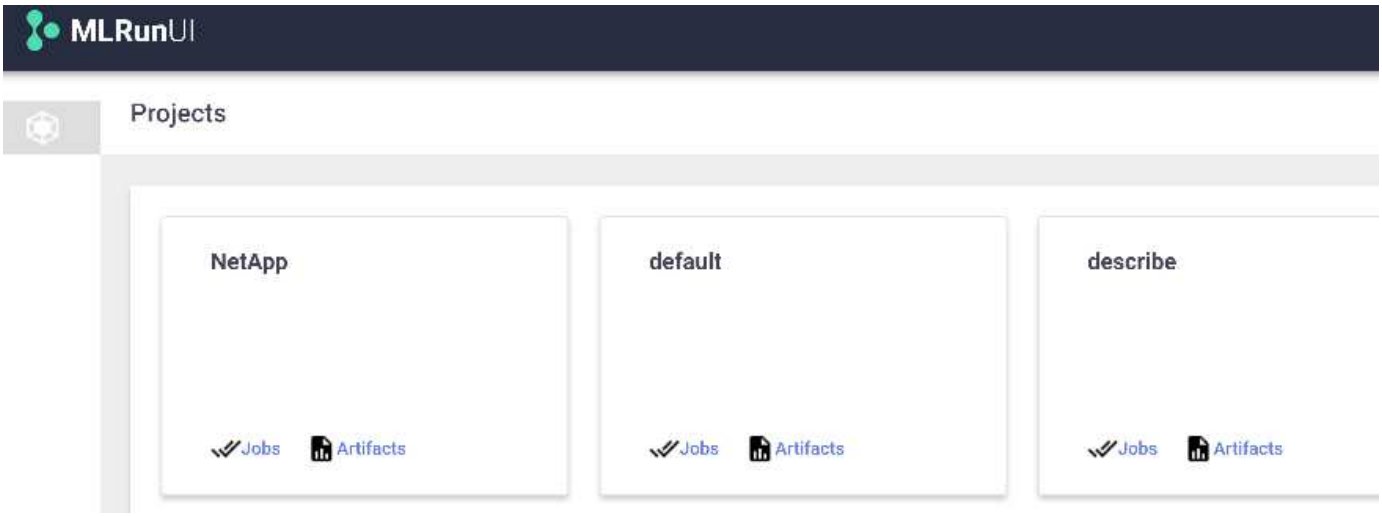

Pour chaque tâche, nous stockons des détails supplémentaires.

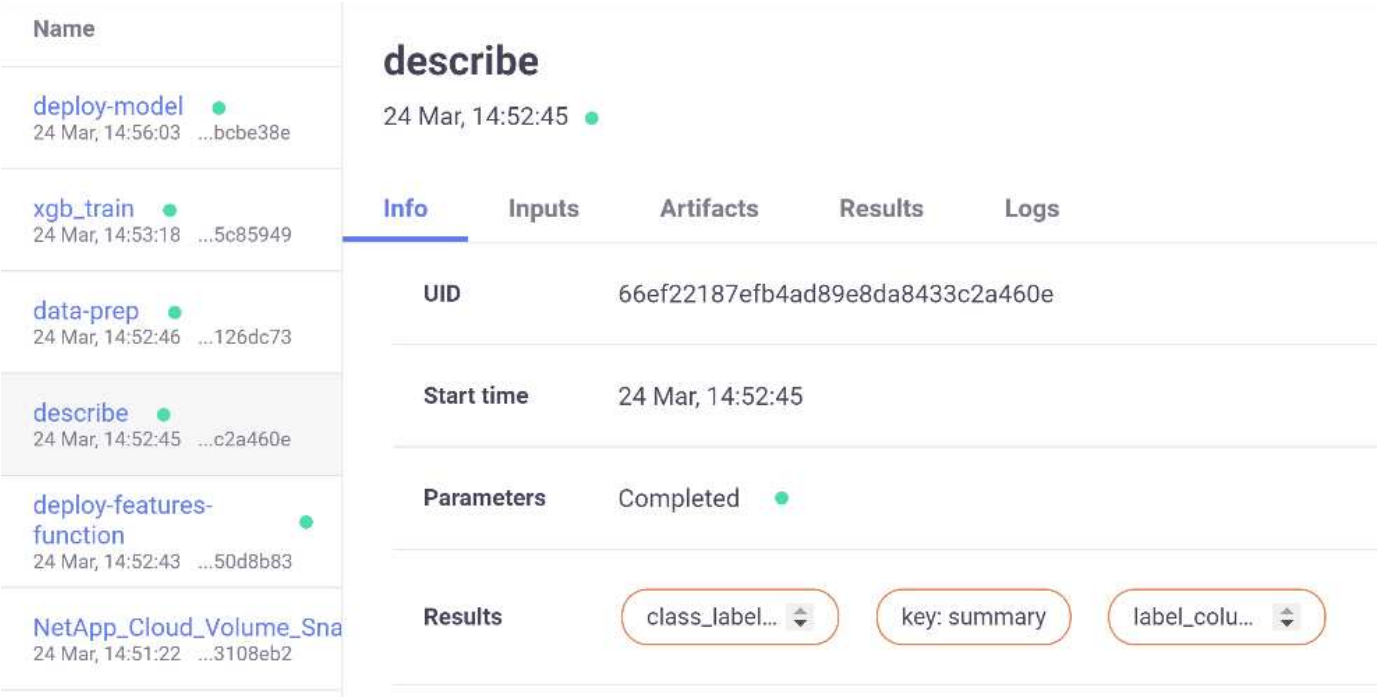

Il y a plus d'informations sur MLRun que ce document. Les artefacts al, y compris la définition des étapes et fonctions, peuvent être enregistrés dans la base de données API, versionnés et appelés individuellement ou en tant que projet complet. Les projets peuvent également être enregistrés et transmis à Git pour une utilisation ultérieure. Nous vous encourageons à en savoir plus sur le "MLRun site GitHub".

"Next : déployer Grafana Dashboard"

Déployez Grafana Dashboard

Après le déploiement de tout, nous inférons les nouvelles données. Les modèles prévoient une défaillance sur l'équipement du périphérique réseau. Les résultats de la prédiction sont conservés dans une table de timeseries d'Iguazio. Vous pouvez visualiser les résultats avec Grafana dans la plate-forme intégrée à la politique de sécurité et d'accès aux données d'Iguazio.

Vous pouvez déployer le tableau de bord en important le fichier JSON fourni dans les interfaces de Grafana.

1. Pour vérifier que le service Grafana est exécuté, consultez la section Services.

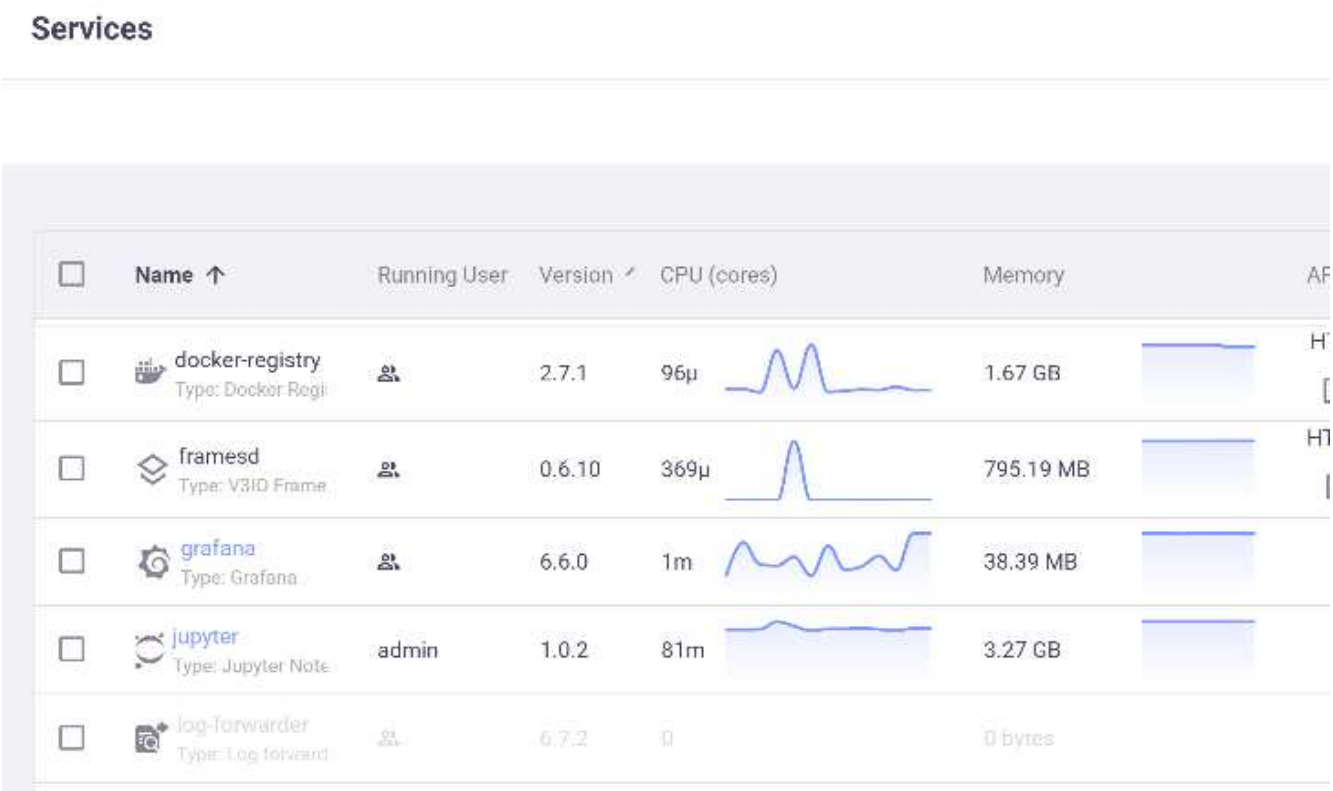

2. Si ce n’est pas le cas, déployez une instance à partir de la section Services :
   a. Cliquez sur Nouveau service.
   b. Sélectionnez Grafana dans la liste.
   c. Acceptez les valeurs par défaut.
   d. Cliquez sur étape suivante.
   e. Entrez votre ID utilisateur.
   f. Cliquez sur Save Service.
   g. Cliquez sur appliquer les modifications en haut.
3. Pour déployer le tableau de bord, téléchargez le fichier `NetopsPredictions-Dashboard.json` Via l’interface Jupyter.

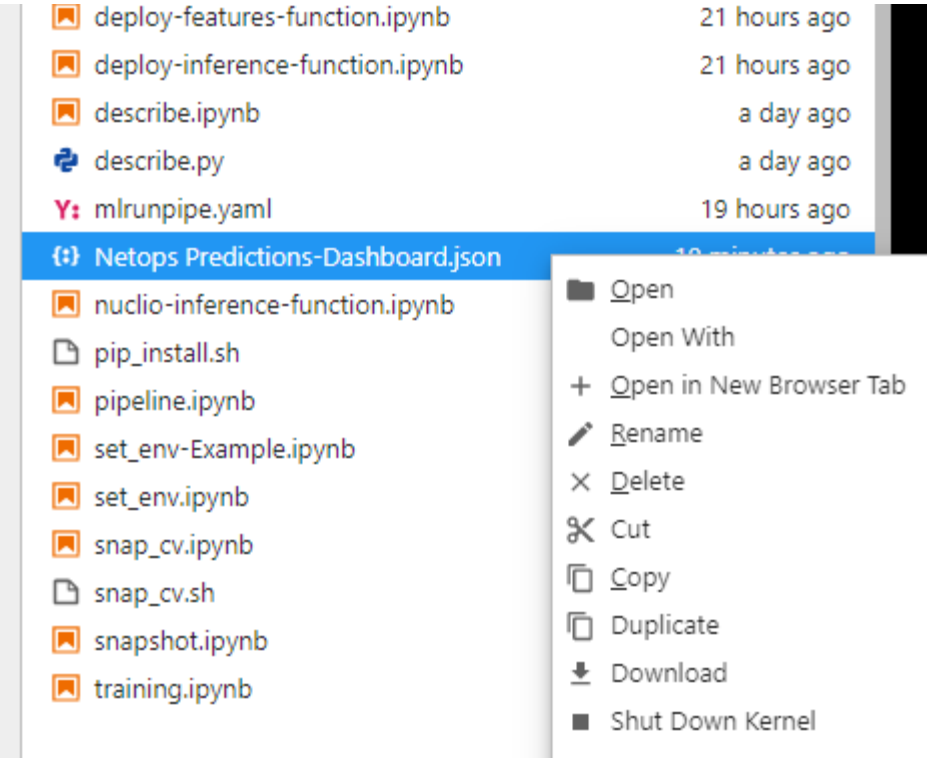

4. Ouvrez Grafana à partir de la section Services et importez le tableau de bord.

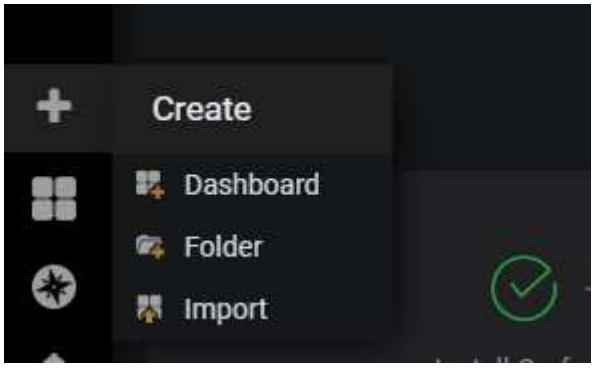

5. Cliquez sur Télécharger `*.json` Et sélectionnez le fichier que vous avez téléchargé précédemment (`NetopsPredictions-Dashboard.json`). Le tableau de bord s'affiche une fois le téléchargement terminé.

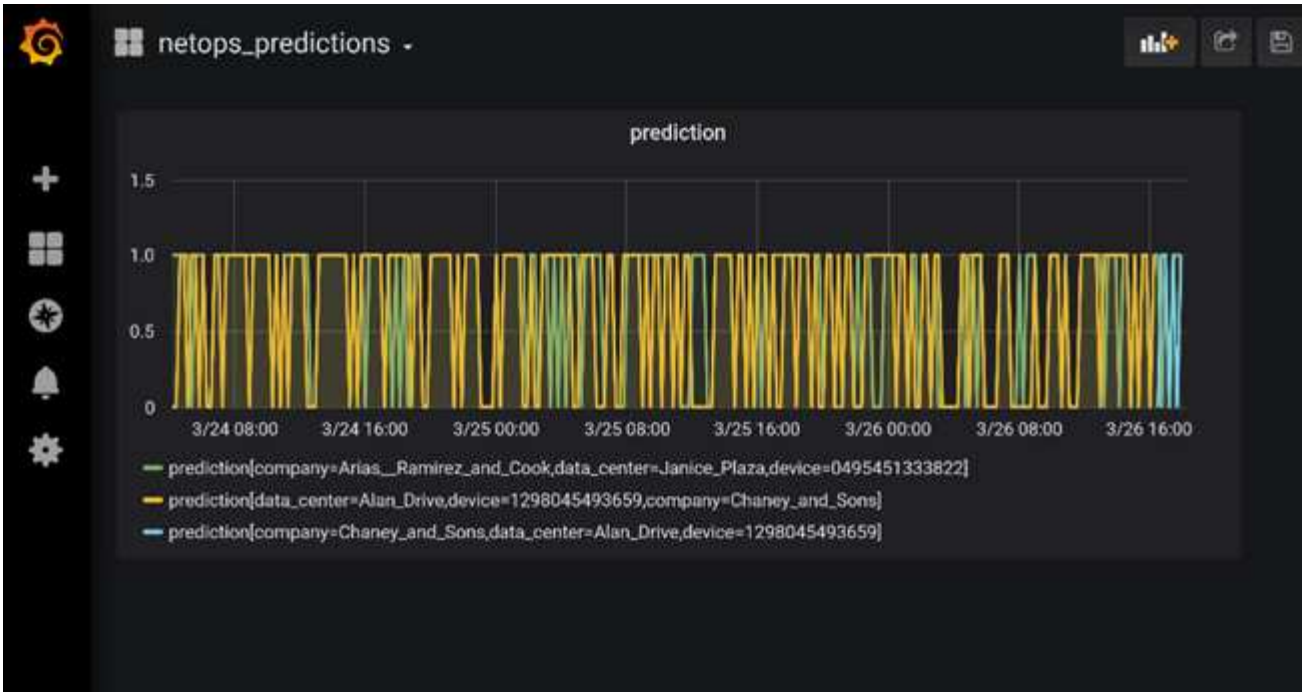

Déployer la fonction nettoyage

Lorsque vous générez un grand nombre de données, il est important de préserver la propreté et l'organisation des données. Pour ce faire, déployez la fonction de nettoyage avec le `cleanup.ipynb` bloc-notes.

Avantages

NetApp et Iguazio accélèrent et simplifient le déploiement des applications d'IA et DE ML en créant dans des frameworks essentiels, comme Kubeflow, Apache Spark et TensorFlow, avec des outils d'orchestration comme Docker et Kubernetes. En unifiant le pipeline de données de bout en bout, NetApp et Iguazio réduisent la latence et la complexité inhérentes à de nombreuses charges de travail informatiques avancées, afin de combler l'écart entre le développement et les opérations. Les data Scientists peuvent exécuter des requêtes sur d'importants jeux de données et partager en toute sécurité les données et les modèles algorithmiques avec les utilisateurs autorisés au cours de la phase d'entraînement. Une fois que les modèles conteneurisés sont prêts pour la production, vous pouvez facilement les déplacer d'environnements de développement à des environnements opérationnels.

"Suivant: Conclusion"

Conclusion

Lors de la création de vos propres pipelines d'IA et DE ML, la configuration de l'intégration, de la gestion, de la sécurité et de l'accessibilité des composants d'une architecture représente un véritable défi. Le fait de donner aux développeurs accès à leur environnement et de le contrôler constitue un autre ensemble de défis.

L'association de NetApp et d'Iguazio rassemble ces technologies en tant que services gérés afin d'accélérer l'adoption de technologies et d'améliorer le délai de mise sur le marché des nouvelles applications d'IA/ML.

"Suivante : où trouver des informations complémentaires"

Tr-4915 : déplacement des données avec les workflows E-Series et BeeGFS pour l'IA et l'analytique

Cody Harryman et Ryan rodine, NetApp

Le rapport TR-4915 explique comment déplacer des données depuis n'importe quel référentiel de données vers un système de fichiers BeeGFS reposant sur un système de stockage SAN NetApp E-Series. Pour les applications d'intelligence artificielle (IA) et de machine learning (ML), il peut être nécessaire de déplacer de grands jeux de données dépassant plusieurs pétaoctets de données vers leurs clusters BeeGFS pour le développement de modèles. Ce document décrit comment le réaliser en utilisant les outils NetApp XCP et NetApp Cloud Sync.

https://www.netapp.com/pdf.html?item=/media/65882-tr-4915.pdf

Informations sur le copyright

Copyright © 2022 NetApp, Inc. Tous droits réservés. Imprimé aux États-Unis. Aucune partie de ce document protégé par copyright ne peut être reproduite sous quelque forme que ce soit ou selon quelque méthode que ce soit (graphique, électronique ou mécanique, notamment par photocopie, enregistrement ou stockage dans un système de récupération électronique) sans l'autorisation écrite préalable du détenteur du droit de copyright.

Les logiciels dérivés des éléments NetApp protégés par copyright sont soumis à la licence et à l'avis de non-responsabilité suivants :

CE LOGICIEL EST FOURNI PAR NETAPP « EN L'ÉTAT » ET SANS GARANTIES EXPRESSES OU TACITES, Y COMPRIS LES GARANTIES TACITES DE QUALITÉ MARCHANDE ET D'ADÉQUATION À UN USAGE PARTICULIER, QUI SONT EXCLUES PAR LES PRÉSENTES. EN AUCUN CAS NETAPP NE SERA TENU POUR RESPONSABLE DE DOMMAGES DIRECTS, INDIRECTS, ACCESSOIRES, PARTICULIERS OU EXEMPLAIRES (Y COMPRIS L'ACHAT DE BIENS ET DE SERVICES DE SUBSTITUTION, LA PERTE DE JOUISSANCE, DE DONNÉES OU DE PROFITS, OU L'INTERRUPTION D'ACTIVITÉ), QUELLES QU'EN SOIENT LA CAUSE ET LA DOCTRINE DE RESPONSABILITÉ, QU'IL S'AGISSE DE RESPONSABILITÉ CONTRACTUELLE, STRICTE OU DÉLICTUELLE (Y COMPRIS LA NÉGLIGENCE OU AUTRE) DÉCOULANT DE L'UTILISATION DE CE LOGICIEL, MÊME SI LA SOCIÉTÉ A ÉTÉ INFORMÉE DE LA POSSIBILITÉ DE TELS DOMMAGES.

NetApp se réserve le droit de modifier les produits décrits dans le présent document à tout moment et sans préavis. NetApp décline toute responsabilité découlant de l'utilisation des produits décrits dans le présent document, sauf accord explicite écrit de NetApp. L'utilisation ou l'achat de ce produit ne concède pas de licence dans le cadre de droits de brevet, de droits de marque commerciale ou de tout autre droit de propriété intellectuelle de NetApp.

Le produit décrit dans ce manuel peut être protégé par un ou plusieurs brevets américains, étrangers ou par une demande en attente.

LÉGENDE DE RESTRICTION DES DROITS : L'utilisation, la duplication ou la divulgation par le gouvernement sont sujettes aux restrictions énoncées dans le sous-paragraphe (b)(3) de la clause Rights in Technical Data-Noncommercial Items du DFARS 252.227-7013 (février 2014) et du FAR 52.227-19 (décembre 2007).

Les données contenues dans les présentes se rapportent à un produit et/ou service commercial (tel que défini par la clause FAR 2.101). Il s'agit de données propriétaires de NetApp, Inc. Toutes les données techniques et tous les logiciels fournis par NetApp en vertu du présent Accord sont à caractère commercial et ont été exclusivement développés à l'aide de fonds privés. Le gouvernement des États-Unis dispose d'une licence limitée irrévocable, non exclusive, non cessible, non transférable et mondiale. Cette licence lui permet d'utiliser uniquement les données relatives au contrat du gouvernement des États-Unis d'après lequel les données lui ont été fournies ou celles qui sont nécessaires à son exécution. Sauf dispositions contraires énoncées dans les présentes, l'utilisation, la divulgation, la reproduction, la modification, l'exécution, l'affichage des données sont interdits sans avoir obtenu le consentement écrit préalable de NetApp, Inc. Les droits de licences du Département de la Défense du gouvernement des États-Unis se limitent aux droits identifiés par la clause 252.227-7015(b) du DFARS (février 2014).

Informations sur les marques commerciales

NETAPP, le logo NETAPP et les marques citées sur le site http://www.netapp.com/TM sont des marques déposées ou des marques commerciales de NetApp, Inc. Les autres noms de marques et de produits sont des marques commerciales de leurs propriétaires respectifs.